Najważniejsze osiągnięcia i wydarzenia związane z teorią informacji w perspektywie historycznej

Krzysztof Wesołowski

Czym jest teoria informacji

- Teoria informacji jest dziedziną nauki, w której zainteresowania są skoncentrowane na określeniu ilościowym, przechowywaniu oraz przekazywaniu informacji.
- Zręby teorii informacji podał Claude Shannon in 1948 w przełomowym artykule pt. ***"A Mathematical Theory of Communication„*** opublikowanym w czasopiśmie Bell System Technical Journal (BSTJ).
- Shannon przedstawił podstawowe granice dla operacji przetwarzania sygnałów takich jak efektywna reprezentacja wiadomości generowanych przez źródło, kompresja danych oraz szybkość przekazywania informacji przez zawodne (takie, w których występują zakłócenia) kanały.

Czym zajmuje się teoria informacji

- Ustala graniczne parametry systemów telekomunikacyjnych
  - Kodowanie źródłowe – efektywna reprezentacja wiadomości generowanych przez źródło,
  - Określenie granicy szybkości przekazywania informacji przez kanał telekomunikacyjny
  - Kodowanie kanałowe – związane z graniczną szybkością transmisji w określonych kanałach
- Podaje wskazówki służące optymalizacji zaawansowanych systemów telekomunikacyjnych

Czym jest teoria informacji

- Teoria informacji jest wiedzą na styku matematyki, statystyki, informatyki, fizyki, neurobiologii, inżynierii informacji oraz elektrotechniki.
- Wybrane zastosowania teorii informacji:
  - wnioskowanie statystyczne,
  - przetwarzanie języków naturalnych,
  - kryptografia,
  - neurobiologia,
  - bioinformatyka (kody molekularne),
  - dobór modeli w statystyce,
  - termofizyka, obliczenia kwantowe,
  - lingwistyka,
  - rozpoznawanie wzorców, itp.

Kilka informacji o Shannonie

- Claude Elwood Shannon (30.04.1916 – 24.02.2001)
  - Absolwent University of Michigan (B.Sc.) oraz MIT (M.Sc.)

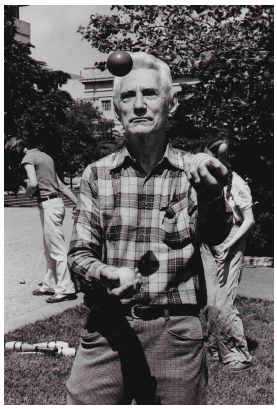



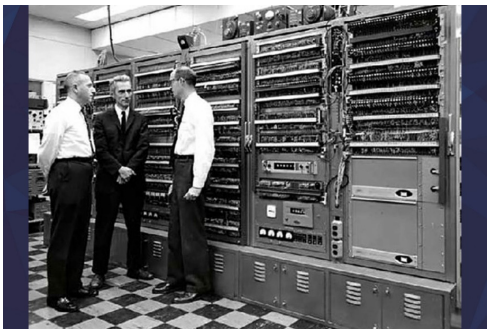


Photo: © Stanley Rowin

Kilka informacji o Shannonie

- Twórca teorii informacji (pracując w Bell Labs, 1948), teorii projektowania układów cyfrowych (jako 21-letni student MIT udowodnił w swojej pracy M.Sc., że elektryczne zastosowanie algebry Boole'a pozwala na konstrukcję dowolnej zależności numerycznej.
- W czasie II Wojny Światowej Shannon zajmował się kryptoanalizą, mając znaczący wkład w łamaniu szyfrów i bezpiecznej komunkacji.

Shannon i jego inteligentna mysz magnetyczna poruszająca się w labiryncie z układami cyfrowymi pod jego spodem

Kilka informacji o Shannonie

- Shannon obronił pracę doktorską pt. An Algebra for Theoretical Genetics w MIT w roku 1940.
- Elektromechaniczny komputer cyfrowy (edukacyjny układ treningowy) Shannona z zastosowaniem układów cyfrowych – przykład zainteresowania i hobby Shannona

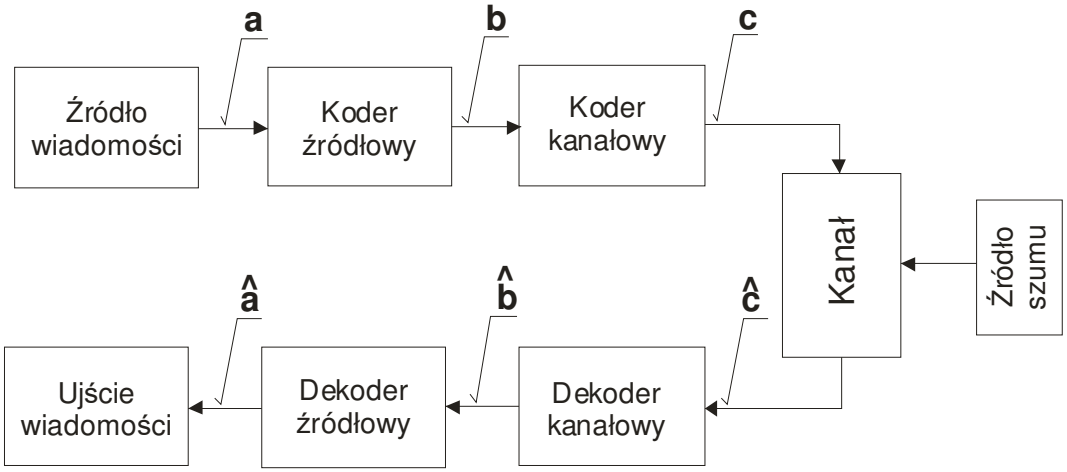


Podstawowe osiągnięcia teorii informacji

- Prace poprzedzające przełomowy artykuł Shannona (1948):
  - pewne idee teorii informacji były wprowadzone w Bell Labs. przy założeniu równych prawdopodobieństw zdarzeń.
- Prekursorzy teorii informacji
  - H. Nyquist, „O pewnych czynnikach wpływających na szybkość telegrafowania, BSTJ, 1924
    - Twierdzenie o częstotliwości próbkowania
    - Czas ma charakter dyskretny
  - R. V. L. Hartley, „Transmisja informacji”, BSTJ, 1928
    - Propozycja powiązania zawartości informacyjnej wiadomości z logarytmem wszystkich wiadomości danego źródła

Model systemu informacyjnego

- Model przedstawia podstawowe bloki systemu:



Model systemu informacyjnego

- Źródło wiadomości
  - Ciągłe lub dyskretne
- Źródło dyskretne (częste założenia):
  - wysyła w takt zegara wiadomości ze skończonego zbioru *wiadomości elementarnych* – tak jest w sieciach komputerowych
  - jest *stacjonarne* – własności statystyczne nie zależą od czasu – wiadomości są generowane z prawdopodobieństwami niezmiennymi w czasie
- Koder źródłowy
  - Reprezentacja wiadomości za pomocą sekwencji symboli elementarnych
  - Dążenie do możliwie efektywnej reprezentacji wiadomości za pomocą krótkich bloków symboli
- Koder kanałowy
  - Realizuje zabezpieczenie transmitowanych symboli przed błędami w trakcie transmisji przez wprowadzanie dodatkowych symboli (redundancja)

Pojęcie informacji, miara informacji

- **Definicja:**
  - **Informacja jest wiedzą otrzymaną przez odbiór wiadomości, która pozwala odbiorcy zrealizować lub ulepszyć jego działanie**
- Cechy informacji:
  - Charakter potencjalny – **może** być wykorzystana do działania
  - Charakter względny – dla jednego odbiorcy jest wartościowa, dla innego nie
- Wiadomość – pojęcie pierwotne
- Pomiar „ilości informacji" wynika z następujących obserwacji:
  - im wiadomość mniej oczekiwana, tym większa ilość informacji w niej zawarta,
  - Obserwacja dwóch wiadomości statystycznie niezależnych skutkuje odebraniem informacji o ilości będącej sumą ilości informacji dla każdej wiadomości z osobna

Pojęcie informacji, miara informacji

- **Definicja:**
  - Niech *a* będzie wiadomością, która jest wysyłana przez źródło z prawdopodobieństwem $P(a)$. Mówimy, że wraz z obserwacją wiadomości *a* odbiorca uzyskuje

$$I(a) = \log_r \frac{1}{P(a)}$$

    jednostek ilości informacji.
- Jednostki ilości informacji:
  - Jeśli r=2, to **bit**
  - Jeśli r=e, to **nat**
  - Jeśli r=10, to **Hartley**

Pojęcie informacji, miara informacji

- Uwagi dodatkowe:
  - Stochastyczny charakter źródła wiadomości (wiadomości mają określone prawdopodobieństwa)
  - Wiadomość pewna ($P(a)=1$) nie niesie informacji
  - Im odebrana wiadomość jest mniej oczekiwana, tym bardziej może się przyczynić do korekty działania odbiorcy, tym większa ilość informacji w niej zawarta;
  - obserwacja dwóch wiadomości występujących statystycznie niezależnie od siebie powinna się wiązać z ilością informacji, która jest sumą ilości informacji uzyskanej przez odbiór każdej z wiadomości.

Dyskretne źródło bezpamięciowe

- **Dyskretne źródło *bezpamięciowe*** jest scharakteryzowane przez alfabet wiadomości $X=\{a_1,a_2,\ldots,a_K\}$ i skojarzony z nim rozkład prawdopodobieństw ich wystąpienia $\{P(a_1),P(a_2),\ldots,P(a_K)\}$. Generowane wiadomości są statystycznie niezależne.
- **Entropią** źródła bezpamięciowego ***X*** scharakteryzowanego przez alfabet $X=\{a_1,a_2,\ldots,a_K\}$ i skojarzony z nim rozkład $\{P(a_1),P(a_2),\ldots,P(a_K)\}$ nazywamy średnią ilością informacji uzyskanej przez obserwację pojedynczej wiadomości na wyjściu źródła i daną wzorem:

$$H(X) = E[I(a_i)] = \sum_{i=1}^{K} P(a_i) \log \frac{1}{P(a_i)}$$

- Entropia opisuje niepewność co do generowanych wiadomości

Kodowanie źródłowe dla źródła bezpamięciowego

- Formalna definicja kodu źródłowego

Definicja 1.8. *Niech $X = \{a_1, a_2, \ldots, a_K\}$ oznacza alfabet źródła (zbiór wiadomości podlegających kodowaniu), natomiast $Y = \{y_1, y_2, \ldots, y_N\}$ będzie zbiorem symboli kodowych. Kod jest relacją, która każdej wiadomości z alfabetu źródła przyporządkowuje w sposób* ***wzajemnie jednoznaczny*** *ciąg symboli wybranych ze zbioru symboli kodowych. Ciąg symboli kodowych reprezentujących określoną wiadomość nazywamy* ***słowem kodowym*** *(lub zamiennie –* ***ciągiem kodowym****).*

- Średnia długość ciągu kodowego *L:* Wartość oczekiwana długości ciągów kodowych

$$L = \sum_{i=1}^{K} l_i P_i$$

l_i – długość ciągu kodowego reprezentującego wiadomość a_i o prawdopodobieństwie P_i

Kodowanie źródłowe dla źródła bezpamięciowego

- Pierwsze twierdzenie Shannona (o kodowaniu źródłowym):

Twierdzenie 1.3. *Średnia długość ciągu kodowego kodu jednoznacznie dekodowalnego bez opóźnienia, służącego do reprezentowania wiadomości źródła bezpamięciowego* $\boldsymbol{X}$*, jest nie mniejsza niż wartość entropii źródła (obliczonej w jednostkach r-narnych).*

$$L \geq \frac{H(X)}{\log r} = H_r(X)$$

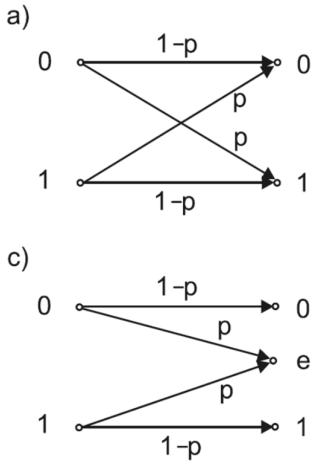
- Istnieje szereg metod kodowania źródłowego, które zapewniają optymalną, lub bliską optymalnej, reprezentację wiadomości elementarnych występujących w ciągu wiadomości generowanych przez źródło.
- Zastosowanie: kompresja danych (.ZIP), kodowanie obrazów

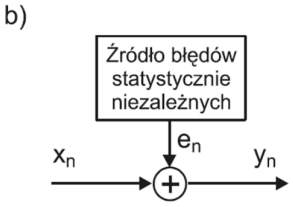
Kodowanie źródłowe dla źródła bezpamięciowego

- Kodowanie źródłowe może być:
  - bezstratne – można w odbiorniku odtworzyć dokładnie postać ciągu wiadomości podlegających kodowaniu
  - stratne – nie jest możliwe powyższe (np. kodowanie obrazów, sekwencji wizyjnych, dźwięku – ze względu na własności narządów wzorku i słuchu człowieka)
- Przykłady metod kodowania źródłowego - bezstratnego:
  - Algorytm Huffmanna
  - Dynamiczny algorytm Huffmanna
  - Algorytm Shannona-Fano
  - Kodowanie arytmetyczne
  - Algorytm Lempela-Ziva
  - Kodowanie obrazu w faksie,
  - itp.

Przepustowość kanału

- Rozpatrujemy model kanału ze zbiorem symboli wejściowych ***X*** i wyjściowych ***Y***





Opis modeli:

a) Binarny kanał bezpamięciowy
b) Reprezentacja binarnego kanału bezpamięciowego ze źródłem błędów statystycznie niezależnych
c) Kanał binarny z wymazywaniem

Przepustowość kanału

- Ogólny schemat blokowy modelu transmisji



- Nadawane są symbole są zbioru ***X*** a odbierane symbole ze zbioru ***Y***.
- Przez obserwację kolejnych symboli $y \in \boldsymbol{Y}$ uzyskujemy wiedzę o nadanym symbolu $x \in \boldsymbol{X}$. Kanał przekazuje więc informację!
- Entropia na wejściu (*a priori*): $H(\boldsymbol{X})$
- Entropia na wyjściu (*a posteriori*): $H(\boldsymbol{X}|\boldsymbol{Y})$
- Średnia ilość informacji wzajemnej: $I(\boldsymbol{X};\boldsymbol{Y})=H(\boldsymbol{X})-H(\boldsymbol{X}|\boldsymbol{Y})$
- Średnia ilość informacji przekazanej przez kanał: $I(\boldsymbol{X};\boldsymbol{Y})$

Przepustowość kanału

- Przepustowość kanału: maksymalna średnia ilość informacji pomiędzy wejściem a wyjściem kanału (względem rozkładu prawdopodobieństw symboli wejściowych

$$C = \max_{\{P(x_j)\}} I(\mathcal{X};\mathcal{Y})$$

- Można pokazać, że dla kanału ciągłego o szerokości pasma B:

Twierdzenie 1.7. *Przepustowość kanału o pasmie ograniczonym do B Hz, w którym sygnał jest zakłócany przez addytywny szum gaussowski o gęstości widmowej mocy $N_0/2$, jest opisana wzorem*

$$C = B\log\left(1+\frac{P}{N_0 B}\right) \quad [\text{bit/s}] \tag{1.106}$$

przy czym P jest mocą średnią transmitowanego sygnału.

Twierdzenie Shannona o kodowaniu kanałowym

- Dla kanału binarnego bezpamięciowego:

Twierdzenie 1.4. *Rozważmy binarny kanał symetryczny bezpamięciowy, cechujący się prawdopodobieństwem przekłamania p i przepustowością $C = 1 - H(p)$. Niech ε będzie dowolnie małą liczbą dodatnią i niech $M = 2^{n(C-\varepsilon)}$. W przypadku wystarczająco dużej liczby n, spośród 2^n możliwych bloków binarnych o długości n można wybrać podzbiór M bloków w taki sposób, że prawdopodobieństwo błędnego zdekodowania odebranego bloku będzie dowolnie małe.*

- Sprawność kodu: liczba bloków binarnych: $M = 2^{n(C-\varepsilon)}$ - blok reprezentuje $n(C-\varepsilon)$ binarnych symboli. Zatem sprawność:

$$R = \frac{n(C-\varepsilon)}{n} = C - \varepsilon$$

Sprawność kodu może co najwyżej osiągnąć wartość przepustowości kanału

Historia teorii informacji i kodowania

A timeline of events related to information theory, quantum information theory and statistical physics, data compression, error correcting codes and related subjects.

- 1872 – Ludwig Boltzmann presents his H-theorem, and with it the formula $\Sigma p_i \log p_i$ for the entropy of a single gas particle
- 1878 – J. Willard Gibbs defines the Gibbs entropy: the probabilities in the entropy formula are now taken as probabilities of the state of the *whole* system
- 1924 – Harry Nyquist discusses quantifying "intelligence" and the speed at which it can be transmitted by a communication system
- 1928 – Ralph Hartley introduces Hartley information as the logarithm of the number of possible messages, with information being communicated when the receiver can distinguish one sequence of symbols from any other (regardless of any associated meaning)
- 1940 – Alan Turing introduces the deciban as a measure of information inferred about the German Enigma machine cypher settings by the Banburismus process

Historia teorii informacji i kodowania

- 1944 – Claude Shannon's theory of information is substantially complete
- 1947 – Richard W. Hamming invents Hamming codes for error detection and correction (to protect patent rights, the result is not published until 1950)
- 1948 – Claude E. Shannon publishes *A Mathematical Theory of Communication*
- 1949 – Claude E. Shannon publishes *Communication in the Presence of Noise* – Nyquist–Shannon sampling theorem and Shannon–Hartley law
- 1949 – Claude E. Shannon's *Communication Theory of Secrecy Systems* is declassified
- 1949 – Robert M. Fano publishes *Transmission of Information*. M.I.T. Press, Cambridge, Massachusetts – Shannon–Fano coding
- 1949 – Leon G. Kraft discovers Kraft's inequality, which shows the limits of prefix codes
- 1949 – Marcel J. E. Golay introduces Golay codes for forward error correction
- 1951 – Solomon Kullback and Richard Leibler introduce the Kullback–Leibler divergence
- 1951 – David A. Huffman invents Huffman encoding, a method of finding optimal prefix codes for lossless data compression

Historia teorii informacji i kodowania

- 1953 – August Albert Sardinas and George W. Patterson devise the Sardinas–Patterson algorithm, a procedure to decide whether a given variable-length code is uniquely decodable
- 1954 – Irving S. Reed and David E. Muller propose Reed–Muller codes
- 1955 – Peter Elias introduces convolutional codes
- 1957 – Eugene Prange first discusses cyclic codes
- 1959 – Alexis Hocquenghem, and independently the next year Raj Chandra Bose and Dwijendra Kumar Ray-Chaudhuri, discover BCH codes
- 1960 – Irving S. Reed and Gustave Solomon propose Reed–Solomon codes
- 1962 – Robert G. Gallager proposes low-density parity-check codes; they are unused for 30 years due to technical limitations
- 1965 – Dave Forney discusses concatenated codes
- 1966 – Fumitada Itakura (Nagoya University) and Shuzo Saito (Nippon Telegraph and Telephone) develop linear predictive coding (LPC), a form of speech coding[1]
- 1967 – Andrew Viterbi reveals the Viterbi algorithm, making decoding of convolutional codes practicable

Historia teorii informacji i kodowania

- 1968 – Elwyn Berlekamp invents the Berlekamp–Massey algorithm; its application to decoding BCH and Reed–Solomon codes is pointed out by James L. Massey the following year
- 1968 – Chris Wallace and David M. Boulton publish the first of many papers on Minimum Message Length (MML) statistical and inductive inference
- 1970 – Valerii Denisovich Goppa introduces Goppa codes
- 1972 – Nasir Ahmed proposes the discrete cosine transform (DCT), which he develops with T. Natarajan and K. R. Rao in 1973;[2] the DCT later became the most widely used lossy compression algorithm, the basis for multimedia formats such as JPEG, MPEG and MP3
- 1976 – Gottfried Ungerboeck gives the first paper on trellis modulation; a more detailed exposition in 1982 leads to a raising of analogue modem POTS speeds from 9.6 kbit/s to 33.6 kbit/s
- 1976 – Richard Pasco and Jorma J. Rissanen develop effective arithmetic coding techniques
- 1977 – Abraham Lempel and Jacob Ziv develop Lempel–Ziv compression (LZ77)

Historia teorii informacji i kodowania

- 1989 – Phil Katz publishes the `.zip` format including DEFLATE (LZ77 + Huffman coding); later to become the most widely used archive container
- 1993 – Claude Berrou, Alain Glavieux and Punya Thitimajshima introduce Turbo codes
- 2006 – first Asymmetric numeral systems entropy coding: since 2014 popular replacement of Huffman and arithmetic coding in compressors like Facebook Zstandard or Apple LZFSE
- 2008 – Erdal Arıkan introduces polar codes, the first practical construction of codes that achieves capacity for a wide array of channels