Wielka czwórka w telekomunikacji: ruch, jakość, zasoby i koszty

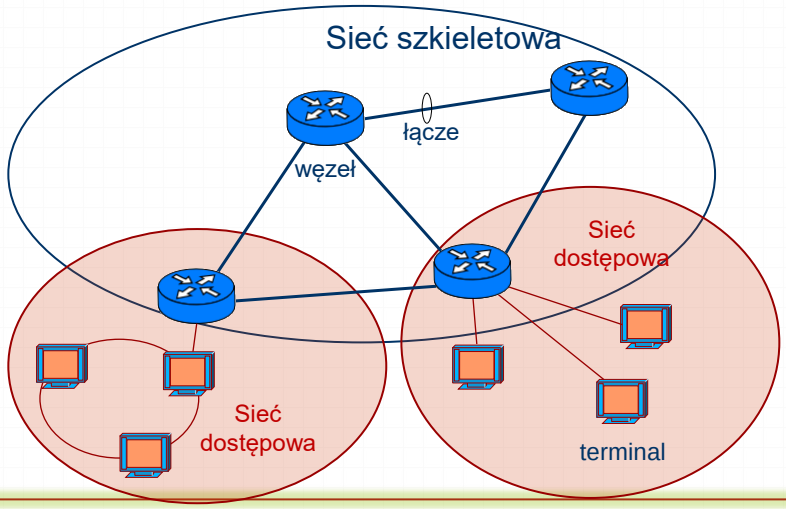
Mariusz Głąbowski

Sieci telekomunikacyjne

- Sieć telekomunikacyjna składa się z
  - węzłów (terminale, węzły sieciowe)
  - połączeń między węzłami (fizycznych, logicznych)
- Sieci dostępowe
  - łączą terminale z węzłami sieci
- Sieci szkieletowe
  - łączą ze sobą węzły sieci

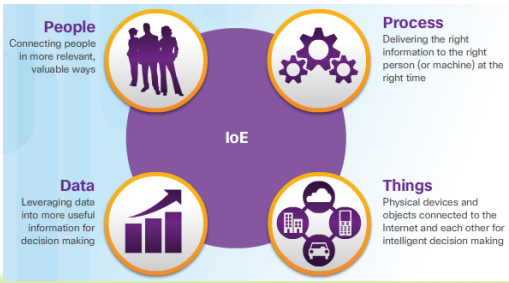
2

Tradycyjne sieci telekomunikacyjne



IoE

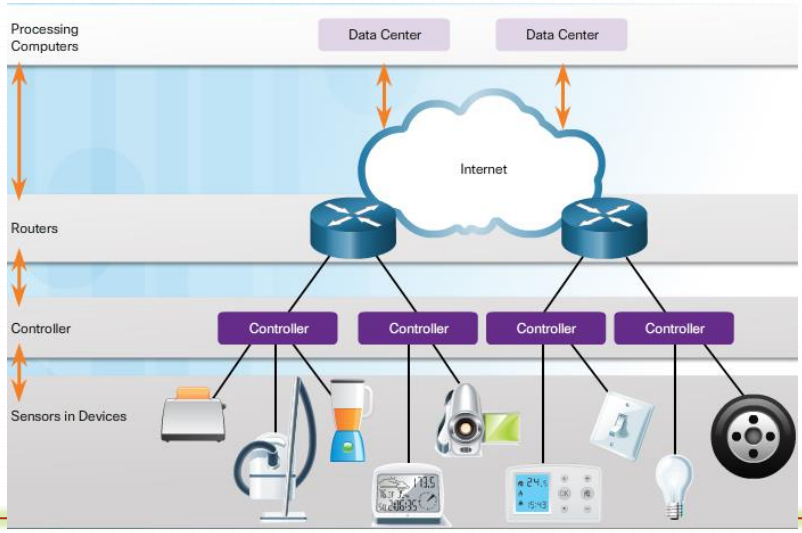
- Cztery elementy
  - Ludzie, procesy, dane i rzeczy
- Co to są rzeczy
  - Zawierają wbudowaną technologię do interakcji z serwerami wewnętrznymi i środowiskiem zewnętrznym
  - Mają możliwość pracy w sieci
  - Potrafią komunikować się za pośrednictwem bezpiecznej, niezawodnej i dostępnej platformy sieciowej
  - Potrafią tworzyć ogromne ilości danych.



Internet Rzeczy

- Sensory/czujniki
  - Zbierają dane z urządzeń innych niż komputery
  - konwertują fizyczne aspekty naszego środowiska na sygnały elektryczne, które mogą być przetwarzane przez komputery
  - Przykłady: czujniki wilgotności gleby, czujniki temperatury powietrza, czujniki promieniowania i czujniki ruchu
- RFID - identyfikacja w zakresie fal radiowych
  - Przekazują informacje między znacznikami RFID a czytnikami RFID
  - Zazwyczaj znaczniki RFID służą do identyfikacji i śledzenia urządzeń, w których są osadzone
- Sterownik
  - Zbiera dane z czujników i zapewnia połączenie z Internetem
  - Może mieć możliwość podejmowania natychmiastowych decyzji lub wysyłania danych do bardziej wydajnego komputera w celu analizy.

Internet Rzeczy

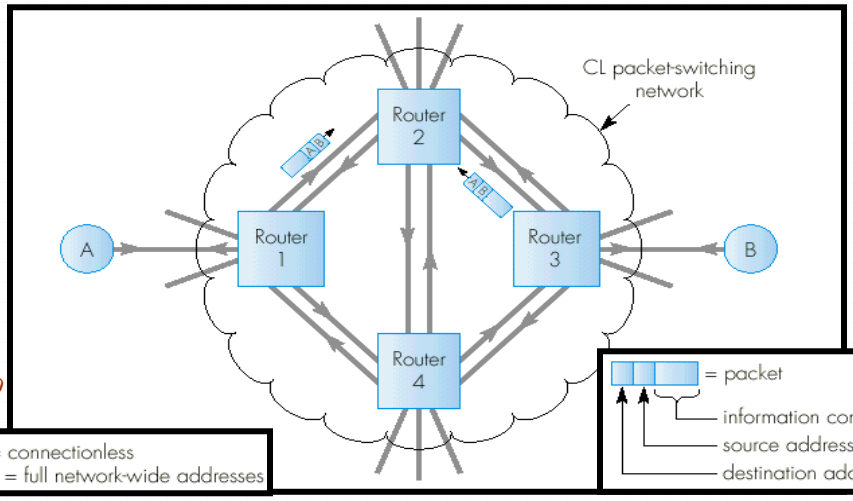


Typy sieci/komutacji

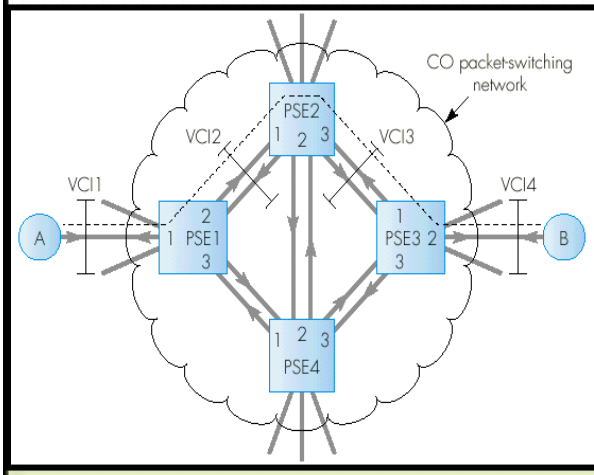
- Komutacja kanałów
  - sieci telefoniczne
  - sieci komórkowe wczesnych generacji
  - sieci optyczne (częściowo)
- Komutacja pakietów
  - sieci zorientowane połączeniowo: MPLS, X.25, Frame Relay, ATM, MetroEthernet
  - sieci bezpołączeniowe: IP (?), SS7, MTP, Ethernet

7

Sieci pakietowe bezpołączeniowe



Sieci pakietowe połączeniowe



PSE1 routing table:

IN	OUT
VCI1/Link1	VCI2/Link2
VCI2/Link2	VCI1/Link1

PSE2 routing table:

IN	OUT
VCI2/Link1	VCI3/Link3
VCI3/Link3	VCI2/Link1

PSE3 routing table:

IN	OUT
VCI3/Link1	VCI4/Link2
VCI4/Link2	VCI3/Link1

9

Ruch telekomunikacyjny



- Ruch jest tworzony przez zbiór użytkowników
- System obsługuje ruch z parametrami Quality of Service (QoS)

10

Terminologia (definicje intuicyjne)

- Ruch telekomunikacyjny
  - pakiety, zgłoszenia, połączenia, przepływy, strumienie pakietów…
  - stosowanie pojęć zależne od rozpatrywanej skali czasu
- System
  - oddzielne urządzenia (łącze, przełącznik, ruter, serwer…) lub zestaw urządzeń (pole komutacyjne, sieć, sieć IP,…) obsługujących ruch.
- Parametry jakości usług (QoS)
  - prawdopodobieństwo blokady, prawdopodobieństwo straty, czas oczekiwania,…
  - stosowanie pojęć zależne od rozpatrywanej skali czasu oraz poziomu analizy sieci

11

Quality of Service (QoS)

- Zdefiniowae na podstawie umów o gwarantowanym poziomie usług (SLA)
  - wymagania systemowe
  - umowa między klientem a operatorem (usługodawcą)
- Definiowany na podstawie zbiorczego efektu działania systemu określającego stopień zadowolenia klienta (ITU-T E.800)
- Zdefiniowane na podstawie mechanizmów, które mogą sterować zasobami sieciowymi
  - progi, rezerwacja zasobów, kompresja ruchu,….

12

Uproszczona techniczna definicja Quality of Service

- Zbiór technologii, które pozwalają użytkownikom otrzymywać od sieci przewidywalny poziom usług w kontekście przepustowości/przepływności (bandwith), opóźnienia (delay) i zmienności opóźnienia (jitter)

13

Wprowadzenie
Różnorodność wymagań QoS/QoE/QoC etc

- spowodowana różnorodnością usług realizowanych w
  - sieciach zorientowanych połączeniowo, np. ATM
  - sieciach zorientowanych bezpołączeniowo, np. Internet
- przesyłanie pakietów na zasadzie best effort okazało się niewystarczające
- konieczne stało się zatem opracowanie nowych architektur sieci dla wielousługowej sieci szerokopasmowej B-ISDN
  - ATM
  - IP
    - Integrated Services
    - Differentiated Services
  - MPLS/GMPLS/MPLS-TE/MPLS-TP
  - Carrier Ethernet

14

Różnorodność wymagań jakościowych

- Wymagania jakościowe mogą pojawić się ze strony
  - użytkowników indywidualnych, np. granica opóźnienia dla interaktywnej komunikacji głosowej
  - użytkowników biznesowych, np. konieczność realizacji transakcji w określonych horyzoncie czasowym
- QoS dla danej klasy pakietów może być określany w sposób
  - względny, tzn. w stosunku do innych klas pakietów
  - bezwzględny, tzn. poprzez podanie pewnych wartości liczbowych, np. wartości opóźnienia lub blokady (Service Level Agreement)

15

Dwie perspektywy postrzegania QoE/QoS

- Perspektywa użytkownika
  - Użytkownicy postrzegają, czy ich aplikacje działają poprawnie
    - Głos, wideo, dane
- Perspektywa zarządzających siecią
  - Potrzeba zarządzania przepływnością w celu dostarczenia aplikacjom pożądanych parametrów
    - Sterowanie opóźnieniem, zmiennością opóźnienia, utratą pakietów

16

Różnorodność wymagań jakościowych

- QoS można określać dla
  - zagregowanego strumienia ruchu
  - lub dla pojedynczych strumieni ruchu (ang. flow)
- Nadmiar ruchu może być odrzucany:
  - na poziomie pakietów (ang. policing)
  - na poziomie strumieni (przepływów) (ang. admission control)

17

Modele QoS

- Dwa modele QoS
  - Model oparty na rezerwowaniu zasobów
  - Model oparty na rozróżnianiu klas ruchu
- Główna różnica:
  - Sposób specyfikowania żądanej jakości usług (sygnalizacja vs. oznaczenie pakietów)

18

Elementy wspomagające tworzenie sieci o przewidywalnej jakości obsługi

- Wiedza o wydajności planowanych i istniejących sieci
  - Modelowanie
    - Analityczne
    - Symulacyjne
  - Monitorowanie
    - Analiza bieżących wskaźników
    - Usuwanie uszkodzeń
  - Ocena wydajności
    - Model (różne poziomy szczegółowości)
    - Testbed
    - Pomiary
- Konieczność poznania mechanizmów różnicujących jakość obsługi oraz technik monitorowania i oceny wydajności sieci

19

Elementy wspomagające tworzenie sieci o przewidywalnej jakości obsługi

- Podstawowe elementy projektowania i utrzymania sieci oferujących gwarantowane parametry jakościowe
  - stosowanie inżynierii ruchu w celu przewidywania natężenia ruchu oraz w celu takiego wymiarowania sieci, aby prawdopodobieństwo przekroczenia ustalonych parametrów QoS było odpowiednio małe
  - ciągłe monitorowanie i analizowanie stanu sieci
  - ograniczanie ruchu rywalizującego o dostęp do tych samych zasobów
  - stosowanie odpowiednich mechanizmów różnicujących QoS

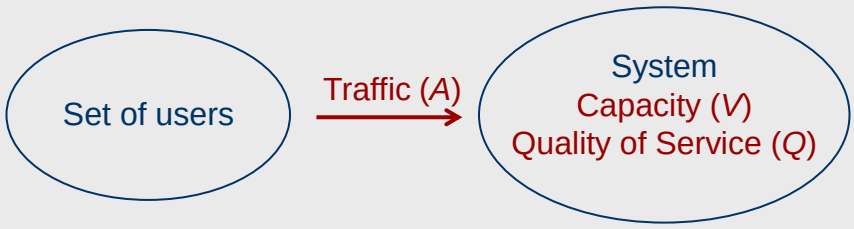
20

Różnorodność wymagań jakościowych

- Przyjmuje się, że QoS zależy od przypadkowego charakteru ruchu
- Inne typy ruchu
  - Ruch w sieciach pakietowych wykazuje cechę samopodobieństwa
    - Ethernet
    - Właściwości statystyczne ruchu samopodobnego są zdecydowanie różne od właściwości uzyskiwanych na podstawie modeli Poisson'owskich
      - Ograniczenie zjawiska samopodobieństwa

21

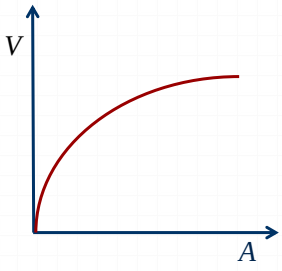
Problemy inżynierii ruchu



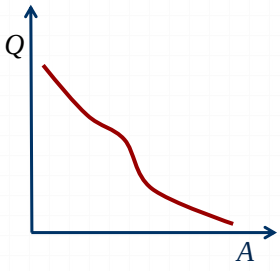
1. Determine Q on the basis of A and V, $Q = f(A,V)$.
2. Determine A on the basis of Q and V, $A = f(Q,V)$.
3. Determine V on the basis of A and Q, $V = f(A,Q)$.

22

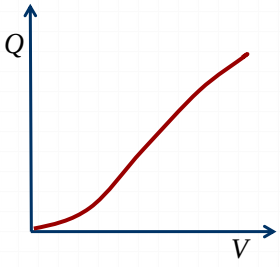
Problemy inżynierii ruchu



$V = f(A, Q = \text{const})$



$Q = f(A, V = \text{const})$



$Q = f(V, A = \text{const})$

23

Charakter ruchu

- Główny podział usług – charakteru ruchu
  - Usługi wrażliwe na opóźnienie
  - Usługi wrażliwe na straty

24

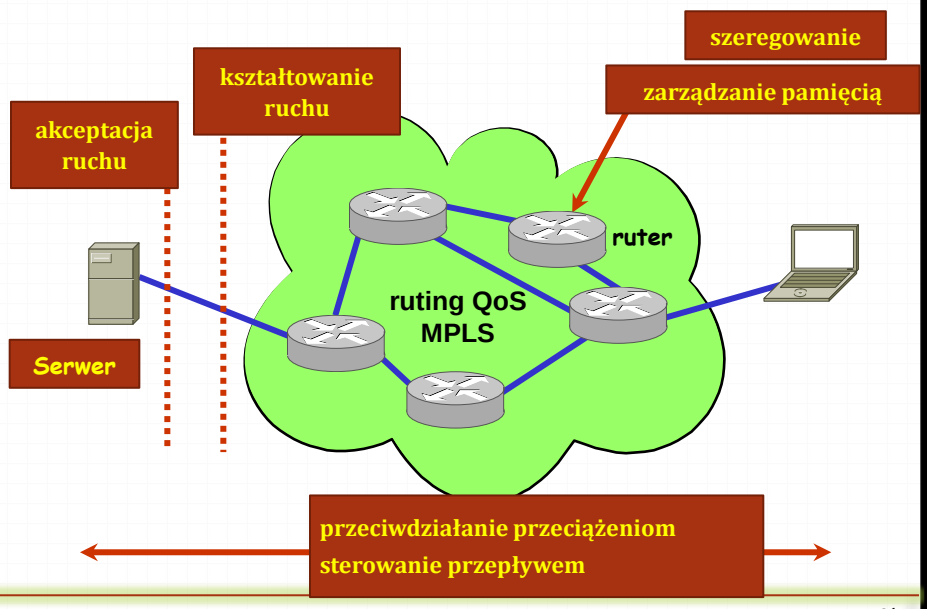
Charakter ruchu

PODZIAŁ RUCHU	DELAY-SENSITIVE TRAFFIC	LOSS-SENSITIVE TRAFFIC
PRZYKŁADY	konferencja video telefonia video na żądanie	transfer danych

- Główny podział usług – charakteru ruchu

25

Mechanizmy sterujące QoS



26

Mechanizmy sterujące QoS

- Admission Control – akceptacja ruchu
- Traffic Policing (Traffic Access Control) – kształtowanie ruchu
- Packet Scheduling – szeregowanie pakietów
- Buffer Management – zarządzanie pamięcią buforową
- Flow & Congestion Control – Sterowanie przepływem & przeciwdziałanie przeciążeniom
- QoS routing – QoS ruting

27

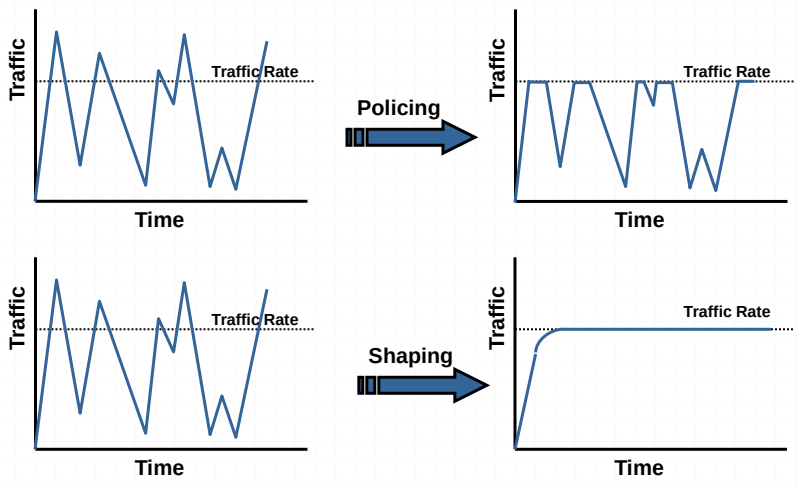
Admission Control

- Ogranicza obciążenie systemu kolejkowego poprzez określenie, czy przychodzące nowe żądanie może zostać obsłużone
  - Wpływ na aktualnie obsługiwane żądania
  - Możliwość spełnienia parametrów jakościowych dla przychodzącego żądania
- Wykonywane po odebraniu nowego żądania połączenia
  - Odebrać lub odrzucić połączenie
- Deskryptor źródła ruchu
  - PCR, SCR, MBS i MCR
- Wymagania QoS
- opóźnienie, zmienność opóźnienia, wskaźnik utraty komórek

Traffic Access Control

- Kształtuje zachowanie przepływów danych na wejściu i w określonych punktach w sieci
- Ruch akceptowanych połączeń powinien być zgodny z deskryptorem ruchu
- Nadmiar ruchu może zostać odrzucony, oznaczony z niższym priorytetem lub opóźniony, tj. ukształtowany.

Traffic Policing and Traffic Shaping



Packet Scheduling

- Określa dyscyplinę obsługi kolejki w węźle
  - kolejność, w jakiej pakiety są faktycznie przesyłane.
- Współdzielony interfejs wyjściowy
  - Wymuszenie odpowiedniego udziału w zasobach interfejsu wyjściowego
    - np. priorytety
- Sprawiedliwość - fairness
- Ochrona przed złośliwymi użytkownikami

Narzędzia QoS

- Traffic shaping and traffic policing
- Zarządzanie kolejkami
  - RED, WRED, ECN
- Zarządzanie przeciążeniem
  - PQ
  - CQ
  - WFQ
  - CBWFQ
- Efektywność łącza
  - RTP i CRTP

32

Inżynieria ruchu

Agner Krarup Erlang (1878-1929)

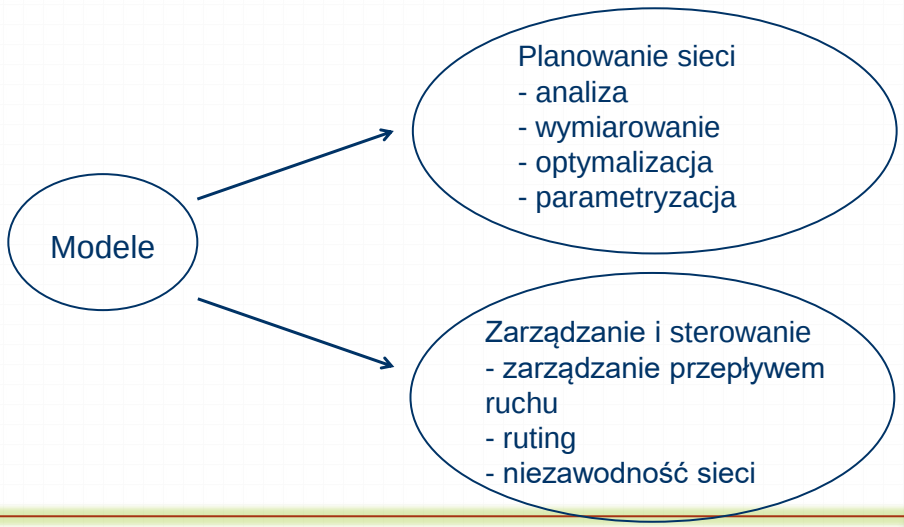


Modelowanie systemów telekomunikacyjnych

- Modele ruchu są probabilistyczne (stochastyczne)
  - parametry systemu są deterministyczne
  - ruch ma charakter probabilistyczny
  - parametry ruchu są zmiennymi losowymi
  - czasowe zachowanie ruchu w systemie opisywane jest przez procesy stochastyczne
- Ograniczenia modeli ruchu
  - model opisuje zwykle tylko fragment działania rzeczywistego systemu
  - w większości przypadków model jest mało dokładny, przybliżony, więc w konsekwencji modelowanie jest sztuką aproksymacji

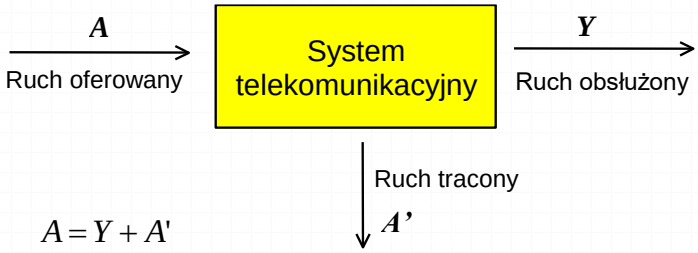
35

Modelowanie systemów telekomunikacyjnych



36

Typy ruchu



$A = Y + A'$

- UWAGA!
  - Potocznie, pod pojęciem ruchu rozumiemy jego natężenie

37

Definicje typów ruchu

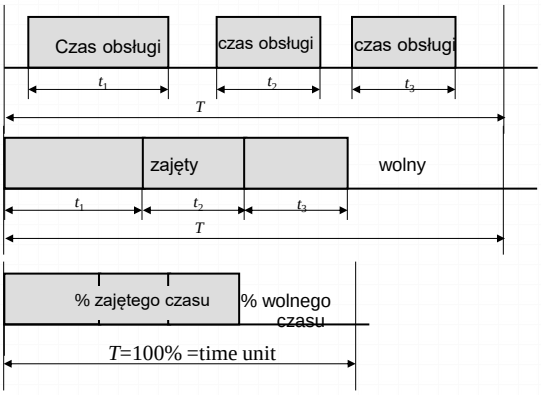
- Ruch oferowany
  - pojęcie, które określa hipotetyczny ruch (nie jest mierzalny) tworzony przez zgłoszenia pojawiające się na wejściu systemu,
- Ruch obsłużony (załatwiany)
  - określa ruch, który zostanie obsłużony przez system
  - zgłoszenia, które zastaną wolne zasoby w systemie wytworzą ruch obsłużony
  - wielkość mierzalna
- Ruch tracony
  - określa ruch, który nie będzie obsłużony przez system
  - zgłoszenia, dla których brak wolnych zasobów w systemie, zostaną odrzucone i wytworzą ruch tracony.

38

Ruch w IoT

- Połączenia M2M
  - czujniki, siłowniki i sterowniki
  - zdefiniowane łącze komunikacyjne
  - programowanie, które instruuje urządzenie, jak interpretować dane i na podstawie predefiniowanych parametrów jak przekazywać te dane
- Połączenia M2P
  - Ludzie mogą wysyłać informacje do systemów technicznych i otrzymywać informacje z tych systemów.
  - Zebrana informacja z połączeń M2M pozwala ludziom podejmować optymalne decyzje.
- Połączenia P2P
  - Współpraca za pośrednictwem głosu, wideo i danych
- Interakcje P2P w rozwiązaniach IoE
- M2M, M2P, P2P
  - Interakcja w celu opracowania rozwiązania problemu
  - Zapewnia organizacjom i osobom indywidualnym przydatne informacje i płynną automatyzację.

Ruch i natężenie ruchu



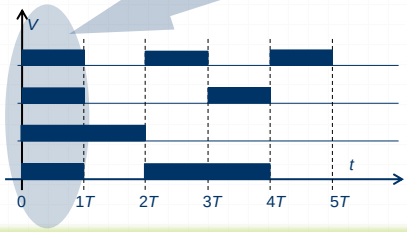
$$A = \frac{t_1 + t_2 + t_3}{T} = \frac{t_{busy}}{T} = \frac{\%\ \text{zajetosci jednostki czasu}}{\text{jednostka czasu}}$$

40

Definicja natężenia ruchu 1

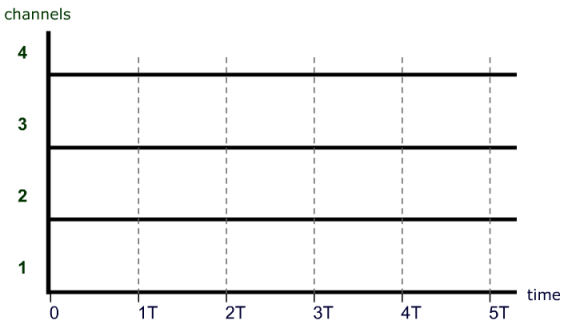
- Natężenie ruchu jest równe średniej liczbie jednocześnie zajętych kanałów.

$$A(Def.1) = \sum_{i=1}^{N} \sum_{j=1}^{V} t_{i,j} / t_{obs} = \frac{(4+1+2+2+1)T}{5T} = 2\ Erl.$$



41

Definicja natężenia ruchu 1



$$A(Def.1) = \sum_{i=1}^{N} \sum_{j=1}^{V} t_{i,j} / t_{obs.} = \frac{(0+0+0+0+0)T}{5T} = 0\ Erl$$

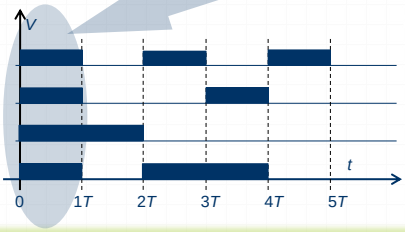
©

42

Definicja natężenia ruchu 2

- Natężenie ruchu jest stosunkiem sumy czasów zajętości kanałów w okresie obserwacji do czasu obserwacji.

$$A(Def.2) = \sum_{i=1}^{N}\sum_{j=1}^{V} t_{i,j} / t_{obs.} = \frac{(3+2+2+3)T}{5T} = 2Erl.$$



43

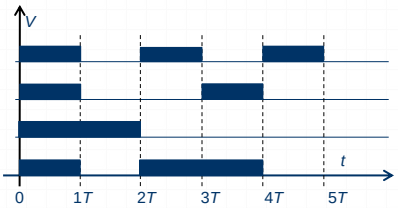
Definicja natężenia ruchu 3

- Natężenie ruchu to iloczyn średniej liczby zgłoszeń (połączeń) w czasie jednostkowym i średniego czasu trwania połączenia.

ruch oferowany

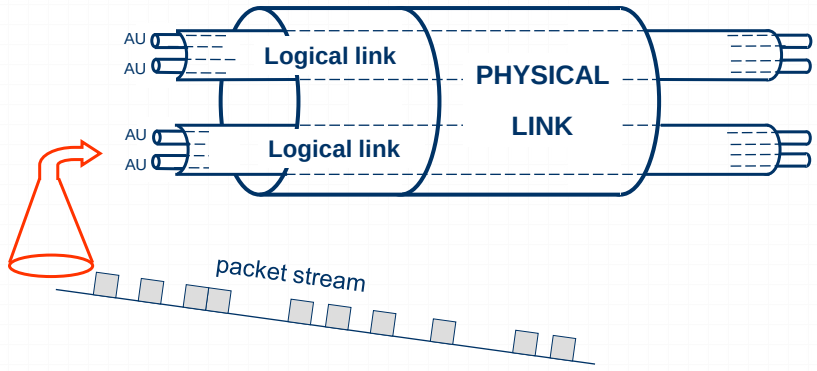
ruch obsłużony

$$A(Def.3) = ch = (\frac{8}{5T})(\frac{10T}{8}) = 2Erl.$$



44

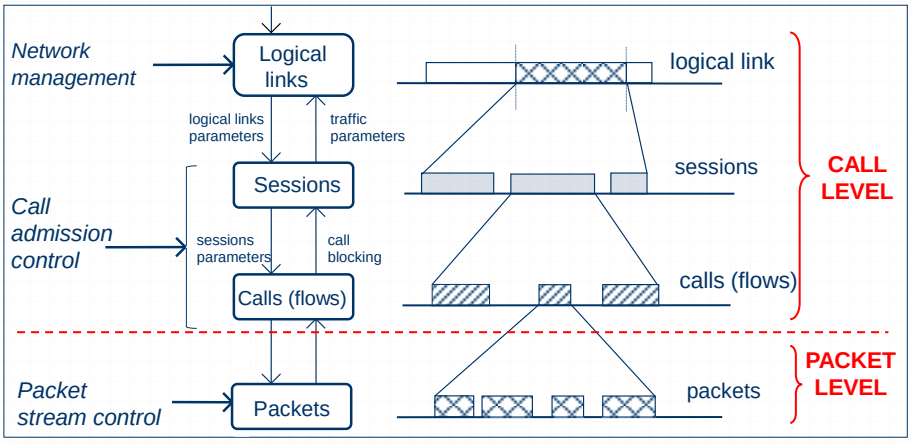
Zgłoszenia i pakiety



CALL = requirement of a given bit-rate for packet stream

45

Poziom zgłoszeń i pakietów w połączeniowych sieciach pakietowych



46

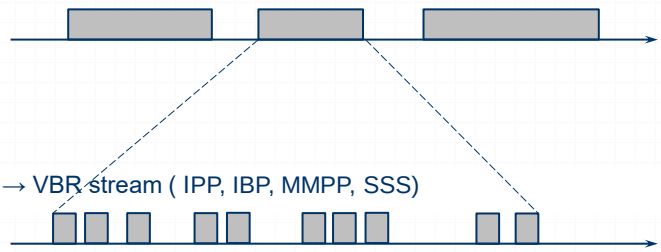
Modelowanie na poziomie zgłoszeń i pakietów

- poziom zgłoszeń
  - zakładamy, że na poziomie sesji i na poziomie zgłoszeń/połączeń napływające żądania mogą być przybliżone przez strumienie Poissona
- poziom pakietów
  - strumienie pakietów na poziomie pakietów mają złożoną strukturę wewnętrzną (samopodobieństwo)

47

Charakter ruchu

Call level → Poisson stream*



Packet level → VBR stream (IPP, IBP, MMPP, SSS)

* Bonald T., Roberts J., *Internet and the Erlang Formula*, **ACM Computer Communications Review**, vol. 42, no. 1, 2012, pp.23-30.

Modelowanie na poziomie zgłoszeń i pakietów

- poziom zgłoszeń
  - modele jednousługowe (single rate)
  - modele wielousługowe (multi rate)
- poziom pakietów
  - modele systemów kolejkowych ze złożonym strumieniem wejściowym uwzględniające samopodobny charakter ruchu

49

Pojęcie blokady

- Blokada
  - stan systemu, w którym połączenie przychodzące na wejście systemu nie może być obsłużone z powodu zajętości wszystkich zasobów w systemie.
- Zjawisko blokowania generuje straty ruchu w sieci:
  - Prawdopodobieństwo blokady
  - Prawdopodobieństwo strat

50

Współczynnik strat

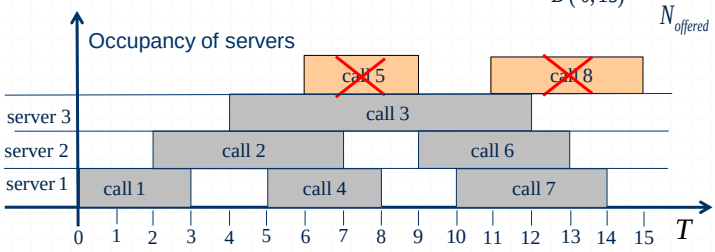
- *współczynnik strat zgłoszeń* w przedziale (t_1,t_2) określa stosunek liczby zgłoszeń straconych w systemie $N_{lost}(t_1,t_2)$ do liczby wszystkich oferowanych zgłoszeń w tym systemie $N_{offered}(t_1,t_2)$:

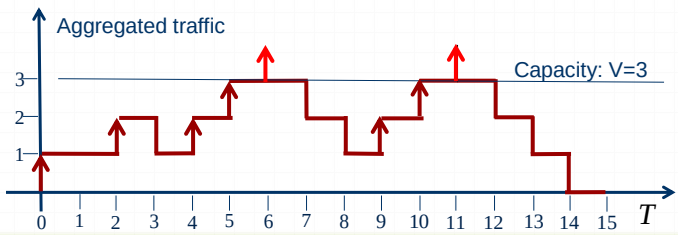
$$B(t_1,t_2) = \frac{N_{lost}(t_1,\ t_2)}{N_{offered}(t_1,\ t_2)} = \frac{N_{offered}(t_1,\ t_2) - N_{carried}(t_1,\ t_2)}{N_{offerd}(t_1,\ t_2)}$$

51

Prawdopodobieństwo strat

$$B(0,15) = \frac{N_{lost}(0,\ 15)}{N_{offered}(0,\ 15)} = \frac{2}{8} = 0.25$$





52

Współczynnik/prawdopodobieństwo blokady

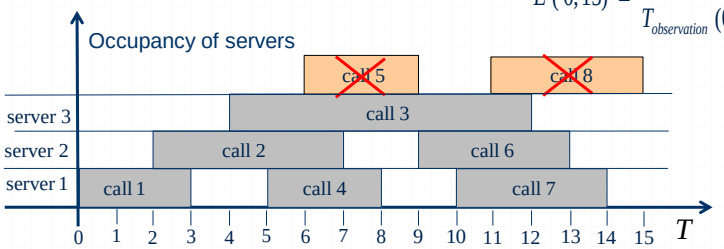
- Współczynnik blokady (prawdopodobieństwo blokady) E (t_1 , t_2)
  - W przedziale (t_1 , t_2)
  - Jest stosunkiem czasu $T_{blocking}(t_1 , t_2)$ gdy wszystkie serwery były zajęte do czasu obserwacji $T(t_1 , t_2)$

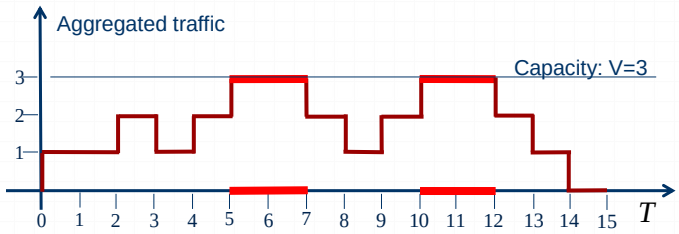
$$E(t_1, t_2) = \frac{T_{blocking}(t_1, t_2)}{T(t_1, t_2)}$$

53

Blocking probability

$$E(0,15) = \frac{T_{blocking}(0, 15)}{T_{observation}(0, 15)} = \frac{4}{15} \cong 0.267$$

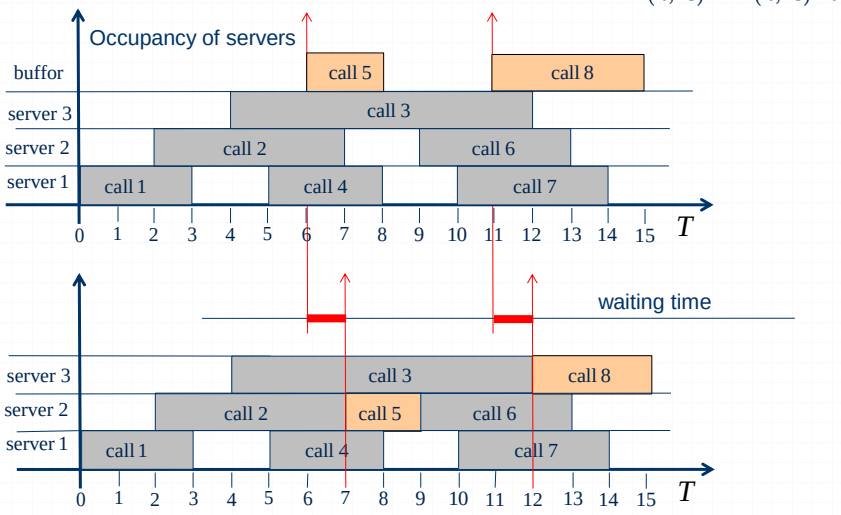




54

Kolejkowanie

$E(0,15) = B(0,15) = 0$



Wahania ruchu

- Ruch generowany jest przez dużą populację użytkowników, którzy działają niezależnie od siebie.
  - W konsekwencji ruch może wykazywać znaczne wahania
- Można wyróżnić:
  - Wahania na skali lat (wzrost ruchu ze względu na nowych użytkowników, nowe taryfy, nowe usługi)
  - sezonowe (miesiące)
  - zmiany z dnia na dzień (dni)
  - zmiany z godziny na godzinę
- Wahania spowodowane przewidywalnymi (regularnymi i nieregularnymi) zdarzeniami zewnętrznymi
  - regularne (Boże Narodzenie)
  - nieregularne (głosowanie tele)

Traffic variations

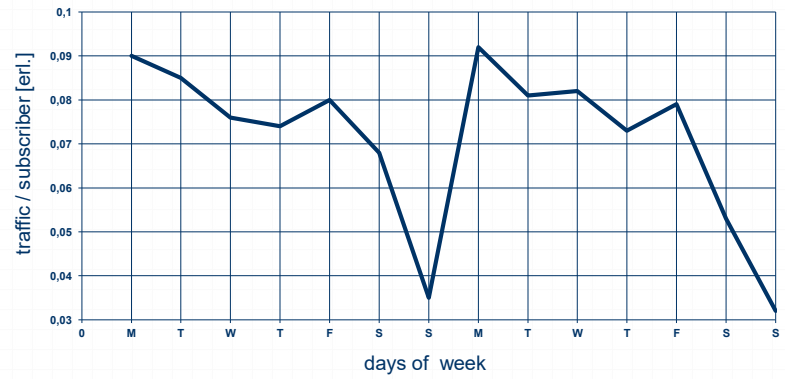
Seasonal variations (voice traffic)



57

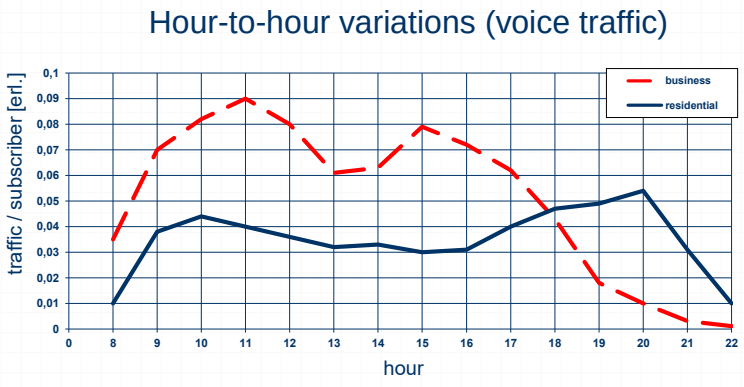
Traffic variations

Day-to-day variations (voice traffic)



58

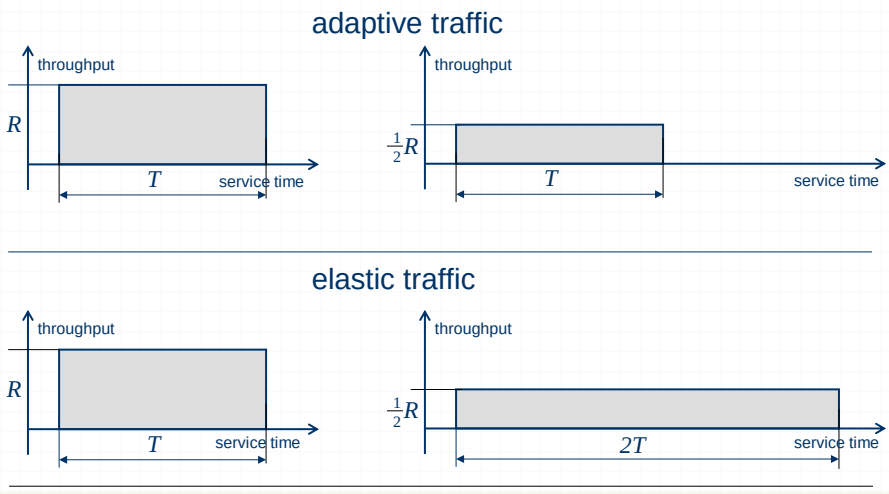
Traffic variations



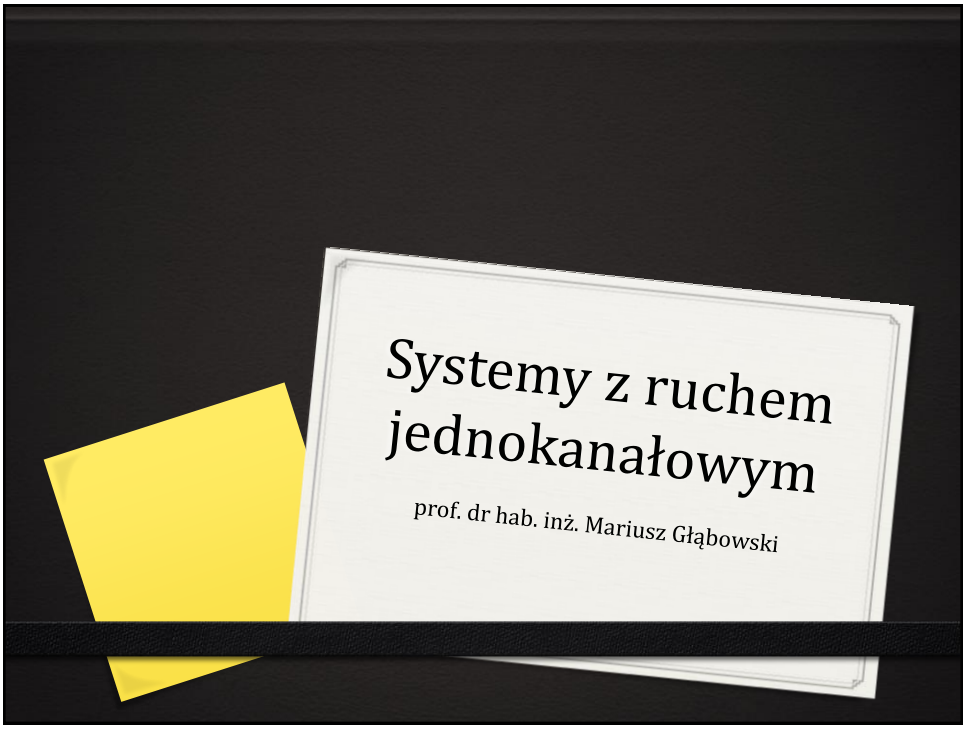
Typy ruchu generowanego w sieci

- W większości sieci parametry ruchu są powiązane z parametrami oferowanych usług.
- Zawsze możemy wyróżnić następujące strumienie ruchu:
- Na poziomie pakietów
  - ruch o stałej przepływności (CBR),
  - ruch o zmiennej przepływności (VBR),
- Na poziomie zgłoszeń
  - ruch strumieniowy,
  - ruch adaptacyjny,
  - ruch elastyczny.

Ruch elastyczny i adaptacyjny



61



Pojęcia podstawowe

- Jednokanałowe strumienie zgłoszeń
  - Każde zgłoszenie wymaga do zestawienia połączenia zawsze tej samej wielkości zasobów sieci, np. sieć telefoniczna, 64kb/s
- Wymiarowanie
  - Określenie takiej wymaganej wielkości zasobów, aby straty nie przekroczyły zadanej wartości.
- Modele oparte na procesach Markowa

Strumień Poissona i jego właściwości

stacjonarność: intensywność strumienia nie zależy od czasu:
$\lambda(t) = \lambda = const,$

brak następstw: liczba zgłoszeń w wybranym przedziale t_1 nie ma wpływu na liczbę zgłoszeń w dowolnie wybranym przedziale t_2 ,

pojedynczość: w elementarnym odcinku czasu t może pojawić się co najwyżej jedno zgłoszenie

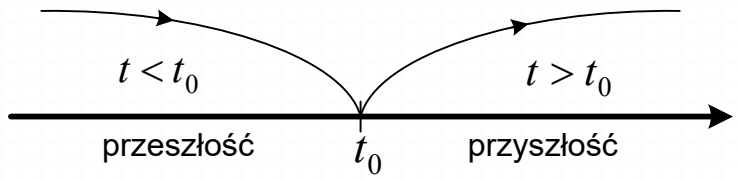
3

Strumień obsługi

- Strumieniem obsługi nazywamy szereg momentów zakończenia obsługi zgłoszeń.
- Parametry opisu strumienia obsługi
  - Czas obsługi
  - Prawdopodobieństwa elementarne
  - Dystrybuanta i funkcja gęstości rozkładu czasu obsługi
  - Prawdopodobieństwa zakończenia obsługi przez *i* zgłoszeń w czasie *t*
  - Parametr strumienia obsługi *N(t)*

4

Procesy Markowa



- Procesem Markowa nazywamy taki proces stochastyczny, w którym dla dowolnego momentu czasu t_0 , przyszła trajektoria procesu zależy wyłącznie od jego stanu $S(t_0)$ w rozważanym momencie t_0 i nie zależy od trajektorii, która w przeszłości doprowadziła ten proces do stanu $S(t_0)$

5

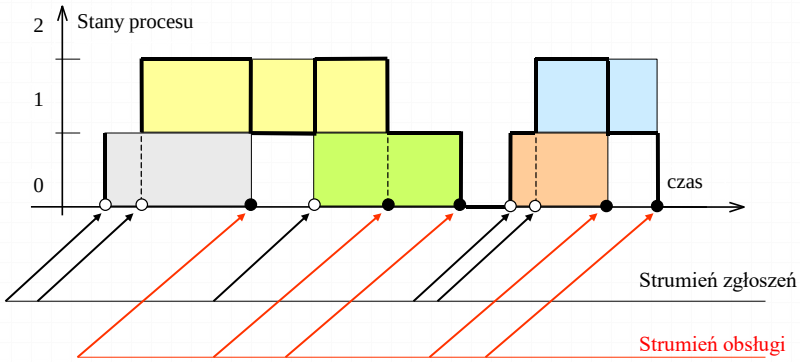
Procesy Markowa

- Proces Markowa z dyskretnymi stanami i ciągłym czasem
  - Procesem Markowa z dyskretną przestrzenią stanów ciągłym czasem nazywamy taki proces Markowa, który spełnia następujące postulaty:
    - przeliczalny zbiór stanów
    - skokowe zmiany stanów
    - nieokreślone momenty zmian stanu

6

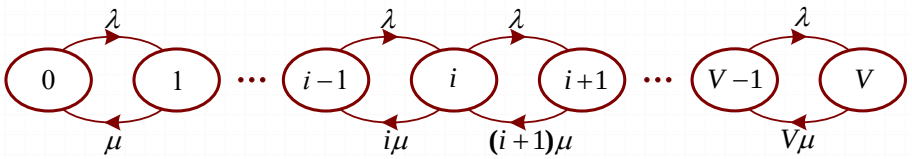
Procesy Markowa

- Trajektoria procesu Markowa – proces obsługi



7

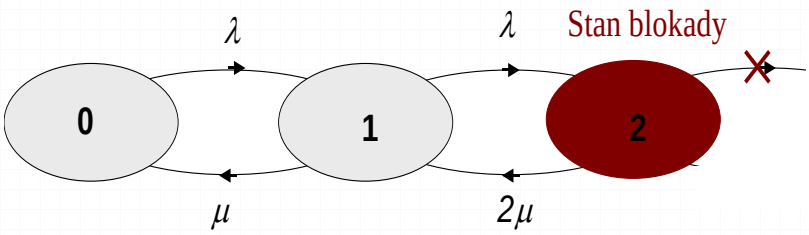
Diagram stanów



- Do analizy procesów Markowa wykorzystuje się często geometryczne diagramy, tzw. diagramami stanów. Na diagramach odpowiednie stany oznacza się okręgami (elipsami, prostokątami itp.), natomiast możliwe przejścia między nimi strzałkami

8

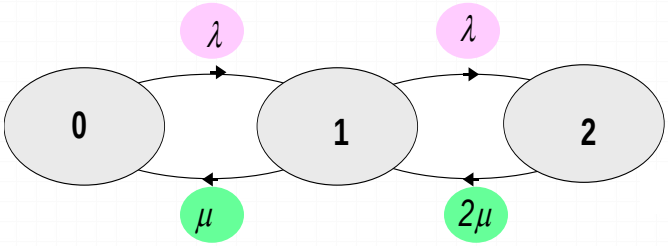
Proces narodzin i śmierci w systemie M/M/2



- stan 0 – wszystkie łącze wolne
- stan 1 – jedno łącze zajęte
- stan 2 – dwa łącze zajęte

Proces narodzin i śmierci w systemie M/M/2

Nieskończona liczba źródeł ruchu



Skończona liczba stanowisk obsługi

Równania Kołmogorowa

- Dysponując diagramem procesu Markowa, można skonstruować probabilistyczny model danego systemu.
- Rozważany system może znajdować się w jednym z *V+1* stanów z prawdopodobieństwem $p_i(t)$
- W celu określenia wszystkich prawdopodobieństw stanu $p_i(t)$ w funkcji czasu *t*, zestawia się i rozwiązuje tzw. równania Chapmana-Kołmogorowa (w skrócie równania Kołmogorowa).
- Równania te są równaniami różniczkowymi, w których niewiadomymi funkcjami są prawdopodobieństwa przebywania systemu w stanach określonych przez dyskretny proces Markowa z ciągłym czasem.

Prawdopodobieństwa elementarne

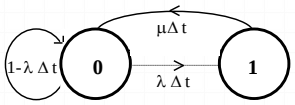
- W strumieniu Poissona prawdopodobieństwo pojawienia się jednego zgłoszenia w elementarnym przedziale czasowym jest wprost proporcjonalne do długości tego przedziału i wynosi: $P_1(\Delta t) = \lambda \Delta t + \theta(\Delta t) = \lambda \Delta t$
- W strumieniu obsługi prawdopodobieństwo zakończenia obsługi jednego zgłoszenia w elementarnym przedziale czasowym jest wprost proporcjonalne do długości tego przedziału i wynosi:

$$P_1(\Delta t) = \mu \Delta t + \theta(\Delta t) = \mu \Delta t$$

- gdzie: θ jest nieskończenie małą wartością, wyższego rzędu w porównaniu z Δt: $\lim_{\Delta t \to 0} \frac{\theta(\Delta t)}{\Delta t} = 0$

Równania Kołmogorowa dla systemu M/M/2

- Określenie prawdopodobieństwa $P_0(t+\Delta t)$



prawdopodobieństawa zdarzeń w czasie Δt

był w stanie "0" i przeszedł do stanu "1": **λ Δt**

był w stanie "0" i pozostał w stanie "0": **1- λ Δt**

był w stanie "1" i przeszedł do stanu "0": **μ Δt**

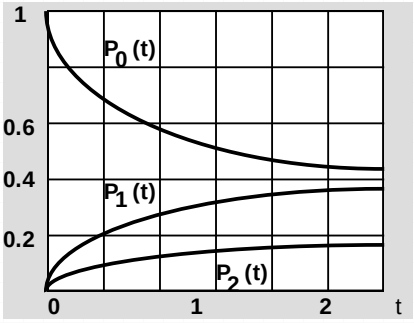
$$P_0(t+\Delta t) = P_0(t)[1-\lambda\Delta t] + P_1(t)\mu\Delta t,$$

$$\frac{P_0(t+\Delta t) - P_0(t)}{\Delta t} = -\lambda P_0(t) + \mu P_1(t),$$

$$\frac{dP_0(t)}{dt} = -\lambda P_0(t) + \mu P_1(t).$$

Równania Kołmogorowa dla systemu M/M/2

$$\begin{cases} \frac{dP_0(t)}{dt} = -\lambda P_0(t) + \mu P_1(t), \\ \frac{dP_1(t)}{dt} = \lambda P_0(t) - (\lambda+\mu) P_1(t) + 2\mu P_2(t), \\ \frac{dP_2(t)}{dt} = \lambda P_1(t) - 2\mu P_2(t), \\ P_0(t) + P_1(t) + P_2(t) = 1 \end{cases}$$



Rozwiązanie równań Kołmogorowa systemu M/M/2 dla λ=μ=1, $P_0(0)=1$.

Równania Kołmogorowa dla systemu M/M/2

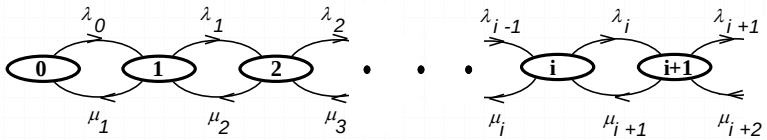
$$\begin{cases} \dfrac{dP_0(t)}{dt} = -\lambda P_0(t) + \mu P_1(t), \\ \dfrac{dP_1(t)}{dt} = \lambda P_0(t) - (\lambda+\mu)P_1(t) + 2\mu P_2(t), \\ \dfrac{dP_2(t)}{dt} = \lambda P_1(t) - 2\mu P_2(t), \\ P_0(t) + P_1(t) + P_2(t) = 1 \end{cases}$$

Stan ustalony

$$\begin{cases} 0 = -\lambda P_0 + \mu P_1, \\ 0 = \lambda P_0 - (\lambda+\mu)P_1 + 2\mu P_2, \\ 0 = \lambda P_1 - 2\mu P_2, \\ P_0 + P_1 + P_2 = 1 \end{cases}$$

$$P_i = \lim_{t\to\infty} P_i(t)$$
$$dP_i / dt = 0$$

Uogólniony proces narodzin i śmierci



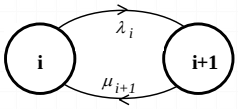
$$\begin{cases} -\lambda_0 P_0 + \mu_1 P_1 = 0, \\ \lambda_0 P_0 - (\lambda_1+\mu_1)P_1 + \mu_2 P_2 = 0, \\ \bullet\bullet\bullet, \\ \lambda_{i-1} P_{i-1} - (\lambda_i+\mu_i)P_i + \mu_{i+1} P_{i+1} = 0, \\ \bullet\bullet\bullet, \\ \sum_{i\geq 0} P_i = 1. \end{cases}$$

stąd:

$$\begin{cases} \lambda_0 P_0 = \mu_1 P_1, \\ \lambda_1 P_1 = \mu_2 P_2, \\ \bullet\bullet\bullet, \\ \lambda_i P_i = \mu_{i+1} P_{i+1}, \\ \bullet\bullet\bullet, \\ \sum_{i\geq 0} P_i = 1. \end{cases}$$

Lokalne równania równowagi

Strumienie pomiędzy sąsiednimi stanami są w równowadze



$$\lambda_i P_i = \mu_{i+1} P_{i+1}$$

Rozwiązanie procesu:

$$P_k = \frac{\lambda_0 \lambda_1 \cdots \lambda_{k-1}}{\mu_1 \mu_2 \cdots \mu_k} P_0 = \prod_{i=1}^{k} \frac{\lambda_{i-1}}{\mu_i} P_0 = C_k P_0 \quad \text{gdzie} \quad P_0 = \frac{1}{\sum_{k \geq 0} C_k}$$

Ruch i natężenie ruchu

- Do ilościowego opisu ruchu telekomunikacyjnego wykorzystuje się parametr nazywany natężeniem ruchu telekomunikacyjnego.
- Jednostką natężenia ruchu jest jeden Erlang (*1 Erl.*).
- Jeden Erlang odpowiada czasowi trwania jednego jedno-godzinnego połączenia w okresie obserwacji równym jednej godzinie.

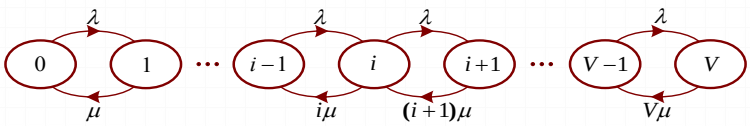
Model Erlanga

- Założenia modelu
  - Pojemność systemu – V stanowisk obsługi (łączy, kanałów), z których każde jest dostępne dla dowolnego zgłoszenia, jeśli tylko nie jest zajęte,
  - Zgłoszenia pochodzą od nieograniczonej liczby źródeł ruchu i tworzą strumień Poissona o intensywności λ,
  - Czas obsługi opisany jest rozkładem wykładniczym, wartość średnia czasu obsługi wynosi $1/\mu$,
  - Zgłoszenie nie przyjęte do obsługi, z powodu braku wolnych stanowisk jest tracone.

19

Równania stanu

- Diagram procesu obsługi



- Równania stanu

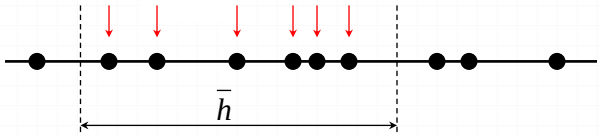
$$\begin{cases} \lambda[P_0]_V = \mu[P_1]_V \\ \dots \\ \lambda[P_{i-1}]_V = i\mu\,[P_i]_V \\ \dots \\ \lambda[P_{V-1}]_V = V\mu[P_V]_V \\ \sum_{i=0}^{V}[P_i]_V = 1 \end{cases}$$

$$[p_k]_V = \frac{\left(\frac{\lambda}{\mu}\right)^k}{k!} \Big/ \sum_{i=0}^{V} \frac{\left(\frac{\lambda}{\mu}\right)^i}{i!}$$

20

Interpretacja λ/μ

$$\frac{\lambda}{\mu} = \lambda \frac{1}{\mu} = \lambda \bar{h}$$

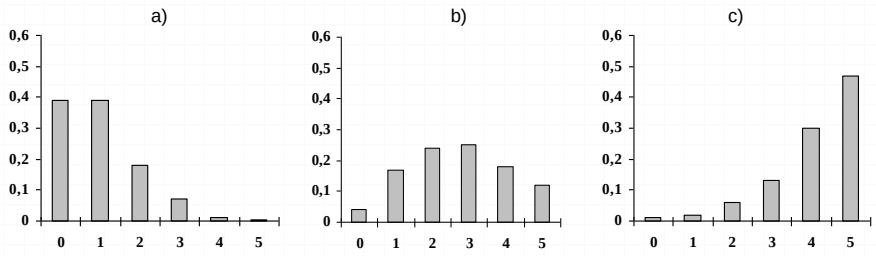


λ/μ determines the average number of arrivals within average service time

21

Model Erlanga

$$[p_k]_V = \frac{(\lambda/\mu)^k}{k!} \Big/ \sum_{i=0}^{V} \frac{(\lambda/\mu)^i}{i!} = \frac{A^k}{k!} \Big/ \sum_{i=0}^{V} \frac{A^i}{i!} \quad \text{where} \quad A = \lambda/\mu$$



Model Erlanga: M/M/N/0

$$E_{1,N}(A) = [p_V]_V = \frac{\frac{A^V}{V!}}{\sum_{i=0}^{V} \frac{A^i}{i!}}$$

- Wzór Erlanga (pierwszy wzór Erlanga)
  - równanie opisujące taki stan wiązki doskonałej obsługującej ruch jednokanałowy, w którym wszystkie kanały wiązki są zajęte (stan blokady):
  - W teorii ruchu wykazano, że w przypadku wiązki doskonałej prawdopodobieństwo blokady jest równe prawdopodobieństwu strat. Prawdopodobieństwa te często oznacza się symbolem Ev(A).

Model Erlanga: M/M/N/0

$$E_{1,N}(A) = \frac{AE_{1,N-1}(A)}{N + AE_{1,N-1}(A)}$$

$$E_{1,0}(A) = \frac{A^0}{0!} \Big/ \frac{A^0}{0!} = 1$$

- Rekurencyjne właściwości wzoru Erlanga

Charakterystyka ruchowa systemu M/M/N/0

$$Q = 1 - E_V(A)$$

- przepustowość wiązki

$$Y_V = \sum_{k=0}^{V} kP_k = \frac{\sum_{k=0}^{V} k\frac{A^k}{k!}}{\sum_{k=0}^{V}\frac{A^k}{k!}} = \frac{A\sum_{k=0}^{V-1}\frac{A^k}{k!}}{\sum_{k=0}^{V}\frac{A^k}{k!}} = A[1 - E_V(A)]$$

- wartość średnia ruchu załatwianego (średnia wartość liczby jednocześnie zajętych kanałów)

$$A' = A - Y_V = AE_V(A)$$

Tablice wzoru Erlanga

- W praktyce inżynierskiej można spotkać się z dwoma rodzajami tablic wzoru Erlanga.

Tablica pierwszego typu

N	A1	A2	A3	N
1	B11	B21	B31	1
2	B12	B22	B32	2
3	B13	B23	B33	3

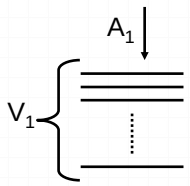
Tablica drugiego typu

N	B1	B2	B3	N
1	A11	A21	A31	1
2	A12	A22	A32	2
3	A13	A23	A33	3

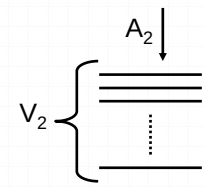
Fragment tablicy Erlanga

Pojemność	Prawdopodobieństwo blokady *B*			
V	B=0.02	B=0.01	B=0.005	B=0.001
	Ruch oferowany *A*			
1	0.02	0.01	0.005	0.001
2	0.22	0.15	0.105	0.046
3	0.60	0.45	0.35	0.19
4	1.10	0.90	0.70	0.44
5	1.70	1.40	1.10	0.80
6	2.30	1.90	1.60	1.10
7	2.90	2.50	2.20	1.60
8	3.60	3.10	2.70	2.10
9	4.30	3.80	3.30	2.60
10	5.10	4.50	4.00	3.10

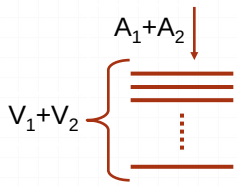
Prawo wiązki



$$E_{1,V_1}(A_1) = \frac{A_1^{V_1}}{V_1!} \Big/ \sum_{i=0}^{V_1} \frac{A_1^i}{i!}$$



$$E_{1,V_2}(A_2) = \frac{A_2^{V_2}}{V_2!} \Big/ \sum_{i=0}^{V_2} \frac{A_2^i}{i!}$$



$$E_{1,V_1+V_2}(A_1+A_2) = \frac{\dfrac{(A_1+A_2)^{V_1+V_2}}{(V_1+V_2)!}}{\sum_{i=0}^{V_1+V_2} \dfrac{(A_1+A_2)^i}{i!}}$$

$$E_{V_1+V_2}(A_1+A_2) < \max\left[E_{V_1}(A_1), E_{V_2}(A_2)\right]$$

Prawo wiązki

$A_1 = 5{,}1$ Erl.
$V_1 = 10$
$E_{V_1}(A_1) = 0{,}02$

$A_2 = 12$ Erl.
$V_1 = 20$
$E_{V_2}(A_2) = 0{,}01$

$$E_{(V_1+V_2)}(A_1 + A_2) = 0{,}001$$

- Przykład

Wzór Palma-Jacobaeusa

- Określa prawdopodobieństwo zajętości określonych kanałów w wiązce doskonałej ze stratami
  - W wiązce o pojemności V oznaczono x kanałów, które uważa się za ściśle określone stanowiska obsługi
  - Oznaczenia:
    - P(x | i) - warunkowe prawdopodobieństwo zajętości x określonych kanałów, pod warunkiem, że w wiązce zajętych jest *i* dowolnych kanałów,
    - H(x)- prawdopodobieństwo zajętości *x* określonych kanałów,
    - P_i - prawdopodobieństwo zajętości i dowolnych kanałów

$$H(x) = \sum_{i=x}^{V} P(x|i) P_i$$

$$P_i = \frac{A^i}{i!} \Big/ \sum_{j=0}^{V} \frac{A^j}{j!}$$

Wzór Palma-Jacobaeusa

$$P(x \mid i) = \binom{N-x}{i-x} \Big/ \binom{N}{i} = \frac{(N-x)!}{N!} \frac{i!}{(i-x)!}.$$

$$H(x) = \sum_{i=x}^{N} P(x \mid i) P_i = \frac{\frac{(N-x)!}{N!} \sum_{i=x}^{N} \frac{A^i}{i!} \frac{i!}{(i-x)!}}{\sum_{j=0}^{N} \frac{A^j}{j!}} = \frac{\frac{(N-x)!}{N!} \sum_{k=0}^{N-x} \frac{A^{x+k}}{(x+k)!} \frac{(k+x)!}{k!}}{\sum_{j=0}^{N} \frac{A^j}{j!}} = \frac{\frac{A^N}{N!} \sum_{k=0}^{N-x} \frac{A^k}{k!}}{\sum_{j=0}^{N} \frac{A^j}{j!} \frac{A^{N-x}}{(N-x)}}.$$

- Warunkowe prawdopodobieństwo zajętości x określonych kanałów, pod warunkiem, że i kanałów jest zajętych:

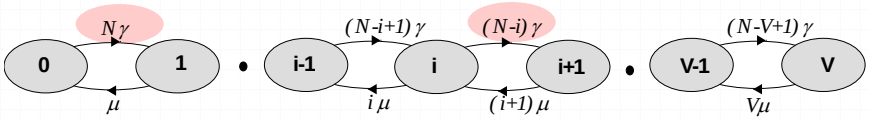
$$H(x) = \frac{E_{1,N}(A)}{E_{1,N-x}(A)}$$

Model Engseta

Założenia:

- Jest V kanałów w wiązce i każdy z nich jest dostępny dla dowolnego zgłoszenia, jeśli tylko nie jest zajęty
- Zgłoszenia tworzą strumień od ograniczonej do N (N>V) liczby źródeł. Każde wolne źródło ma intensywność γ,
- Czas obsługi jest opisany rozkładem wykładniczym
- Zgłoszenie nie przyjęte do obsługi jest tracone

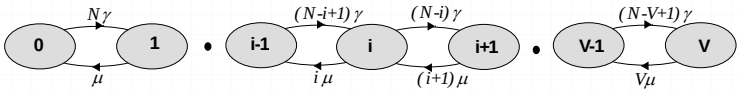
Model Engseta Diagram



stan „0” - wszystkie kanały są wolne / N źródeł wolnych,
stan „1” - jeden kanał jest zajęty, (*N-1*) źródeł wolnych,

. . .,
stan „i” - *i* kanałów jest zajętych / (*N-i*) źródeł wolnych,
. . .,
stan „V” - wszystkie kanały są zajęte / (*N-V*) źródeł wolnych.

Model Engseta



$$\begin{cases} N\gamma\,[p_0]_V = \mu[p_1]_V \\ \dots \\ (N-i+1)\gamma\,[p_{i-1}]_V = i\mu\,[p_i]_V \\ \dots \\ (N-V+1)\gamma\,[p_{V-1}]_V = V\mu[p_V]_V \\ \sum_{i=0}^{V}[p_i]_V = 1 \end{cases}$$

$$[p_i]_V = \binom{N}{i}\alpha^i \Big/ \sum_{j=0}^{V}\binom{N}{j}\alpha^j$$

$\alpha = \gamma / \mu$

ruch oferowany przez wolne źródło

Model Engseta

prawdopodobieństwo blokady:

$$[p_V]_V = E = E(\alpha, V, N) = \binom{N}{V}\alpha^V \Big/ \sum_{j=0}^{V}\binom{N}{j}\alpha^j$$

prawdopodobieństwo strat:

$$B(\gamma, V, N) = \frac{(N-V)\gamma\,[p_V]_V}{\sum_{j=0}^{V}(N-j)\gamma\,[p_j]_V} = \binom{N-1}{V}\alpha^V \Big/ \sum_{j=0}^{V}\binom{N-1}{j}\alpha^j$$

$$B(\alpha, V, N) = E(\alpha, V, N-1)$$

prawdopodobieństwo strat w wiązce, której oferowany jest ruch od *N* źródeł jest równe prawdopodobieństwu blokady w wiązce, której oferowany jest ruch od *N-1* źródeł

Rekurencyjne właściwości wzoru Engseta

$$E(\alpha, V, N) = \frac{\alpha(N-V+1)\;E(\alpha, V-1, N)}{V+\alpha(N-V+1)\;E(\alpha, V-1, N)}$$

$$E(\alpha, 0, N) = 1$$



Plan wykładu

- Wprowadzenie
- Strategie kierowania ruchu w sieciach telekomunikacyjnych
- Metody szacowania optymalnej liczby łączy:
  - w wiązkach bezpośrednich
  - w wiązkach tranzytowych
- Przykład wymiarowania wiązek fragmentu sieci publicznej

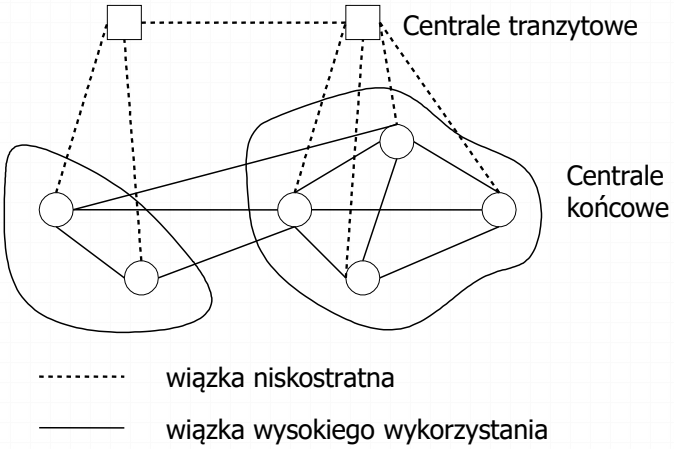
Wprowadzenie

- Podstawą systemu telekomunikacyjnego jest sieć
- Każda sieć telekomunikacyjna składa się z wiązek oraz węzłów
- Struktura nowoczesnych sieci staje się coraz bardziej skomplikowana, a zjawiska ruchowe zachodzące w sieci stają się bardziej złożone i trudniejsze do analizy
- Strategia kierowania ruchu drogami alternatywnymi jest obecnie najbardziej popularną metodą sterowania ruchem w istniejących sieciach telekomunikacyjnych.

Podział wiązek w hierarchicznej sieci telekomunikacyjnej

- Podział ze względu na natłok:
  - wiązki o wysokim wykorzystaniu - w wiązkach tych ruch załatwiany jest z natłokiem większym od założonego współczynnika strat. Ruch nie załatwiany przez taką wiązkę jest przelewany na wiązkę alternatywną.
  - wiązki o małych stratach - w wiązkach tych ruch załatwiany jest z natłokiem nie większym od założonego współczynnika strat. Ruch nie załatwiany przez taką wiązkę jest ruchem straconym.

Struktura tradycyjnej sieci hierarchicznej



Wiązki w hierarchicznej sieci telekomunikacyjnej

- Zarówno wiązki bezpośrednie, jaki i wiązki tranzytowe mogą być wiązkami o wysokim wykorzystaniu lub wiązkami o małych stratach
- Wiązki podstawowe tworzą szkielet sieci telekomunikacyjnej, tzw. *sieć podstawową*
- Sieć podstawowa może być uzupełniona wiązkami o wysokim wykorzystaniu
- Stosowanie wiązek podstawowych zmniejsza koszt sieci i pozwala na zwiększenie jej zdolności przesyłowej bez jednoczesnego zwiększenia pojemności central i przy zachowaniu założonego współczynnika strat

Wiązki w hierarchicznej sieci telekomunikacyjnej

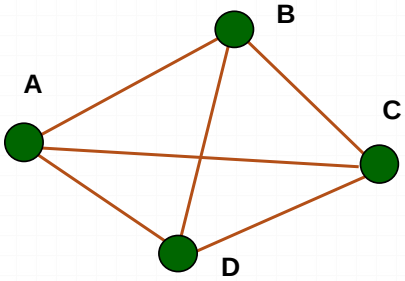
- Wiązki podstawowe są na ogół wiązkami o małych stratach
- Wiązki bezpośrednie są na ogół wiązkami o wysokim wykorzystaniu

Drogi kolejnego wyboru

- Logiczna architektura sieci hierarchicznej:
  - droga bezpośrednia - to droga składająca się z jednej wiązki bezpośredniej,
  - droga pośrednia składa się z dwóch lub więcej wiązek tranzytowych. Ruch nie załatwiony na tej drodze (ruch przelewowy) jest kierowany na następną drogę alternatywną (drogę obejściową, drogę kolejnego wyboru),
  - droga ostatniego wyboru. W skład drogi ostatniego wyboru wchodzą wyłącznie wiązki o małych stratach.

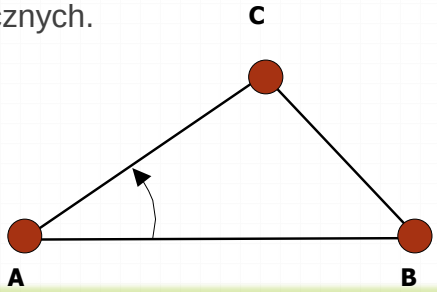
Przykład dróg kolejnego wyboru

- AB – droga bezpośrednia,
- ACB – droga drugiego wyboru,
- ADB – droga trzeciego wyboru,
- ADCB – droga ostatniego wyboru.

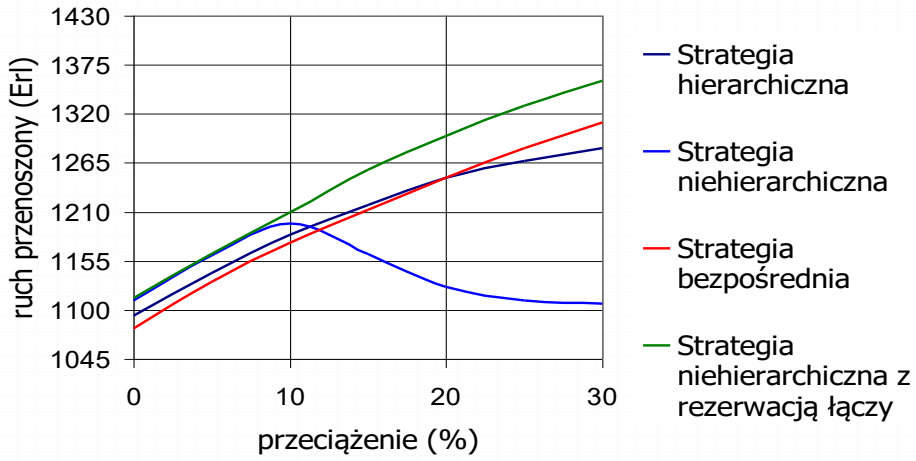


Efektywność strategii kierowania ruchem

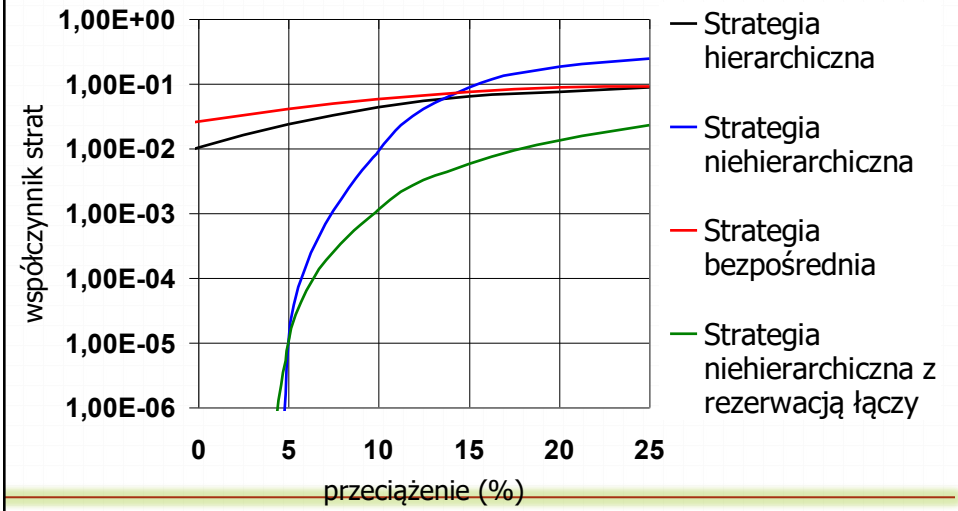
- Dynamiczne strategie kierowania ruchem stosowane w sieciach niehierarchicznych poprawiają niezawodność sieci w przypadku przeciążenia nie większego niż 10%.
- Przy dużych przeciążeniach sieci, strategie dynamiczne tracą swoje właściwości i mogą okazać się gorsze od strategii statycznych.



Efektywność strategii kierowania ruchem

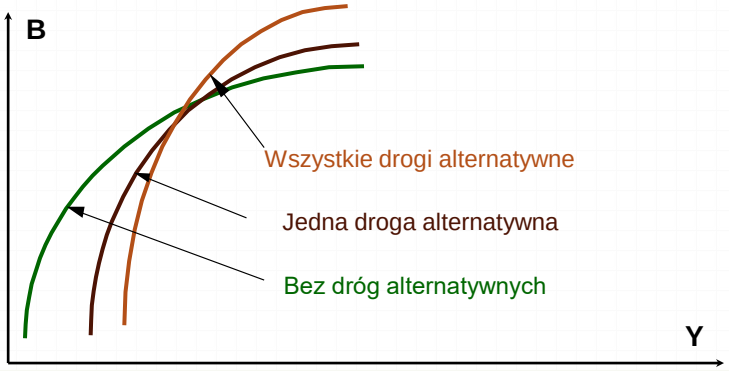


Efektywność strategii kierowania ruchem



Efektywność sieci z drogami alternatywnymi

- Zależność prawdopodobieństwa strat od załatwianego ruchu przy różnej liczbie dróg alternatywnych

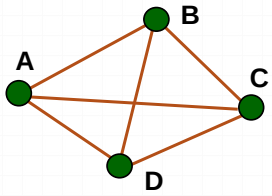


Wymiarowanie wiązek w sieciach telekomunikacyjnych

- Obliczanie parametrów sieci telekomunikacyjnej z drogami alternatywnymi to zagadnienie złożone, sprowadzające się do rozwiązania dwóch problemów:
  - określenie optymalnej liczby łączy w wiązce o wysokim wykorzystaniu która doprowadzi do minimalizacji kosztów projektowanej sieci,
  - określenia liczby łączy w wiązkach o małych stratach w której współczynnik strat nie przekracza zaplanowanej wartości.
- Podstawowy problem - strumień zgłoszeń który składa się na ruch alternatywny nie jest strumieniem przypadkowym, zgodnym z rozkładem Poissona.

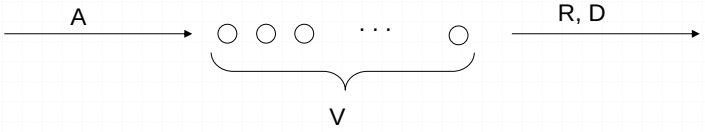
Wymiarowanie wiązek w sieciach telekomunikacyjnych

- Liczba łączy w wiązkach o wysokim wykorzystaniu jak i w wiązkach ostatniego wyboru powinna być dobrana w taki sposób, aby zapewnić żądaną w projekcie jakość obsługi odpowiednich strumieni przy minimalnym koszcie wszystkich wiązek sieci.



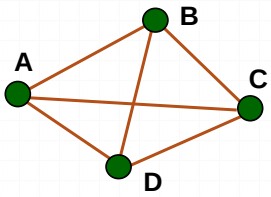
Ruch przelewowy

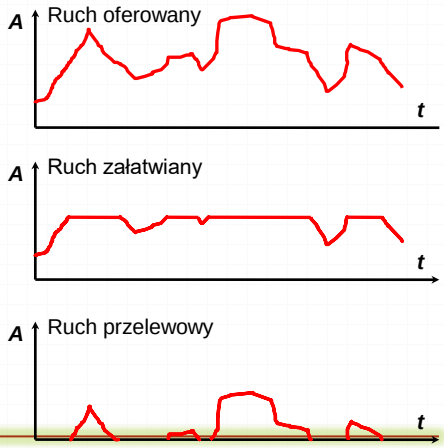
- Kiedy jedna wiązka obsługuje zarówno ruch bezpośredni jak i przelewowy to liczbę łączy niezbędną do ich obsługi tego ruchu nie można określać wyłącznie na podstawie średnich wartości ruchów oferowanych tej wiązce.



Rozkład ruchu dla wiązki doskonałej o wysokim wykorzystaniu

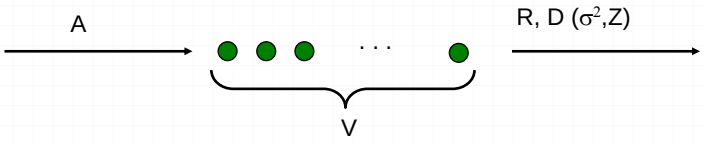
- AB - droga bezpośrednia,
- ACB - droga II - go wyboru,
- ADB - droga III - go wyboru,
- ADCB - droga ostatniego wyboru





Ocena statystyczna strumienia ruchu spływającego

- Wartość średnia *R* ruchu spływającego
- Wariancja σ^2 ruchu spływającego
- Współczynnik degeneracji *Z*
- Współczynnik rozsiewności (rozrzutu) *D*



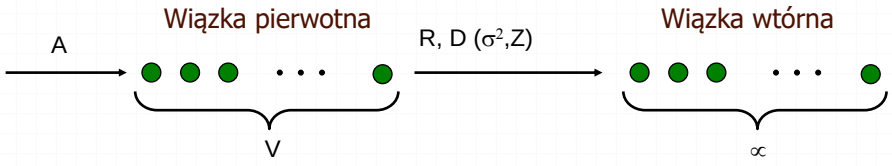
$$D = \sigma^2 - R$$

$$Z = \sigma^2 / R$$

Ocena statystyczna strumienia ruchu spływającego

Parametr	Ruch oferowany	Ruch obsługiwany	Ruch przelewowy
Współczynnik degeneracji	Z = 1	Z < 1	Z > 1
Współczynnik rozsiewności	D = 0	D < 0	D > 0

Ocena statystyczna strumienia ruchu spływającego

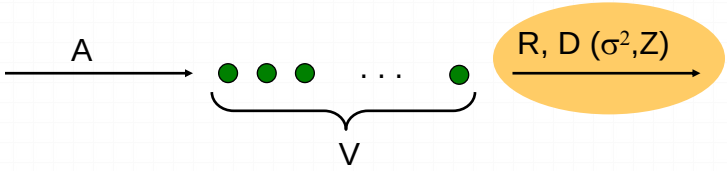


- Proces Markowa w wiązce z przelewem ruchu

$$p_{i,j} = \lim_{t\to\infty} P\{i(t) = i, j(t) = j\}$$

$i(t)$ jest liczbą zajętych łączy w wiązce pierwotnej, $j(t)$ jest liczbą zajętych łączy w nieskończonej, wtórnej wiązce

Ruch przelewowy



Parametry ruchu przelewowego:

Wartość średnia *R* ruchu spływającego

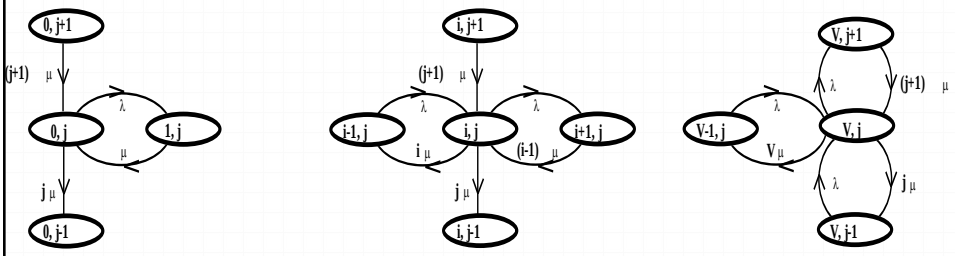
Wariancja σ^2 ruchu spływającego

Współczynnik degeneracji $Z = \sigma^2 / R$

Współczynnik rozsiewności $D = \sigma^2 - R$

Ocena statystyczna strumienia ruchu spływającego

- Typy stanów procesu



$$-(\lambda + i\mu)p_{i,j} + \mu p_{i+1,j} + (j+1)\mu p_{i,j+1} = 0$$

$$-(\lambda + i\mu + j\mu)p_{i,j} + \lambda p_{i-1,j} + (j+1)\mu p_{i,j+1} + (j+1)\mu p_{i+1,j-1} = 0$$

$$-(\lambda + V\mu + \sum_{j=0}^{\infty}\sum_{i=0}^{V} p_{i,j} = 1^{1,j} + \lambda p_{V,j-1} + (j+1)\mu p_{V,j+1} = 0$$

Ocena statystyczna strumienia ruchu spływającego

- Wzory Riordana

$$R = AE_V(A)$$

$$\sigma^2 = R\left(\frac{A}{V+1-A+R}+1-R\right)$$

$$R = AE_V(A)$$

$$D = R\left(\frac{A}{V+1-A+R}-R\right)$$

ZAPAMIĘTAJ!

W ruchu Poissonowskim wariancja jest równa wartości średniej, stąd:

$$R = A, \quad \sigma^2 = A, \quad D = 0$$

Metoda jednoparametryczna

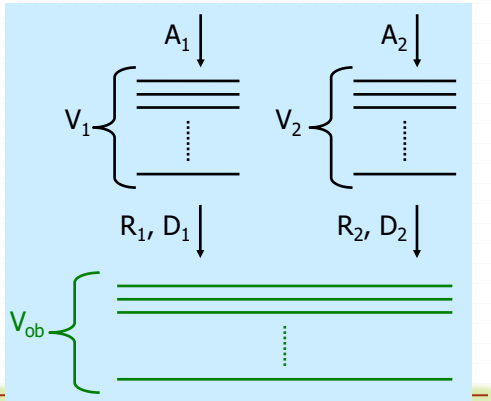
- Określenie parametrów ruchu spływającego:

$$R_i = A_i E_{V_i}(A_i)$$

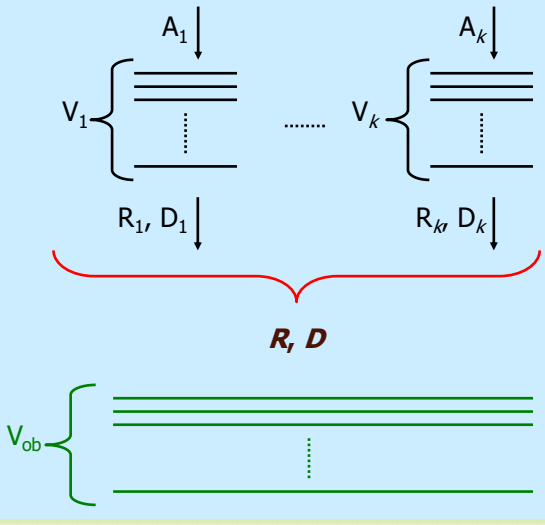
$$R = \sum_{i=1}^{k} R_i$$

Określenie pojemności wiązki alternatywnej:

$$B = E_{(V_{ob})}(R)$$



Metoda ERT – krok 1
Parametry ruchu spływającego

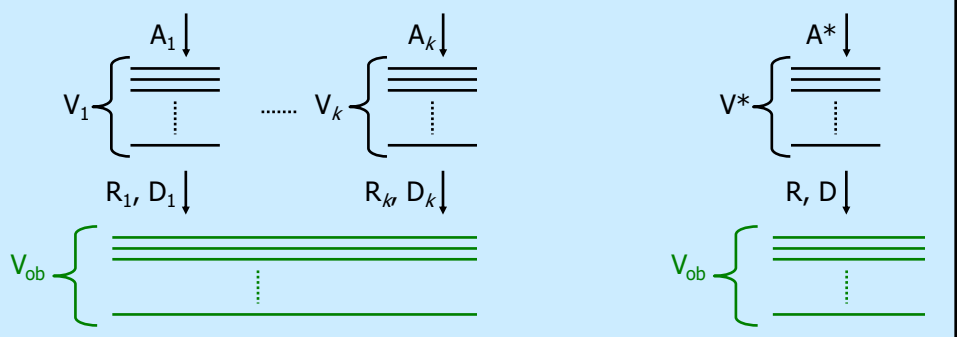


$$\begin{cases} R_i = A_i E_{V_i}(A_i) \\ D_i = R_i\left(\dfrac{A_i}{V_i + 1 - A_i + R_i} - R_i\right) \end{cases}$$

$$R = \sum_{i=1}^{k} R_i$$

$$D = \sum_{i=1}^{k} D_i$$

Metoda ERT – krok 2
Parametry wiązki ekwiwalentnej

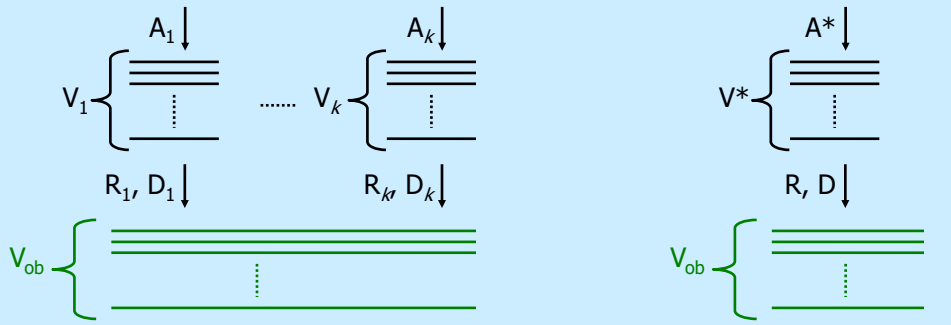


$$\begin{cases} R = A^* E_{V^*}(A^*) \\ D = R\left(\dfrac{A^*}{V^* + 1 - A^* + R} - R\right) \end{cases}$$

$$\begin{cases} A^* = \sigma^2 + 3\dfrac{\sigma^2}{R}\left(\dfrac{\sigma^2}{R} - 1\right) \\ V^* = A^*\dfrac{(R^2 + \sigma^2)}{R^2 + \sigma^2 - R} - R - 1 \end{cases}$$

Metoda ERT – krok 3
Pojemność wiązki obejściowej

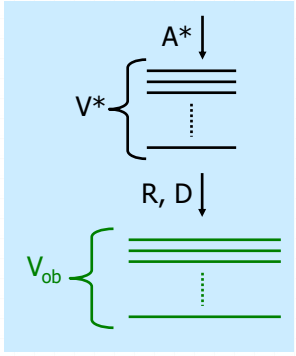
- Ze względu na prawdopodobieństwo blokady w sieci



$$B = E_{(V^*+V_{ob})}(A^*)$$

Metoda ERT – krok 3
Pojemność wiązki obejściowej

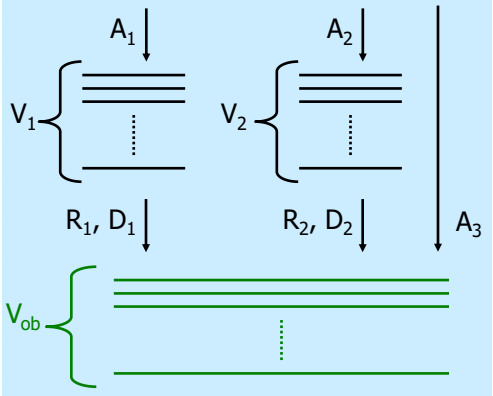
- Ze względu na prawdopodobieństwo blokady w wiązce obejściowej



$$B_{ob} = \frac{A^* E_{(V^*+V_{ob})}(A^*)}{R}$$

Metoda ERT
Ruch przelewowy + ruch Poissonowski

- Określenie parametrów ruchu spływającego:

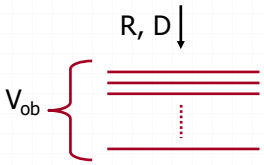


$$R = R_1 + R_2 + A_3$$

$$D = D_1 + D_2 + 0$$

Metoda Fredericksa - Haywarda

- Prawdopodobieństwo blokady w wiązce alternatywnej

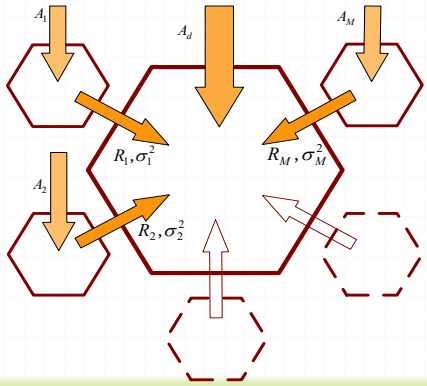


$$Z = \sigma^2 / R$$

$$B = E_{\frac{V_{ob}}{Z}}(\frac{R}{Z})$$

Model przelewu międzykomórkowego

- Model ten dotyczy komórek, w których występuje możliwość przelewu ruchu nieobsłużonego do innych komórek.



Model przelewu międzykomórkowego

- Ruch przelewowy

Ruch obsługiwany w komórce

Ruch generowany w komórce	Ruch przelewany do komórki
$Z = \frac{wariancja}{wartość\ średnia} = 1$	$Z = \frac{wariancja}{wartość\ średnia} \geq 1$
Wymiarowanie na podstawie wzoru Erlanga/Engseta	Wymiarowanie na podstawie metody ERT/ Haywarda
$B = f(A, V, N)$	$B = f(A, Z, V, N)$

Model przelewu międzykomórkowego

- Wartość średnia ruchu przelewanego do komórki dostępowej z komórki *i*, (wzory Riordana):

$$R_i = A_i E_{V_i}(A_i)$$

- Wariancja ruchu przelewanego do komórki dostępowej z komórki *i*, (wzory Riordana)

$$\sigma_i^2 = R_i\left(\frac{A_i}{V_i + 1 - A_i + R_i} + 1 - R_i\right)$$

- Wartość średnia całkowitego ruchu oferowanego komórce dostępowej z uwzględnieniem ruchu własnego komórki dostępowej

$$R = A_d + \sum_{i=1}^{M} R_i$$

Model przelewu międzykomórkowego

- Wariancja całkowitego ruchu oferowanego komórce dostępowej, z uwzględnieniem ruchu własnego komórki dostępowej

$$\sigma^2 = A_d + \sum_{i=1}^{M} \sigma_i^2$$

- Współczynnik degeneracji całkowitego ruchu oferowanego komórce dostępowej

$$Z = \sigma^2 / R$$

- Prawdopodobieństwo blokady komórki dostępowej (wzór Haywarda)

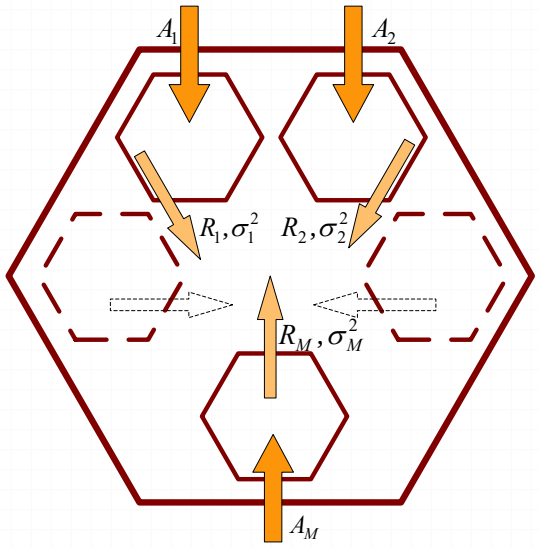
$$E_d = E_{\frac{V}{Z}}\left(\frac{R}{Z}\right)$$

- Jeżeli wartość *V/Z* jest niecałkowita to dla otrzymania wartości E_d stosujemy metodę interpolacji liniowej.

Model przelewu wewnątrzkomórkowego

- Model dotyczy makrokomórek podzielonych ma *M* mikrokomórek
- Założenia
  - Każda mikrokomórka obsługuje ruch PCT1
  - Każda mikrokomórka ma do dyspozycji, pewną, przydzieloną pulę kanałów
  - Istnieje wydzielona liczba kanałów wspólna dla wszystkich mikrokomórek, ktróra obsługuje ruch nieobsłużony w mikrokomórkach
  - Nie ma możliwości przelewu makrokomórka! mikrokomórka
  - Wspólne kanały nie obsługują własnego ruchu PCT1

Model przelewu wewnątrzkomórkowego



Model przelewu wewnątrzkomórkowego

- Wartość średnia ruchu przelewanego do wspólnych kanałów makrokomórki z mikrokomórki *i*

$$R_i = A_i E_{V_i}(A_i)$$

gdzie

A_i - natężenie ruchu PCT1 oferowanego w mikrokomórce o numerze porządkowym *i*

V_i - pojemność mikrokomórki o numerze porządkowym *i*

- Wariancja ruchu przelewanego do wspólnych kanałów makrokomórki z mikrokomórki *i*

$$\sigma_i^2 = R_i\left(\frac{A_i}{V_i + 1 - A_i + R_i} + 1 - R_i\right)$$

Model przelewu wewnątrzkomórkowego

- Wartość średnia ruchu oferowanego wspólnym kanałom makrokomórki

$$R = \sum_{i=1}^{M} R_i$$

- Wariancja ruchu oferowanego wspólnym kanałom makrokomórki

$$\sigma^2 = \sum_{i=1}^{M} \sigma_i^2$$

- Współczynnik degeneracji ruchu oferowanego wspólnym kanałom makrokomórki

$$Z = \sigma^2 / R$$

Model przelewu wewnątrzkomórkowego

- Prawdopodobieństwo blokady makrokomórki (wzór Haywarda)

$$E = E_{\frac{V}{Z}}\left(\frac{R}{Z}\right)$$

- Jeżeli wartość *V/Z* jest niecałkowita to dla otrzymania wartości *E* stosujemy metodę interpolacji Newtona

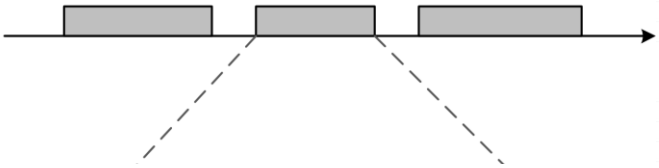


Plan prezentacji

- Wprowadzenie
- Reprezentacja ruchu
- Modele systemów wielousługowych

Reprezentacja ruchu

Call level → Poisson stream



Packet level → VBR stream (IPP, IBP, MMPP, SSS)



3

Pojęcie pasma równoważnego

- Pasmo równoważne
  - stała przepływność określająca wielkość zasobów, które sieć przydziela danemu zgłoszeniu w celu zapewnienia wymaganej jakości obsługi
- Zasada wyboru pasma równoważnego:
  - Skutek obsługi zgłoszenia VBR w sieci =skutek obsługi zgłoszenia CBR (pasmo równoważne)

4

Dyskretyzacja pasma

- Dyskretyzacja pasma to:
  - zamiana w danym systemie wszystkich źródeł VBR ekwiwalentnymi źródłami CBR z wyznaczonymi pasmami ekwiwalentnymi,
  - określenie JA (Jednostki Alokacji) w systemie,
  - wyrażenie w JA pojemności systemu i wszystkich ekwiwalentnych źródeł VBR

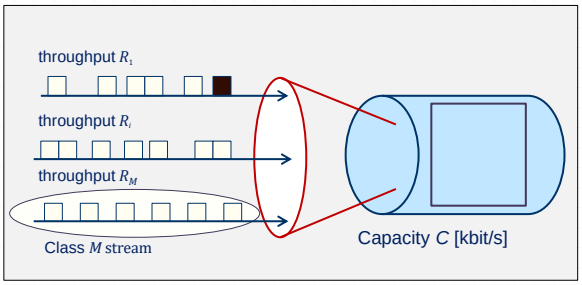
$$R_{\mathrm{BBU}} = \mathrm{GCD}\,(R_1, R_2, \ldots, R_M)$$

$$t_i = R_i / R_{\mathrm{BBU}}$$

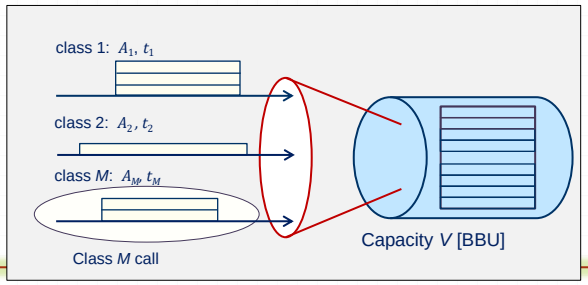
$$V = C / R_{\mathrm{BBU}}$$

5

Dyskretyzacja pasma



BEFORE DISCRETIZATION



AFTER DISCRETIZATION

6

System wielousługowy pełnodostępny

- Parametry:
  - V
    - pojemność systemu wyrażona w jednostkach BBU,
  - A_i
    - oferowany ruch klasy i,
  - M
    - liczba oferowanych strumieni połączeń w systemie,
  - t_i
    - liczba żądanych jednostek alokacji według wywołania klasy i,
  - $[P_n]_V$
    - rozkład zajętości, prawdopodobieństwo zajętości n BBU.

7

Wielowymiarowy proces Markowa w systemie z ruchem zintegrowanym



Mikrostan: $\{x_1, x_2, \ldots, x_M\}$ $p(x_1, x_2, \ldots, x_M)$

Wielowymiarowy proces Markowa w systemie z ruchem zintegrowanym

- Ponieważ wszystkie strumienie zgłoszeń są niezależne, możemy każdy mikrostan zapisać w postaci iloczynowej

$$p(x_1, \ldots, x_i, \ldots, x_M) = \prod_{j=1}^{M} p(x_j)$$

Rozwiązanie:

$$p(x_1, \ldots, x_i, \ldots, x_M) = \frac{1}{G} \prod_{j=1}^{M} \frac{A_j^{x_j}}{x_j!}$$

$$G = \sum_{z_1=0}^{V} \cdots \sum_{z_j=0}^{l_j} \cdots \sum_{z_M=0}^{l_M} \prod_{i=1}^{M} \frac{A_i^{z_i}}{z_i!}$$

Jednowymiarowy proces Markowa w systemie z ruchem zintegrowanym

Makrostan: {n}, gdzie n jest całkowitą liczbą PJP w wiązce

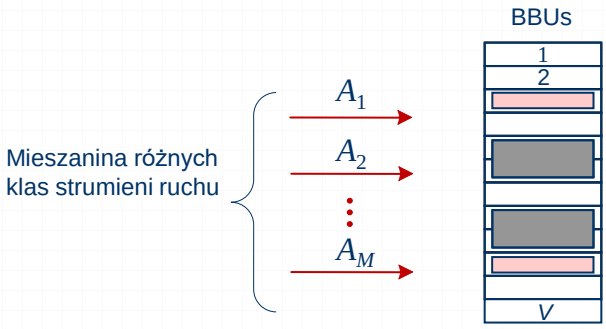
Prawdopodobieństwo makrostanu:

$$P(n) = \sum_{\Omega(n)} p(x_1, x_2, \ldots, x_M)$$

gdzie $\Omega(n)$ jest zbiorem wszystkich mikrostanów $\{x_1, \ldots, x_i, \ldots, x_M\}$, które spełniają równanie:

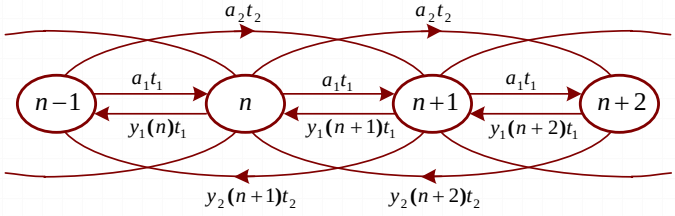
$$n = \sum_{i=1}^{M} x_i t_i$$

System wielousługowy pełnodostępny



Równanie Kaufmana-Robertsa

$$n\,P(n) = \sum_{i=1}^{M} a_i t_i \; P(n - t_i)$$



Algorytm obliczeń rozkładu K-R

- Załóżmy, że pewna wiązka o pojemności V obsługuje dwie klasy ruchu o parametrach t_1=1, t_2=2. Mamy:

$$nP(n) = a_1 P(n-1) + 2a_2 P(n-2)$$

- Obliczamy wartość prawdopodobieństwa P(1):

$$P(1) = a_1 P(0) = x_1 P(0)$$

- Obliczamy wartość prawdopodobieństwa P(2):

$$P(2) = \frac{[(a_1)^2 + 2a_2]}{2} P(0) = x_2 P(0)$$

$$2P(2) = a_1 P(1) + 2a_2 P(0)$$
$$2P(2) = a_1^2 P(0) + 2a_2 P(0)$$

Algorytm obliczeń rozkładu K-R

- Obliczamy wartości kolejnych prawdopodobieństw *P(i)*:

$$P(i) = x_i P(0)$$

Rezultaty obliczeń mają postać współczynników liczbowych x_i przemnożonych przez stałą – prawdopodobieństwo *P(0)*

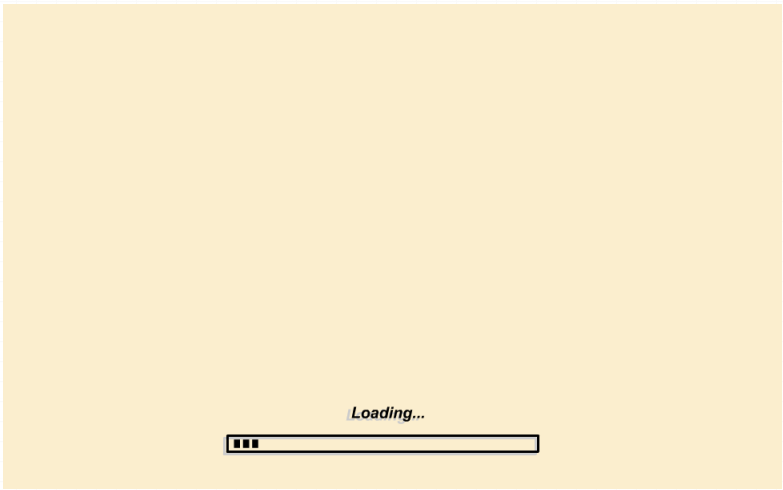
- Na podstawie równania normującego obliczamy wartość P(0):

$$P(0)\sum_{n=0}^{V} x_n = 1 \quad \Rightarrow \quad P(0) = 1/\sum_{n=0}^{V} x_n$$

- Obliczamy rzeczywiste wartości kolejnych prawdopodobieństw P(i):

$$P(i) = x_i / \sum_{n=0}^{V} x_n$$

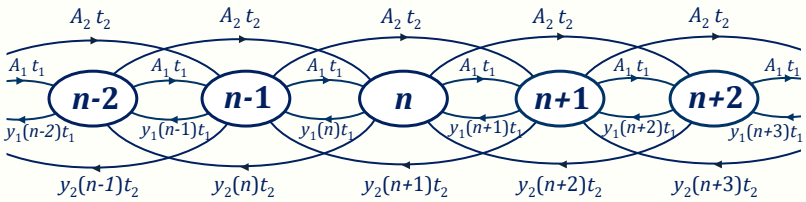
Wiązka doskonała



System wielousługowy pełnodostępny*

Rozkład zajętości $$n\,[P_n]_V = \sum_{i=1}^{M} A_i\, t_i\, [P_{n-t_i}]_V$$

Prawdopodobieństwo blokady $$E_i = \sum_{n=V-t_i+1}^{V} [P_n]_V$$



* Kaufman J.S.: *Blocking in a shared resource environment*, **IEEE Transactions on Communications**, vol. COM-29, No. 10, 1981, s. 1474-1481.
* Roberts J.W.: A service system with heterogeneous user requirements, [in] *Performance of Data Communications Systems and their Applications*, (Ed. G. Pujolle), **Elsevier**, Amsterdam, 1981.



Możliwości poprawy

- Normalizacja
- Dedykowane algorytmy

Algorytm NPGI
Nilsson, Perry, Gersht, Iversen

Podstawą proponowanego algorytmu jest oryginalny algorytm Kaufmana-Robertsa

$$P(n) = \frac{1}{n} \sum_{i=0}^{M} A_i t_i P(n - t_i)$$

Wprowadzana jest funkcja $\beta(n,k)$, która ma następującą interpretację probabilistyczną: *prawdopodobieństwo zajętości $n-k$ PJP w systemie o pojemności n wynosi:*

$$\beta(n,k) = \frac{P(n-k)}{\Sigma_{l=0}^{n} P(l)} \quad \text{gdzie: } 0 \leqslant k \leqslant n$$

3

Algorytm NPGI
Nilsson, Perry, Gersht, Iversen

Dla $k > 0$ można przeprowadzić następującą operację:

$$\beta(n,k) = \frac{P(n-1-(k-1)}{\Sigma_{l=0}^{n-1} P(l) + P(n)} \quad \text{gdzie: } 0 \leqslant k \leqslant n$$

4

Algorytm NPGI
Nilsson, Perry, Gersht, Iversen

Dzieląc licznik i mianownik przez sumę w mianowniku, otrzymujemy:

$$\beta(n,k) = \frac{\beta(n-1,k-1)}{1+\frac{1}{n}\Sigma_{i=0}^{M} A_i t_i \beta(n-1,t_i-1)},$$

a dla $k=0$:

$$\beta(n,0) = \frac{\frac{1}{n}\Sigma_{i=0}^{M} A_i t_i \beta(n-1,t_i-1)}{1+\frac{1}{n}\Sigma_{i=0}^{M} A_i t_i \beta(n-1,t_i-1)}$$

Powyższe równania pozwalają na rekurencyjne obliczenia prawdopodobieństwa zajętości $n-k$ PJP, tj. $\beta(n,k)$.

5

Algorytm NPGI
Nilsson, Perry, Gersht, Iversen

Prawdopodobieństwo blokady dla klasy i otrzymamy na podstawie następującego wzoru:

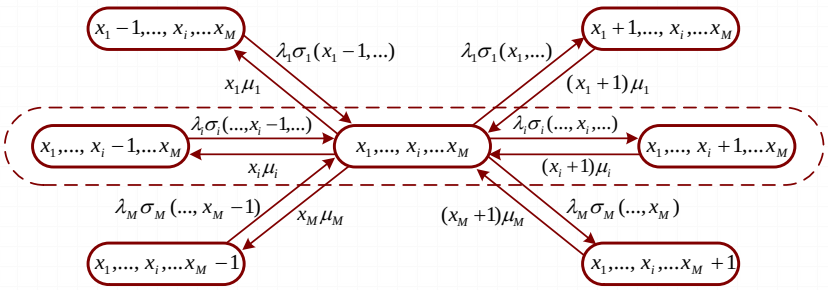
$$B_i = \sum_{j=0}^{t_i-1} \beta(V,j).$$

6

Ruch wielousługowy

Systemy zależne od stanu

Systemy zależne od stanu



$\sigma_i(x_{1,\ldots,}x_M)$ jest warunkowym prawdopodobieństwem przejścia

Uogólnione równanie Kaufmana-Robertsa

$$n\,P(n) = \sum_{i=1}^{M} a_i t_i \sigma_i(n-t_i) P(n-t_i)$$

gdzie:

$$\sigma_i(x_1,..,x_i,..,x_M) = \sigma_i(n)$$

$$\left|\frac{\sigma_i(n)-\sigma_i(n-1)}{\sigma_i(n-1)}\right| << 1$$

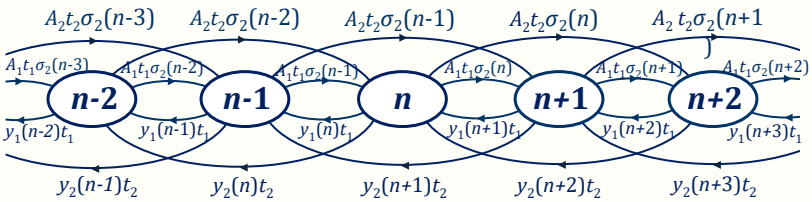
Prawdopodobieństwo blokady

$$E_i = \sum_{n=0}^{V-t_i} P(n)\left[1-\sigma_i(n)\right] \quad + \quad \sum_{n=V-t_i+1}^{V} P(n)$$

System wielousługowy zależny od stanu

Rozkład zajętości: $$n[P_n]_V = \sum_{i=1}^{M} A_i\, t_i\, \sigma_i(n-t_i)\,[P_{n-t_i}]_V$$

Prawdopodobieństwo blokady: $E_i = \sum_{n=0}^{V} [1-\sigma_i(n)]\,[P_n]_V$



4

Klasyfikacja systemów zależnych od stanu

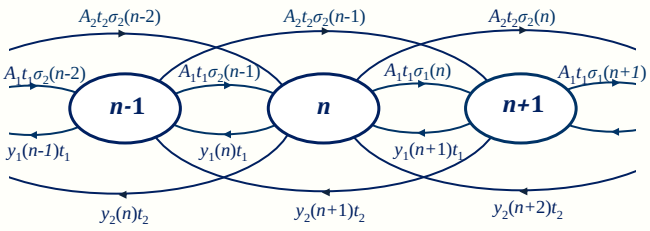
- Zależność wynikająca ze strumieni zgłoszeń
  - Strumień Engseta, strumień Pascala;
- Zależność wynikająca ze struktury systemu
  - Wiązka o ograniczonej dostępności, systemy przelewowe;
- Zależność wynikająca z działania funkcji CAC
  - Mechanizmy progowe, mechanizmy kompresji.

5

Zależność wynikająca ze strumieni zgłoszeń –Engset*

$$n[P_n]_V = \sum_{i=1}^{M} A_i\, t_i\, \sigma_i(n-t_i)\,[P_{n-t_i}]_V$$

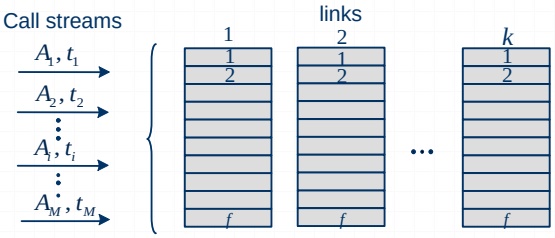
where: $\sigma_i(n) = \left(N_i - y_i(n)\right) / N_i$, N_i - number of class *i* sources.



* Głąbowski M.: Modelling of State-dependent Multi-rate Systems carrying BPP traffic, **Annales of Telecommunications**, Springer, vol. 63, no. 7-8, 2008, pp. 393-407.
* Głąbowski M., Stasiak M., Weissenberg J.: Properties of recurrent equations for the full-availability group with BPP traffic, **Mathematical Problems in Engineering**, 2012, article ID 547909, DOI:10.1155/2012/547909

Zależność wynikająca ze struktury systemu – LAG*

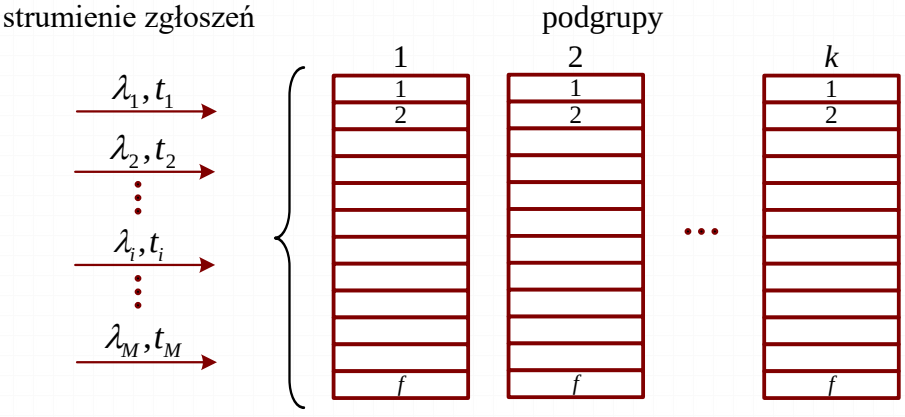
Wiązka o ograniczonej dostępności to model separowanych zasobów przenoszących wspólnie mieszaninę różnych strumieni ruchu



$$n[P_n]_V = \sum_{i=1}^{M} A_i\, t_i\, \sigma_i(n-t_i)\,[P_{n-t_i}]_V$$

*Stasiak M.: Blocking probability in a limited-availability group carrying mixture of different multi-channel traffic streams. **Ann. Telecommun.**, vol. 48, No. 1-2, 1993, pp. 71-76

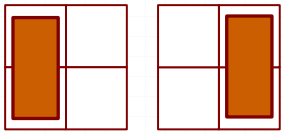
Wiązka z ograniczoną dostępnością



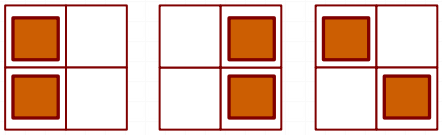
Pojemność wiązki: $V = kf$

Rozmieszczenie wolnych PJP

1 zgłoszenie – żądanie 2 PJP

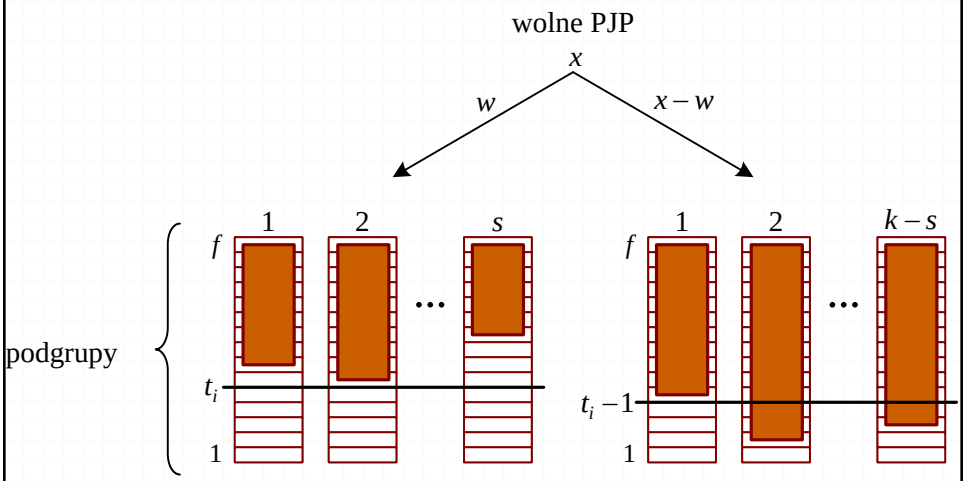


2 zgłoszenia – { żądanie 1 PJP, żądanie 1 PJP }



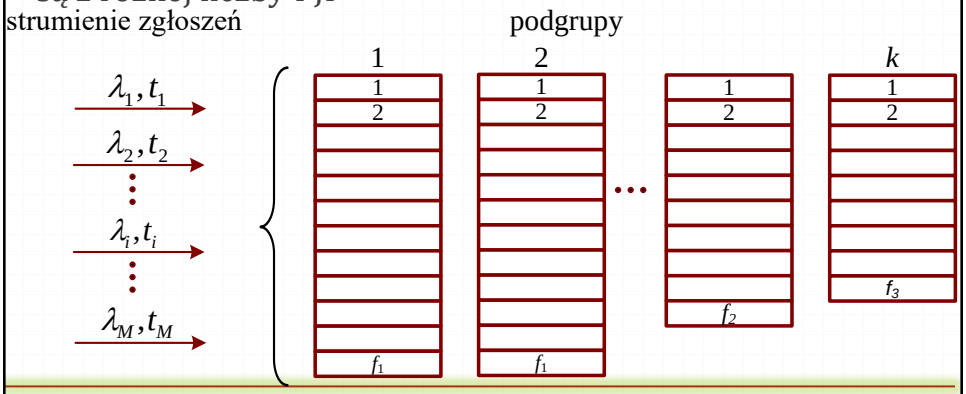
$$F(x,k,f,t)=\sum_{i=0}^{\left\lfloor \frac{x-kt}{f-t+1} \right\rfloor} (-1)^i \binom{k}{i} \binom{x-k(t-1)-1-i(f-t+1)}{k-1}$$

Rozkład dostępnych podgrup



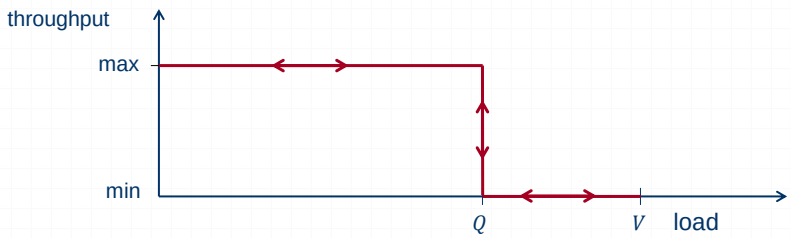
Uogólniony model wiązki z ograniczoną dostępnością

- Model ten dotyczy wiązek z ograniczoną dostępnością, w których podgrupy zbudowane są z różnej liczby PJP



Zależność wynikająca z działania funkcji CAC – rezerwacja zasobów

Działanie mechanizmu rezerwacji dla jednego strumienia ruchu



Rezerwacja statyczna

Rezerwacja dynamiczna

- Definicja: Wiązka z rezerwacją jest wiązką w której wyznaczono granicę rezerwacji Q . Wszystkie „wyższe” od Q stany należą do *obszaru rezerwacji*, w którym zgłoszenia są blokowane.
- Zasada wyrównywania blokady: Jeżeli granica rezerwacji jest jednakowa dla każdej klasy zgłoszeń i równa różnicy między pojemnością systemu i liczbą PJP żądanych przez klasę „najstarszą”, to prawdopodobieństwa blokad wszystkich klas zgłoszeń są wyrównane.

Rezerwacja dynamiczna

- Łańcuch Markowa dla WD z rezerwacją

Rezerwacja dynamiczna – model*

Aproksymacja rozkładu zajętości - uogólniona rekurencja Kaufmana-Robertsa:

$$n[P_n]_V = \sum_{i=1}^{M} A_i\, t_i\, \sigma_i(n-t_i)\,[P_{n-t_i}]_V$$

$$\sigma_i(n) = \begin{cases} 0 & \text{for} \quad n > Q \\ 1 & \text{for} \quad n \le Q \end{cases}$$

Prawdopodobieństwo blokady: $E_i = \sum_{n=Q+1}^{V} [P_n]_V$

*Roberts J.W.: Teletraffic models for the Telcom 1 Integrated Services Network, *Proc. 10th Int. Teletraffic Congress*, Montreal, 1983, paper 1.1. 2..

Pełnodostępne systemy progowe

- Pełnodostępne systemy progowe:
  - model jednoprogowy STM
  - model wieloprogrowy MTM
  - model wieloprogowy z powtórzeniami MRM/M

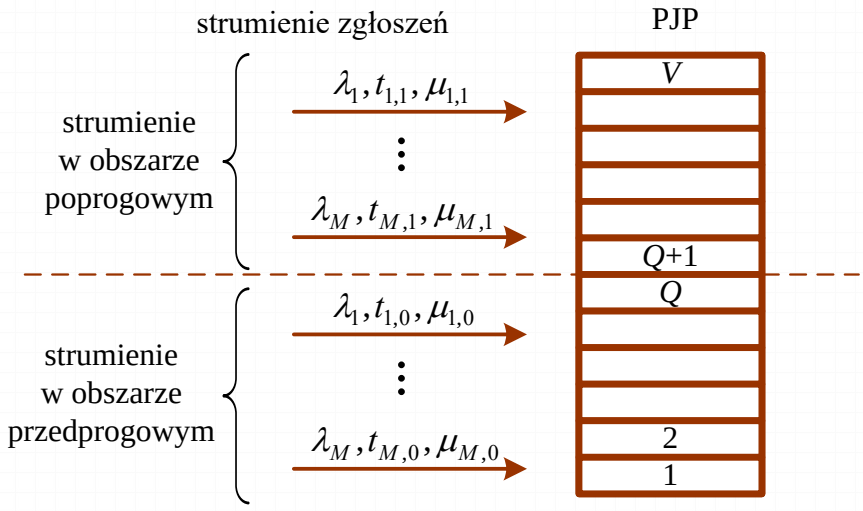
Podstawowy model jednoprogowy STM

- Jest to model wiązki pełnodostępnej o pojemności V PJP z ruchem zintegrowanym PCT1 (tj. wszystkie strumienie ruchu są strumieniami Erlanga), w której wprowadzono dodatkowo tzw. ***próg Q***, jednakowy dla wszystkich M klas zgłoszeń
- We wszystkich stanach n, takich że: $0 \leq n \leq Q$ (tzw. ***obszar przedprogowy***), strumień ruchu oferowanego klasy i ($i \in 1,\ldots, M$) jest opisany parametrami:$\{\lambda_0, t_{i,0}, \mu_{i,0}\}$

Podstawowy model jednoprogowy STM

- Dla wszystkich stanów n starszych od Q, to jest takich że $Q \leq n \leq V$ (tzw. ***obszar poprogowy***), strumień ten jest opisany parametrami: $\{\lambda_1, t_{i,1}, \mu_{i,1}\}$
- Na ogół w rozważanych w literaturze modelach przyjmuje się, że $t_{i,0} > t_{i,1}$ oraz $\mu^{-1}_{i,0} < \mu^{-1}_{i,1}$

Podstawowy model jednoprogowy STM



Rozkład zajętości podstawowego modelu jednoprogowego STM

- W rezultacie uwzględnienia definicji makrostanu i postępowania analogicznego jak w przypadku wiązki pełnodostępnej rozkład zajętości w obszarze przedprogowym można zapisać:

$$n\,[P_n]_V = \sum_{i=1}^{M} A_{i,0} t_{i,0} \sigma_{i,0} (n - t_{i,0}) \left[P_{n-t_{i,0}}\right]_V$$

Podobnie dla obszaru poprogowego:

$$n\,[P_n]_V = \sum_{i=1}^{M} A_{i,1} t_{i,1} \sigma_{i,1} (n - t_{i,1}) \left[P_{n-t_{i,1}}\right]_V$$

Rozkład zajętości podstawowego modelu jednoprogowego STM

- Procesy obsługi zachodzące w systemie STM nie są procesami odwracalnymi, ponieważ w zależności od stanu zajętości wiązki zmieniają się parametry oferowanego strumienia ruchu
- Rozkład zajętości w systemie STM aproksymuje się rozkładem URKR

Rozkład zajętości podstawowego modelu jednoprogowego STM

gdzie:

$A_{i,0}$ jest natężeniem ruchu klasy i, oferowanego wiązce w obszarze przedprogowym:

$$A_{i,0} = \frac{\lambda_i}{\mu_{i,0}} \qquad \sigma_{i,0}(n) = \begin{cases} 1 & \text{dla } n \le Q, \\ 0 & \text{dla } n > Q. \end{cases}$$

$A_{i,1}$ jest natężeniem ruchu klasy i, oferowanego wiązce w obszarze poprogowym:

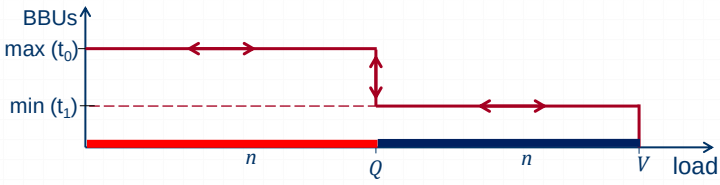
$$A_{i,1} = \frac{\lambda_i}{\mu_{i,1}} \qquad \sigma_{i,1}(n) = \begin{cases} 0 & \text{dla } n \le Q, \\ 1 & \text{dla } n > Q, \end{cases}$$

Rozkład zajętości podstawowego modelu jednoprogowego STM

- Ponieważ obszary stanów: przedprogowy i poprogowy są rozłączne, ostatecznie rozkład zajętości w systemie progowym STM można zapisać w postaci:

$$n\,[P_n]_V = \sum_{i=1}^{M} A_{i,0} t_{i,0} \sigma_{i,0}(n - t_{i,0}) \left[P_{n-t_{i,0}}\right]_V + \\ + \sum_{i=1}^{M} A_{i,1} t_{i,1} \sigma_{i,1}(n - t_{i,1}) \left[P_{n-t_{i,1}}\right]_V$$

Service process in STM*

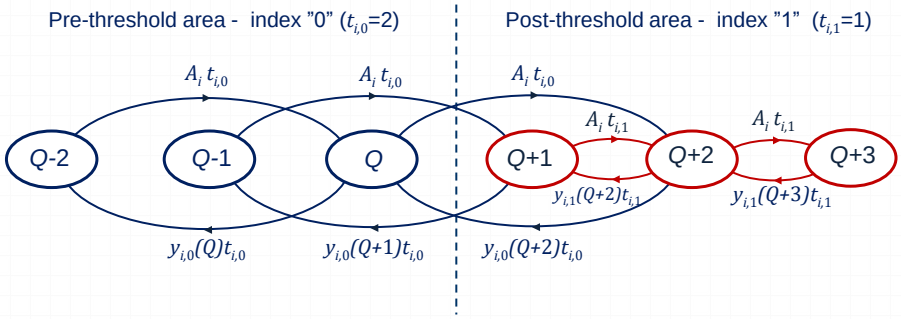


$$n[P_n]_V = \sum_{i=1}^{M} A_{i,0}\, t_{i,0}\, \sigma_{i,0}\left(n - t_{i,0}\right)\left[P_{n-t_{i,0}}\right]_V + \sum_{i=1}^{M} A_{i,1}\, t_{i,1}\, \sigma_{i,1}\left(n - t_{i,1}\right)\left[P_{n-t_{i,1}}\right]_V$$

Pre-threshold area:	Post-threshold area:
$A_{i,0} = \lambda_i / \mu_{i,0}$	$A_{i,1} = \lambda_i / \mu_{i,1}$
$\sigma_{i,0}(n) = \begin{cases} 1 & \text{for} \quad n \le Q_i \\ 0 & \text{for} \quad n > Q_i \end{cases}$	$\sigma_{i,1}(n) = \begin{cases} 0 & \text{for} \quad n \le Q_i \\ 1 & \text{for} \quad n > Q_i \end{cases}$

*Kaufman J.S. Blocking with retrials in a completely shared resource environment. **Journal of Performance Evaluation**, No. 15, 1992, pp. 99-113.

Diagram of the Markov process in STS



26

Prawdopodobieństwo blokady w modelu jednoprogowym STM

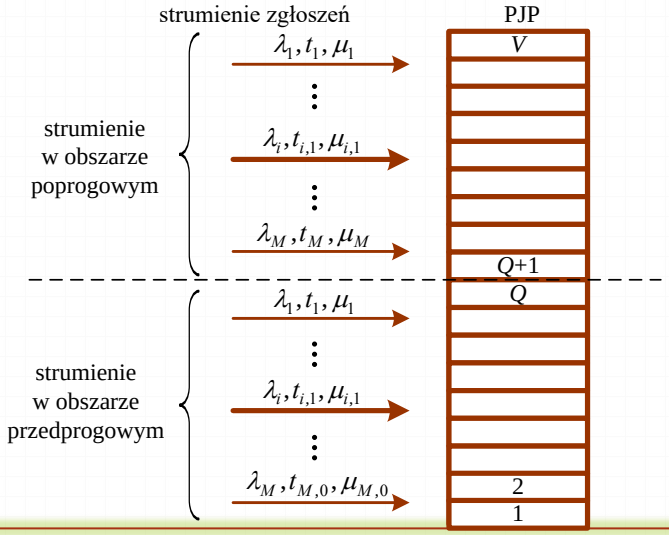
- Prawdopodobieństwo blokady (strat) dla zgłoszenia klasy *i* w systemie STM jest zależne od wartości przyjętego progu i może być zapisane następująco:

$$E_i = B_i = \begin{cases} \sum_{n=V-t_{i,0}+1}^{V} [P_n]_V & \text{dla } Q > V - t_{i,1}, \\ \sum_{n=V-t_{i,1}+1}^{V} [P_n]_V & \text{dla } Q \leq V - t_{i,1}. \end{cases}$$

Model jednoprogowy dla jednej klasy zgłoszeń (model STM/1)

- Model STM/1 jest szczególnym przypadkiem modelu STM
- W modelu STM/1 zakładamy, że próg Q_i wprowadza się tylko dla jednej, wybranej klasy *i*
- Pozostałe klasy ruchu są obsługiwane bezprogowo

Model jednoprogowy dla jednej klasy zgłoszeń (model STM/1)



Model jednoprogowy dla jednej klasy zgłoszeń (model STM/1)

- W odpowiednich równaniach i wzorach dotyczących systemu STM - przyjmiemy:

$$\begin{cases} t_{j,0} = t_{j,1} = t_j, & \mu_{j,0} = \mu_{j,1} = \mu_j, & \sigma_{j,0} = \sigma_{j,1} = 1 & \text{dla } i \neq j \\ t_{j,0} \neq t_{j,1}, & \mu_{j,0} \neq \mu_{j,1}, & \sigma_{j,0} \neq \sigma_{j,1} & \text{dla } i = j \end{cases}$$

- Rozkład zajętości:

$$n\,[P_n]_V = A_{i,0}t_{i,0}\sigma_{i,0}(n - t_{i,0})\left[P_{n-t_{i,0}}\right] +$$
$$+A_{i,1}t_{i,1}\sigma_{i,1}(n-t_{i,1})\left[P_{n-t_{i,1}}\right] + \sum_{j=1,j\neq i}^{M} A_i t_i \left[P_{n-t_i}\right]_V$$

Model jednoprogowy dla jednej klasy zgłoszeń (model STM/1)

$$E_j = B_j = \begin{cases} \sum_{n=V-t_j+1}^{V} [P_n]_V & \text{dla } j \neq i, \\ \sum_{n=V-t_{i,0}+1}^{V} [P_n]_V & \text{dla } j = i \text{ i } Q > V - t_{i,1}, \\ \sum_{n=V-t_{i,1}+1}^{V} [P_n]_V & \text{dla } j = i \text{ i } Q \leq V - t_{i,1}. \end{cases}$$

- Prawdopodobieństwo blokady:

Model jednoprogowy dla wszystkich klas zgłoszeń (model STM/M)

- Model STM/M jest uogólnieniem modelu STM
- W modelu STM/M zakładamy,że próg Q_i wprowadza się indywidualnie dla każdej klasy *i*
- charakterystyki systemu STM przy założeniu, że odpowiednie progi wprowadzono dla każdej klasy ruchu *i*:

$$t_{i,0} \neq t_{i,1}\ \mu_{i,0} \neq \mu_{i,1},\ \sigma_{i,0} \neq \sigma_{i,1}\ \bigwedge_i 1 \leq i \leq M$$

Model jednoprogowy dla wszystkich klas zgłoszeń (model STM/M)

- Rozkład zajętości:

$$n\,[P_n]_V = \sum_{i=1}^{M} A_{i,0} t_{i,0} \sigma_{i,0}(n - t_{i,0}) \left[P_{n-t_{i,0}}\right]_V + \\ + \sum_{i=1}^{M} A_{i,1} t_{i,1} \sigma_{i,1}(n - t_{i,1}) \left[P_{n-t_{i,1}}\right]_V$$

gdzie dla każdego *i* mamy:

$$\sigma_{i,0}(n) = \begin{cases} 0 \;\; dla \;\; n \le Q_i \\ 1 \;\; dla \;\; n > Q_i \end{cases} \qquad \sigma_{i,1}(n) = \begin{cases} 0 \;\; dla \;\; n \le Q_i \\ 1 \;\; dla \;\; n > Q_i \end{cases}$$

Model jednoprogowy dla wszystkich klas zgłoszeń (model STM/M)

- Prawdopodobieństwo blokady:

$$E_i = B_i = \begin{cases} \sum_{n=V-t_{i,0}+1}^{V} [P_n]_V & dla \;\; Q > V - t_{i,1} \\ \sum_{n=V-t_{i,1}+1}^{V} [P_n]_V & dla \;\; Q \le V - t_{i,1} \end{cases}$$

- Strumienie obsługi:

$$y_{i,k}(n) = \begin{cases} A_{i,0}\sigma_{i,0}(n - t_{i,0})[P_n - t_{i,0}]_V / [P_n]_V & dla \;\; k = 0, n \le Q_i + t_{i,0} \\ A_{i,1}\sigma_{i,1}(n - t_{i,1})[P_n - t_{i,1}]_V / [P_n]_V & dla \;\; k = 1, n > Q_i + t_{i,1} \end{cases}$$

Model wieloprogowy dla wszystkich klas zgłoszeń (model MTM/M)

- dla każdej klasy zgłoszeń wprowadza się indywidualnie zbiór progów:

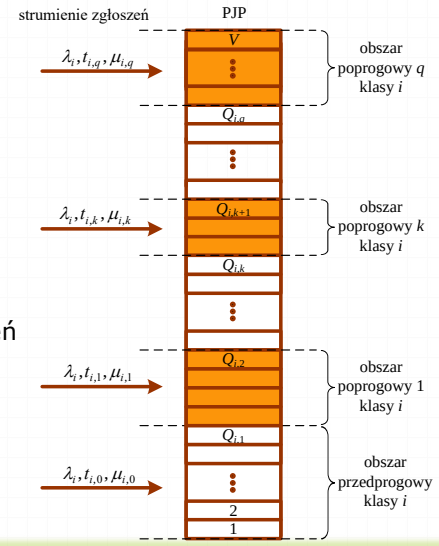
$$\{Q_{i,1}, Q_{i,2}, \ldots, Q_{i,q}\}$$

przy czym zakłada się że:

$$\{Q_{i,1} \leq Q_{i,2} \leq \ldots \leq Q_{i,q}\}$$

Model wieloprogowy dla wszystkich klas zgłoszeń (model MTM/M)

Działanie systemu wieloprogowego na przykładzie jednej klasy zgłoszeń



Model wieloprogowy dla wszystkich klas zgłoszeń (model MTM/M)

- Rozkład zajetości:

$$n\,[P_n]_V = \sum_{i=1}^{M}\sum_{k=0}^{q} A_{i,k}t_{i,k}\sigma_{i,k}(n-t_{i,k})\left[P_{n-t_{i,k}}\right]_V$$

gdzie dla każdej pary {*i*,*k*}, takiej że:

$$1 \le i \le M$$
$$0 \le k \le q$$

mamy:

$$\sigma_{i,k}(n) = \begin{cases} 0 & dla\ Q_{i,k} \le n \le Q_{i,k} \\ 1 & dla\ reszty \end{cases}$$

Model wieloprogowy dla wszystkich klas zgłoszeń (model MTM/M)

- Prawdopodobieństwo blokady:

$$E_i = \sum_{k=0}^{q} E_{i,k}$$

gdzie $E_{i,k}$ jest prawdopodobieństwem blokady zgłoszeń klasy *i* w obszarze progowym *k* klasy *i*:

$$E_{i,k} = \begin{cases} 0 & dla \begin{cases} V - t_{i,k} \ge Q_{i,k+1} \\ V - t_{i,k} > Q_{i,k} \end{cases} \\ \sum_{n=V-t_{i,k}+1}^{Q_{i,k+1}} [P_n]_V & dla \begin{cases} V - t_{i,k} < Q_{i,k+1} \\ V - t_{i,k} > Q_{i,k} \end{cases} \\ \sum_{n=Q_k+1}^{Q_{i,k+1}} [P_n]_V & dla \begin{cases} V - t_{i,k} < Q_{i,k+1} \\ V - t_{i,k} \le Q_{i,k} \end{cases} \end{cases}$$

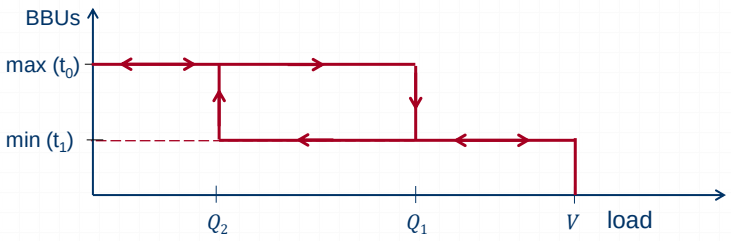
Model wieloprogowy dla wszystkich klas zgłoszeń (model MTM/M)

- Strumienie obsługi:

$$y_{i,k}(n) = A_{i,k}\sigma_{i,k}(n - t_{i,k})[P_n - t_{i,k}]_V / [P_n]_V$$

$$dla\ 0 \le k \le q\ ,\ Q_{i,k} + t_{i,k} \le n \le Q_{i,k+1} + t_{i,k}$$

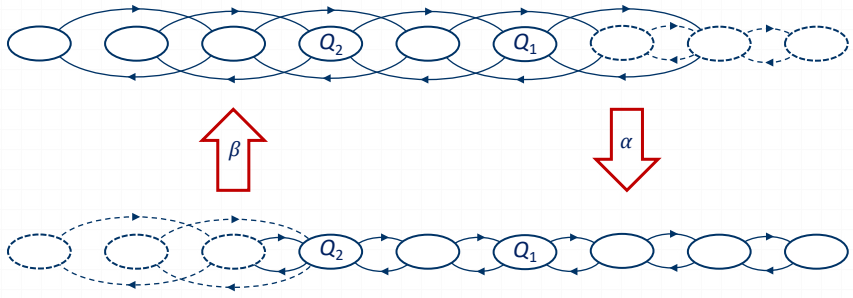
Single-Hysteresis Model (SHM) - working idea



40

Service process in SHS

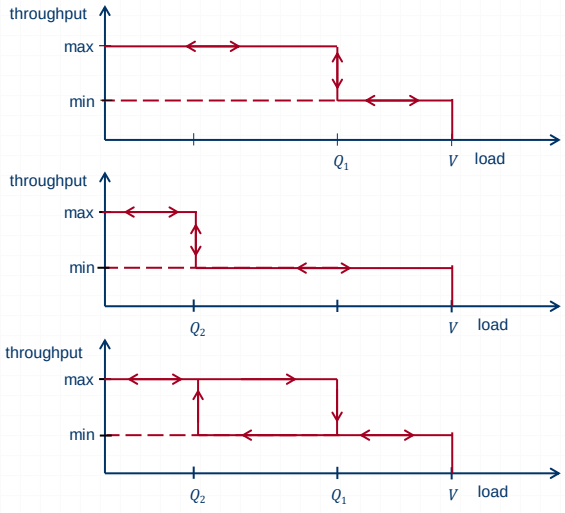
The service process in SHS can be approximated by two weighted processes in boundary STSs, depending on the direction of load changes.



$$[H_n]_V = P(Q_1)[P_n]_{V,Q_1} + P(Q_2)[P_n]_{V,Q_2}$$

41

Service process in SHS



$P_{Q1}(n)$

$P_{Q_2}(n)$

$P_{Q_1,Q_2}(n)$

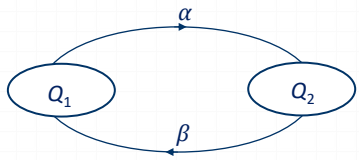
42

Occupancy distribution in SHM*

$$[H_n]_V = P(Q_1)[P_n]_{V,Q_1} + P(Q_2)[P_n]_{V,Q_2}$$

where the parameters $P(Q_1)$ and $P(Q_2)$ are determined on the basis of two-state Markovian process that switches service process in STM

$$P(Q_1) = \frac{\beta}{\alpha+\beta}, \qquad P(Q_2) = \frac{\alpha}{\alpha+\beta}$$



*Stasiak M., Sobieraj M., Weissenberg J., Zwierzykowski P.: Analytical Model of the Single Threshold Mechanism with Hysteresis for Multi-service Networks, **IEICE Transactions on Communications**, vol. E95-B, No. 01, 2012, pp. 120-132.

SHS calculations – system parameters

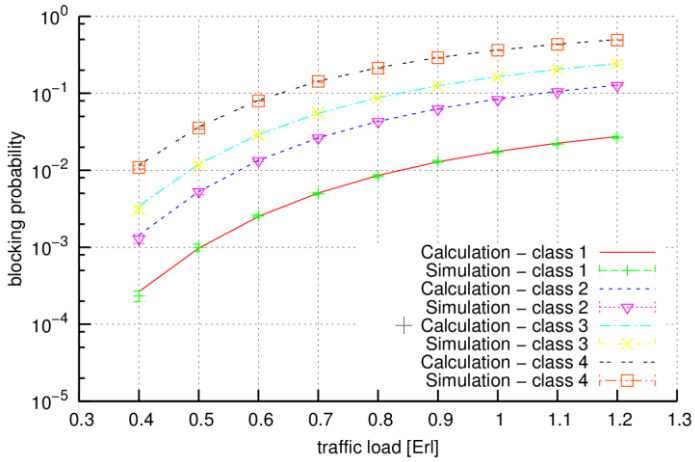
WCDMA radio interface

Structure : V=8000 (BBUs), Q_1=6500, Q_2=4000,

traffic parameters : $t_{1,0}$=53, $t_{2,0}$=257, $t_{2,1}$=129, $t_{3,0}$=503, $t_{4,0}$=1118, $t_{4,1}$=559,

traffic mixture : $A_{1,0}\,t_{1,0} : A_{1,0}\,t_{1,0} : A_{1,0}\,t_{1,0} : A_{1,0}\,t_{1,0}$ = 15: 5: 40: 40.

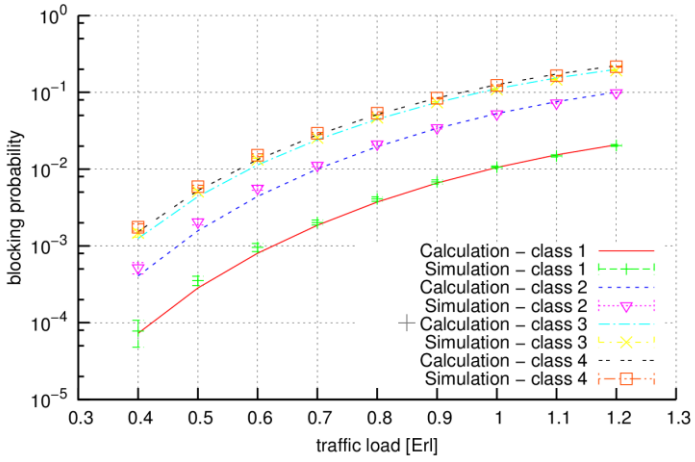
SHS calculations – blocking probability



System without hysteresis

45

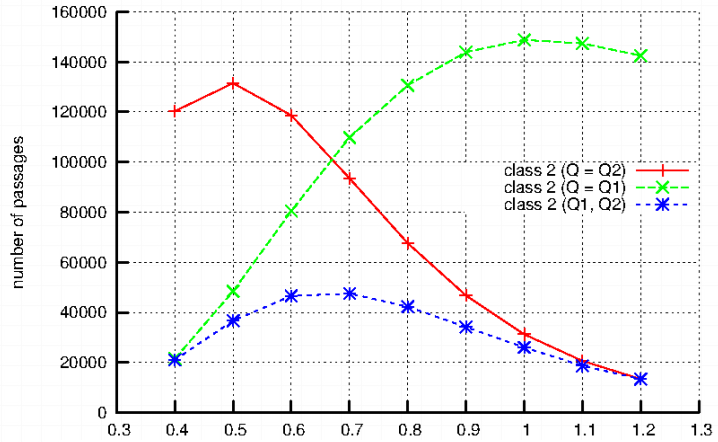
SHS calculations – blocking probability



System with hysteresis for the second and fourth class of traffic

46

SHS calculations – number of passages



System with hysteresis for the second class of traffic

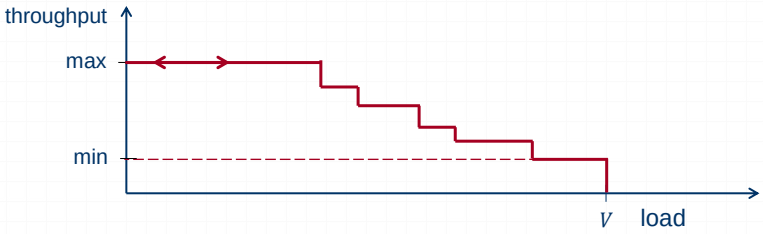
47

Thresholdless compression

Calls that undergo compression:

– decrease occupied number of BBUs, when there is no free resources for a new call appearing in the system,

– increase occupied number of BBUs, when a serviced call terminates.



48

Compression coefficient

Compression coefficient (in a given state n) is a measure for a change in the number of BBUs of compressed call:

$$\omega_i(n) = \frac{t_{i,\max}}{t_i(n)}$$

Maximum compression coefficient determines the ratio of the maximum number of BBUs to the minimum number of BBUs to be accepted for service of calls of a given class:

$$\omega_{i,\max} = \frac{t_{i,\max}}{t_{i,\min}}$$

Maximum compression case*

Occupancy distribution:

$$n[P_n]_V = \sum_{i=1}^{M_k} A_i\, t_{i,\min}\, [P_{n-t_i}]_V + \sum_{j=1}^{M_{nk}} A_j\, t_j\, [P_{n-t_j}]_V$$

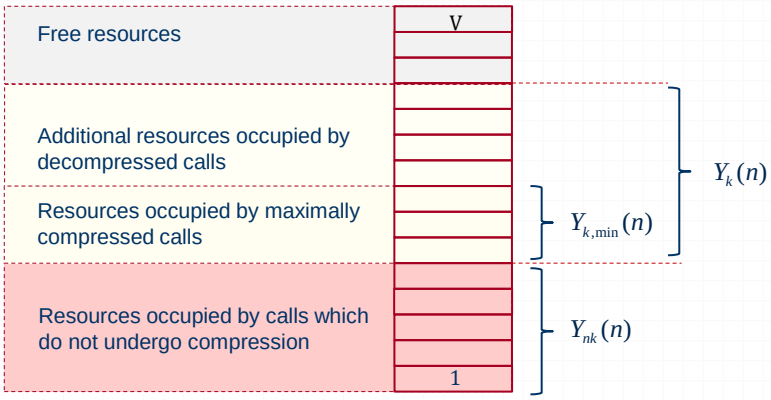
where: M_k is the number of traffic classes that undergo compression and M_{nk} is the number of traffic classes that do not undergo compression.

Blocking probability can be determined in the conditions of maximum compression only:

$$E_i = \sum_{n=V-t_{i,\min}+1}^{V} [P_n]_V \quad \text{for } i \in M_k, \qquad E_j = \sum_{n=V-t_j+1}^{V} [P_n]_V \quad \text{for } i \in M_{nk}$$

*Stasiak, M., Zwierzykowski, P., Wiewióra, J., Parniewicz, D.: Analytical Model of Traffic Compression in the UMTS network, **Lecture Notes in Computer Science**, Springer, vol. 5652, 2009, pp. 79–93.

Current compression case



Occupied resources $Y_k(n) = \omega\, Y_{k,\min}(n)$

51

Numerical example

IuB interface

Structure : V=21000 (BBUs),

traffic parameters :

Speech ($t_{1,\min}$ = 16, $\omega_{1,\max}$ = 1),

Real-time Gaming ($t_{2,\min}$ = 10, $\omega_{2,\max}$ = 20),

Mobile TV ($t_{3,\min}$ = 64, $\omega_{3,\max}$ = 10),

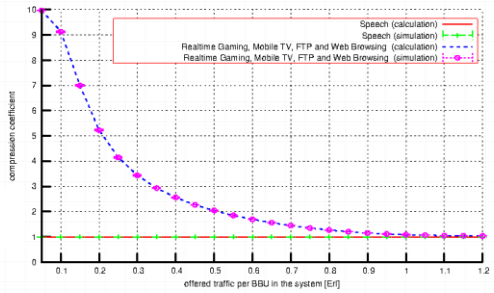
Web Browsing ($t_{4,\min}$ = 500, $\omega_{4,\max}$ = 10)

traffic mixture : $A_1 t_1 : A_2 t_2 : A_3 t_3 : A_4 t_4$ = 1: 3: 5: 10.

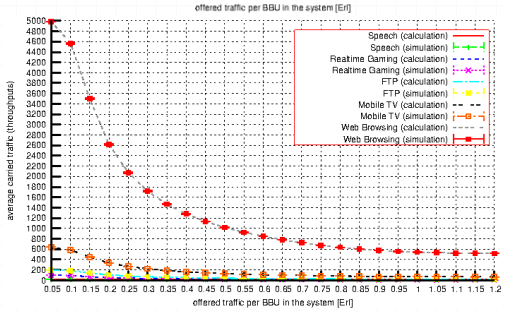
52

HSDPA traffic in IuB (DL) interface

Compression coefficient



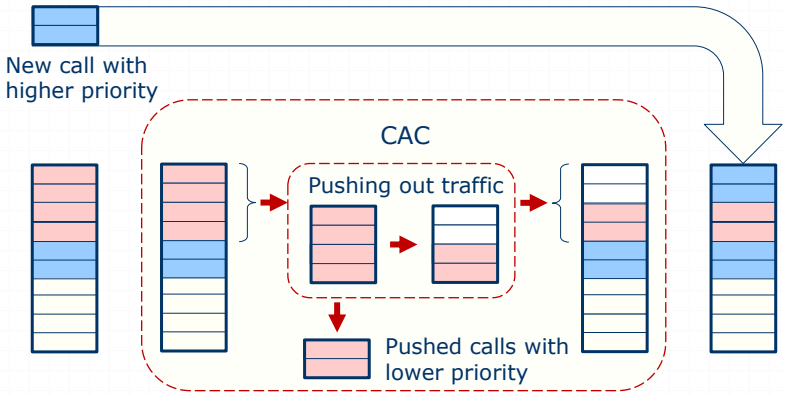
Average throughput



53

Priorities – working idea

The arrival of a new call with a higher priority can, in the case of the lack of free resources, terminate the currently serviced connections with a lower priority



54

Priorities – component systems

System 1
The FAG carrying only one traffic class.

System 2
The FAG without priorities carrying two traffic classes.

System 3
The FAG with priorities carrying two traffic classes.

Priorities – modeling of two traffic classes*

Occupancy distribution

System 1: $[E_1]_{S1} = \mathrm{FAG}\{(A_1, t_1)\}$

System 2: $[E_1, E_2]_{S2} = \mathrm{FAG}\{(A_1, t_1), (A_2, t_2)\}$

System 3: $[E_1, E_2]^P_{S3} = \mathrm{F}\{[E_1]_{S1}, [E_1, E_2]_{S2}\}$

Blocking probability

$$[E_1]^P_{S3} = [E_1]_{S1}$$

$$[E_2]^P_{S3} = \frac{A_1 t_1 \left([E_1]_{S2} - [E_1]_{S1}\right) + A_2 t_2 [E_2]_{S2}}{A_2 t_2}$$

*Stasiak M., Wiewióra J., Zwierzykowski P.: An Approximate Model of the WCDMA Interface Servicing a Mixture of Multi-rate Traffc Streams with Priorities, **Lecture Notes in Computer Science,** Springer, vol. 5261, 2008, pp. 168-180.

Priorities – numerical results (WCDMA)

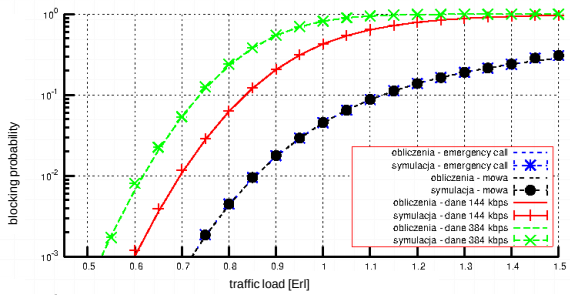
Class of service	Speech	Video call	Data	Data
W [Mchipps]	3.84	3.84	3.84	3.84
R_j [kbps]	12.2	64	144	384
E_b/N_0 [dB]	4	2	1.5	1
L_j	0.0053	0.0257	0.0503	0.118

- The services were demanded in the following proportions: A_1t_1: A_2t_2: A_3t_3: A_4t_4 = 10:1:1:1,
- The LBBU was equal to 0.0001 of the interface capacity,
- Interface capacity: V= 5000 BBUs.

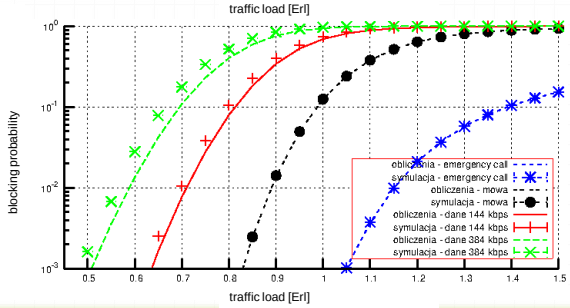
57

Numerical results

WCDMA without priorities



WCDMA with priorities



58

Resources limitations

Assumptions

- All traffic classes are serviced by the group,
- Some traffic classes do not entirely make use of the allocated resources and occupy at least G BBUs, where $G < V$,
- Example – a limitation of resources of the Iub interface (in the UMTS network) for R99 traffic classes that is accompanied by unlimited (or limited) HSUPA traffic.

59

Resources limitations

The problem is to find such a state *N* in which the number of BBUs occupied by calls of constrained classes meets the condition:

$$G(N) = G$$

60

Resources limitations modeling

FAG without limitations

$$n[P_n]_V = \sum_{i=1}^{M} A_i t_i \left[P_{n-t_i}\right]_V$$

$$y_i(n) = A_i \left[P_{n-t_i}\right]_V / \left[P_{n-t_i}\right]_V$$

$$G(n=N) = G = \sum_{i=1}^{S} y_i(N)\, t_i$$

FAG with limitations

$$n[P_n]_V = \sum_{i=1}^{M} A_i t_i\, \sigma_i(n-t_i) \left[P_{n-t_i}\right]_V$$

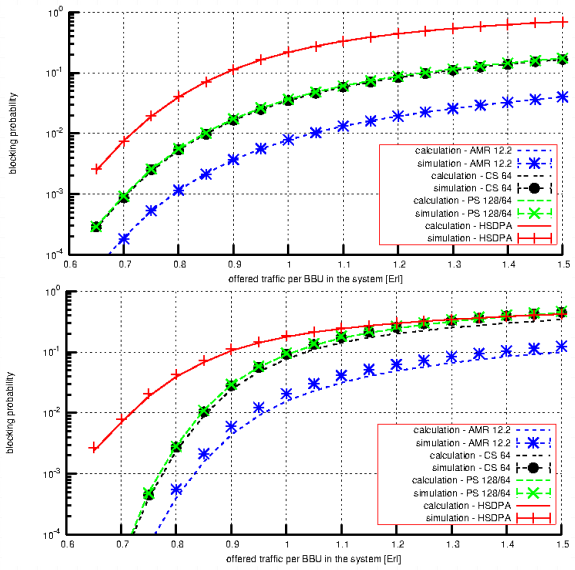
$$\sigma_i(n) = \begin{cases} 1 & \text{for } n \le N - t_i \\ 0 & \text{for } n > N - t_i \end{cases}$$

*Stasiak M, Głąbowski M., Wiśniewski A., Zwierzykowski P.: Modeling and Dimensioning of Mobile Networks. From GSM to LTE. **A John Wiley and Sons, Ltd, Publication**, 2011, pp.1- 315

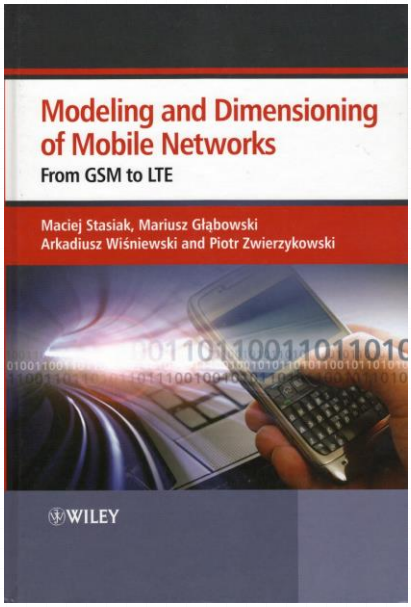
Resources limitations

system without limitations

system with limitations



62

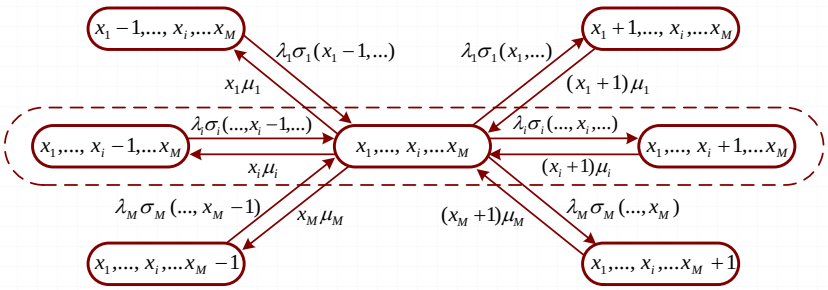

Modeling and Dimensioning
of Mobile Networks
From GSM to LTE
Maciej Stasiak, Mariusz Głąbowski
Arkadiusz Wiśniewski and Piotr Zwierzykowski
WILEY

63

Ruch wielousługowy

Systemy zależne od stanu

Systemy zależne od stanu



$\sigma_i(x_{1,\ldots,}x_M)$ jest warunkowym prawdopodobieństwem przejścia

Uogólnione równanie Kaufmana-Robertsa

$$n\,P(n) = \sum_{i=1}^{M} a_i t_i \sigma_i(n-t_i) P(n-t_i)$$

gdzie:

$$\sigma_i(x_1,..,x_i,..,x_M) = \sigma_i(n)$$

$$\left|\frac{\sigma_i(n)-\sigma_i(n-1)}{\sigma_i(n-1)}\right| << 1$$

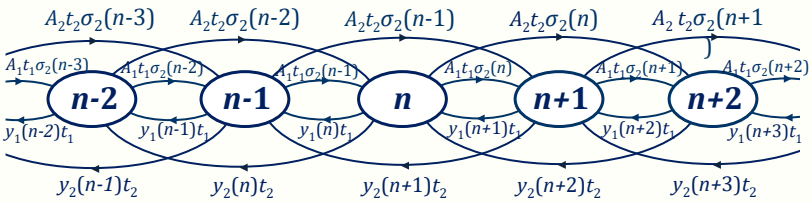
Prawdopodobieństwo blokady

$$E_i = \sum_{n=0}^{V-t_i} P(n)\left[1-\sigma_i(n)\right] \quad + \quad \sum_{n=V-t_i+1}^{V} P(n)$$

System wielousługowy zależny od stanu

Rozkład zajętości: $$n[P_n]_V = \sum_{i=1}^{M} A_i\, t_i\, \sigma_i(n-t_i)\,[P_{n-t_i}]_V$$

Prawdopodobieństwo blokady: $E_i = \sum_{n=0}^{V} [1-\sigma_i(n)]\,[P_n]_V$



4

Klasyfikacja systemów zależnych od stanu

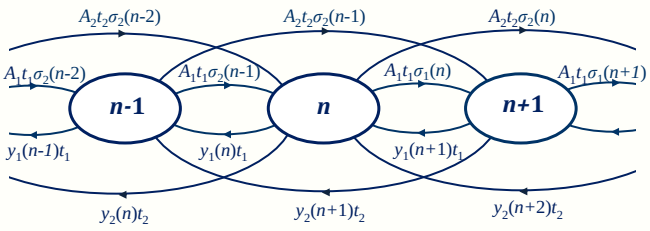
- Zależność wynikająca ze strumieni zgłoszeń
  - Strumień Engseta, strumień Pascala;
- Zależność wynikająca ze struktury systemu
  - Wiązka o ograniczonej dostępności, systemy przelewowe;
- Zależność wynikająca z działania funkcji CAC
  - Mechanizmy progowe, mechanizmy kompresji.

5

Zależność wynikająca ze strumieni zgłoszeń –Engset*

$$n[P_n]_V = \sum_{i=1}^{M} A_i\, t_i\, \sigma_i(n-t_i)\,[P_{n-t_i}]_V$$

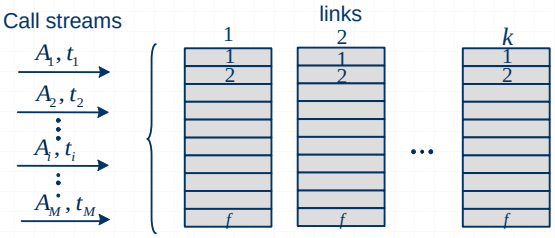
where: $\sigma_i(n) = \left(N_i - y_i(n)\right) / N_i$, N_i - number of class *i* sources.



* Głąbowski M.: Modelling of State-dependent Multi-rate Systems carrying BPP traffic, **Annales of Telecommunications**, Springer, vol. 63, no. 7-8, 2008, pp. 393-407.
* Głąbowski M., Stasiak M., Weissenberg J.: Properties of recurrent equations for the full-availability group with BPP traffic, **Mathematical Problems in Engineering**, 2012, article ID 547909, DOI:10.1155/2012/547909

Zależność wynikająca ze struktury systemu – LAG*

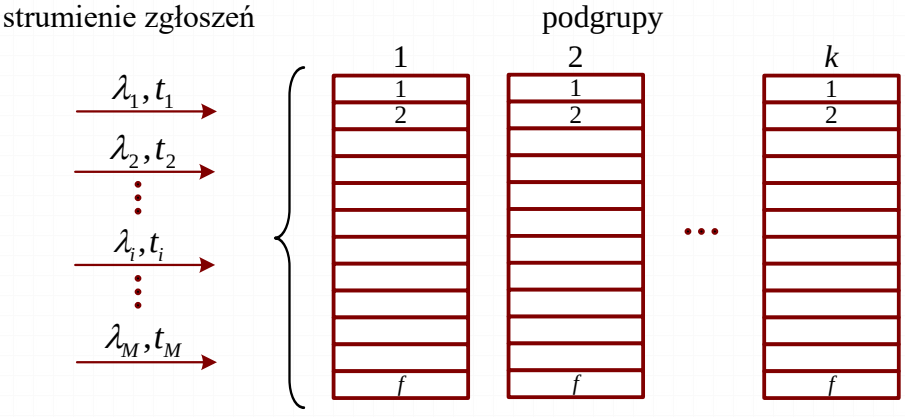
Wiązka o ograniczonej dostępności to model separowanych zasobów przenoszących wspólnie mieszaninę różnych strumieni ruchu



$$n[P_n]_V = \sum_{i=1}^{M} A_i\, t_i\, \sigma_i(n-t_i)\,[P_{n-t_i}]_V$$

*Stasiak M.: Blocking probability in a limited-availability group carrying mixture of different multi-channel traffic streams. **Ann. Telecommun.**, vol. 48, No. 1-2, 1993, pp. 71-76

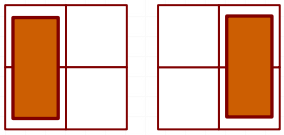
Wiązka z ograniczoną dostępnością



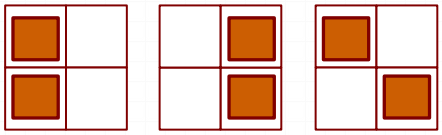
Pojemność wiązki: $V = kf$

Rozmieszczenie wolnych PJP

1 zgłoszenie – żądanie 2 PJP

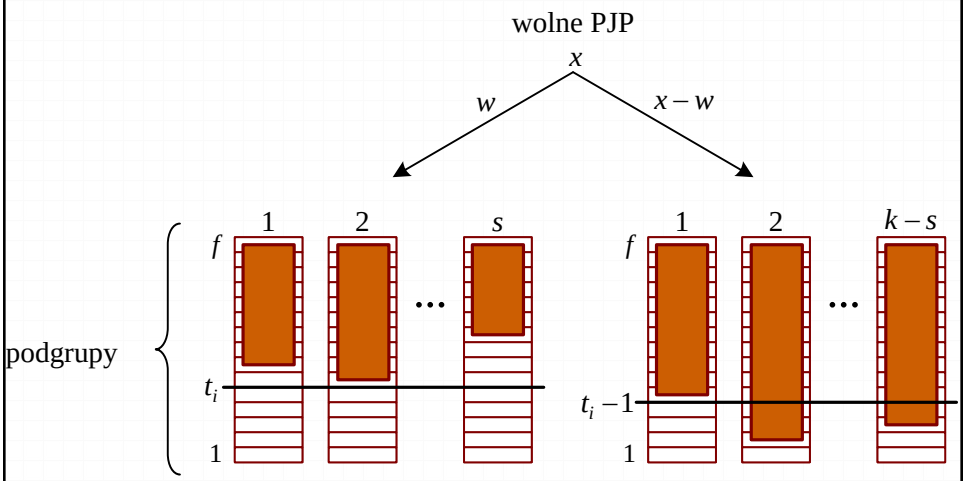


2 zgłoszenia – { żądanie 1 PJP, żądanie 1 PJP }



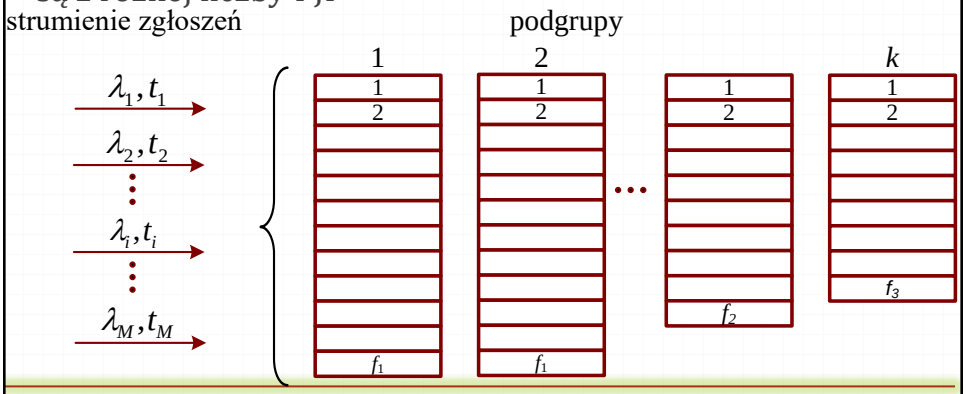
$$F(x,k,f,t)=\sum_{i=0}^{\left\lfloor \frac{x-kt}{f-t+1} \right\rfloor} (-1)^i \binom{k}{i} \binom{x-k(t-1)-1-i(f-t+1)}{k-1}$$

Rozkład dostępnych podgrup



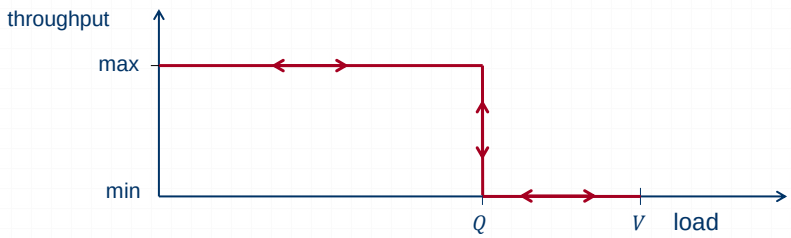
Uogólniony model wiązki z ograniczoną dostępnością

- Model ten dotyczy wiązek z ograniczoną dostępnością, w których podgrupy zbudowane są z różnej liczby PJP



Zależność wynikająca z działania funkcji CAC – rezerwacja zasobów

Działanie mechanizmu rezerwacji dla jednego strumienia ruchu



Rezerwacja statyczna

Rezerwacja dynamiczna

- Definicja: Wiązka z rezerwacją jest wiązką w której wyznaczono granicę rezerwacji Q . Wszystkie „wyższe” od Q stany należą do *obszaru rezerwacji*, w którym zgłoszenia są blokowane.
- Zasada wyrównywania blokady: Jeżeli granica rezerwacji jest jednakowa dla każdej klasy zgłoszeń i równa różnicy między pojemnością systemu i liczbą PJP żądanych przez klasę „najstarszą”, to prawdopodobieństwa blokad wszystkich klas zgłoszeń są wyrównane.

Rezerwacja dynamiczna

- Łańcuch Markowa dla WD z rezerwacją

Rezerwacja dynamiczna – model*

Aproksymacja rozkładu zajętości - uogólniona rekurencja Kaufmana-Robertsa:

$$n[P_n]_V = \sum_{i=1}^{M} A_i\, t_i\, \sigma_i(n-t_i)\,[P_{n-t_i}]_V$$

$$\sigma_i(n) = \begin{cases} 0 & \text{for} \quad n > Q \\ 1 & \text{for} \quad n \le Q \end{cases}$$

Prawdopodobieństwo blokady: $E_i = \sum_{n=Q+1}^{V} [P_n]_V$

*Roberts J.W.: Teletraffic models for the Telcom 1 Integrated Services Network, *Proc. 10th Int. Teletraffic Congress*, Montreal, 1983, paper 1.1. 2..

Pełnodostępne systemy progowe

- Pełnodostępne systemy progowe:
  - model jednoprogowy STM
  - model wieloprogrowy MTM
  - model wieloprogowy z powtórzeniami MRM/M

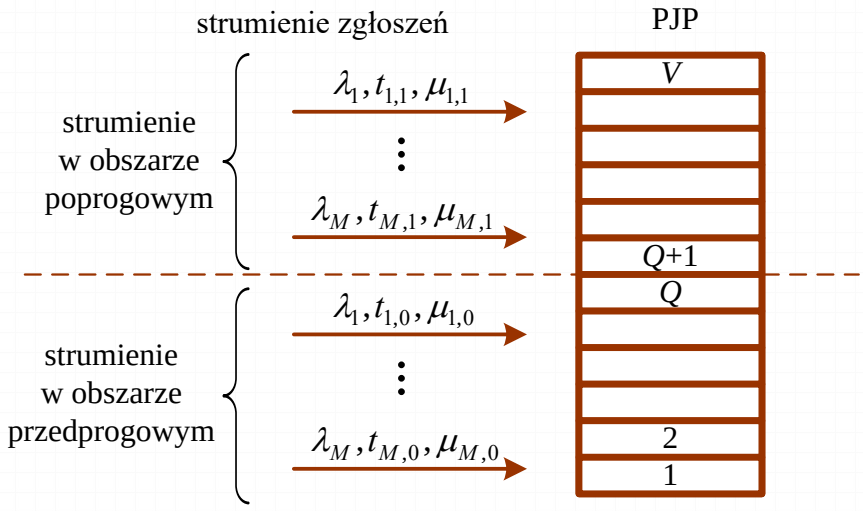
Podstawowy model jednoprogowy STM

- Jest to model wiązki pełnodostępnej o pojemności V PJP z ruchem zintegrowanym PCT1 (tj. wszystkie strumienie ruchu są strumieniami Erlanga), w której wprowadzono dodatkowo tzw. ***próg Q***, jednakowy dla wszystkich M klas zgłoszeń
- We wszystkich stanach n, takich że: $0 \leq n \leq Q$ (tzw. ***obszar przedprogowy***), strumień ruchu oferowanego klasy i ($i \in 1,\ldots, M$) jest opisany parametrami:$\{\lambda_0, t_{i,0}, \mu_{i,0}\}$

Podstawowy model jednoprogowy STM

- Dla wszystkich stanów n starszych od Q, to jest takich że $Q \leq n \leq V$ (tzw. ***obszar poprogowy***), strumień ten jest opisany parametrami: $\{\lambda_1, t_{i,1}, \mu_{i,1}\}$
- Na ogół w rozważanych w literaturze modelach przyjmuje się, że $t_{i,0} > t_{i,1}$ oraz $\mu^{-1}_{i,0} < \mu^{-1}_{i,1}$

Podstawowy model jednoprogowy STM



Rozkład zajętości podstawowego modelu jednoprogowego STM

- W rezultacie uwzględnienia definicji makrostanu i postępowania analogicznego jak w przypadku wiązki pełnodostępnej rozkład zajętości w obszarze przedprogowym można zapisać:

$$n\,[P_n]_V = \sum_{i=1}^{M} A_{i,0} t_{i,0} \sigma_{i,0} (n - t_{i,0}) \left[P_{n-t_{i,0}}\right]_V$$

Podobnie dla obszaru poprogowego:

$$n\,[P_n]_V = \sum_{i=1}^{M} A_{i,1} t_{i,1} \sigma_{i,1} (n - t_{i,1}) \left[P_{n-t_{i,1}}\right]_V$$

Rozkład zajętości podstawowego modelu jednoprogowego STM

- Procesy obsługi zachodzące w systemie STM nie są procesami odwracalnymi, ponieważ w zależności od stanu zajętości wiązki zmieniają się parametry oferowanego strumienia ruchu
- Rozkład zajętości w systemie STM aproksymuje się rozkładem URKR

Rozkład zajętości podstawowego modelu jednoprogowego STM

gdzie:

$A_{i,0}$ jest natężeniem ruchu klasy i, oferowanego wiązce w obszarze przedprogowym:

$$A_{i,0} = \frac{\lambda_i}{\mu_{i,0}} \qquad \sigma_{i,0}(n) = \begin{cases} 1 & \text{dla } n \le Q, \\ 0 & \text{dla } n > Q. \end{cases}$$

$A_{i,1}$ jest natężeniem ruchu klasy i, oferowanego wiązce w obszarze poprogowym:

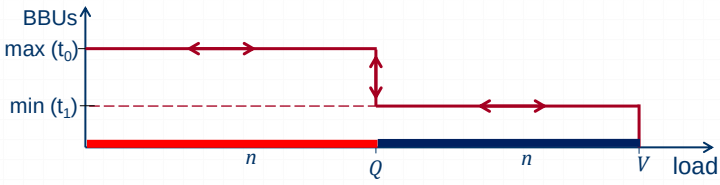
$$A_{i,1} = \frac{\lambda_i}{\mu_{i,1}} \qquad \sigma_{i,1}(n) = \begin{cases} 0 & \text{dla } n \le Q, \\ 1 & \text{dla } n > Q, \end{cases}$$

Rozkład zajętości podstawowego modelu jednoprogowego STM

- Ponieważ obszary stanów: przedprogowy i poprogowy są rozłączne, ostatecznie rozkład zajętości w systemie progowym STM można zapisać w postaci:

$$n\,[P_n]_V = \sum_{i=1}^{M} A_{i,0} t_{i,0} \sigma_{i,0}(n - t_{i,0}) \left[P_{n-t_{i,0}}\right]_V + \\ + \sum_{i=1}^{M} A_{i,1} t_{i,1} \sigma_{i,1}(n - t_{i,1}) \left[P_{n-t_{i,1}}\right]_V$$

Service process in STM*

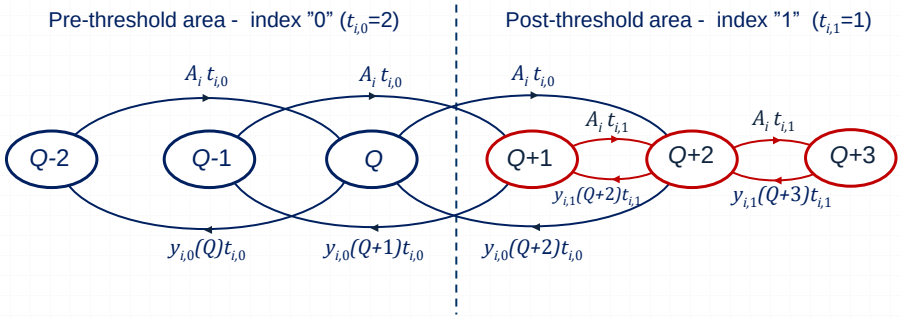


$$n[P_n]_V = \sum_{i=1}^{M} A_{i,0}\, t_{i,0}\, \sigma_{i,0}\left(n - t_{i,0}\right)\left[P_{n-t_{i,0}}\right]_V + \sum_{i=1}^{M} A_{i,1}\, t_{i,1}\, \sigma_{i,1}\left(n - t_{i,1}\right)\left[P_{n-t_{i,1}}\right]_V$$

Pre-threshold area:	Post-threshold area:
$A_{i,0} = \lambda_i / \mu_{i,0}$	$A_{i,1} = \lambda_i / \mu_{i,1}$
$\sigma_{i,0}(n) = \begin{cases} 1 & \text{for} \quad n \le Q_i \\ 0 & \text{for} \quad n > Q_i \end{cases}$	$\sigma_{i,1}(n) = \begin{cases} 0 & \text{for} \quad n \le Q_i \\ 1 & \text{for} \quad n > Q_i \end{cases}$

*Kaufman J.S. Blocking with retrials in a completely shared resource environment. **Journal of Performance Evaluation**, No. 15, 1992, pp. 99-113.

Diagram of the Markov process in STS



26

Prawdopodobieństwo blokady w modelu jednoprogowym STM

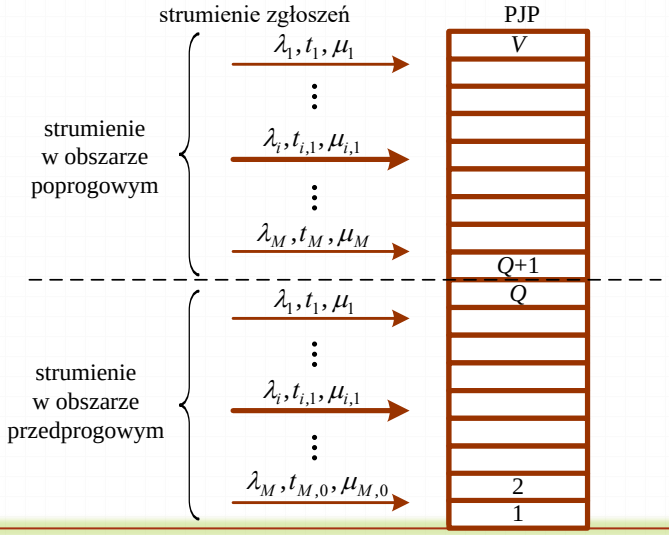
- Prawdopodobieństwo blokady (strat) dla zgłoszenia klasy *i* w systemie STM jest zależne od wartości przyjętego progu i może być zapisane następująco:

$$E_i = B_i = \begin{cases} \sum_{n=V-t_{i,0}+1}^{V} [P_n]_V & \text{dla } Q > V - t_{i,1}, \\ \sum_{n=V-t_{i,1}+1}^{V} [P_n]_V & \text{dla } Q \leq V - t_{i,1}. \end{cases}$$

Model jednoprogowy dla jednej klasy zgłoszeń (model STM/1)

- Model STM/1 jest szczególnym przypadkiem modelu STM
- W modelu STM/1 zakładamy, że próg Q_i wprowadza się tylko dla jednej, wybranej klasy *i*
- Pozostałe klasy ruchu są obsługiwane bezprogowo

Model jednoprogowy dla jednej klasy zgłoszeń (model STM/1)



Model jednoprogowy dla jednej klasy zgłoszeń (model STM/1)

- W odpowiednich równaniach i wzorach dotyczących systemu STM - przyjmiemy:

$$\begin{cases} t_{j,0} = t_{j,1} = t_j, & \mu_{j,0} = \mu_{j,1} = \mu_j, & \sigma_{j,0} = \sigma_{j,1} = 1 & \text{dla } i \neq j \\ t_{j,0} \neq t_{j,1}, & \mu_{j,0} \neq \mu_{j,1}, & \sigma_{j,0} \neq \sigma_{j,1} & \text{dla } i = j \end{cases}$$

- Rozkład zajętości:

$$n\,[P_n]_V = A_{i,0}t_{i,0}\sigma_{i,0}(n - t_{i,0})\left[P_{n-t_{i,0}}\right] +$$
$$+A_{i,1}t_{i,1}\sigma_{i,1}(n-t_{i,1})\left[P_{n-t_{i,1}}\right] + \sum_{j=1,j\neq i}^{M} A_i t_i \left[P_{n-t_i}\right]_V$$

Model jednoprogowy dla jednej klasy zgłoszeń (model STM/1)

$$E_j = B_j = \begin{cases} \sum_{n=V-t_j+1}^{V} [P_n]_V & \text{dla } j \neq i, \\ \sum_{n=V-t_{i,0}+1}^{V} [P_n]_V & \text{dla } j = i \text{ i } Q > V - t_{i,1}, \\ \sum_{n=V-t_{i,1}+1}^{V} [P_n]_V & \text{dla } j = i \text{ i } Q \leq V - t_{i,1}. \end{cases}$$

- Prawdopodobieństwo blokady:

Model jednoprogowy dla wszystkich klas zgłoszeń (model STM/M)

- Model STM/M jest uogólnieniem modelu STM
- W modelu STM/M zakładamy,że próg Q_i wprowadza się indywidualnie dla każdej klasy *i*
- charakterystyki systemu STM przy założeniu, że odpowiednie progi wprowadzono dla każdej klasy ruchu *i*:

$$t_{i,0} \neq t_{i,1}\ \mu_{i,0} \neq \mu_{i,1},\ \sigma_{i,0} \neq \sigma_{i,1}\ \bigwedge_i 1 \leq i \leq M$$

Model jednoprogowy dla wszystkich klas zgłoszeń (model STM/M)

- Rozkład zajętości:

$$n\,[P_n]_V = \sum_{i=1}^{M} A_{i,0} t_{i,0} \sigma_{i,0}(n - t_{i,0}) \left[P_{n-t_{i,0}}\right]_V + \\ + \sum_{i=1}^{M} A_{i,1} t_{i,1} \sigma_{i,1}(n - t_{i,1}) \left[P_{n-t_{i,1}}\right]_V$$

gdzie dla każdego *i* mamy:

$$\sigma_{i,0}(n) = \begin{cases} 0 \;\; dla \;\; n \le Q_i \\ 1 \;\; dla \;\; n > Q_i \end{cases} \qquad \sigma_{i,1}(n) = \begin{cases} 0 \;\; dla \;\; n \le Q_i \\ 1 \;\; dla \;\; n > Q_i \end{cases}$$

Model jednoprogowy dla wszystkich klas zgłoszeń (model STM/M)

- Prawdopodobieństwo blokady:

$$E_i = B_i = \begin{cases} \sum_{n=V-t_{i,0}+1}^{V} [P_n]_V & dla \;\; Q > V - t_{i,1} \\ \sum_{n=V-t_{i,1}+1}^{V} [P_n]_V & dla \;\; Q \le V - t_{i,1} \end{cases}$$

- Strumienie obsługi:

$$y_{i,k}(n) = \begin{cases} A_{i,0}\sigma_{i,0}(n - t_{i,0})[P_n - t_{i,0}]_V / [P_n]_V & dla \;\; k = 0, n \le Q_i + t_{i,0} \\ A_{i,1}\sigma_{i,1}(n - t_{i,1})[P_n - t_{i,1}]_V / [P_n]_V & dla \;\; k = 1, n > Q_i + t_{i,1} \end{cases}$$

Model wieloprogowy dla wszystkich klas zgłoszeń (model MTM/M)

- dla każdej klasy zgłoszeń wprowadza się indywidualnie zbiór progów:

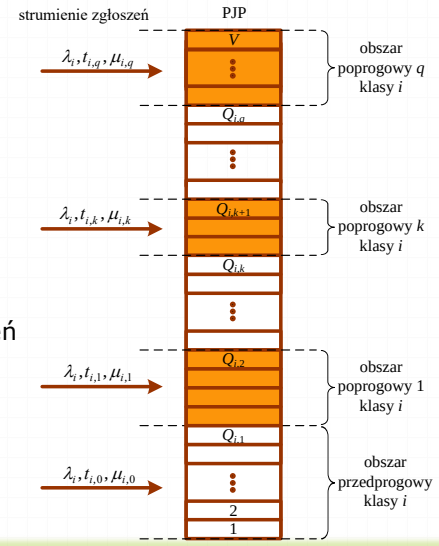
$$\{Q_{i,1}, Q_{i,2}, \ldots, Q_{i,q}\}$$

przy czym zakłada się że:

$$\{Q_{i,1} \leq Q_{i,2} \leq \ldots \leq Q_{i,q}\}$$

Model wieloprogowy dla wszystkich klas zgłoszeń (model MTM/M)

Działanie systemu wieloprogowego na przykładzie jednej klasy zgłoszeń



Model wieloprogowy dla wszystkich klas zgłoszeń (model MTM/M)

- Rozkład zajetości:

$$n\,[P_n]_V = \sum_{i=1}^{M}\sum_{k=0}^{q} A_{i,k}t_{i,k}\sigma_{i,k}(n-t_{i,k})\left[P_{n-t_{i,k}}\right]_V$$

gdzie dla każdej pary {*i*,*k*}, takiej że:

$$1 \le i \le M$$
$$0 \le k \le q$$

mamy:

$$\sigma_{i,k}(n) = \begin{cases} 0 & dla\ Q_{i,k} \le n \le Q_{i,k} \\ 1 & dla\ reszty \end{cases}$$

Model wieloprogowy dla wszystkich klas zgłoszeń (model MTM/M)

- Prawdopodobieństwo blokady:

$$E_i = \sum_{k=0}^{q} E_{i,k}$$

gdzie $E_{i,k}$ jest prawdopodobieństwem blokady zgłoszeń klasy *i* w obszarze progowym *k* klasy *i*:

$$E_{i,k} = \begin{cases} 0 & dla \begin{cases} V - t_{i,k} \ge Q_{i,k+1} \\ V - t_{i,k} > Q_{i,k} \end{cases} \\ \sum_{n=V-t_{i,k}+1}^{Q_{i,k+1}} [P_n]_V & dla \begin{cases} V - t_{i,k} < Q_{i,k+1} \\ V - t_{i,k} > Q_{i,k} \end{cases} \\ \sum_{n=Q_k+1}^{Q_{i,k+1}} [P_n]_V & dla \begin{cases} V - t_{i,k} < Q_{i,k+1} \\ V - t_{i,k} \le Q_{i,k} \end{cases} \end{cases}$$

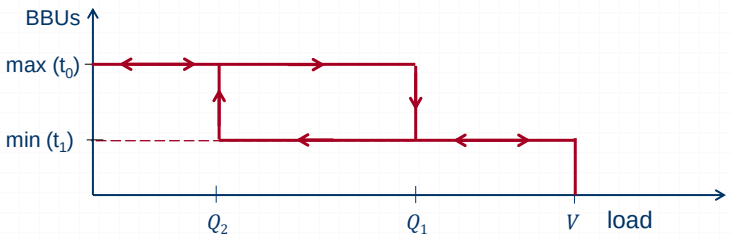
Model wieloprogowy dla wszystkich klas zgłoszeń (model MTM/M)

- Strumienie obsługi:

$$y_{i,k}(n) = A_{i,k}\sigma_{i,k}(n - t_{i,k})[P_n - t_{i,k}]_V / [P_n]_V$$

$$dla\ 0 \le k \le q\ ,\ Q_{i,k} + t_{i,k} \le n \le Q_{i,k+1} + t_{i,k}$$

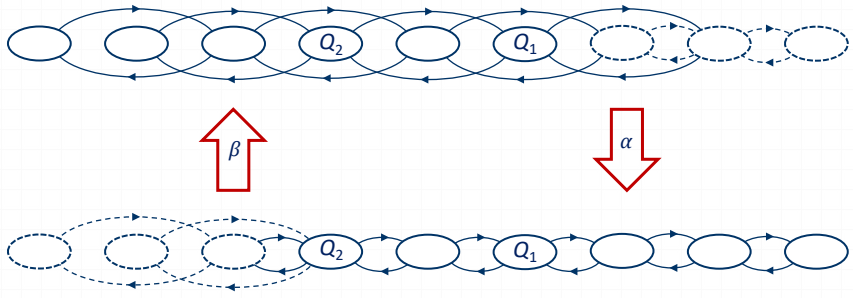
Single-Hysteresis Model (SHM) - working idea



40

Service process in SHS

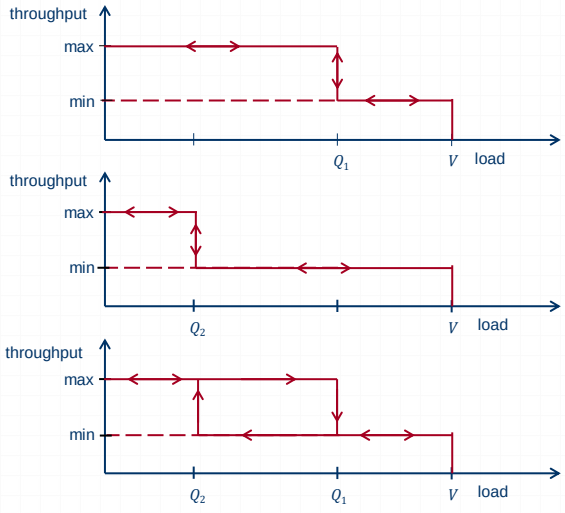
The service process in SHS can be approximated by two weighted processes in boundary STSs, depending on the direction of load changes.



$$[H_n]_V = P(Q_1)[P_n]_{V,Q_1} + P(Q_2)[P_n]_{V,Q_2}$$

41

Service process in SHS



$P_{Q1}(n)$

$P_{Q_2}(n)$

$P_{Q_1,Q_2}(n)$

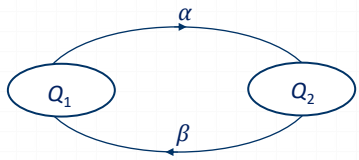
42

Occupancy distribution in SHM*

$$[H_n]_V = P(Q_1)[P_n]_{V,Q_1} + P(Q_2)[P_n]_{V,Q_2}$$

where the parameters $P(Q_1)$ and $P(Q_2)$ are determined on the basis of two-state Markovian process that switches service process in STM

$$P(Q_1) = \frac{\beta}{\alpha+\beta}, \qquad P(Q_2) = \frac{\alpha}{\alpha+\beta}$$



*Stasiak M., Sobieraj M., Weissenberg J., Zwierzykowski P.: Analytical Model of the Single Threshold Mechanism with Hysteresis for Multi-service Networks, **IEICE Transactions on Communications**, vol. E95-B, No. 01, 2012, pp. 120-132.

SHS calculations – system parameters

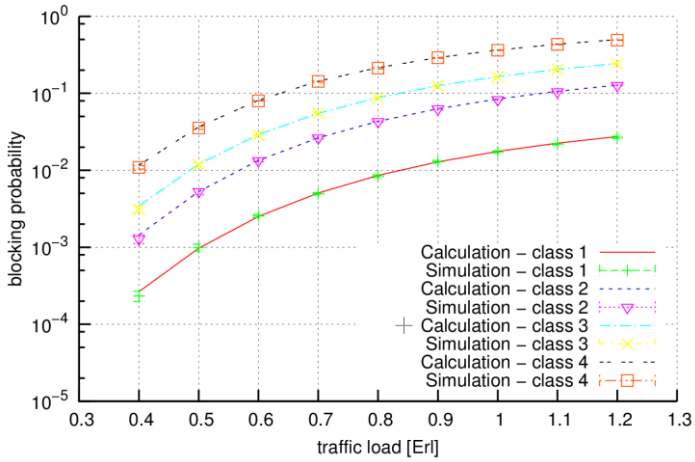
WCDMA radio interface

Structure : V=8000 (BBUs), Q_1=6500, Q_2=4000,

traffic parameters : $t_{1,0}$=53, $t_{2,0}$=257, $t_{2,1}$=129, $t_{3,0}$=503, $t_{4,0}$=1118, $t_{4,1}$=559,

traffic mixture : $A_{1,0}\,t_{1,0} : A_{1,0}\,t_{1,0} : A_{1,0}\,t_{1,0} : A_{1,0}\,t_{1,0}$ = 15: 5: 40: 40.

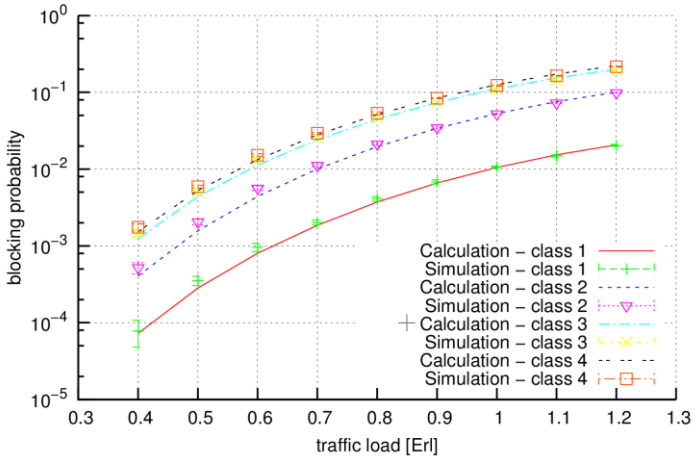
SHS calculations – blocking probability



System without hysteresis

45

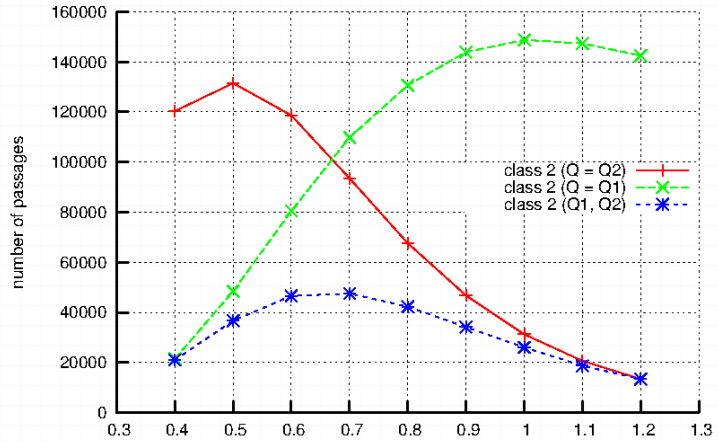
SHS calculations – blocking probability



System with hysteresis for the second and fourth class of traffic

46

SHS calculations – number of passages



System with hysteresis for the second class of traffic

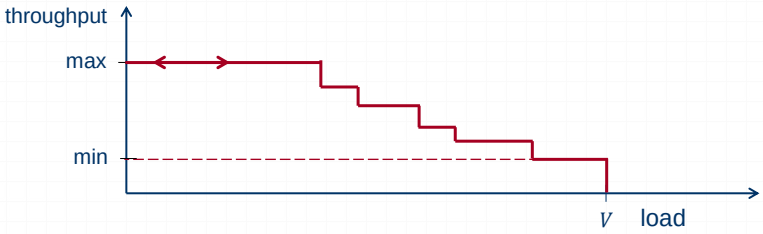
47

Thresholdless compression

Calls that undergo compression:

– decrease occupied number of BBUs, when there is no free resources for a new call appearing in the system,

– increase occupied number of BBUs, when a serviced call terminates.



48

Compression coefficient

Compression coefficient (in a given state n) is a measure for a change in the number of BBUs of compressed call:

$$\omega_i(n) = \frac{t_{i,\max}}{t_i(n)}$$

Maximum compression coefficient determines the ratio of the maximum number of BBUs to the minimum number of BBUs to be accepted for service of calls of a given class:

$$\omega_{i,\max} = \frac{t_{i,\max}}{t_{i,\min}}$$

Maximum compression case*

Occupancy distribution:

$$n[P_n]_V = \sum_{i=1}^{M_k} A_i\, t_{i,\min}\, [P_{n-t_i}]_V + \sum_{j=1}^{M_{nk}} A_j\, t_j\, [P_{n-t_j}]_V$$

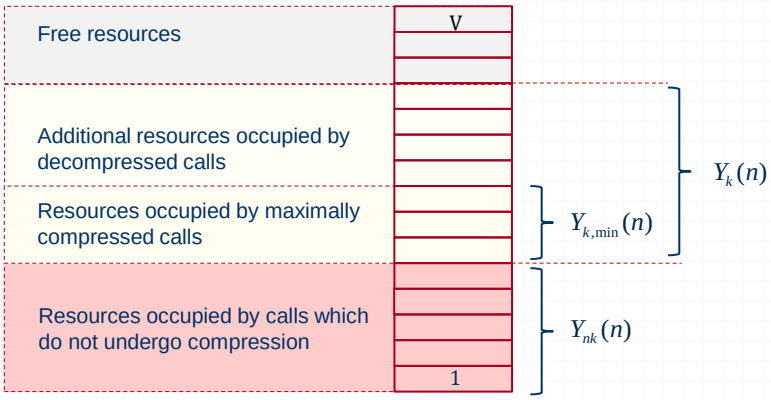
where: M_k is the number of traffic classes that undergo compression and M_{nk} is the number of traffic classes that do not undergo compression.

Blocking probability can be determined in the conditions of maximum compression only:

$$E_i = \sum_{n=V-t_{i,\min}+1}^{V} [P_n]_V \quad \text{for } i \in M_k, \qquad E_j = \sum_{n=V-t_j+1}^{V} [P_n]_V \quad \text{for } i \in M_{nk}$$

*Stasiak, M., Zwierzykowski, P., Wiewióra, J., Parniewicz, D.: Analytical Model of Traffic Compression in the UMTS network, **Lecture Notes in Computer Science**, Springer, vol. 5652, 2009, pp. 79–93.

Current compression case



Occupied resources $Y_k(n) = \omega\, Y_{k,\min}(n)$

51

Numerical example

IuB interface

Structure : V=21000 (BBUs),

traffic parameters :

Speech ($t_{1,\min}$ = 16, $\omega_{1,\max}$ = 1),

Real-time Gaming ($t_{2,\min}$ = 10, $\omega_{2,\max}$ = 20),

Mobile TV ($t_{3,\min}$ = 64, $\omega_{3,\max}$ = 10),

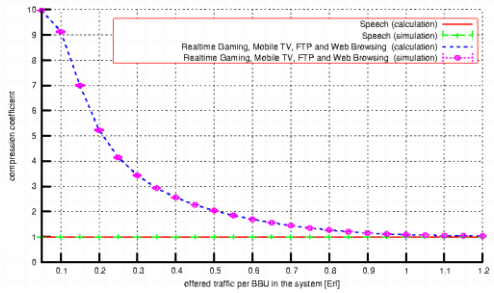
Web Browsing ($t_{4,\min}$ = 500, $\omega_{4,\max}$ = 10)

traffic mixture : $A_1 t_1 : A_2 t_2 : A_3 t_3 : A_4 t_4$ = 1: 3: 5: 10.

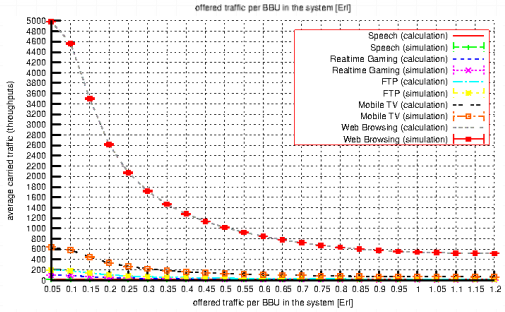
52

HSDPA traffic in IuB (DL) interface

Compression coefficient



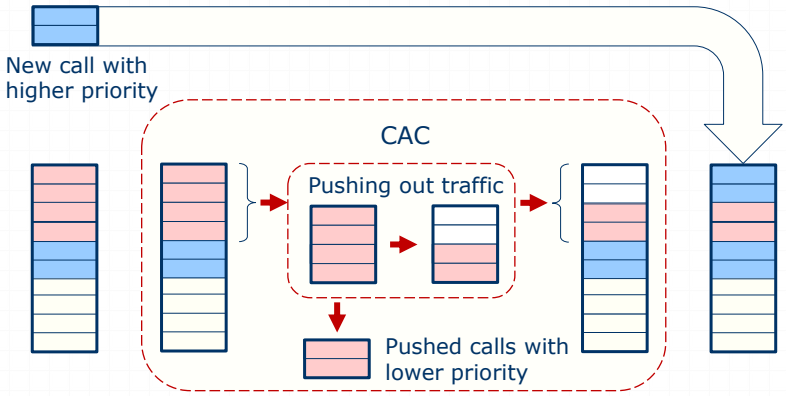
Average throughput



53

Priorities – working idea

The arrival of a new call with a higher priority can, in the case of the lack of free resources, terminate the currently serviced connections with a lower priority



54

Priorities – component systems

System 1
The FAG carrying only one traffic class.

System 2
The FAG without priorities carrying two traffic classes.

System 3
The FAG with priorities carrying two traffic classes.

Priorities – modeling of two traffic classes*

Occupancy distribution

System 1: $[E_1]_{S1} = \mathrm{FAG}\{(A_1, t_1)\}$

System 2: $[E_1, E_2]_{S2} = \mathrm{FAG}\{(A_1, t_1), (A_2, t_2)\}$

System 3: $[E_1, E_2]^P_{S3} = \mathrm{F}\{[E_1]_{S1}, [E_1, E_2]_{S2}\}$

Blocking probability

$$[E_1]^P_{S3} = [E_1]_{S1}$$

$$[E_2]^P_{S3} = \frac{A_1 t_1 \left([E_1]_{S2} - [E_1]_{S1}\right) + A_2 t_2 [E_2]_{S2}}{A_2 t_2}$$

*Stasiak M., Wiewióra J., Zwierzykowski P.: An Approximate Model of the WCDMA Interface Servicing a Mixture of Multi-rate Traffc Streams with Priorities, **Lecture Notes in Computer Science,** Springer, vol. 5261, 2008, pp. 168-180.

Priorities – numerical results (WCDMA)

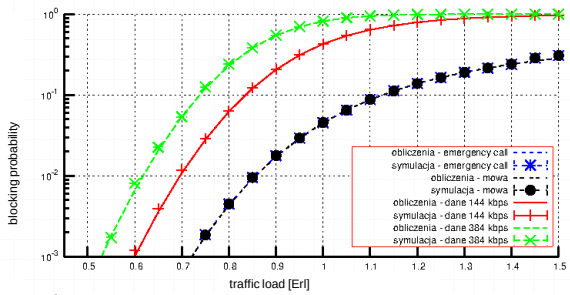
Class of service	Speech	Video call	Data	Data
W [Mchipps]	3.84	3.84	3.84	3.84
R_j [kbps]	12.2	64	144	384
E_b/N_0 [dB]	4	2	1.5	1
L_j	0.0053	0.0257	0.0503	0.118

- The services were demanded in the following proportions: A_1t_1: A_2t_2: A_3t_3: A_4t_4 = 10:1:1:1,
- The LBBU was equal to 0.0001 of the interface capacity,
- Interface capacity: V= 5000 BBUs.

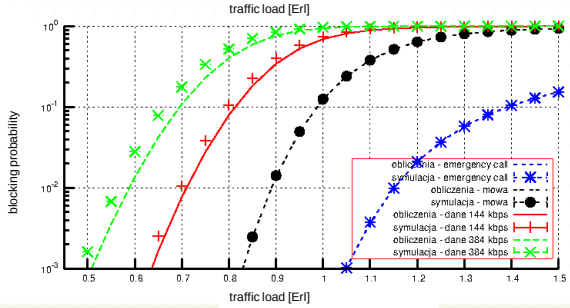
57

Numerical results

WCDMA without priorities



WCDMA with priorities



58

Resources limitations

Assumptions

- All traffic classes are serviced by the group,
- Some traffic classes do not entirely make use of the allocated resources and occupy at least G BBUs, where $G < V$,
- Example – a limitation of resources of the Iub interface (in the UMTS network) for R99 traffic classes that is accompanied by unlimited (or limited) HSUPA traffic.

59

Resources limitations

The problem is to find such a state *N* in which the number of BBUs occupied by calls of constrained classes meets the condition:

$$G(N) = G$$

60

Resources limitations modeling

FAG without limitations

$$n[P_n]_V = \sum_{i=1}^{M} A_i t_i \left[P_{n-t_i}\right]_V$$

$$y_i(n) = A_i \left[P_{n-t_i}\right]_V / \left[P_{n-t_i}\right]_V$$

$$G(n=N) = G = \sum_{i=1}^{S} y_i(N)\, t_i$$

FAG with limitations

$$n[P_n]_V = \sum_{i=1}^{M} A_i t_i\, \sigma_i(n-t_i) \left[P_{n-t_i}\right]_V$$

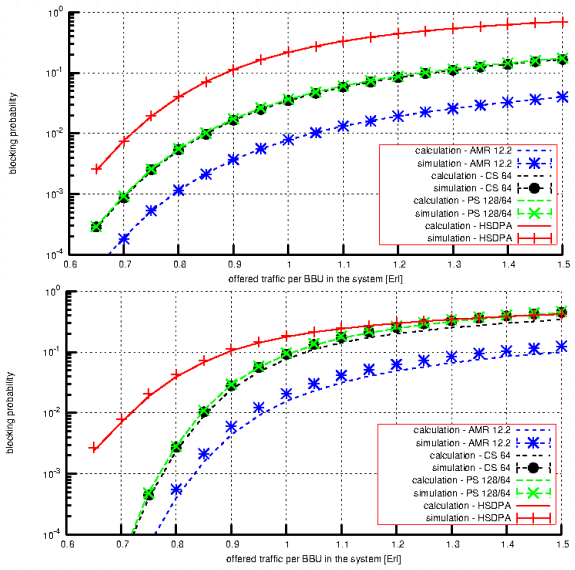
$$\sigma_i(n) = \begin{cases} 1 & \text{for } n \le N - t_i \\ 0 & \text{for } n > N - t_i \end{cases}$$

*Stasiak M, Głąbowski M., Wiśniewski A., Zwierzykowski P.: Modeling and Dimensioning of Mobile Networks. From GSM to LTE. **A John Wiley and Sons, Ltd, Publication**, 2011, pp.1- 315

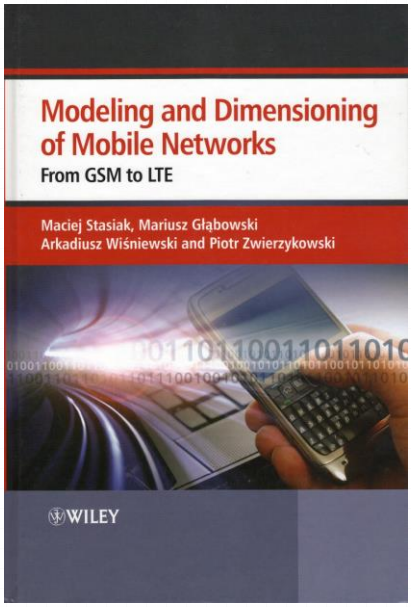
Resources limitations

system without limitations

system with limitations



62


Modeling and Dimensioning
of Mobile Networks
From GSM to LTE
Maciej Stasiak, Mariusz Głąbowski
Arkadiusz Wiśniewski and Piotr Zwierzykowski
WILEY

63



Modelowanie systemów z ruchem zintegrowanym i przelewem ruchu

- Wzory Kaufmana-Robertsa pozwalają na prawidłowe modelowanie systemów ze strumieniami PCT1 i/lub PCT2, oferowanymi bezpośrednio wiązkom telekomunikacyjnym
- Strumień zgłoszeń spływający z wiązki podstawowej nie jest zgodny z rozkładem Poissona
- ruch przelewowy jest opisywany przez dwa parametry:
  - wartość średnią ruchu przelewanego **R** na wiązkę alternatywną (obejściową)
  - wariancję σ^2

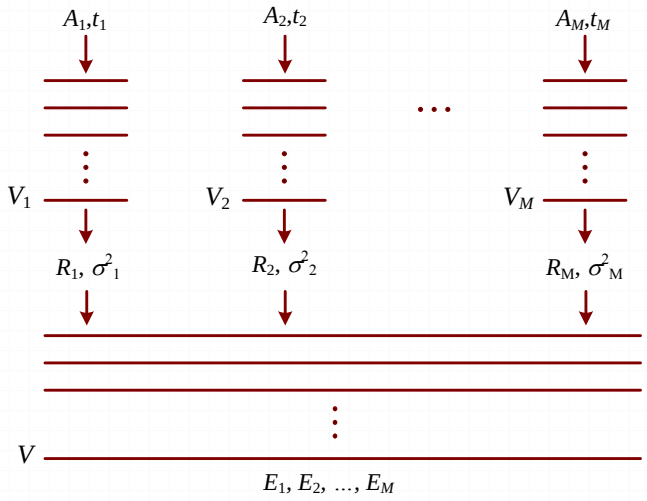
Modelowanie systemów z ruchem zintegrowanym i przelewem ruchu

- Strumień zgłoszeń Poissona
  - obu tych parametrów są równe ($\mathbf{R}=\sigma^2$)
- Strumień zgłoszeń spływających
  - wariancja jest zawsze większa (nieraz nawet kilkakrotnie) od wartości średniej
- Strumień przelewowy jest bardziej nierównomierny niż strumień zgłoszeń oferowanych
- Wzory Kaufmana-Robertsa w swojej podstawowej postaci (opracowane przy założeniu wykładniczego czasu odstępów pomiędzy zgłoszeniami) nie mogą być stosowane do wyznaczania współczynników blokady zgłoszeń ruchu zintegrowanego w wiązce alternatywnej

Model jednoklasowy KR dla wiązki z ruchem przelewowym

- Założenia modelu:
  - każdej z wiązek podstawowych oferowana jest tylko jedna klasa zgłoszeń
  - w systemie znajduje się M wiązek podstawowych o wysokim wykorzystaniu
  - wiązka o numerze i ma pojemność równą V_i PJP
  - każdej wiązce oferowany jest inny strumień zgłoszeń charakteryzujący się natężeniem ruchu A_i
  - Zgłoszenia klasy i żądają do zestawienia połączenia t_i PJP.

Model jednoklasowy KR dla wiązki z ruchem przelewowym



Parametry ruchu spływającego

- Współczynniki blokady w wiązkach podstawowych można obliczyć przy pomocy
  - wzoru Erlanga:
    - jedno zgłoszenie klasy *i* zajmuje jednocześnie t_i PJP - z punktu widzenia wzoru Erlanga jest to równoznaczne z t_i-krotnym zmniejszeniem pojemności wiązki o rzeczywistej pojemności V_i PJP
  - wzorów Kaufmana-Robertsa
    - wiązka o pojemności V_i, której oferowany jest jeden strumień zgłoszeń o rozkładzie Poissona, tworzony przez zgłoszenia żądające do zestawienia połączenia t_i PJP

Parametry ruchu spływającego

- Znając współczynniki blokady w wiązkach podstawowych możemy obliczyć parametry ruchu spływającego każdej z klas, czyli wartość średnią R_i i wariancję σ_i^2 (wzory Riordana)
- Następnie na podstawie R_i i σ_i^2 określamy poziom nierównomierności poszczególnych strumieni ruchu spływającego, obliczając wartości współczynników degeneracji

$$Z_i = \sigma_i^2 / R_i$$

Prawdopodobieństwo blokady w wiązce alternatywnej

- Wiązka alternatywna obsługuje M klas zgłoszeń (z każdej wiązki podstawowej spływają na nią zgłoszenia jednej klasy)
- Współczynniki blokady zgłoszeń poszczególnych klas wyznacza się analogicznie do metody Hayworda (wzory Kaufmana-Robertsa)

$$E_1, E_2, \ldots, E_M = KR\left(\frac{R_1}{Z_1}, \frac{R_2}{Z_2}, \ldots, \frac{R_M}{Z_M}; t_1, t_2, \ldots, t_M; \frac{V}{Z}\right)$$

Prawdopodobieństwo blokady w wiązce alternatywnej

- Wzory Kaufmana-Robertsa przyjmą następującą postać:

$$n\,[P_n]_{V/Z} = \sum_{i=1}^{M} \frac{R_i}{Z_i} t_i \left[P_{n-t_i}\right]_{V/Z}$$

$$B_i = E_i = \sum_{n=\frac{V}{Z}-t_i+1}^{\frac{V}{Z}} [P_n]_{V/Z}$$

- Współczynnik degeneracji Z pełni funkcję normalizującą

Wyznaczanie zbiorczego współczynnika *Z*

- Do wiązki tranzytowej napływa M klas zgłoszeń, z których każda może posiadać inną wartość współczynnika Z_i
- Aby znormalizować pojemność wiązki alternatywnej konieczna jest znajomość zbiorczego współczynnika degeneracji

$$Z = \sum_{i=1}^{M} Z_i k_i$$

gdzie

$$k_i = \frac{R_i t_i}{\sum_{l=1}^{M} R_l t_l}$$

Wymiarowanie wiązek tranzytowych z ruchem zintegrowanym

- Algorytm wymiarowania wiązki, której oferowany jest zintegrowany ruch przelewowy, składający się z M klas zgłoszeń:
  1. Wyznaczenie pojemności wiązek elementarnych v_1, v_2, …, v_M:

$$E_i = B_i = E_{\frac{v_i}{Z_i}}\left(\frac{R_i}{Z_i}\right)$$

Wymiarowanie wiązek tranzytowych z ruchem zintegrowanym

2. Wyznaczenie początkowej pojemności wiązki V_{gr} z ruchem przelewowym na podstawie wartości v_i obliczonych w poprzednim kroku ($v_1+v_2+\ldots+v_M$):

$$V_{gr} = \frac{v_1}{Z_1} + \frac{v_2}{Z_2} + \ldots + \frac{v_M}{Z_M}$$

Wymiarowanie wiązek tranzytowych z ruchem zintegrowanym

3. Cykliczne zmniejszanie pojemności wiązek elementarnych i określanie współczynników blokady zgłoszeń, tak długo jak długo spełniony jest warunek:

$$e_1 \leq E_1;\ e_2 \leq E_2;\ \ldots; e_M \leq E_M$$

Gdzie

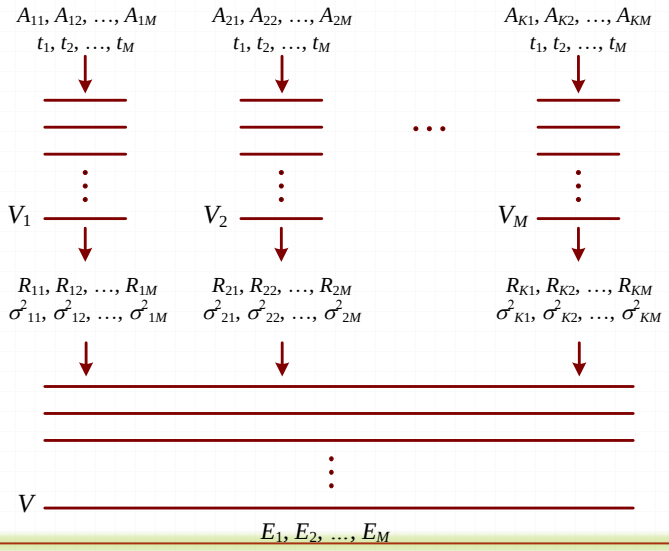
$$e_1, e_2, \ldots, e_M = KR\left(\frac{R_1}{Z_1}, \frac{R_2}{Z_2}, \ldots, \frac{R_M}{Z_M}; t_1, t_2, ..., t_M; \frac{V}{Z}\right)$$

Wymiarowanie wiązek tranzytowych z ruchem zintegrowanym

4. Określenie poszukiwanej pojemności wiązki alternatywnej, poprzez zsumowanie uzyskanych w poprzednim kroku pojemności wiązek składowych $v_1+v_2+...+v_M$, dla których spełnione są jeszcze warunki wyrażone wzorem:

$$e_1 \leq E_1;\ e_2 \leq E_2;\ \ldots; e_M \leq E_M$$

Model wieloklasowy KR dla wiązki z ruchem przelewowym



Model wieloklasowy KR dla wiązki z ruchem przelewowym

- Założenia modelu:
  - system składa się z K wiązek bezpośrednich o wysokim wykorzystaniu
  - każdej z wiązek jest oferowanych M klas zgłoszeń (zgłoszenia klasy i żądają do zestawienia połączenia t_i PJP)
  - natężenie ruchu zgłoszeń klasy i oferowanych wiązce j wynosi $A_{i,j}$ Erl

Model wieloklasowy KR dla wiązki z ruchem przelewowym

- Współczynnik blokady zgłoszeń klasy *i* w wiązce *j* ($E_{i,j}$) można określić przy pomocy wzorów Kaufmana-Robertsa:

$$n\,P(n) = \sum_{i=1}^{M} A_{i,j} t_i \; P(n - t_i)$$

$$E_{i,j} = \sum_{n=V-t_i+1}^{V_j} P(n)$$

- Na podstawie wyznaczonych prawdopodobieństw blokad wyznaczany jest wartość średnią natężenia ruchu spływającego $R_{i,j}$:

$$R_{i,j} = A_{i,j} E_{i,j}$$

Model wieloklasowy KR dla wiązki z ruchem przelewowym

- Określenie wariancji każdego ze strumieni
  - przeprowadzamy dekompozycję każdej wiązki rzeczywistej na *M* fikcyjnych wiązek składowych o pojemnościach V_{ij}.
  - Każda wiązka fikcyjna będzie obsługiwała wyłącznie zgłoszenia jednej klasy, co umożliwi zastosowanie wzorów Riordana do określenia wariancji σ_{ij}^2 ruchu klasy *i* spływającego z wiązki *j*.

Model wieloklasowy KR dla wiązki z ruchem przelewowym

- Określenie pojemności wiązek fikcyjnych
  - Wyznaczymy ruch załatwiany klasy *i* w wiązce *j*

$$Y_{i,j} = A_{i,j}(1 - E_{i,j})$$

  - Wartość $Y_{i,j}$ określa średnią liczbę zgłoszeń klasy *i*, obsłużonych w wiązce *j*.
  - Wyrażona w PJP średnia wartość natężenia ruchu klasy *i* będzie równa $Y_{i,j}t_i$
  - Pojemność fikcyjnej wiązki składowej $V_{i,j}$ - część rzeczywistej wiązki V_j, która nie jest zajmowana przez zgłoszenia pozostałych klas (różnych od klasy *i*).

Model wieloklasowy KR dla wiązki z ruchem przelewowym

- Pojemność wiązki V_{ij} jest równa:

$$V_{i,j} = V_j - \sum_{l=1;l\neq i}^{M} Y_{l,j}t_l$$

gdzie V_j jest pojemnością wiązki podstawowej, a suma po prawej stronie równania określa liczbę PJP zajmowanych przez zgłoszenia pozostałych klas

Model wieloklasowy KR dla wiązki z ruchem przelewowym

- wariancja poszczególnych strumieni zgłoszeń

$$\sigma_{i,j}^2 = R_{i,j}\left(\frac{A_{i,j}}{\frac{V_{i,j}}{t_i}+1-A_{i,j}+R_{i,j}} + 1 - R_{i,j}\right)$$

- gdzie iloraz $V_{i,j}/t_i$ normalizuje system do przypadku jednousługowego

Model wieloklasowy KR dla wiązki z ruchem przelewowym

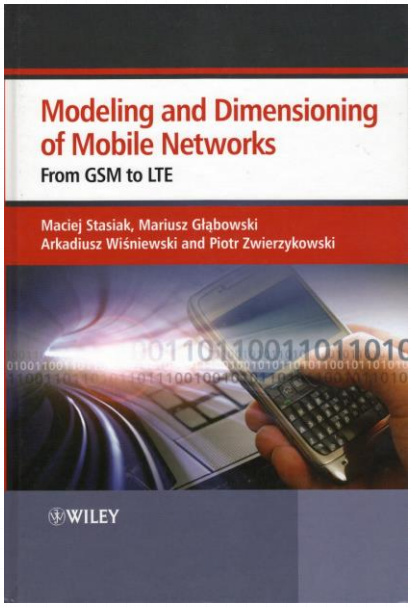
- Poszczególne strumienie zgłoszeń napływające do systemu są statystycznie niezależne

$$R_i = \sum_{j=1}^{K} R_{i,j}$$

$$\sigma_i^2 = \sum_{j=1}^{K} \sigma_{i,j}^2$$

Model wieloklasowy KR dla wiązki z ruchem przelewowym

- W celu wyznaczenia pojemności wiązki alternatywnej możemy zastosować opisany wcześniej algorytm wymiarowania wiązki alternatywnej, obsługującej przelewowy ruch zintegrowany



24



Wprowadzenie

Wprowadzenie

- Potrzeba stosowania i egzekwowania SLA dla IP
  - Konkurencja między SP
  - Wzrost znaczenia aplikacji IP dla biznesu.
- SLA
  - Kontrakt dostarczenia usługi
    - Usługa transportowa IP
  - Wymagania SLA powinny wynikać z wymagań aplikacji korzystających z usługi transportowej

3

Wprowadzenie

- Kluczowe metryki dla oceny wydajności usługi IP
  - Opóźnienie
  - Zmienność opóźnienia
  - Strata pakietów
  - Przepustowość
  - Dostępność usług
  - Zapewnienie kolejności strumieni
- QoS oznacza zobowiązanie (SLA) do zapewnienie określonych wartości tych metryk

4

Wprowadzenie

- Wymagania aplikacji i usług stanowią dane wejściowe oraz kryteria oceny skuteczności zaprojektowanej sieci pod względem QoS
  - Sieć z opóźnienie 500 ms nie jest odpowiednia dla VoIP (200 ms)
  - Sieć z opóźnienie 50 ms – prawdopodobnie przewymiarowana i zbyt kosztowna dla VoIP.
- Zróżnicowanie usług (QoS) musi być zauważalne przez klientów, aby byli oni skłonni ponosić dodatkowe koszty SLA

5

Wprowadzenie

- Liczbowa definicja SLA
  - Wartości bezwzględne
    - Opóźnienie jednokierunkowe w najgorszym przypadku 100 ms
  - Statystycznie
    - Prawdopodobieństwo straty 0,01%
- Sama statystyczna wartość nie wystarcza do określenia, czy taka sieć może zapewnić właściwą obsługę danej aplikacji
  - Niezbędne jest określenie sposobu wyliczania tego parametru
    - 1 utracony pakiet na każde 100 może być ok dla VoIP
    - 10 kolejno utraconych pakietów na 1000 może utrudnić korzystanie z VoIP

6

SLA – standaryzacja

- IETF powołałoIP Performance Metrics [IPPM] Working Group (WG)
- Zadania IPPM
  - Definicja zbioru ustandaryzowanych metryk i procedur umożliwiających ich dokładny pomiar i dokumentację, które mogą być odniesione do wydajności, jakości i niezawodności usług IP
- Celem IPPM WG było:
  - Opracowanie metryk, mierzalnych przez operatorów sieci, użytkowników końcowych i niezależnych testerów
- Celem IPPM WG nie było:
  - Definiowanie metryk subiektywnych (dobry, zły)
- RFC2330 – Framework for IP Performance Metrics
- Operatorzy w SLA między operatorami i klientami nie korzystają w ogólności z definicji IPPM
  - SLA „inżynierskie” i „marketingowe”

Metryki SLA

Klasyfikacja metryk SLA

- Opóźnienie sieciowe (Network Delay)
- Zmienność opóźnienia
- Strata pakietów
- Pasmo i przepływność
- Zapewnienie kolejności strumieni
- Dostępność
- Quality of Expierience

Opóźnienia

Opóźnienie sieciowe

- Definiowane jako jednokierunkowe dla usług nie-elastycznych, wrażliwych na opóźnienie
  - VoIP, wideo
  - Metryka zdefiniowana w RFC2679
- Definiowane jako dwukierowe (RTT) dla usług elastycznych, korzystających z TCP.
  - Metryka zdefiniowana w RFC2681
- Opóźnienie e2e
  - Suma wszystkich opóźnień na ścieżce
- Jitter
  - Wariancja opóźnienia

11

Opóźnienie sieciowe

- Elementy składowe - 1
  - Opóźnienie propagacyjne
  - Opóźnienie serializacji
  - Opóźnienie przełączania
  - Opóźnienie szeregowania
- Elementy składowe -2
  - Opóźnienie propagacyjne
  - Opóźnienie serializacji
  - Opóźnienie przetwarzania
  - Opóźnienie kolejkowania

12

Opóźnienie propagacyjne

- Opóźnienie ścieżki – suma opóźnień łączy
- W przybliżeniu
  - 4 ms na 1000 km dla kabla miedzianego współosiowego
  - 5 ms na 1000 km dla włókien światłowodowych
- Opóźnienie propagacyjne nie wynika bezpośrednio z odległości geograficznej
  - Długość ścieżki > odległości geograficznej
  - Sposób oceny:
    - ITUT G.826

D	R
$D < 1000\,\text{km}$	$R = 1.5 * D$
$1000\,\text{km} \leqslant D \leqslant 1200\,\text{km}$	$R = 1500\,\text{km}$
$D > 1200\,\text{km}$	$R = 1.25 * D$

13

Opóźnienie przełączania/komutacji

- Opóźnienie przełączania lub przetwarzania lub komutacji
  - Czas między otrzymaniem pakietu na interfejsie wejściowym do czasu jego wstawienia do kolejki wyjściowej (związanej z szeregowaniem pakietów)
- Zazwyczaj nieistotne w wysokowydajnych ruterach
  - Przy przetwarzaniu sprzętowym około 10–20 μs na pakiet
  - Przy przetwarzaniu programowym około 2–3 ms.
- Zmniejszenie opóźnienie – uaktualnienie urządzeń
  - Zazwyczaj nieopłacalne z uwagi na niski udział w całości opóźnienia

14

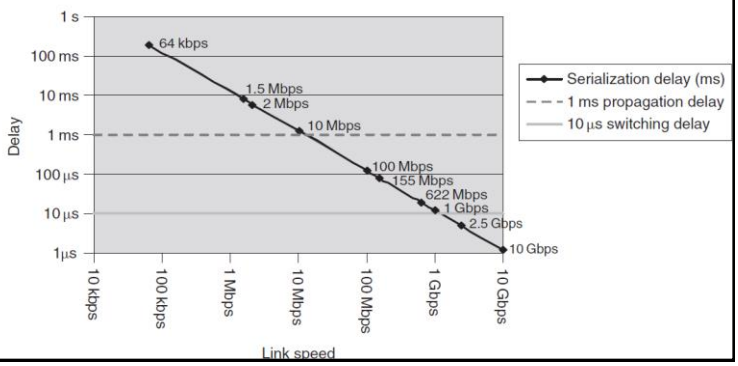
Opóźnienie szeregowania

- Opóźnienie szeregowania – kolejkowania
  - Czas między wstawieniem do kolejki wirtualnej związanej z interfejsem wyjściowym do momentu rozpoczęcia jego wyprowadzania przez interfejs wyjściowy
- Zależny od algorytmu szeregowania i stopnia wykorzystania kolejki wirtualnej
  - Zależność od natężenia ruchu oferowanego

15

Opóźnienie serializacji

- Czas potrzebny na wyprowadzenie pakietu przez określony interfejs fizyczny
  - Zależy od szybkości łącza i rozmiaru pakietu
- Traktowane jako mało istotne dla łączy o > 155 Mb/s
  - Istotne dla łączy o niskich przepływnościach



Zmienność opóźnienia - Jitter

- Jitter – zmienność opóźnienia sieci
  - Obliczany dla kolejno napływających dwóch pakietów
    - Zdefiniowany w RFC3393
  - W praktyce obliczany jako wariancja opóźnienia w odniesieniu do innych metryk, np. średniego opóźnienia lub minimalnego opóźnienia
- Odnosi się to opóźnienia transmisji jednokierunkowej
- Aplikacje wykorzystujące TCP dość niewrażliwe na jitter
- Aplikacje wrażliwe na jitter korzystają z buforów w odbiorniku
  - Zmiana zmiennych opóźnień na stałe

17

Zmienność opóźnienia - Jitter

- Powodowany zmiennością opóźnień sieciowych
  - Opóźnienia propagacyjnego
  - Opóźnienia szeregowania
  - Opóźnienia przełączania
  - Opóźnienia serializacji

18

Metody ograniczania opóźnienia

- Czynniki wpływające na kolejkowanie i serializację
  - Średnia długość kolejki
  - Średnia długość pakietów w kolejce
  - Przepływność łącza
- Zmniejszanie opóźnień dla przepływów wrażliwych na opóźnienia
  - Zwiększenie przepływności
  - Stosowanie zróżnicowanych priorytetów
  - Zmiana priorytetów
  - Kompresja pola danych
  - Kompresja nagłówków

19

Utrata pakietów

20

Utrata pakietów

- Liczba utraconych pakietów między zdefiniowanym punktem wejściowym i wyjściowym sieci
- Pakiet uważany jest za stracony, gdy nie dotrze do miejsca docelowego w określonym czasie
- Metryka packet loss rate (PLR) zdefiniowana w RFC2680
  - Definiowana dla transmisji jednokierunkowej
  - Transmisja dwukierunkowa może być asymetryczna
    - Niezbędny niezależny pomiar w każdym kierunku
- Istotna nie tylko stopa utraconych pakietów, ale także:
  - Rozkład strat
    - Różne postrzeganie jakości przy tej samej wartości średniej, ale rożnym rozkładzie
  - Konieczność wprowadzenia dodatkowych parametrów

21

Utrata pakietów

- Dodatkowe metryki w RFC3357
  - "loss period"
    - Częstość i czas trwania okresu czasu, w którym są gubione pakiety
  - "loss distance"
    - Odstęp czasu między kolejnymi okresami utraty pakietów
- Przyczyny utraty pakietów
  - Natłok
  - Błędy niższych warstw
  - Uszkodzenia elementów sieci
  - Straty w aplikacjach urządzeń końcowych
- Ochrona przed utratą pakietów
  - Korekcja błędów, nadmiarowość, retransmisje

22

Natłok

- Zapełnienie buforów
- Gubione pakiety, dla których brak miejsca w buforach
- Zarządzanie natłokiem
  - Zarządzanie ruchem (obciążeniem)
  - Zarządzanie pamięcią buforową
  - Zarządzanie mechanizmami szeregowania pakietów

Błędy niższych warstw

- Błędy w warstwie fizycznej
  - Odrzucanie ramek
- Bit Error Ratio – BER – zależy od technologii L1 i L2
  - Włókna światłowodowe – 1*10^{-13}
  - SDH i SONET – 1 * 10^{-12}
  - E1/T1 – 1*10^{-9}
  - Dla LAN i MAN max BER = 1*10^{-8}
  - ADSL – 1 * 10^{-7}
  - Usługi satelitarne – 1 * 10^{-6}

Uszkodzenia elementów sieciowych

- Pakiety mogą być gubione do momentu „naprawy” uszkodzonego elementu
- Czas „naprawy” zależy od technologii
  - Czysty IP (bez MPLS)
    - Czas na przeliczenie tras przez protokoły rutingu dynamicznego
      - Setki milisekund
- Brak tras alternatywnych
- Wzrost odporności na uszkodzenia dzięki MPLS-TE FRR lub IP FRR
  - 50 ms.
- Możliwość stosowania odpowiednich technik L2
  - Automatic Protection Switching (APS) – SONET
  - Multiplex Section Protection (MSP) – SDH

25

Utrata w aplikacjach urządzeń końcowych

- Problem z danymi w buforach urządzenia docelowego
  - Zbyt dużo – overflows
    - Bufor pełny
    - Wpływ na praktycznie każdy typ aplikacji
  - Zbyt mało – underflows
    - Wpływ na aplikacje czasu rzeczywistego
- Zapobieganie
  - Właściwe projektowanie sieci i aplikacji systemów końcowych

26

Pasmo i przepustowość

Pasmo

- Usługi IP
  - Przy ich sprzedaży podawane jest pasmo – „bandwidth”
- Pasmo
  - Odnosi się często do przepływności L2
  - Rzadko do określenia zakresu fal elektromagnetycznych
  - Często ma różne znaczenia
    - Link capacity
    - Class capacity
    - Path capacity
    - Bulk transport capacity

Pasmo

- Link capacity - pojemność łącza
  - Liczba bitów możliwych do przesłania w 1 sekundzie
  - Rozważana dla L2 i L3
- Pojemność L2
  - Wartość zazwyczaj stała, zależna od właściwości L1
    - Dla ADSL – zmienna
- Pojemność L3
  - Wartość zależna od
    - Przepływności L2
    - Enkapsulacji L2
    - Rozmiaru pakietu L3
- Link capacity – pasmo łącza, szybkość łącza

29

Pasmo

- Class capacity
  - Minimalna gwarantowana przepływność dla klasy
  - Klasyfikacja ruchu do klas QoS
  - Agregowanie strumieni ruchu do klas
  - Definiowana jako pasmo klasy

30

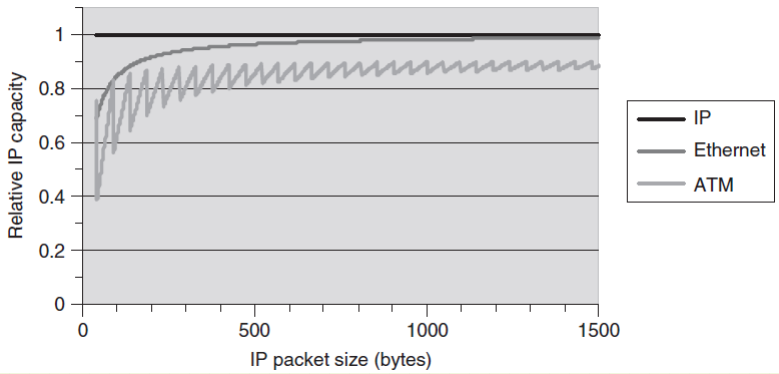
Pasmo - Bulk Transport Capacity

- Możliwa do uzyskania przepustowość dla danych użytkownika między źródłem a ujściem
  - RFC3148
  - Uśredniona wartość przepustowości w długim okresie obserwacji przy zastosowaniu w warstwie transportowej protokołów zarządzana przeciążeniem
    - TCP
- Ograniczone przez
  - pojemność ścieżki
  - Stopa utraty pakietów
  - RTT
- Wartość niższa od pojemności łącza zdefiniowanej w SLA
- Reprezentuje "goodput"
  - Cześć przepustowości dostępnej dla komunikujących się użytkowników

31

Narzut L2

- Pojemność L3 zależy od medium używanego przez L2, enkapsulacji L2 i wielkości pakietu L3
- Narzut L2 – ilość danych dodawanych w trakcie enkapsulacji



32

Narzut L2

- Pojemność L3 zależy od wielkości pakietu enkapsulowanego w ramkę
- Pytanie o udział w zasobach interfejsów wyjściowych
  - Na poziomie L3?
  - Na poziomie L2?
- Równy udział na L3 może skutkować różnym udziałem na L2, jeżeli pakiety obu klas znacznie się różnią wielkością.



Zależność SLA i aplikacji

- Wpływ usług sieciowych z różnymi SLA na aplikacje zależy od typu aplikacji
  - Zbyt duża stopa utraty pakietów lub zbyt duże opóźnienie
    - Problemy z aplikacjami czasu rzeczywistego
      - Ale też problem ze zdefiniowaniem „zbyt duża”
  - Im większy udział utraconych pakietów lub opóźniania, tym większe problemy mają protokoły L4 w utrzymaniu wysokiej przepustowości
  - Niezbędna wiedza o tych zależnościach
    - Unikanie przewymiarowania
    - Zapewnienie odpowiednich usług dla aplikacji

2

Zależność SLA i aplikacji

- Konieczność poznania profilu ruchowego aplikacji
  - Charakterystyka źródła ze względu na generowany ruch
  - Oczekiwania źródła odnośnie obsługi jego ruchu przez sieć
  - Po raz pierwszy dokładnie opisany w ATM
- Typowe aplikacje
  - VoIP
  - Strumieniowanie wideo
  - Wideokonferencje
  - Aplikacje TPC ukierunkowane na przepustowość
  - Aplikacje interaktywne
  - Gry on-line

3

VoIP

- Transportowany zazwyczaj w postaci cyfrowych strumieni RTP z wykorzystaniem UDP
- RTP
  - Protokół L4 do zapewnienia usługi przenoszenia strumieni VoIP od nadawcy do odbiorcy
- SIP
  - protokół sygnalizacyjny do zestawiania strumieni przenoszenia RTP oraz określania formatów mediów (kodeków)
- Wpływ utraty pakietów i opóźnienia na VoIP zależy od użytego kodeka i jakości implementacji usługi w urządzeniu końcowym

4

VoIP

- Kodeki VoIP
  - Konwersja sygnałów analogowych na cyfrowe i odwrotnie
  - Najczęściej używane
    - ITU G.71x i G.72x
- ITU G.71x
  - PCM
- ITU G.72x
  - Adaptive Differential PCM (ADPCM)
  - Przewiduje wartość następnej próbki na podstawie poprzedniej
  - Przekazywana informacja o różnicy między przewidywaną wartością a rzeczywistą
  - Strumień o niższej intensywności niż PCM

5

VoIP

- Kodeki oparte na ramkach - frame-based codecs
  - ITU G.729 i ITU G.723
- Zaawansowane techniki
  - Algebraic Code Excited Linear Prediction (ACELP)
- ACELP
  - Dzieli próbkowany sygnał wejściowy na bloki próbek
  - Bloki zazwyczaj 20ms
  - Blok przetwarzane jako jednostka
  - W czasie przetwarzania ramki, enkoder stosuje technikę „analysis-by-synthesis”
    - Enkoder sprawdza, które parametry wejściowe, podane na filtr syntezujący, pozwolą na najlepszą rekonstrukcję sygnału mowy
    - Enkoder używa książki kodowej do wskazania danych wejściowych do filtra
    - Informacja ta przekazywana jest do dekodera

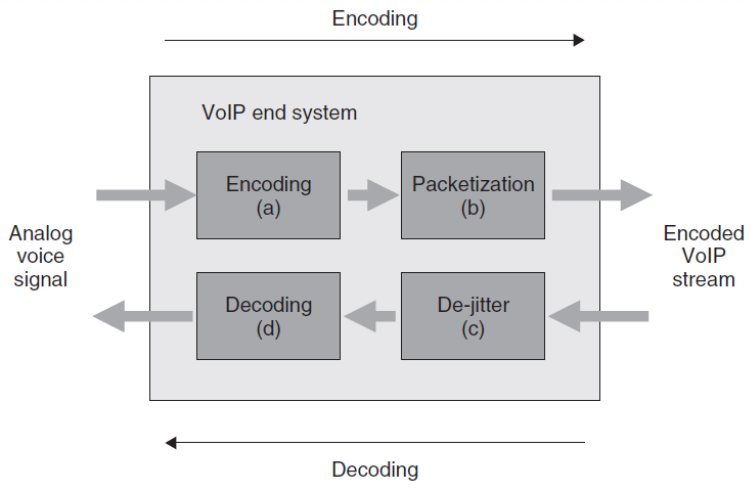
6

VoIP

- Algorytmy wywodzące się z ACELP
  - Low-Delay Code Excited Linear Prediction (LD-CELP)
  - Conjugate Structure ACELP (CS-ACELP)
- Kodeki dla VoIP różnią się złożonością, wymaganą przepustowością i zapewnianą jakością postrzeganą przez użytkowników końcowych
- Istnieją kodeki stosujące kompresję w celu ograniczenia wymagań w zakresie przepustowości
  - Utrata szczegółów

7

VoIP



8

Kodeki VoIP

ITU-T Codec	Codec type	Maximum codec delay (ms) (a1 d)	Bitrate (bps)	Packetization interval (ms) (b)	pps	Payload size (bytes)	IP pkt size (bytes)[i]	IP bps
G.711	PCM	0.375	64 000	10	100	80	120	96 000
G.711	PCM	0.375	64 000	20	50	160	200	80 000
G.711	PCM	0.375	64 000	30	33.33	240	280	74 659
G.723.1	ACELP	97.5	5 300	30	33.33	20	60	15 998
G.723.1	ACELP	97.5	5 300	15	16.67	40	80	10 669
G.726.16	ADPCM	0.375	16 000	10	100	20	60	48 000
G.726.16	ADPCM	0.375	16 000	20	50	40	80	32 000
G.726.16	ADPCM	0.375	16 000	30	33.33	60	100	26 664
G.726.24	ADPCM	0.375	24 000	10	100	30	70	56 000
G.726.24	ADPCM	0.375	24 000	10	50	60	100	40 000
G.726.24	ADPCM	0.375	24 000	10	33.33	90	130	34 663
G.726.32	ADPCM	0.375	32 000	10	100	40	80	64 000

9

Kodeki Voip

ITU-T Codec	Codec type	Maximum codec delay (ms) (a1 d)	Bitrate (bps)	Packetization interval (ms) (b)	pps	Payload size (bytes)	IP pkt size (bytes)[i]	IP bps
G.726.32	ADPCM	0.375	32 000	20	50	80	120	48 000
G.726.32	ADPCM	0.375	32 000	30	33.33	120	160	42 662
G.726.40	ADPCM	0.375	40 000	10	100	50	90	72 000
G.726.40	ADPCM	0.375	40 000	20	50	100	140	56 000
G.726.40	ADPCM	0.375	40 000	30	33.33	150	190	50 662
G.728	LD-CELP	1.875	16 000	10	100	20	60	48 000
G.728	LD-CELP	1.875	16 000	20	50	40	80	32 000
G.728	LD-CELP	1.875	16 000	30	33.33	60	100	26 664
G.729A	CS-ACELP	35	8 000	10	100	10	50	40 000
G.729A	CS-ACELP	35	8 000	20	50	20	60	24 000
G.729A	CS-ACELP	35	8 000	30	33.33	30	70	18 665

10

VoIP
Wpływ opóźnienia

- Istotna metryka – opóźnienie w jedną stronę, w każdym kierunku
- Główny wpływ – zapewnienie interaktywności rozmowy
  - Problem z rozpoznaniem, czy przerwa wynika z intencji rozmówcy czy jest wynikiem opóźnienia systemu
  - Problem z kompensacją echa
- Dopuszczalne opóźnienie
  - ITU-T G.114
    - 150 ms w jedną stronę powinno satysfakcjonować wszystkich użytkowników transmisji głosu
    - Akceptacja kończy się przy 400ms

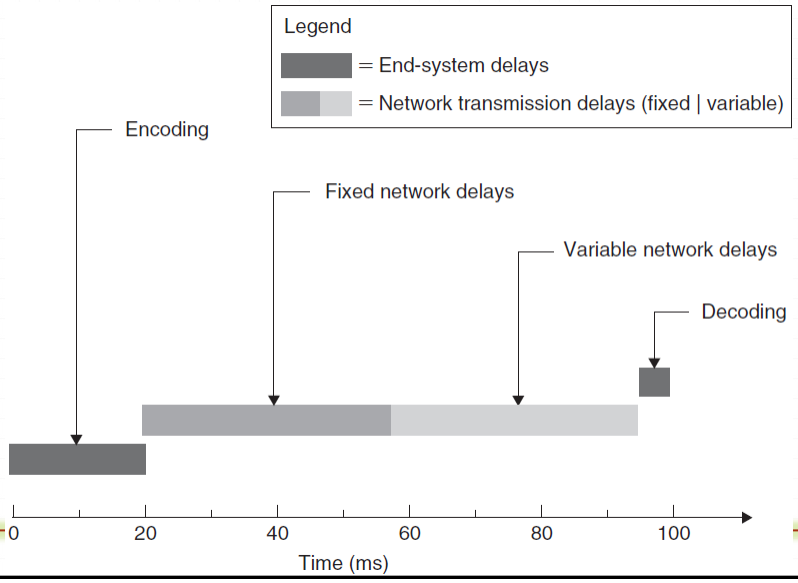
11

VoIP
Wpływ opóźnienia

Ear-to-mouth delay (D)	R factor	Objective MOS
$D < 150$ ms	80–89	5
150 ms $< D <$ 250 ms	70–79	4
250 ms $< D <$ 325 ms	60–69	3
325 ms $< D <$ 425 ms	50–59	2
$D > 425$ ms	90–100	1

12

VoIP – elementy opóźnienia



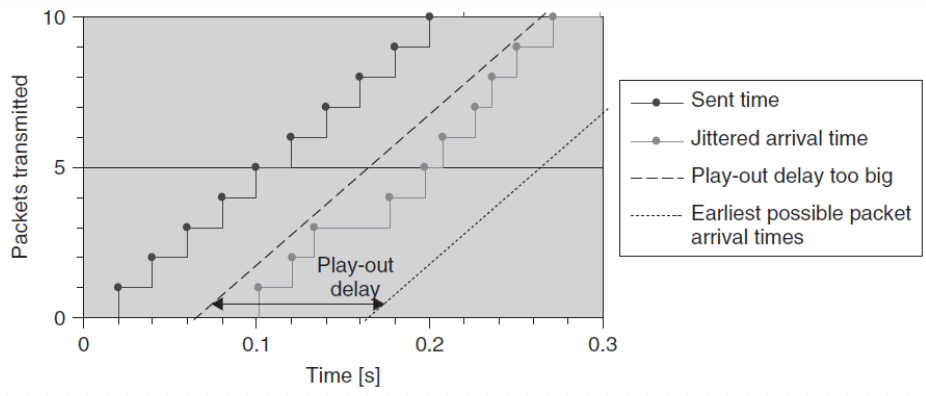
13

VoIP – wpływ jitter'a

- Jitter nie ma większego wpływ na jakość VoIP niż samo opóźnienie sieciowe
  - Często mylne założenie
- Aplikacje wrażliwe na jitter (VoIP) stosują bufory w urządzeniach docelowych w celu kompensacji jitter'a i obsługi pakietów napływających w niewłaściwej kolejności
- Dekodowanie sygnału jest procesem synchronicznym
  - Dane do dekodera muszą napływać jako CBR
- Problem z doborem właściwej pojemności bufora
  - Zbyt duży
    - Dodatkowe opóźnienia
  - Zbyt mały
    - Brak pakietów do przetworzenia

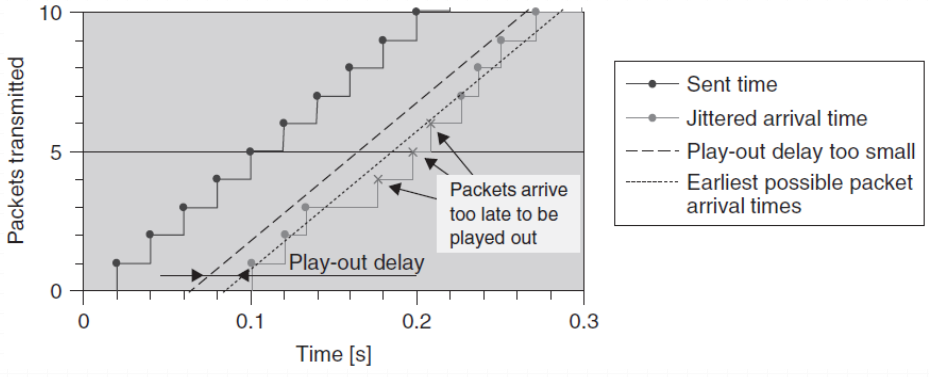
14

Zbyt duży bufor



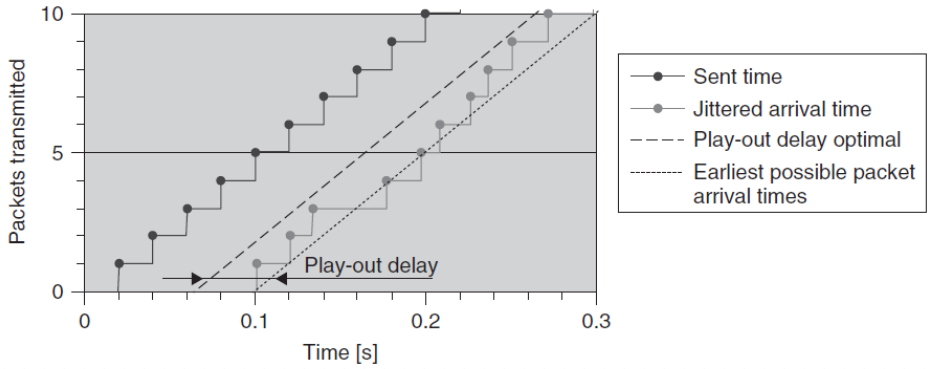
15

Zbyt mały bufor



16

Optymalny bufor – wartość ustalana dynamicznie



17

VoIP – wpływ strat

- Packet Loss Concealment (PLC)
  - Technika maskowania efektu utraty pakietu
  - Realizacja zależna od typu kodeka.
  - PLC dla G.711
    - Powtórzenie poprzednio otrzymanej próbki
      - Sygnał mowy jest lokalnie stacjonarny
    - Efektywny dla strat w czasie 20 ms
  - PLC dla G.729 i G.723
    - Bardziej wyrafinowane technika
    - Pozwalają na tolerowanie strat w czasie 30–40 ms
      - Pod warunkiem dostępu do danych historycznych niezbędnych do interpolacji
      - Problem z krótkimi głoskami

18

VoIP – wpływ strat

- Dla poprawnie dobranego interwału pakietyzacji (20–30 ms w zależności od kodeka) strata jednego pakietu może być ukryta
  - Strata dwóch lub więcej kolejnych pakietów może wpływać na znaczące pogorszenie jakości głosu
- Wpływ
  - Natłoku
    - Z punktu widzenia VoIP sieci powinny być wolne od natłoku
    - Mechanizmy CAC
  - Błędów w niższych warstwach
  - Uszkodzeń elementów sieciowych
  - Strat w aplikacjach systemów końcowych

19

VoIP – wpływ strat

- Wpływ błędów w niższych warstwach
  - Niezależne od mechanizmów QoS
  - Przykład 1
    - BER = 1*10^{-9}
    - Równomierny rozkład błędów
    - Jeden błąd – utrata pakietów
    - Kodek G.711–20 ms
      - Pakiety 200 bajtów, 50 pakietów/s
    - PLR = 1 * 10^{-9} * 200 * 8 = 1.6 * 10^{-6}
    - Bez PLC odstęp między stratami = 1/(1.6 * 106 * 50pps * 60)s = 208min
    - PLC może zwiększyć odległość między błędami

20

VoIP – wpływ strat

- Wpływ błędów w niższych warstwach
  - Niezależne od mechanizmów QoS
- Przykład 1
  - BER = 1 * 10^{-7};
  - PLR = 1 * 10^{-7} * 200 * 8=1.6 * 10^{-4}
  - Bez PLC – błąd co 2 minuty
  - Z PLC
    - Utrata dwóch kolejnych pakietów
    - (1.6 * 10^{-4})^2=2.6 * 10^-8
    - Odległość między stratami 1/(2.6 * 10^-8 * 50pps * 60 seconds * 60 minutes * 24 hours)=9 dni

VoIP – wpływ przepustowości

- Kodeki VoIP wytwarzają strumienie o stałej przepływności bitowejVoIP
  - Bez kompresji ciszy
    - Voice activation detection (VAD)
    - Uaktywniany po wykryciu ciszy dłuższe niż założona wartość progowa
    - Większość rozmów – 50% ciszy
      - Znaczące ograniczenie wymaganych zasobów (średnio)

VoIP – wpływ przepustowości

- Sieci zaprojektowane dla VoIP muszą zapewnić
  - Bliską zeru stopę utraty pakietów
    - Brak natłoku z punktu widzenia pakietów VoIP
  - Konieczność obsługi strumieni VoIP dla wartości szczytowych natężenia ruchu, bez przekroczenia
    - Dopuszczalnych strat
    - Dopuszczalnych opóźnień i ich wariancji

VoIP – wpływ przepustowości

- Problemy w przypadku multipleksacji statystycznej
  - Sieć przykładowo zaprojektowana do jednoczesnej obsługi 30 użytkowników
  - Problem z określeniem max liczby użytkowników, którzy z tych zasobów mogą korzystać
    - Rozkłady czasu między zgłoszeniami, czasu trwania połączenia
    - Określenie prawdopodobieństwa, że co najmniej 50 użytkowników równocześnie będzie chciało skorzystać z usługi
    - Konieczność wprowadzenia mechanizmów AC

VoIP – wpływ zmiany kolejności pakietów

- Zmiana kolejności pakietów ma zazwyczaj niewielki wpływ na ruch
- Intensywność tego zjawiska musiałaby być duża, aby wpłynąć na strumień VoIP, dla którego odstęp między pakietami jest krotnością np. 20 ms
- Główna przyczyna
  - Mechanizmy równoważenia obciążenia
    - Wpływ na przepustowość aplikacji i jitter

25

Wideo

26

Strumieniowanie Wideo

- Aplikacje strumieniowania wideo pozwalają klientom żądać przesyłania wideo z serwerów
- Odtwarzanie rozpoczyna się przed otrzymaniem danych całego strumienia
- Używane do rozgłaszania kanałów wideo
  - IP multicast
- Używane w usłudze video on demand (VOD)
  - IP unicast.
- Strumieniowanie wideo oparte na IP
  - Strumienie danych kodowane z wykorzystaniem standardów Motion Picture Expert Group (MPEG) i transportowane z wykorzystaniem RTP, korzystając z UDP
- MPEG
  - definiuje kodowanie dla samego strumienia wideo
- RFC2250, RFC 2343 i RFC3640
  - Określa jak dane audio i wideo czasu rzeczywistego są formatowane dla transportu RTP
- RTP
  - Protokół warstwy transportowej
  - Odpowiedzialny za dostarczanie strumienia od nadawcy do odbiorcy
- Real-time Streaming Protocol (RTSP) [RFC2326]
  - Zestawianie strumieni RTP
- Możliwe inne systemy kodowania

27

MPEG

- Komitet MPEG
  - International Organization for Standardization/International Electrotechnical Commission (ISO/IEC)
  - Standardy cyfrowego audio i wideo
  - Standardy wykorzystujące IP
  - MPEG-2
    - Szeroko stosowany w telewizji
  - MPEG-4 Advanced Video Coding (AVC)

28

Kodowanie MPEG

- Enkoder MPEG
  - Konwertuje i kompresuje sygnał wideo w ciąg obrazów/ramek
  - Zazwyczaj niewielka zmiana między ramkami
    - Transmitowana tylko różnica
- Typy ramek MPEG
  - Ramki "I" – „wewnętrzne" - intra
  - Ramki "P" – kodowane z predykcją
  - Ramki "B" – dwukierunkowe

29

Kodowanie MPEG

- Ramki "I" – „wewnętrzne" - intra
  - Przenoszą kompletną ramkę wideo i są kodowane bez referencji do innych ramek
  - Mogą korzystać z kompresji przestrzennej
    - Piksele w ramach ramki są powiązane z ich sąsiadami
    - Możliwość zredukowania nadmiarowości przestrzennej
    - Mniejszy rozmiar ramki, użycie predykcji do rekonstrukcji ramki
  - Otrzymana ramka I jest punktem referencyjnym dla dekodowania otrzymanego strumienia MPEG
- Ramki "P" – kodowane z predykcją
  - Kodowane z wykorzystaniem kompensacji ruchu
    - Motion compensation (temporal compression)
  - Przewidywanie kodowanej ramki na podstawie poprzedniej ramki odniesienia (referencyjnej) typu I lub P
  - Zwiększają stopień kompresji w stosunku do ramek I
    - 10-30% rozmiaru ramek I
- Ramki "B" – dwukierunkowe
  - Wykorzystują poprzednie lub następne ramki I lub B jako swoje punkty referencyjne dla kompensacji ruchut
  - Zapewniają dalszą kompresję
    - 5–15% rozmiaru skojarzonych ramek I

30

Kodowanie MPEG

- Ramki "I" – „wewnętrzne" - intra
  - Przenoszą kompletną ramkę wideo i są kodowane bez referencji do innych ramek
  - Mogą korzystać z kompresji przestrzennej
    - Piksele w ramach ramki są powiązane z ich sąsiadami
    - Możliwość zredukowania nadmiarowości przestrzennej
    - Mniejszy rozmiar ramki, użycie predykcji do rekonstrukcji ramki
  - Otrzymana ramka I jest punktem referencyjnym dla dekodowania otrzymanego strumienia MPEG
- Ramki "P" – kodowane z predykcją
  - Kodowane z wykorzystaniem kompensacji ruchu
    - Motion compensation (temporal compression)
  - Przewidywanie kodowanej ramki na podstawie poprzedniej ramki odniesienia (referencyjnej) typu I lub P
  - Zwiększają stopień kompresji w stosunku do ramek I
    - 10-30% rozmiaru ramek I

31

Kodowanie MPEG

- Ramki są grupowane w Group of Pictures (GOP)
  - European PAL (Phase-Alternating Line) MPEG-2
    - GOP o rozmiarze 15
    - 25 ramek na sekundę
    - Każdy GOP 15/25 sekund wideo
  - North American NTSC (National Television Systems Committee)
    - GOP o rozmiarze 18
    - 29.97 fps
    - Każdy GOP 18/30 sekund wideo
- Wiele możliwych struktur GOP
  - Układ ramek I, P, B określony przez
    - format sygnału wejściowegoany
    - Ograniczenia przepływności bitowej na enkodowany strumień wideo
      - Wpływa na żądany stopień kompresji
    - Żądane opóźnienie kodowania/dekodowania

32

Kodowanie MPEG

- Każdy GOP ma
  - 1 ramkę I
  - Od 2 do 14 ramek P
  - Od 2 do 10 ramek B
- Wiele wariantów kodowania wideo
- Określona struktura GOP, użyta do kodowania strumienia video, może mieć istotne znaczenie przy określaniu wpływu strat w sieci, opóźnienia i przepustowości na możliwość odtworzenia wideo w odbiorniku

33

Wpływ opóźnienia

- Główną metryka jest opóźnienie transmisji jednokierunkowej
- Wpływ opóźnienia/jitter'a na interaktywność
- Wpływ zależny od typu aplikacji strumieniowania:
  - Broadcast Video
  - Video-on-demand

34

Broadcast video - IPTV

- Usługa telewizji dostarczona z wykorzystaniem IP
- Zazwyczaj używany multicast IP
- Wpływ opóźnienia e2e
  - Czas potrzebny na zmianę kanału telewizyjnego
    - Pożądany: 1-2 sekundy
- Czas zależny od:
  - Sterowane zdalne i przetwarzanie STB
  - Opóźnienie transmisji w sieci
  - Przetwarzanie multicast
  - Opóźnienie transmisji w sieci
  - Buforowanie STB/przetwarzanie

35

Broadcast video - IPTV

- Czas zmiany kanału zależny od:
  - Sterowane zdalne i przetwarzanie STB
    - Max 50 ms
  - Opóźnienie transmisji w sieci
  - Przetwarzanie multicast
  - Opóźnienie transmisji w sieci
  - Buforowanie STB/przetwarzanie

36

Broadcast video - IPTV

- Czas zmiany kanału zależny od:
  - Sterowane zdalne i przetwarzanie STB
  - Opóźnienie transmisji w sieci
    - Czas przesłania od STB do pierwszego urządzenia multicast, przetwarzającego wiadomości IGMP
      - Serializacja, przełączanie, propagacja, kolejkowanie
      - ~100 ms
  - Przetwarzanie multicast
  - Opóźnienie transmisji w sieci
  - Buforowanie STB/przetwarzanie

37

Broadcast video - IPTV

- Czas zmiany kanału zależny od:
  - Sterowane zdalne i przetwarzanie STB
  - Opóźnienie transmisji w sieci
  - Przetwarzanie multicast
    - Wiadomości opuszczenia grupy
    - Wiadomości dołączenia do grupy
      - Czy ruter aktualnie już obsługuje tę grupę?
    - ~10 ms, max ~100ms
  - Opóźnienie transmisji w sieci
  - Buforowanie STB/przetwarzanie

38

Broadcast video - IPTV

- Czas zmiany kanału zależny od:
  - Sterowane zdalne i przetwarzanie STB
  - Opóźnienie transmisji w sieci
  - Przetwarzanie multicast
  - Opóźnienie transmisji w sieci
  - Buforowanie STB/przetwarzanie

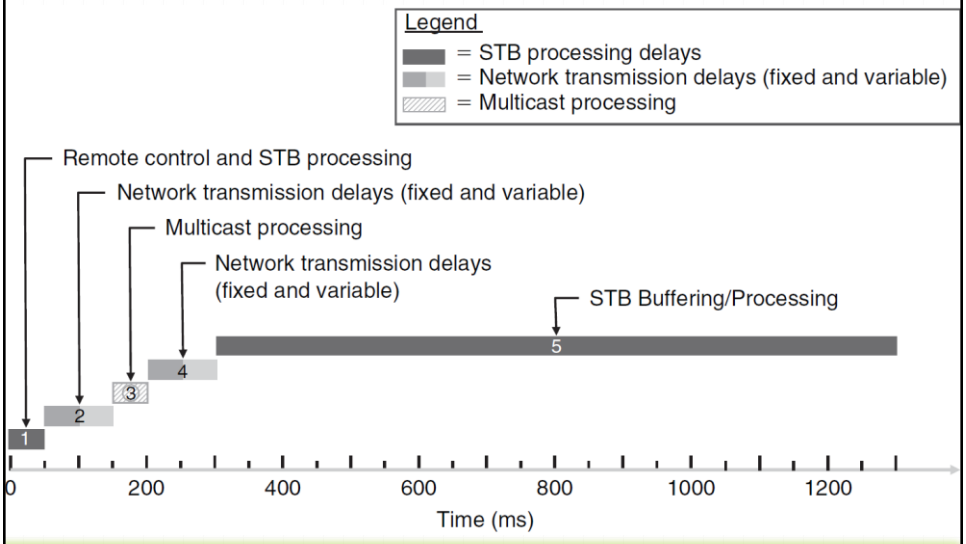
39

Broadcast video - IPTV

- Czas zmiany kanału zależny od:
  - Sterowane zdalne i przetwarzanie STB
  - Opóźnienie transmisji w sieci
  - Przetwarzanie multicast
  - Opóźnienie transmisji w sieci
  - Buforowanie STB/przetwarzanie
    - Bufor do eliminacji jitter'a
      - ~100–200 ms
    - Opóźnienie deszyfrowania
      - ~200 ms.
    - Bufor dekodera MPEG
      - ~500–1000 ms.
    - Opóźnienie ramek IBB
      - ~680 ms

40

Składowe opóźnień zmiany kanału



41

Video on Demand

- Usługi Video-on-demand (VOD) i network personal video recorder (PVR) zazwyczaj dostarczane z wykorzystaniem transmisji unicast
- Usługa VOD
  - Opóźnienie tzw. „finger-to-eye”
  - Czas od wysłania żadania przez użytkownika do zaobserwowania zmiany
    - Np. rozpoczęcie odtwarzania filmu
    - Opóźnienie ~ 1 sekunda

42

Video on Demand

- Elementy wpływające na czas odpowiedzi przy usłudze VoIP realizowanej z wykorzystaniem transmisji unicast
  - Sterowanie zdalne i przetwarzanie STB
    - ~50ms
  - Opóźnienie transmisji w sieci
  - Przetwarzanie „Middleware”
  - Opóźnienie transmisji w sieci
  - Buforowanie /przetwarzanie STB

43

Video on Demand

- Elementy wpływające na czas odpowiedzi przy usłudze VoIP realizowanej z wykorzystaniem transmisji unicast
  - Sterowanie zdalne i przetwarzanie STB
  - Opóźnienie transmisji w sieci
    - ~100 ms
  - Przetwarzanie „Middleware”
  - Opóźnienie transmisji w sieci
  - Buforowanie /przetwarzanie STB

44

Video on Demand

- Elementy wpływające na czas odpowiedzi przy usłudze VoIP realizowanej z wykorzystaniem transmisji unicast
  - Sterowanie zdalne i przetwarzanie STB
  - Opóźnienie transmisji w sieci
  - Przetwarzanie „Middleware”
    - Setki milisekund
  - Opóźnienie transmisji w sieci
  - Buforowanie /przetwarzanie STB

45

Video on Demand

- Elementy wpływające na czas odpowiedzi przy usłudze VoIP realizowanej z wykorzystaniem transmisji unicast
  - Sterowanie zdalne i przetwarzanie STB
  - Opóźnienie transmisji w sieci
  - Przetwarzanie „Middleware”
  - Opóźnienie transmisji w sieci
    - ~100ms
  - Buforowanie /przetwarzanie STB

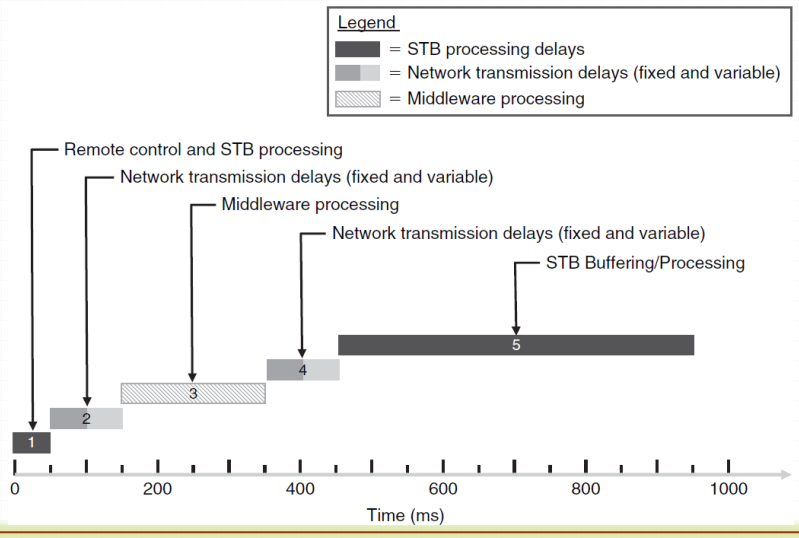
46

Video on Demand

- Elementy wpływające na czas odpowiedzi przy usłudze VoIP realizowanej z wykorzystaniem transmisji unicast
  - Sterowanie zdalne i przetwarzanie STB
  - Opóźnienie transmisji w sieci
  - Przetwarzanie „Middleware”
  - Opóźnienie transmisji w sieci
  - Buforowanie /przetwarzanie STB
    - De-jitter
    - FEC
    - Deszyfrowanie
    - Bufor dekodowania MPEG

47

Video on Demand



48

Wpływ jitter'a

- Dekodery wideo wymagają synchronicznych strumieni
  - Tolerowany jitter – 500 ns
    - Wartość niemożliwa do uzyskania w natywnych sieciach IP
    - Bufory w odbiornikach
- Jitter nie powinien powodować odrzucania pakietów
  - Stosowanie mechanizmów QoS w celu zarządzania opóźnieniami w kolejkach
- Rozmiar bufora w STB
  - Maksymalna możliwa wartość jittera

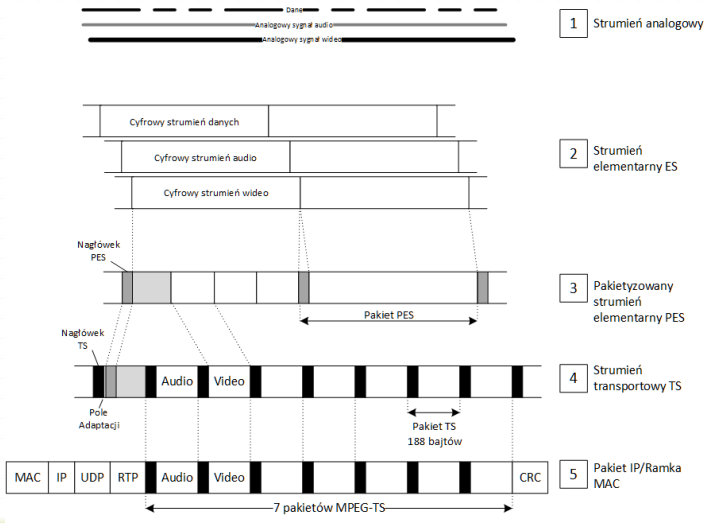
49

Wpływ strat

- Każda ramka MPEG jest transportowana jako pewna liczba strumieni transportowych MPEG-TS
  - Typowa długość MPEG-TS - 188 bajtów
  - Pakiet IP przenosi od 1 do 7 pakietów MPEG-TS
  - Ramka MPEG obejmuje wiele pakietów IP
  - Strata pojedynczego pakietu IP
    - Strat całej ramki MPEG
    - Widoczne zniekształcenie
- Zniekształcenie zależne od typu ramki i struktury GOP

50

Wpływ strat



51

Wpływ strat

- Strata ramki I może powodować zniekształcenie sygnału wideo do momentu otrzymania kolejnej ramki I
- Strat ramki P może wpływać na kilka ramek
- Strata ramki B może wpływać tylko na tę ramkę
- Niezbędny kompromis przy wyborze struktury Gop
  - Większy GOP
    - Większa kompresja
    - Lepsza jakość
    - Większy wpływ utraty pakietu
    - Większe opóźnienie „finger-to-eye”
  - Mniejszy GOP

52

Wpływ strat

- Strata ramki I może powodować zniekształcenie sygnału wideo do momentu otrzymania kolejnej ramki I
- Strat ramki P może wpływać na kilka ramek
- Strata ramki B może wpływać tylko na tę ramkę
- Niezbędny kompromis przy wyborze struktury Gop
  - Większy GOP
    - Większa kompresja
    - Lepsza jakość
    - Większy wpływ utraty pakietu
    - Większe opóźnienie „finger-to-eye”
  - Mniejszy GO
- Oczekiwane jedno zniekształcenie na godzinę

53

Wpływ strat

- Oczekiwane jedno zniekształcenie na godzinę
- Obliczenia
  - Rozważamy strumień MPEG 3.7 Mbps
  - Pakiety o rozmiarze 1356 bajtów
    - Strumienie transportowe przenoszące 7*188 bajtów w każdym pakiecie
    - Plus 40 bajtów nagłówków RTP, UDP, IP
  - Szybkość strumienia ~ 350 pakietów na sekundę
  - Wymagany PLR
    - 1/(350 pps * 60 s * 60 minut)= ~1 * 10^{-6}

54

Wpływ strat

- Przyczyny strat
  - Natłok
  - Błędy w niższych warstwach
    - Forward error correction (FEC).
    - Real-time retransmission
  - Uszkodzenia elementów sieci
    - Nadmiarowość przestrzenna - fizyczna
    - Nadmiarowość czasowa
      - Dwukrotne przesyłanie danych w pewnym odstępie czasu
  - Straty w aplikacjach końcowych
- Sieci dla transmisji wideo powinny praktycznie wolne od strat

55

Wpływ przepustowości

- Standard definition
  - 480i
  - 576i
- High definition
  - 720p
  - 1080i

56

Wideokonferencje

Wideokonferencje

- Sygnalizacja
  - H.323 lub SIP
- Wymagania SLA niezależne od sygnalizacji
- Urządzenia końcowe – terminale – uzgadniają format mediów (kodeki) -> zestawiają kanały logiczne korzystając z kanałów przenoszenia
- Oddzielne kanały logiczne dla audio i wideo
  - Określenie portów UDP wykorzystywanych przez strumienie transportowe RTP
- Kanały audio
  - Wymagania jak dla VoIP
- Kanały wideo
  - Wymagania zazwyczaj niższe niż dla IPTV
- Akceptowalne 80 ms przesunięcia między kanałem audio i wideo

Transmisja danych

Wymagania dla transmisji danych

- Wymagania QoS/QoE słabiej zdefiniowane niż dla głosu i wideo
- Klasyfikacja aplikacji transmisji danych:
  - Interaktywne
  - Bez wymagań odnośnie interaktywności
    - Archiwizacja danych
      - Wymagana odpowiednia przepustowość
- Aplikacje TCP ukierunkowane na przepływność



Definiowanie QoS

QoS?

- Wiele znaczeń terminu QoS
- Usługa w sieciach IP
  - Opis obsługi ruchu klienta w określonej domenie
- Usługa jest użyteczna gdy spełnia oczekiwania aplikacji systemów końcowych, których dane ma przenosić
- Celem usługi jest maksymalizacja satysfakcji użytkownika końcowego z aplikacji korzystającej z danej usługi
- Jakość w kontekście określonej usługi IP
  - Można zdefiniować jakość usług w zakresie podstawowych wymagań dla aplikacji, które mogą być wyrażane w postaci metryk SLA określających wykonanie usługi IP
    - delay, jitter, packet loss, throughput, service availability, and per flow sequence preservation.

3

Definicja QoS

- QoS oznacza więcej niż tylko zapewnienie, że usługa sieciowa jest w stanie sprostać wymaganiom SLA obsługiwanej aplikacji
- Jest to problem zarządzania dostępną pojemnością w zależności od natężenia ruchu
  - Przewymiarowanie
    - Łatwość spełnienia wymagań SLA
    - Nieefektywne kosztowo
  - Minimalizacja kosztów
    - Konieczność zarządzania zasobami w przypadku natłoku
    - Klasyfikacja ruchu do odpowiednich klas

4

Class of Service vs. Type of Service

- Terminy stosowane nieraz zamiennie
  - Czasami w rozumieniu Quality of Service
- Class of service
  - Używany w odniesieniu do parametrów QoS L2
    - Ethernet, ATM
  - Klasyfikacja strumieni ruchu w klasy
    - Traffic class
    - Zbiór strumieniu ruchu traktowanych w ten sam sposób
- Type of service.
  - Odniesienie do 8-bitowego pola w nagłówku pakietu IPv4

5

Best effort

- Termin używany do opisu sieci
  - której celem jest próba dostarczenie pakietów
  - bez gwarancji dostarczenia
    - bez zobowiązań odnośnie opóźnienia, jitter'a, strat, przepustowości
- Termin wielokrotnie niewłaściwie używany
  - Do określenia usług o najniższym SLA w sieciach wielousługowych
  - Określenie IP jako protokołu „best effort"
    - Brak możliwości detekcji / retransmisji straconych pakietów

6

Skale czasu dla QoS

- Skala milisekund
  - Zgęstki ruchu powodujące przeciążenie (natężenie ruchu przekracza dostępną pojemność)
  - Mechanizmy QoS
    - Zarządzanie per węzeł kolejką, szeregowaniem, odrzucaniem
    - Różnicowanie strumienie ruchu
    - Priorytetyzowanie pewnych typów ruchu
    - Zarządzanie przydziałem zasobów – sterowanie opóźnieniem
- Skala setek milisekund
  - RTT dla sieci
  - Istotna dla aplikacji korzystających ze sprzężenia zwrotnego
    - Sterowanie przepływem/przeciążeniem (TCP)
  - Mechanizmy AQM, np. RED
- Skala dziesiątek sekund/minut
  - Planowanie sieci, mechanizmy inżynierii ruchu

Potrzeba rozważań IPQoS

- Technologie L2 (ATM, Ethernet) mają własne mechanizmy QoS
- Istotność mechanizmów IPQoS
  - Najbardziej popularny protokół zapewniający łączność e2e
  - Dodatnie do IP konieczności uwzględniania QoS
- Konieczność opracowania mechanizmów pozwalających wyeliminować przeciążenia dla określonych klas
- Odwzorowanie parametrów QoS L3 w mechanizmy QoS L2
- SLA definiowane w L3 ograniczone SLA L2

Narzędzia QoS

- QoS wymaga zaangażowania szeregu funkcji/mechanizmów, w zależności od architektury sieci (IntServ, DiffServ), w celu zapewnienia możliwości zapewnienia przez sieć charakterystyk SLA wymaganych dla określonych aplikacji
- Mechanizmy funkcjonują w dwóch płaszczyznach
  - Płaszczyzna danych
  - Płaszczyzna sterowania

9

Płaszczyzna danych

- Mechanizmy QoS
  - Bezpośrednio wpływające na przekazywanie pakietów
  - Mocno obciążające węzły
  - Często realizowane sprzętowo
- Kategoryzacja mechanizmów:
  - Klasyfikacja
  - Znakowanie
  - Ograniczanie maksymalnej szybkości bitowej
  - Priorytetyzacja
  - Zapewnienie minimalnej szybkości bitowej

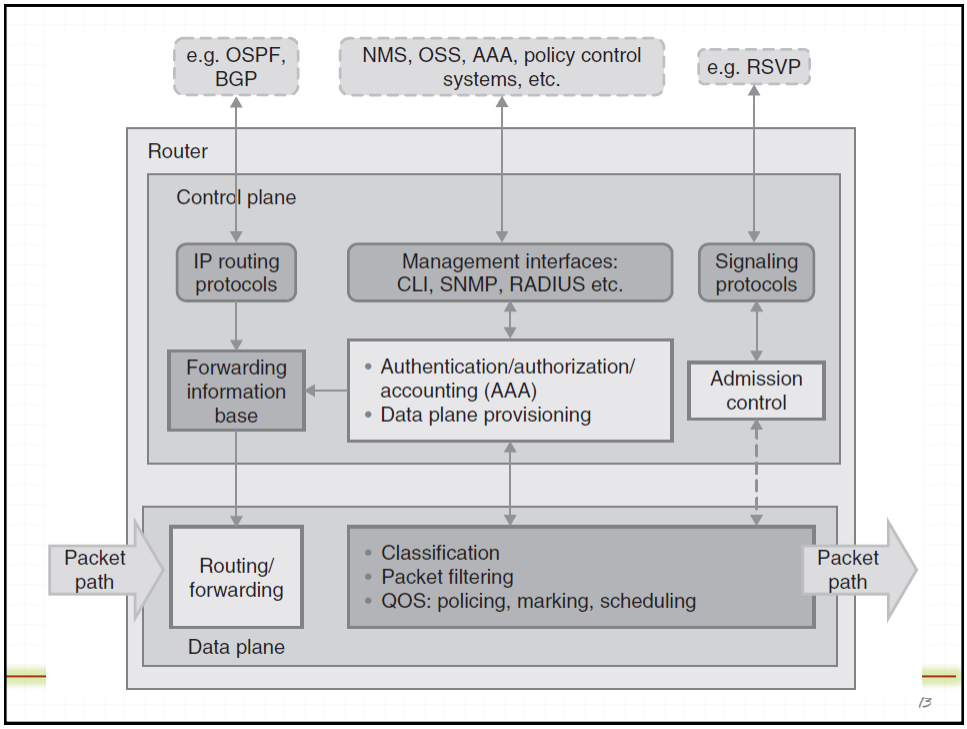
10

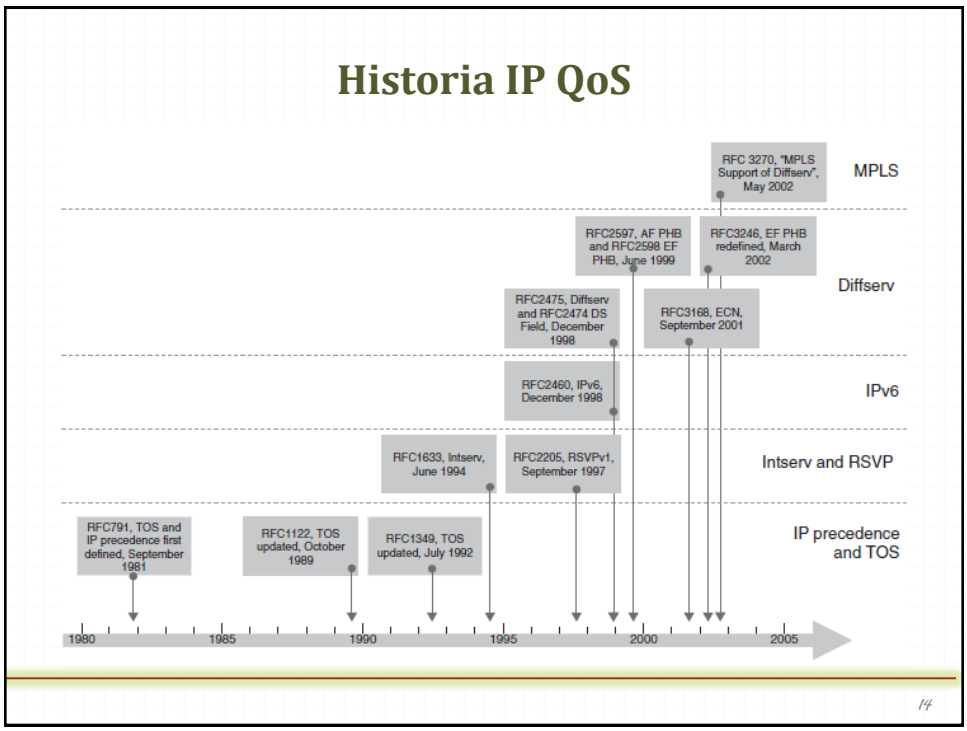
Płaszczyzna danych

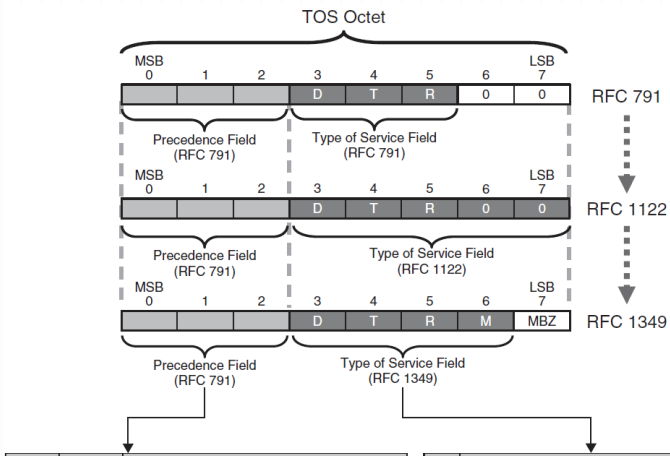
- Klasyfikacja
  - Klasyfikacja pakietów z zagregowanego strumienia ruchu do pewnej liczby klas
    - Możliwość stosowania mechanizmów QoS per klasa
- Znakowanie
  - Jednoznaczne ustawienie pewnej wartości w nagłówku (IP, MPLS) pakietu w celu dalszej prostej i jednoznacznej identyfikacji klasy ruchu
- Ograniczanie maksymalnej szybkości bitowej
  - Policing (nadzór)
  - Kształtowanie (shaping)
- Priorytetyzacja
  - Uprzywilejowanie pewnych klas ruchu przed innymi w celu zarządzania opóźnieniem i jitter'em
- Zapewnienie minimalnej szybkości bitowej
  - Zapewnienie minimalnych zasobów dla różnych klas ruchu
    - Weighted Fair Queuing (WFQ)
    - Deficit Round Robin (DRR) can be used

Płaszczyzna sterowania

- Mechanizmy sterowania i sygnalizacji
  - Sterowanie przyjmowaniem zgłoszeń/sesji/żądań
  - Rezerwacja zasobów
  - Sterowanie mechanizmami z płaszczyzny danych
- Mechanizmy realizowane programowo
- Sygnalizacja
  - RSVP
    - Integrated services architecture
      - Rezerwacja zasobów per przepływ, sterowanie przyjmowaniem przepływów
    - MPLS TE
      - Sygnalizacja tuneli TE
- Architektury: IntServ, DiffServ


e.g. OSPF, BGP
NMS, OSS, AAA, policy control systems, etc.
e.g. RSVP
Router
Control plane
IP routing protocols
Management interfaces: CLI, SNMP, RADIUS etc.
Signaling protocols
Forwarding information base
Authentication/authorization/ accounting (AAA)
Data plane provisioning
Admission control
Packet path
Routing/ forwarding
Classification
Packet filtering
QOS: policing, marking, scheduling
Packet path
Data plane
13


Historia IP QoS
RFC 3270, "MPLS Support of Diffserv", May 2002
MPLS
RFC2597, AF PHB and RFC2598 EF PHB, June 1999
RFC3246, EF PHB redefined, March 2002
Diffserv
RFC2475, Diffserv and RFC2474 DS Field, December 1998
RFC3168, ECN, September 2001
RFC2460, IPv6, December 1998
IPv6
RFC1633, Intserv, June 1994
RFC2205, RSVPv1, September 1997
Intserv and RSVP
RFC791, TOS and IP precedence first defined, September 1981
RFC1122, TOS updated, October 1989
RFC1349, TOS updated, July 1992
IP precedence and TOS
1980
1985
1990
1995
2000
2005
14



Binary	Decimal	Name
111	7	Network Control
110	6	Internet work Control
101	5	Critical and Emergency Call Processing (ECP)
100	4	Flash Override
011	3	Flash
010	2	Immediate
001	1	Priority
000	0	Routine

Bit	Meaning
3	Minimize Delay (D)
4	Maximize Throughput (T)
5	Maximize Reliability (R)
6	Minimize Monetary Cost (M)

15

IP Precedence

- Wykorzystanie tego pola zdefiniowane w RFC 791
  - "An independent measure of the importance of this datagram."
  - Względne priorytetyzowanie pakietów
  - Wprowadzono pewną liczbę określeń ruchu
  - Poszczególne bity pola nie miały indywidualnego znaczenia
    - Istotna całkowita wartość
  - Zapewnia możliwość znakowania pakietów
  - Nie istnieją zalecenia opisujące obsługę ruchu o danej wartości pola IP Precedence – ani bezwzględne, ani względne
    - "Several networks offer service precedence, which somehow treats high precedence traffic as more important than other traffic."

16

Type of Service

- Definicja ewaluowała
  - RFC 791, RFC 1122, RFC 1349
- RFC 1349
  - Wykorzystanie 4 bitów pola TOS field
    - Bity 3-6 oktetu ToS
  - Wskazanie w każdym pakiecie żądnej przez niego obsługi
  - Poszczególne bity mają określone znaczenie
    - Same zera – normalna obsługa
  - Pole TOS nie określa kolejki, do której określone pakiety powinny trafić w węźle
    - Funkcja pola IP precedence
  - Pole TOS określa ścieżkę, którą pakiety powinny być przesyłane

17

Pole ToS

- Znakowanie jest subiektywne
- Nie zdefiniowano, w jaki sposób ma być obsługiwany pakiet z określonym znacznikiem
  - Np. nie zdefiniowano, jak pakiet "minimize delay" powinien być traktowany względem pakietów bez tego znacznika
  - Zgodnie z RFC 1349
    - "setting the TOS field to 1000 (minimize delay) does not guarantee that the path taken by the datagram will have a delay that the user considers 'low'."
- Podobnie w przypadku IP precedence
- RFC 1583 dla OSPF wprowadziło możliwość wyznaczania różnych drzew dla różnych klas usług
  - Nigdy nie zaimplementowano
  - Nowsze RFC 2178 usunęło tę funkcjonalność

18

Type of Service/IP Precedence

- Ograniczenia pól Type of Service/IP Precedence doprowadziły do opracowania architektur Integrated Services i Differentiated Services QOS architectures i zastąpienia pola ToS polem Differentiated Services

19

Implementacja mechanizmów QoS

- Krok 1: Identyfikacja typów ruchu i ich wymagań
  - Audyt sieci
  - Audyt biznesowy
- Krok 2: Podział ruchu na klasy
  - Głos
  - Krytyczne dla działalności firmy
  - O gwarantowanych parametrach QoS
  - Best effort
  - Poniżej best effort
- Krok 3: Definicja polityki QoS dla każdej klasy.

20



Modele QoS

- Dwa modele QoS
  - Model oparty na rezerwowaniu zasobów
  - Model oparty na rozróżnianiu klas ruchu
- Główna różnica:
  - Sposób specyfikowania żądanej jakości usług (sygnalizacja vs. oznaczenie pakietów)

Model QoS oparty na rezerwacji zasobów

- Aplikacje przy pomocy protokołu sygnalizacyjnego zgłaszają sieci swoje wymagania w zakresie przepustowości i opóźnienia
- Węzły sieci przeprowadzają kontrolę dostępności zasobów potrzebnych do zapewnienia żądanego poziomu usługi
- W przypadku dostępności odpowiednich zasobów następuje ich rezerwacja tak, aby dany węzeł sieci mógł świadczyć żądaną jakość usługi
- Rezerwacja gwarantuje aplikacji żądaną jakość usługi, o ile generowany przez nią ruch nie przekracza zgłoszonych parametrów
- Węzeł sieciowy sprawdza i ewentualnie ogranicza ruch do zgłoszonych parametrów, np.
  - model IETF IntServ z użyciem protokołu RSVP

3

Model QoS oparty na rozróżnianiu klas ruchu

- W modelu tym nie ma jawnego zgłaszania przez aplikację wymagań co do jakości usługi, natomiast strumień danych generowany przez aplikację zaliczany jest do jednej z kilku klas ruchu
- Każda klasa ruchu oznaczana jest odpowiednią etykietą zawartą w pakietach danych, na podstawie której węzły sieci dostarczają odpowiedniej jakości usługi
- Węzły sieci nie dostarczają bezwzględnej jakości usług, lecz względną, różnicując ruch na podstawie przynależności do danej klasy
- Model bardzo skalowalny z tego względu, że nie ma konieczności rozpoznawania pojedynczych strumieni danych, przykła:
  - DiffServ

4

Separacja strumieni i dzielenie zasobów

- Brak mechanizmów gwarancji jakości
  - wszystkie zasoby sieci współdzielone na zasadzie współzawodnictwa
- Brak separacji strumieni
  - umożliwia równomierny podział zasobów pomiędzy strumienie i maksymalną efektywność wykorzystania zasobów
  - nie pozwala na różnicowanie jakości usług.
- Szeregowanie = efektywne współdzielenie zasobów
  - Kompromis pomiędzy separacją strumieni, niezbędną do zapewnienia jakości usług, a współdzieleniem zasobów, wymaganym do maksymalizacji efektywności wykorzystania zasobów

5

Ograniczenie opóźnień

- Rodzaje ograniczeń opóźnienia w sieciach
  - deterministyczne
  - Statystyczne
- Rozwiązania oparte na separacji strumieni i współdzieleniu zasobów sieci.

6

Deterministyczne ograniczenia opóźnień

- Wprowadzają maksymalną separację strumieni za cenę znacznej redukcji możliwości stosowania zwielokrotniania statystycznego strumieni.
- Konieczne stosowanie nadmiarowej rezerwacji zasobów, w ilościach gwarantujących zachowanie żądanej jakości usług dla tzw. najgorszego przypadku.
- Wymuszone stosowanie mechanizmów, których zadaniem jest ograniczenie „wybuchowości" źródła ruchu.

7

Statystyczne ograniczenia opóźnień

- Charakterystyczne dla rozwiązań opartych na współdzieleniu zasobów sieci
- Ograniczenia opóźnienia pakietów są obarczone wadami i zaletami różnych sposobów współdzielenia zasobów.

8

Sprawiedliwość i zapewnienie obsługi

- Wielkość dostępnych zasobów mniejsza od sumy żądanych zasobów
  - odrzucanie strumieni albo
  - sprawiedliwe współdzielenie zasobów pomiędzy rywalizujące strumienie
- Odrzucanie strumieni
  - możliwe zachowanie jakości usług dla strumieni pozostawionych do obsługi w sieci i całkowita degradacja jakości usług dla strumieni odrzucanych
- Sprawiedliwe współdzielenie zasobów
  - Gwarancja dostępu do zasobów wszystkim strumieniom
  - Pogorszeniu mogą ulec średnie parametry określające jakość usług.

Trzy modele QoS

Model	Characteristics
Best effort	Brak QoS. Nieistotne kiedy i jak zostaną dostarczone pakiety
Integrated Services (IntServ)	Aplikacje dzięki protokołom sygnalizacji informują sieć o żądanych parametrach QoS
Differentiated Services (DiffServ)	Sieć rozpoznaje klasy strumieni, które żądają/otrzymują odpowiednie parametry QoS

Model Best-Effort

- Internet zaproponowany jako sieć dostarczająca pakiety na zasadzie best-effort.
- Best-effort jest domyślnym trybem dla całego ruchu.
- Brak rozróżnienia między typami strumieni.
- Podobieństwo modelu best-effort do usługi standardowej poczty – "The mail will arrive when the mail arrives."
- Zalety:
  - Wysoka skalowalność
  - Nie są wymagane żadne specjalne mechanizmy
- Wady:
  - Brak gwarancji usług
  - Brak rozróżniania usług

11

Technologie sieciowe
Integrated Services Internet (ISI)

- Różnicowanie usług może odbywać się na poziomie:
  - pojedynczych strumieni (ang. per-flow)
    - określanych przez źródłowy adres IP, numer portu źródłowego, docelowy adres IP, numer portu docelowego oraz protokół (UDP, TCP)
    - bardzo dobra ochrona każdego ze strumieni przed wpływem innych aplikacji;
    - problemy ze skalowalnością
  - zagregowanych strumieni
    - pakiety są grupowane w kilka klas ruchu, na podstawie podobnych wymagań QoS, niezależnie od adresu źródłowego i docelowego
    - dobra skalowalność
    - niższa złożoność sterowania

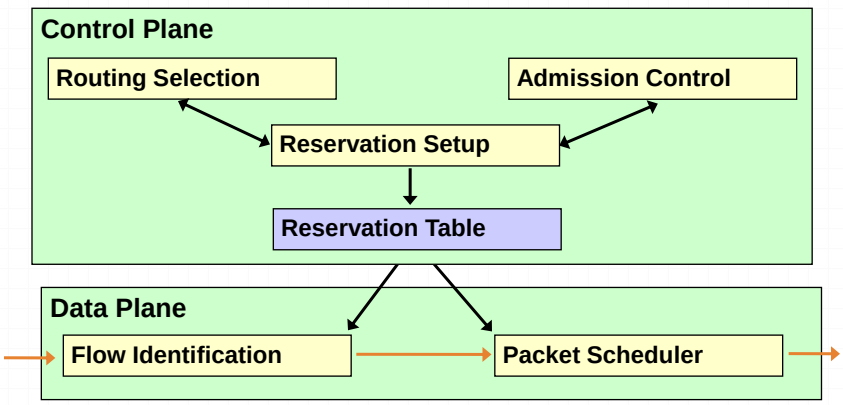
12

Model IntServ

- Gwarancja dostarczenia i przewidywalne zachowanie sieci względem aplikacji
- Zapewnienie wielu poziomów obsługi
- RSVP – protokół sygnalizacyjny dla parametrów QoS
- Żądane parametry QoS powiązane są ze strumieniem pakietów
- Strumienie nie są ustanowione, jeżeli żądane parametry QoS nie mogą być spełnione
- Inteligentne mechanizmy kolejkowania

13

Funkcje IntServ



14

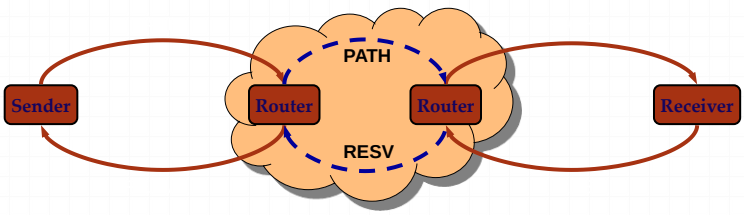
Technologie sieciowe
Integrated Services (IntServ)

- Definiowanie parametrów jakościowych dla pojedynczych strumieni (ang. per-flow)
- Rezerwacja zasobów w ruterach w celu zapewnienia QoS dla określonych strumieni
- Protokołem rezerwacji zasobów jest protokół RSVP

15

Integrated Services (IntServ)
RSVP

- RSVP jest używany przez hosty lub aplikacje do rezerwacji w sieci IP zasobów koniecznych do zapewnienia żądanych parametrów QoS określonym strumieniom ruchu.



16

Integrated Services (IntServ)
RSVP

- RSVP wykorzystuje zasadę starzenia się informacji (ang. soft state), wysyłając cyklicznie wiadomości nadzorujące zarezerwowane połączenie
- Jeżeli wiadomości takie się nie pojawią, to połączenie jest usuwane
- Rezerwacja zasobów na poziomie pojedynczych strumieni powoduje poważne problemy ze skalowalnością, w szczególności w sieci szkieletowej (kolejka dla każdego pojedynczego strumienia)

17

Technologie sieciowe
Differentiated Services (DiffServ)

- DiffServ została zaproponowana przez IETF w celu przezwyciężenia ograniczeń architektury IntServ
- W architekturze DiffServ pakiety są klasyfikowane w ruterach brzegowych do kilku klas usług QoS (zagregowanych strumieni ruchu), którym nadaje się różne poziomy obsługi
- Klasyfikacja pakietów następuje na podstawie informacji zawartej w nagłówku pakietu IP (DS CodePoint - przedefiniowane pole TOS)

18

Technologie sieciowe
Differentiated Services (DiffServ)

- Zawartość DSCP kojarzy dany pakiet z odpowiednią grupą PHB (Per Hop Behaviour), która określa sposób jego obsługi
- PHB określa sposób obsługi danego strumienia pakietów w sposób względny, tzn. w stosunku do innych PHB
- Odwzorowanie DSCP na PHB nie jest ustalone na stałe w każdym węźle
- Ustawienie bitów DSCP następuje przed wprowadzeniem pakietu do domeny DiffServ
- Dwie podstawowe zalety architektury DiffServ
  - kompleksowa obsługa na brzegu sieci,
  - nieskomplikowane przesyłanie w sieci szkieletowej

19

Technologie sieciowe
MPLS

- Nowa technologia dla sieci Internet
- Połączenie
  - datagramu
  - obwodu wirtualnego
- Tradycyjny ruting
  - pakietów IP
    - każdy pakiet niezależnie, od węzła do węzła, na podstawie adresu docelowego i informacji w tabeli rutingu
  - ATM, Frame Relay
    - przed przesłaniem pakietów zestawiane jest połączenie (obwód wirtualny)

20

Technologie sieciowe
MPLS

- Charakterystyka
  - wykorzystanie krótkich etykiet o stałej długości, umieszczanych w nagłówku pakietu
  - Label Switching Router (LSR) podejmuje decyzję o dalszej drodze pakietu na podstawie etykiety
  - LSR zmienia wartość etykiety
    - zmiana etykiety może być sterowana specjalnymi modułami
  - Label-Switched Path (LSP) – ścieżka, którą są przesyłane pakiety w domenie MPLS
    - Odwzorowywanie (mapowanie) etykiet jest ustalone
  - Możliwość budowy sieci VPN
  - Dokładniej o MPLS/GMPLS



Klasyfikacja

Klasyfikacja

- Flow – przepływ
  - W IPv4 definiowany przez 5 parametrów
    - Adres IP źródłowy
    - Adres IP docelowy
    - Port UDP/TCP źródłowy
    - Port UDP/TCP docelowy
    - Protokół warstwy transportowej
  - Czynniki utrudniające klasyfikację przepływów – niedostępność pewnych pól
    - Fragmentacja
      - Brak możliwości identyfikacji kolejnych pakietów przepływu
    - Szyfrowanie
    - Tunelowanie
    - Rozwiązanie w IPv6
      - Flow Label
- Stream
- Class

3

Klasyfikacja

- Flow – przepływ
  - W IPv4 definiowany przez 5 parametrów
    - Adres IP źródłowy
    - Adres IP docelowy
    - Port UDP/TCP źródłowy
    - Port UDP/TCP docelowy
    - Protokół warstwy transportowej
  - Możliwość użycia bardziej zaawansowanych kryteriów
  - Czynniki utrudniające klasyfikację przepływów – niedostępność pewnych pól
    - Fragmentacja
      - Brak możliwości identyfikacji kolejnych pakietów przepływu
    - Szyfrowanie
    - Tunelowanie
    - Rozwiązanie w IPv6
      - Flow Label
- Stream
- Class

4

Klasyfikacja

- Flow – przepływ
- Stream – traffic stream – strumień (ruchu)
  - Strumień ruchu
  - Przepływy zagregowane na podstawie wspólnego kryteriów klasyfikacji
  - Jeden lub wiele przepływów
  - Ruch VoIP wprowadzany przez określoną bramę VoIP
- Class – traffic class – klasa (ruchu)
  - Zagregowane strumienie ruchu lub przepływy
  - Agregacja na potrzeby stosowania wspólnych mechanizmów dla składowych strumieni lub przepływów
  - Może reprezentować cały ruch VoIP z określonej lokalizacji, wprowadzany przez wiele bram VoIP
  - Może obejmować jeden bądź wiele strumieni

5

Typy klasyfikacji

- Implicit
- Complex
- Deep Packet Inspection/Stateful Inspection
- Simple

6

Klasyfikacja „Implicit”

- „Zgrubna” klasyfikacja na potrzeby IP QoS
- Nie wymaga wiedzy o nagłówku lub zawartości pakietu
- Może wykorzystywać parametry L1
  - Interfejs wejściowy
- Może wykorzystywać parametry L2
  - Kanał wirtualny

Klasyfikacja złożona - wielopolowa

- Określenia
  - Complex
  - multi-field
- Pozwala na bardziej szczegółową klasyfikację
- Może uwzględniać określone pola nagłówka lub kombinacje tych pól
  - Niekoniecznie dedykowanych klasyfikacji QoS
  - Obejmuje 5 parametrów opisujących przepływ
- Może uwzględniać parametry L2
  - Adresy MAC (źródłowy, docelowy)

Szczegółowa analiza

- Określenia
- Klasyfikacja wykorzystująca nie tylko pojedynczy nagłówek IP
- Analiza sięgająca danych zawartych w pakiecie
  - Deep Packet Inspection (DPI)
- Klasyfikacja na podstawie sekwencji pakietów
  - Stateful Inspection (SI)
- Klasyfikacja wykorzystująca równocześnie DPI i SI
  - Wykorzystywana do klasyfikacji aplikacji, np. p2p
  - Aplikacja p2p wnoszą duże obciążenie do sieci
  - Celowe utrudnianie ich wykrycia

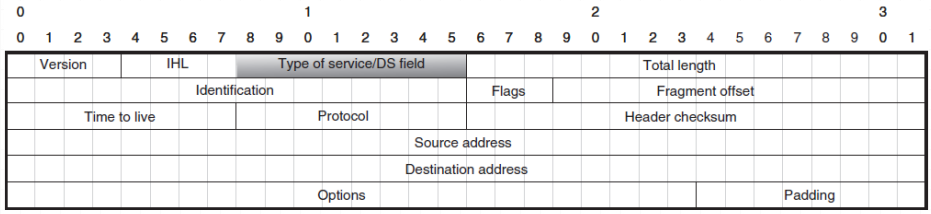
9

Prosta klasyfikacja

- Termin „simple classification”
- Klasyfikacja oparta na polach nagłówka przewidzianych do celów QoS
- Klasyfikacja IP i MPLS
  - Oktet IPv4 Type of Service
  - Oktet IPv6 traffic class
  - Pole Differentiated Service
  - Pole MPLS EXP
  - Znaczniki L2, np. 802.1d

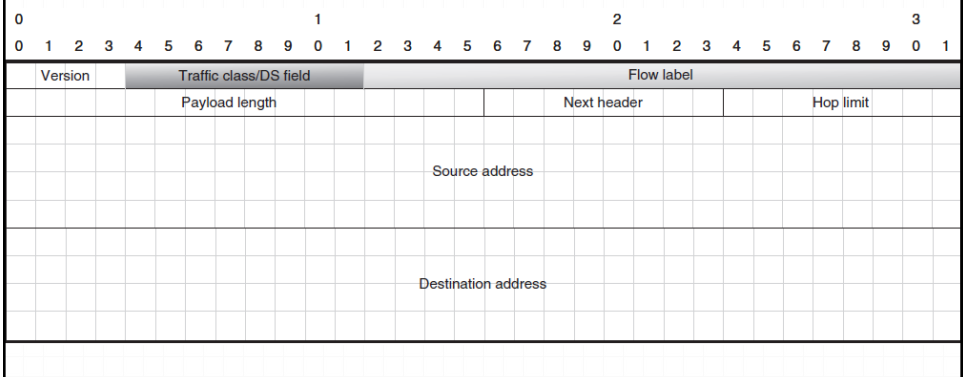
10

ToS



11

Traffic Class



12

Differentiated Service

- Zgodnie z RFC2474 zastąpiło pola
  - Type of Service IPv4
  - Traffic Class IPv6
- 6 z 8 bitów pola DS zdefiniowano jako Differentiated Services code point
  - Dwa najmniej znaczące bity początkowo niezdefiniowane
    - Zgodnie z RFC3168 – zdefiniowane jako ECN Explicit Congestion Notification (ECN)

13

Inne pola

- MPLS EXP
  - RFC3032 – 3 bity dla “experimental use.”
  - RFC3270 – znakowanie QoS
- Znaczniki L2
  - Ethernet – standard 802.1D
    - 3 bitowe pola

14

Możliwości klasyfikacji

- Klasyfikacja może łączyć kryteria klasyfikacja prostej i złożonej
  - Iloczyn logiczny: określony interfejs i określona wartość pola DS.
- Powody rozróżniania klasyfikacji prostej i złożonej
  - Wpływ na złożoność i skalowalność uzyskanego rozwiązania QoS
  - Ręczna klasyfikacja na podstawie adresów – problem ze skalowalnością
  - Złożona klasyfikacja – wpływ na wydajność ruterów
- „Ręczne” klasyfikowanie nie jest stosowane
  - Integrated Services
    - RSVP
  - Differentiated Services
    - Pole DSCP

15

Znakowanie

Marking

16

Znakowanie

- Nazywane jako kolorowanie
- Zapewnienie możliwości rozróżniania strumieni o różnych wymaganiach QoS
- Typowe znaczniki:
  - Warstwa łącza:
    - CoS (ISL, 802.1p)
    - Bity MPLS EXP
    - Frame Relay
  - Warstwa sieci:
    - DSCP
    - IP precedence

17

Klasyfikacja i znakowanie w sieciach LAN z 802.1Q/p

- W polu TCI dwubajtowym występuje m.in. pole PRI
- W IEEE 802.1p pole priorytetu określone jest jako CoS
- Pole PRI – 3 bity
  - Do ośmiu CoS
- Celem IEEE 802.1p jest zapewnienie QoS w sieciach LAN 802.1!
- IEEE 802.1p jest zachowane jedynie w sieciach LAN, nie obowiązuje e-2is preserved through the LAN, not end to end.

18

Klasyfikacja i znakowanie w sieciach LAN z 802.1Q/p

- CoS
  - 7 – zarezerwowane
  - 6 – zarezerwowane
  - 5 – przenoszenie głosu
  - 4 – wideokonferencje
  - 3 – sygnalizacja zgłoszeń
  - 2 – dane o wysokim priorytecie
  - 1 – dane o średnim priorytecie
  - 0 – dane best-effort

19

Klasyfikacja i znakowanie w sieciach WAN

- Możliwość znakowania dzięki nagłówkom FrameRelay
- Wykorzystanie w MPLS pole EXP

20

Znakowanie pakietów IP

- Ustawianie wartości pól służących do klasyfikacji QoS w nagłówkach IP lub MPLS w celu dalszej prostej identyfikacji ruchu
- Dominujące rozwiązania
  - DSCP
  - MPLS EXP
- Miejsce znakowania
  - Urządzenie źródłowe – source making
  - Na wejściu do sieci - Ingress marking

21

Znakowanie w źródle informacji

- Problem zaufania do urządzenia końcowego
- Ustawiony znacznik wykorzystywany w sieci

22

Znakowanie „na wejściu”

- Stosowane, gdy
  - Urządzenie źródłowe nie ma możliwości przeprowadzenia znakowania
  - Urządzenie źródłowe nie jest zaufane
- Znakowanie proste lub złożone przez zaufane urządzenie możliwie jak najbliżej źródła
- Może być użyte do zmiany „remarking” znakowania przeprowadzonego w urządzeniu źródłowym
  - Brak zaufania
- Niezależnie od zaufania w zakresie znakowania, nadzór (policer) nad parametrami wprowadzonego ruchu nadal może być stosowany
  - Ruch zgodny z kontraktem bez mian klasyfikacji
  - Ruch przewyższający kontrakt – zmiana klasyfikacji zastosowanej przez urządzenie źródłowe

23

IP Precedence i DiffServ Code Points

- IPv4
  - 3 najbardziej znaczące bity ToS nazywane są jako IP Precedence (IPP); pozostałe nie są używane
- DiffServ
  - Sześć najbardziej znaczących bitów bajtu ToS nazywane DiffServ Code Point (DSCP);
  - pozostałe dwa używane do sterowania przepływem
- DSCP jest kompatybilne wstecz z IP precedence

24

Zachowanie Per-Hop

- DSCP określa PHB w sieci:
  - Domyślne PHB (FIFO, tail drop)
  - Class-selector PHB (IP precedence)
  - EF PHB
  - AF PHB

25

Expedited Forwarding (EF) PHB

- EF PHB:
  - Gwarantuje minimalną szybkość wyprowadzania danych
  - Gwarantuje przepływność
  - Nadzór nad przepływnością (nadmiar ruchu usuwany)
- Wartość DSCP 101110
  - Zgodność z IP precedence 5 dla urządzeń niekompatybilnych z DiffServ:
  - Bity 5 do 7: 101 = 5 (te same 3 bity używane do IP precedence)
  - Bity 3 i 4: 11 = brak określonego prawdopodobieństwa odrzucenia
  - Bit 2: wartość 0

26

Assured Forwarding (AF) PHB

- AF PHB:
  - Gwarancja przepływności
  - Zezwala na dostęp do dodatkowej przepływności (o ile dostępna)
- 4 standardowe klasy: AF1, AF2, AF3, and AF4
- Zakres wartości DSCP aaadd0:
  - aaa – binarna wartość klasy
  - dd – prawdopodobieństwo odrzucenia

27

Odwzorowanie CoS w QoS

- DSCP mogą być odwzorowane w CoS 802.1Q i vice versa
- DSCP mogą być odwzorowane w MPLS EXP i vice versa

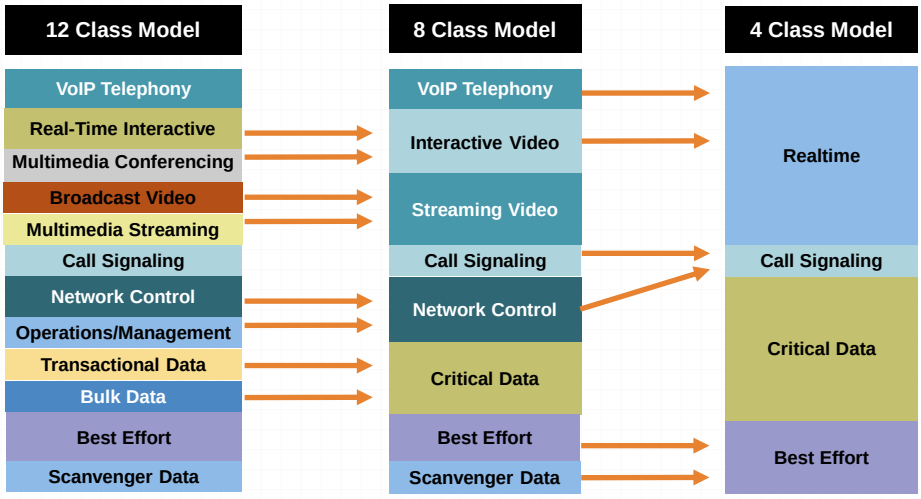
28

RFC Guidelines for Traffic Classes

Application	L3 Classification			IETF	L2
	IPP	PHB	DSCP	RFC	CoS
Network Control	6	CS6	48	RFC 2474	6
VoIP Telephony	5	EF	46	RFC 3246	5
Call Signaling	5	CS5	40	RFC 2474	5
Multimedia Conferencing	4	CS4	34	RFC 2597	4
Real-Time Interactive	4	AF41	32	RFC 2474	4
Multimedia Streaming	3	AF31	26	RFC 2597	3
Broadcast Video	3	CS3	24	RFC 2474	3
Low-Latency Data/Transactional Data	3	AF21	18	RFC 2597	3
Operations/Management	3	CS2	16	RFC 2474	2
High-Troughput Data/Bulk Data	1	AF11	10	RFC 2597	1
Best Effort	0	DF	0	RFC 2474	0
Low-Priority/Scanvenger Data	1	CS1	8	RFC 3662	1

29

The 4-, 8-, and 12-class Traffic Models



30

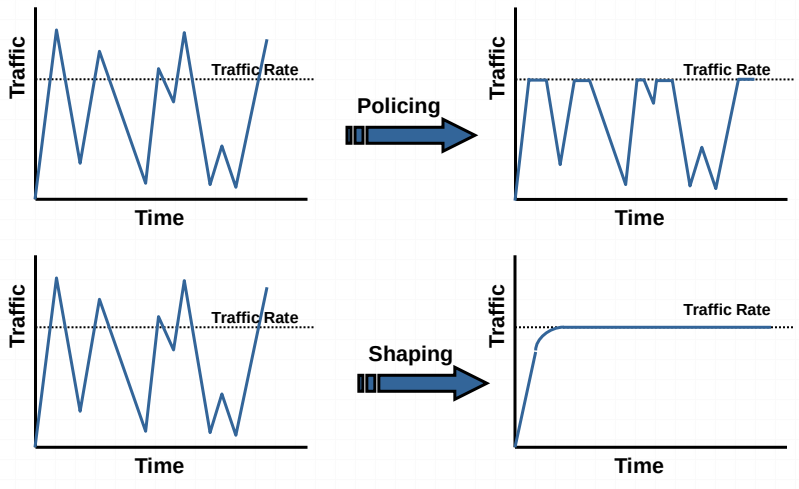
Ustalanie wymagań w stosunku do QoS

- Aby strumień danych otrzymał wymaganą jakość usług, każdy węzeł sieci musi być powiadomiony o tych wymaganiach
- Wyróżniamy dwie metody powiadamiania o wymaganiach na jakość usług
- Etykietowanie pakietów
  - powiadamianie poprzez oznaczanie pakietów
- Sygnalizacja
  - powiadamianie poprzez specjalny protokół

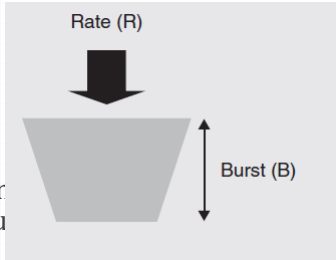
Nadzór i pomiary

Policing and Metering

Traffic Policing i Traffic Shaping



Nadzór



- Nadzór – policing
  - Mechanizm wymuszający nieprzekraczar natężenia ruchu (intensywności napływu
  - Token bucket
    - Mechanizm odmienny od „leaky bucket”
- Prosty algorytm token bucket
  - Pojemność/głębokość wyrażona w bajtach – B
  - Szybkość wyrażona w b/s – R
- Minimalna liczba tokenów – 0
- Maksymalna liczba tokenów – B
- Dodawanie tokenów
  - Stała intensywność
  - Po przetworzeniu pakietu

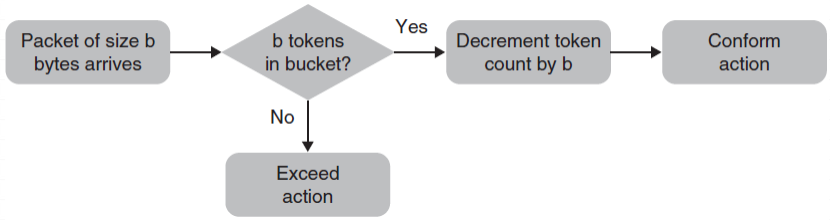
3

Token bucket

- Dla każdego z pakietów określonego strumienia porównywany jest rozmiar pakietu b z liczbą dostępnych tokenów w wiadrze
  - Liczba bajtów/tokenów w wiadrze >=b
    - Spełnia
    - Pakiety wysyłany – najprostsza decyzja
    - Liczba dostępnych bajtów w wiadrze zmniejszana o b
  - Liczba bajtów/tokenów w wiadrze < b
    - Strumień przekroczył ustalenia
    - Pakiet odrzucany – najprostsza decyzja; inne decyzje też możliwe
      - Wymuszenie maksymalnej szybkości R i rozmiaru zgęstki B
    - Możliwe różne działania

4

Token bucket



5

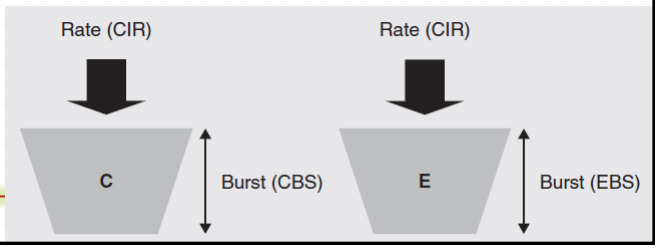
Nadzór

- Mechanizm token bucket można także wykorzystać do znakowania pakietów
  - Pakiety spełniające kontrakt
  - Pakiety niespełniające kontraktu
    - Mogą być przesłane
    - Specjalnie znakowane
- Mechanizm token bucket nie opóźnia ruchu, w przeciwieństwie do mechanizmów kształtowania ruchu
  - Pakiety nie czekają w wiadrze
  - Brak możliwości zmiany kolejności lub priorytetu
    - Możliwe dla mechanizmów szeregowania pakietów

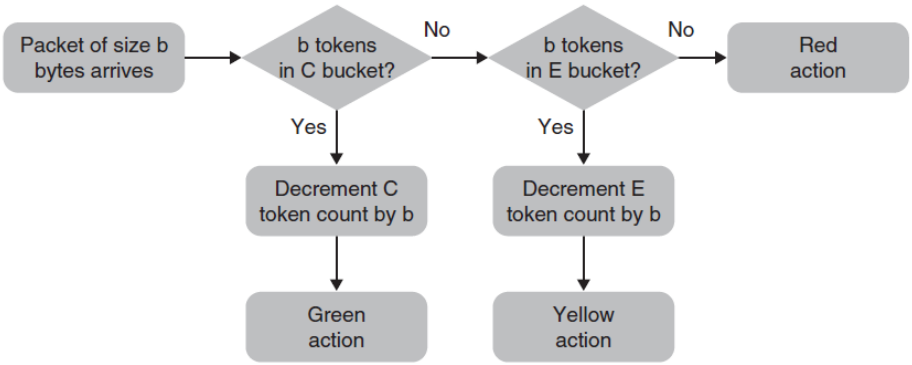
6

RFC 2697: Single Rate Three Color Marker

- Popularny nadzorca
  - SR-TCM
  - IETF RFC 2697
- Służy nadzorowi i znakowaniu
- Trzy kolory
  - Trzy możliwe stany
- Dwa wiadra
  - C – committed
    - CBS
  - E –excess
    - EBS



Znakowanie 3 kolorami



Znakowanie 3 kolorami

- CIR i CBS muszą być > 0
  - Inaczej wszystkie pakiety czerwone
- EBS = 0
  - Tylko dwa stany (zielony, czerwony)
- Pakiety zielone
  - Przesyłane
  - Mogą być znakowane
- Pakiety żółte
  - Przesyłane
  - Mogą być znakowane
  - Gdy EBS=0 -> odrzucane
    - Brak różnicy między czerwonymi i żółtymi.
- Pakiety czerwone
  - Mogą być przesyłane, odrzucane, znakowane

9

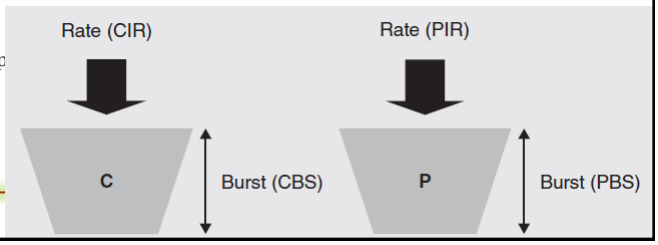
Typowe wykorzystanie SR-TCM dla EBS = 0

- Wymuszanie maksymalnej szybkości dla głosu z EBS = 0
  - Zielony – przesyłanie
  - Czerwony – odrzucanie
  - Efekt
    - Wymuszanie maksymalnej szybkości CIR
    - Wymuszanie rozmiaru zgęstki CBS
    - Ruch niespełniający parametrów – odrzucany (np. EF w DiffServ).
- Znakowanie ruchu do określonego natężenia jako spełniającego kontrakt
  - Kolor zielony, przesyłanie
- Znakowanie ruchu powyżej określonego natężenia jako niespełniającego kontraktu
  - Kolor czerwony, przesyłanie połączone ze znakowaniem (np. AF)

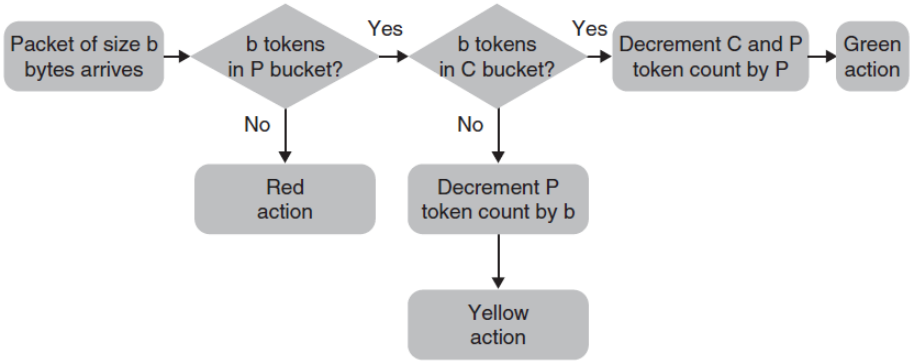
10

RFC 2698: Two Rate Three Color Marker

- Mechanizm nadzoru/znakowania
- RT-TCM
  - two rate three color marker
- Charakterystyka
  - Dwa wiadra
    - C – rozmiar CBS
    - P – rozmiar PBS
  - Różnice w szybkości napełniania wiader
    - C
      - z szybkością CIR
    - P
      - z szybkością PIR (p
  - PIR > CIR
  - PBS > CBS

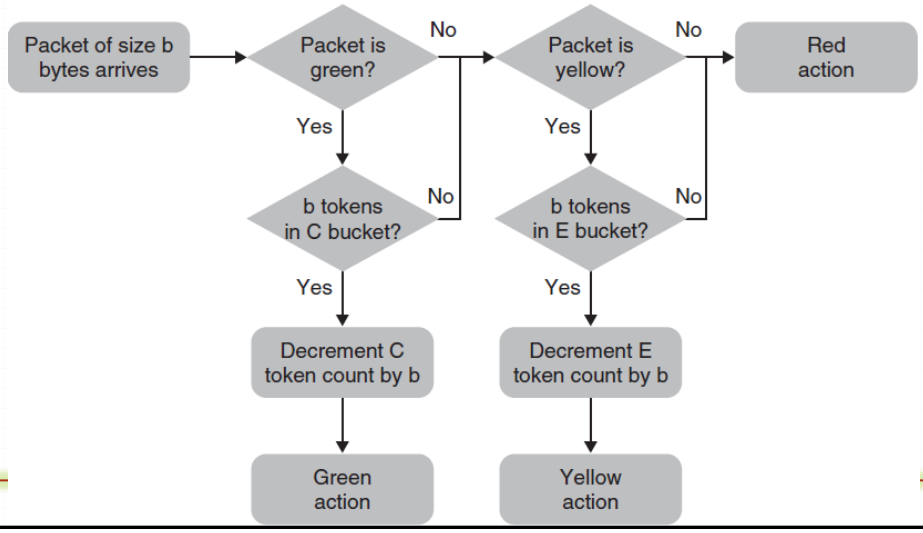


TR-TCM

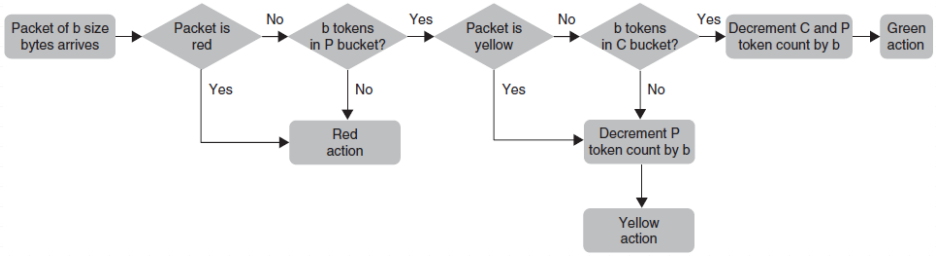


12

Nadzorcy świadomi koloru – RFC 2697



Nadzorcy świadomi koloru – RFC 2698



Pomiary ruchu – metering

- Pomiary intensywności strumieni i rozmiarów zgęstek w celach rozliczeniowych lub pomiarowych
- Prosta metoda pomiaru
  - Zastosowanie nadzorcy SR lub TR
    - Niezależnie od koloru – przesyłanie danych
    - Zliczanie pakietów o określonym kolorze
      - Przepuszczonych, odrzuconych

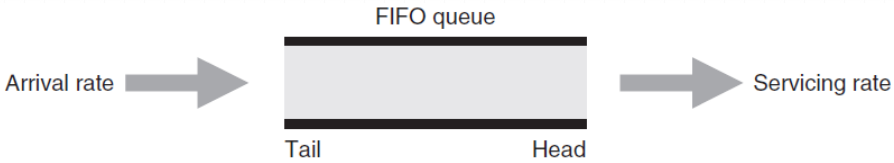


Wprowadzenie

- Contention – natłok
  - Żądania przekraczają zasoby
- Szeregowanie
  - Wpływ na obsługę konkretnych żądań
    - Czas, kolejność
  - Możliwość zmiany kolejności
    - Tylko gdy żądania są kolejkowane/opóźniane

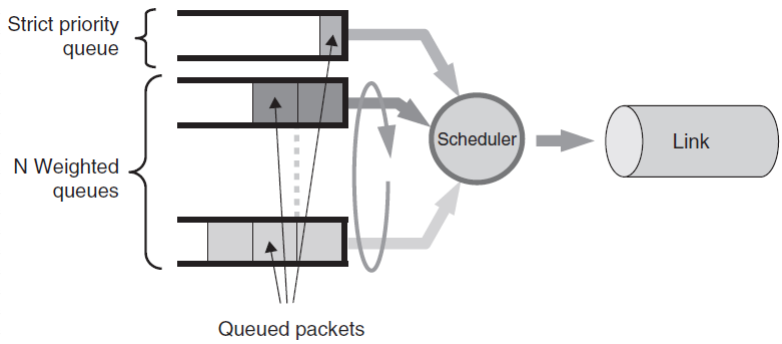
Kolejkowanie i szeregowanie

- Kolejka na lotnisku
  - Zmiana długości w zależności od intensywności napływania pasażerów
  - Wpływ klasy (ekonomiczna, biznesowa)



3

Kolejkowanie i szeregowanie



4

Szeregowanie priorytetowe

- Priority Scheduling
- Kolejka dedykowana dla transmisji głosu/wideo
- Z wywłaszczaniem (pre-emptive)
  - Przerwania
    - Na poziomie pakietowym
      - Przerywana obsługa pakiety o niższym priorytecie
      - Najniższe opóźnienie dla priorytetowej kolejki
      - Transmisję „przerwanego" pakiety trzeba będzie powtórzyć
    - Na poziomie kwantowym
      - Przerwanie obsługi kolejki o niższym priorytecie
      - Nie jest przerywana obsługa pakietu
      - Stosowana praktycznie
- Bez wywłaszczania (non-pre-emptive)
- Ograniczanie zasobów dostępnych dla kolejki priorytetowej

5

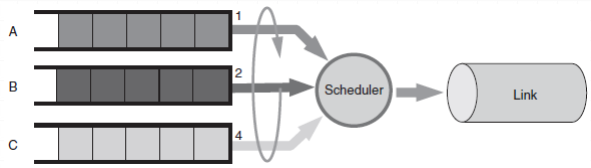
Mechanizmy grupy Weighted Bandwidth Scheduling

- Brak pakietów w kolejkach priorytetowych
  - Możliwość obsługi pozostałych kolejek
- Kolejki nie-priorytetowe zazwyczaj obsługiwane zgodnie z przydzielonym im udziałem w zasobach łączy wyjściowych
- Mechanizm szeregowania
  - Określa udział/wagę każdej z kolejek
  - Wpływa na opóźnienia pakietów w poszczególnych kolejkach
  - Może uwzględniać intensywność zapełniania kolejek
- Kolejki mogą być przypisane
  - Poszczególnym przepływom (flows)
    - Integrated Services
  - Klasom ruchu
    - of Differentiated Services
- Różne warianty

6

Weighted Round Robin

- Kolejki ABC
  - Wagi 1, 2 , 4
  - Obsługa 1, 2 i 4 pakietów z kolejek A, B C
  - A, B, B, C, C, C, C, A, B, B, C, C, C, C, A . . .



7

Weighted Round Robin
Przykład 1

- Wagi wyrażone w liczbie pakietów
- Gdy wszystkie pakiety o jednakowym rozmiarze
  - Udział w zasobach łącza wyjściowego w tych samych proporcjach
- Dla łącza 512 kb/s
  - Kolejka A otrzyma 1/(1+2+4) * 512 = ~73 kbps
    - 14%
  - Kolejka B otrzyma 2/(1+2+4) * 512 = ~146 kbps
    - 29%
  - Kolejka C otrzyma 4/(1+2+4) * 512 = ~ 293 kbps
    - 57%
- Układa szeregowania zapewnia minimalny udział w zasobach
- Konfiguracja
  - Wagi
  - kb/s

8

Weighted Round Robin
Przykład 1

- Zasoby przydzielone „pustej” kolejce mogą być dzielone na „aktywne” kolejki
  - Proporcjonalnie do wag
  - Tzw. mechanizmy “work conserving”
    - Nie pracują, gdy żadna kolejka nie zawiera pakietów
    - Typowy dla IP
- Zasoby „pustej” kolejki nie muszą być dzielone proporcjonalnie do wag
- Ocena jakości układu szeregowania pakietów
  - Uzyskanie założonego udziału w zasobach łączy
    - Sprawiedliwość – fairness
  - WRR jest sprawiedliwy
    - Dla pakietów o równym rozmiarze
    - Dla pełnego cyklu
  - WRR jest sprawiedliwy w zakresie wartości średnich
    - Równa średnia długość pakietu
  - Możliwość zmiany wag w zależności od długości pakietu

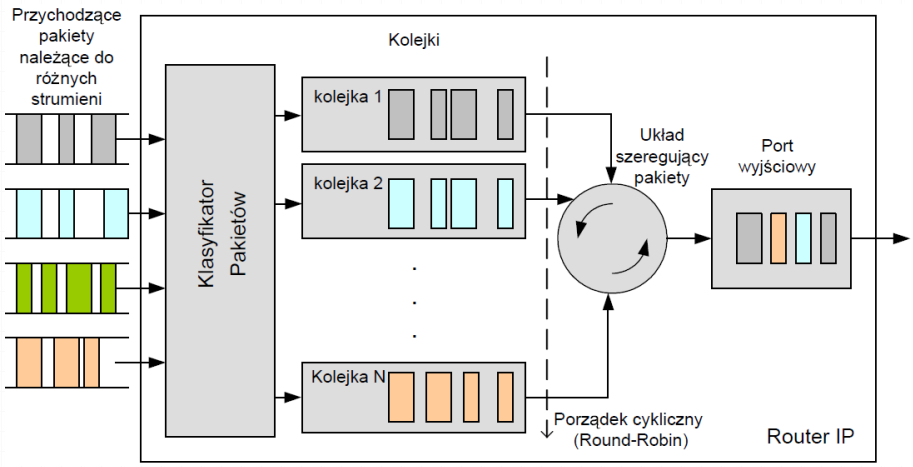
9

Weighted Round Robin
Przykład 2

- Rozmiary pakietów w kolejkach różne
  - Kolejka A – 64 bajty
  - Kolejka B – 1500 bajtów
  - Kolejka C – 300 bajtów
- Łącze wyjściowe
  - 512 kb/s
- Wagi 1, 2, 4
- Uzyskany udział w zasobach:
  - Kolejka A: 512 * (1 * 64)/((1 * 64) + (2 * 1500) + (4 * 300)) =~8 kbps
  - Kolejka B: 512 * (2 * 1500)/((1 * 64) +(2 * 1500)+(4 * 300)) =~360 kbps
  - Kolejka C: 512 * (4 * 300)/((1 * 64)+(2 * 1500)+(4 * 30)) =~144 kbps
  - **Udział daleki od zamierzonego: 1:2:4**

10

Fair Queuing



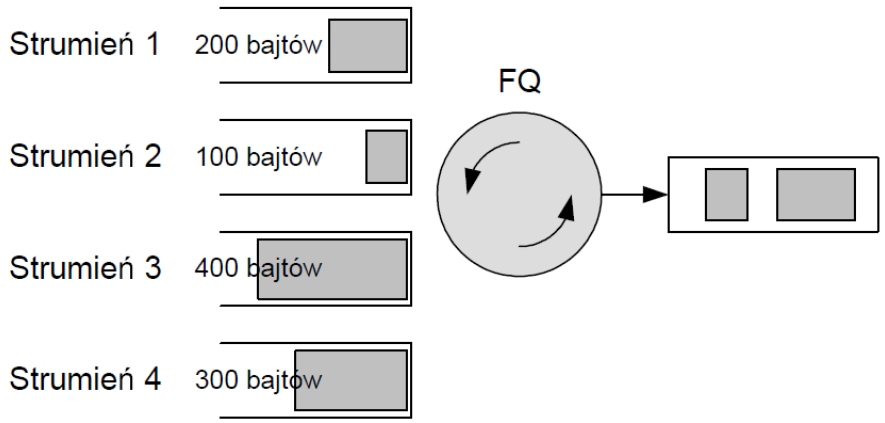
11

Fair Queuing



12

Niesprawiedliwy podział pasma



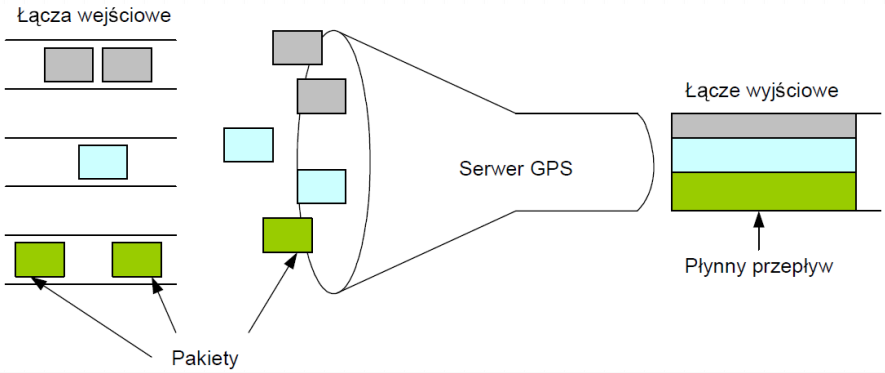
13

Problemy z WRR

- Długość pakietów zmienna w czasie
  - Trudność w uwzględnieniu długości pakietu w określeniu wagi
  - Prowadzi do niesprawiedliwości w udziale w zasobach
- Sprawiedliwość mierzona w odniesieniu do wyidealizowanego schematu Generalized Process Sharing (GPS)
- GPS
  - W każdym cyklu obsługa nieskończenie małej części pakietu (1 bit) z każdej kolejki
    - Idealizacja – jednostką w rzeczywistości jest pakiet
  - Układ szeregowania odwiedza wszystkie niepuste kolejki w skończonym przedziale czasowym (round robin na poziomie pojedynczego bitu)
    - Zapewnia sprawiedliwość dostępu do zasobów
  - Kolejki mogą mieć przypisane wagiA GPS scheduler is idealized in that it assumes that queues can be
- Rzeczywiste mechanizmy szeregowania emulują GPS

14

GPS



15

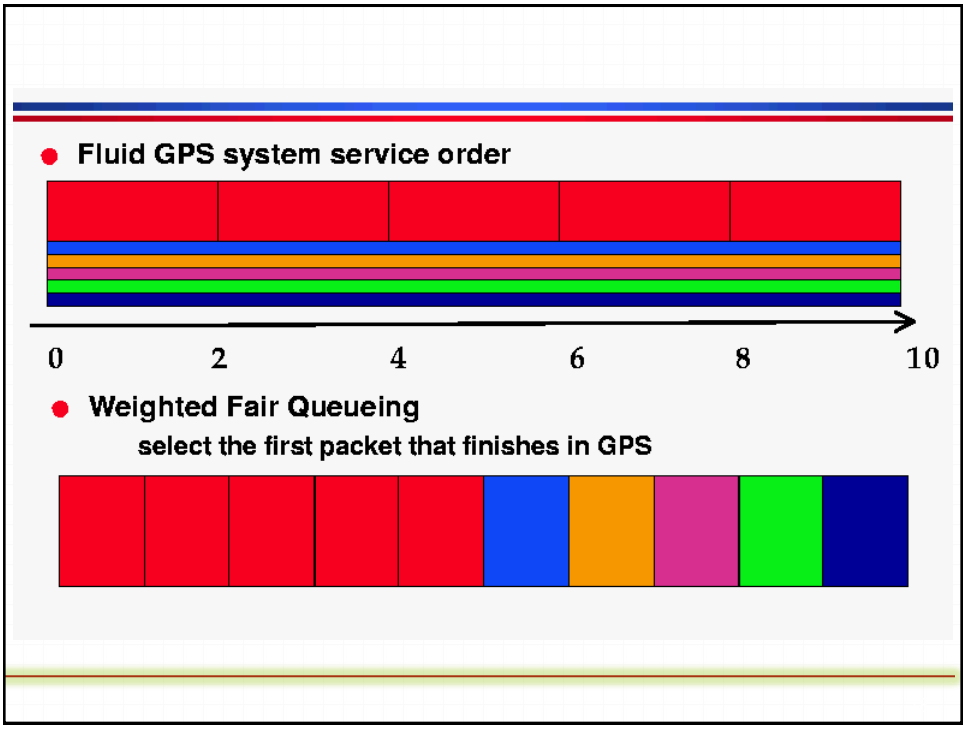
Weighted Fair Queueing

16

WFQ

- W WFQ obliczany jest czas zakończenia obsługi pakietu, gdyby stosowany był GPS
  - Pakiety są obsługiwane zgodnie z czasem ich zakończenia
  - WFQ jest pakietową wersją GPS

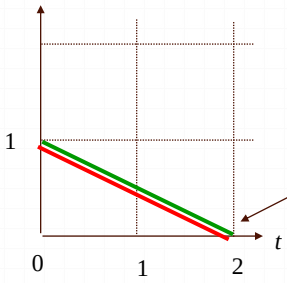
17



GPS vs WFQ (equal length)

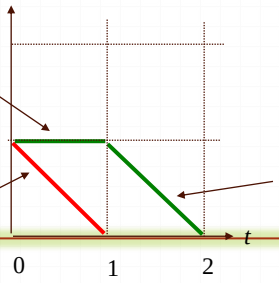
Queue 1
@ t=0

Queue 2
@ t=0



GPS:both packets served at rate 1/2

Both packets complete service at t=2



Packet from queue 2 waiting

Packet from queue 1 being served

Packet-by-packet system (WFQ): queue 1 served first at rate 1; then queue 2 served at rate 1.

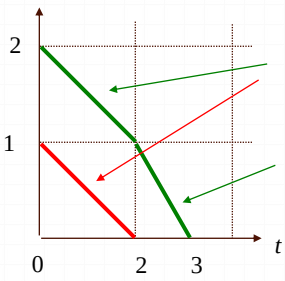
Packet from queue 2 being served

19

GPS vs WFQ (different length)

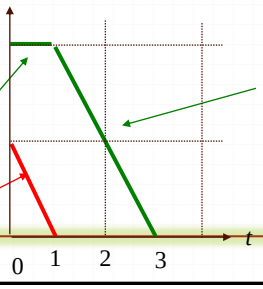
Queue 1
@ t=0

Queue 2
@ t=0



GPS: both packets served at rate 1/2

Packet from queue *2* served at rate 1



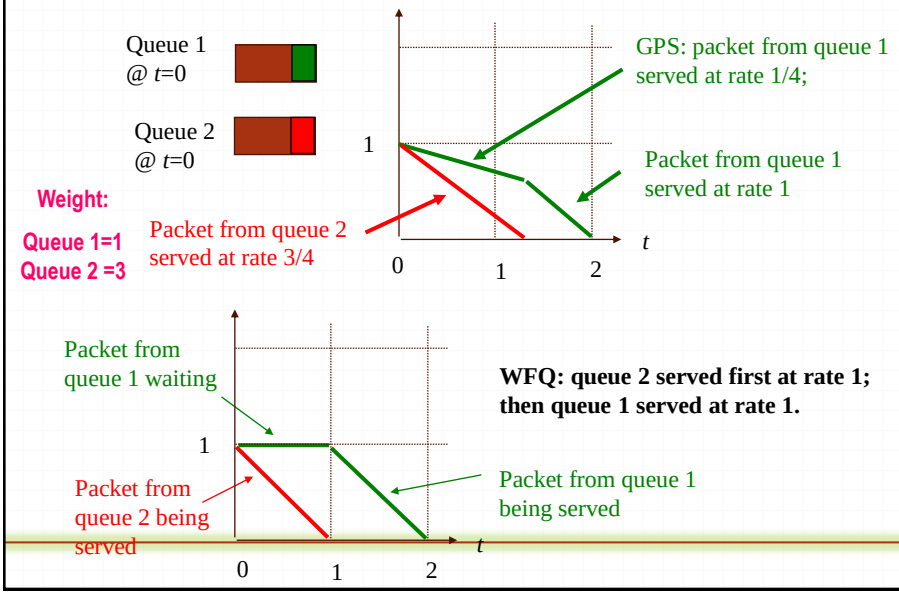
Packet from queue 2 waiting

Packet from queue 1 being served at rate 1

queue 2 served at rate 1

20

GPS vs WFQ



21

Przykład dla WFQ

- Założenia
  - Układ szeregowania pakietów:
    - Kolejka priorytetowa
    - 3 kolejki A, B, C, z wagami
      - Oczekiwany udział w zasobach: 1:2:4 (14%, 29%, and 57%)
  - Kolejki są ciągle zapełnione pakietami o rozmiarze – odpowiednio – 64, 1500 i 300 bajtów
  - Łącze wyjściowe – 512 kbps
  - Pakiety napływają w porządku A1, A2, B1, C1, C2, C3
    - szybciej niż mogą być wyprowadzone
- W WFQ wyznaczana jest wartość zmiennej „round number”
  - Określa czas obsługi pakietu
  - Zmienna określa liczbę odwiedzin kolejki, z której za każdym razem pobierano 1 jednostkę danych (bajt) – np. dla GPS
- Gdy pakiet przybywa do nieaktywnej kolejki
  - Określany jest dla niego czas obsługi (numer sekwencyjny)
    - Do bieżącego czasu dodawany jest rozmiar pakietu pomnożony przez wagę kolejki
      - Udział w zasobach jest odwrotnie proporcjonalny do wagi kolejki

22

Przykład dla WFQ

- Wagi 4, 2 i 1 odpowiadają udziałowi 1:2:4
- Sprawdzenie, czy kolejka jest aktywna
  - Czy zawiera pakiety o numerze sekwencyjnym wyższym niż bieżący „round number”
- Gdy pakiet przybywa do aktywnej kolejki
  - Jego numer sekwencyjny jest obliczany jako suma najwyższego numeru sekwencyjnego w kolejce i iloczynu rozmiaru tego pakietu i wagi kolejki

23

Przykład dla WFQ
Round number = 0

- Przybycie pakietu A1
  - Numer sekwencyjny dla pakietu:
    - 0+64*4=256
- Przybycie pakietu A2, kolejka aktywna
  - Numer sekwencyjny dla tego pakietu:
    - 256+64*4=512
- Przybycie pakietu B1
  - Kolejka nieaktywna, numer sekwencyjny:
    - 0+1500*2 = 3000

24

Przykład dla WFQ
Round number = 0

- Przybycie pakietu c1
  - Kolejka nieaktywna, numer sekwencyjny dla pakietu:
    - 0+300*1=300
- Przybycie pakietu C2
  - Kolejka aktywna, numer sekwencyjny dla pakietu
    - 300+300*1=600
- Przybycie pakietu C3
  - Kolejka aktywna, numer sekwencyjny dla pakietu:
    - 600+300*1=900
- Układ szeregowania rozpoczyna obsługę od pakiety o najmniejszym numerze sekwencyjnym i uaktualnia „round" na wartość równą numerowi sekwencyjnemu tego pakietu
  - Pakiety otrzymane w kolejności A1, A2, B1, C1, C2, C3
  - Pakiety wysyłane w kolejności A1, C1, A2, C2, C3, B1.

25

Deficit Round Robin (DRR

- Modyfikacja WRR umożliwiająca sprawiedliwy udział bez wiedzy o średnim rozmiarze pakietu w poszczególnych kolejkach
  - Zdefiniowanie licznika deficytu dla każdej kolejki
- DRR odwiedza cyklicznie poszczególne kolejki
  - Próba pobrania kwantu danych z kolejki
    - Jednostka (kwant) wyrażony w bajtach a nie w pakietach
- Obsługa tylu pakietów, ile całkowicie mieści się w kwancie
  - Jeżeli pierwszy pakiet większy od kwantu
    - Żaden pakiet nie jest obsługiwany w danym cyklu
      - Gdy więcej pakietów w kolejce
        - Nieużyta cześć kwantu – deficyt – przechodzi do kolejnego cyklu
        - Rodzaj „rekompensaty"
      - Gdy brak pakietów
        - Deficyt zerowany

26

DRR przykład

- Trzy kolejki z wagami
  - A, B, C
  - Alokacja 1:2:4 (14%, 29%, and 57%)
  - Kwanty 100, 200 i 400 accordingly.
- Kolejki niepuste przez cały czas
- Obsługiwane pakiety w kolejkach:
  - 64, 1500, 300 bajtów
- Łącze wyjściowe
  - 512 kb/s

27

DRR przykład

- Liczniki deficytu =0 na początku działania
- Pierwszy cykl
  - Kolejka A – kwant 100, pakiet 64
    - Obsługiwany jeden cały pakiet
    - W kolejce czekają inne pakiety
      - Pozostałość kwantu przenoszona do kolejnego cyklu jako deficyt = 36 bajtów
      - Wartość dodawana do kwantu przy kolejnym cyklu
  - Kolejka B – kwant 200, pakiet 1500 bajtów
    - Niewystarczająca wielkość kwantu do obsługi pakietu
      - Deficyt = 200 bajtów
      - Licznik deficytu wzrasta o 200 w kolejnych 8 cyklach: 8*200=1600
        - Obsługiwany pakiet 1500
        - Deficyt do cyklu 9 równy 100 bajtów

28

DRR przykład

- Pierwszy cykl
- Kolejka C – kwant 400, pakiet 300
  - Obsługiwany cały pakiet
  - W kolejce kolejne pakiety
    - Deficyt: 400-300=100 dodany do kwantu w kolejnym cyklu

29

DRR przykład

Queue		Round 1	Round 2	Round 3	Round 4	Round 5	Round 6	Round 7	Round 8
A	Quantum	100	136	108	144	116	152	124	100
	Pkts sent	1 * 64B {A1}	2 * 64B {A2, A3}	1 * 64B {A4}	2 * 64B {A5, A6}	1 * 64B {A7}	2 * 64B {A8, A9}	2 * 64B {A10, A11}	1 * 64B {A12}
	Deficit	36	8	44	16	52	24	0	36
B	Quantum	200	400	600	800	1000	1200	1400	1600
	Pkts sent	0	0	0	0	0	0	0	1 * 1500B {B1}
	Deficit	200	400	600	800	1000	1200	1400	100
C	Quantum	400	500	600	400	500	600	400	500
	Pkts sent	1 * 300B {C1}	1 * 300B {C2}	2 * 300B {C3, C4}	1 * 300B {C5}	1 * 300B {C6}	2 * 300B {C7, C8}	1 * 300B {C9}	1 * 300B {C10}
	Deficit	100	200	0	100	200	0	100	200

30

DDR

- Liczba zaalokowanych bajtów do każdej kolejki po 8 cyklach:
  - A: 12 * 64=768
  - B: 1 * 1500=1500
  - C: 10 * 300=3000
- Udział w zasobach, z uwzględnieniem deficytów, po 8 cyklach
  - A: (768+36)/((768+36)+(1500+100) (3000+200))=~14%
  - B: (1500+100)/((768+36)+(1500+100) (3000+200))=~29%
  - C: (3000+200)/((768+36)+(1500+100) (3000+200))=~57%
- Sprawiedliwość niezależna od rozmiaru pakietu
  - Może wymagać pewnej minimalnej liczby cykli do uzyskania sprawiedliwego udziału

31

Kryteria wybory mechanizmu szeregowania

- Sprawiedliwość – fairness
  - Czy mechanizm zapewnia założony udział strumieni w zasobach, jaka jest rozbieżność
    - DRR i WFQ preferowane
- Uzyskiwana efektywność dla najgorszego przypadku (opóźnienie)
  - Uzależniona od mechanizmu
  - Uzależniona od liczby kolejek
- Prostota
  - Preferowany DRR

32

Kolejka wyjściowa

- Kolejka interfejsu wyjściowego
  - Do niej trafiają dane wybrane przez mechanizm szeregowania
  - Kolejka FIFO
  - A.K.A transmit ring (tx-ring)
- Nie dopuszcza się strat w tej kolejce
  - Przy jej zapełnieniu (określona granica) mechanizm szeregowania przestaje dostarczać dane
- Rozmiar
  - 1 lub 2 MTU
  - Gdy jeden pakiet wyprowadzany, drugi oczekuje

Chapter 5: Using Specialized Maintenance and Troubleshooting Tools



CCNP TSHOOT: Maintaining and Troubleshooting IP Networks

Cisco | Networking Academy®
Mind Wide Open™

© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public



Chapter 5 Objectives

This chapter covers the following topics:

- Categories of troubleshooting tools
- Traffic-capturing features and tools
- Information gathering with SNMP
- Information gathering with NetFlow
- Network event notification with EEM

© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

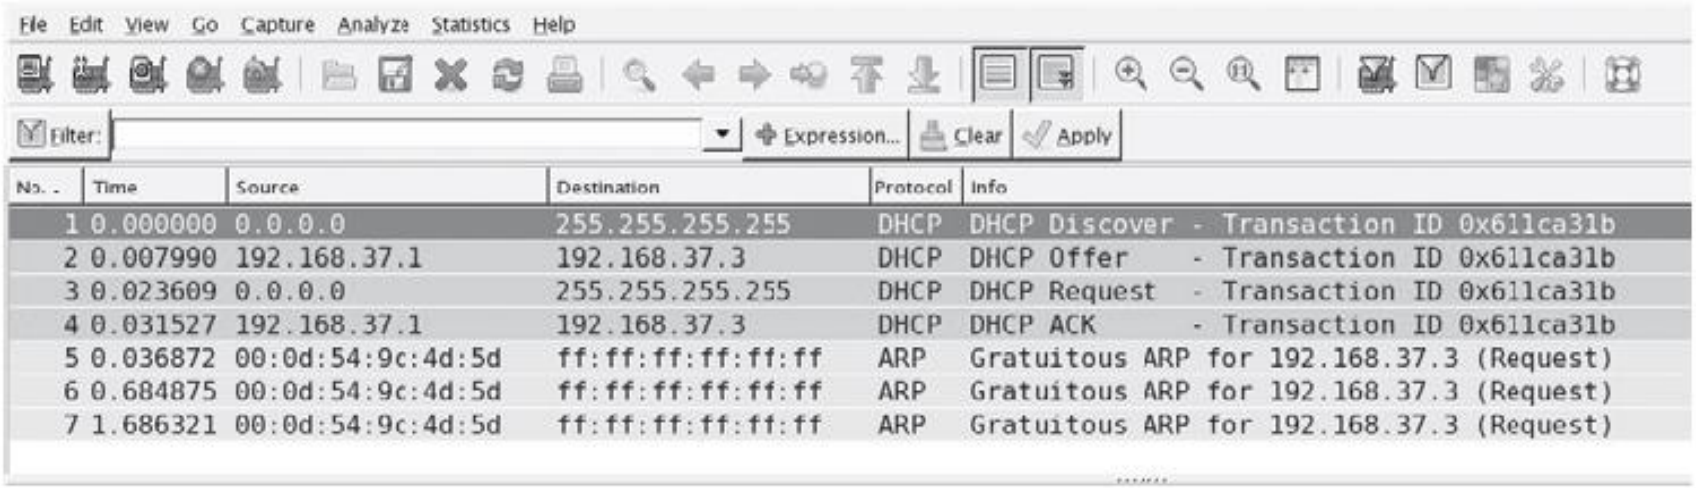
Categories of Troubleshooting Tools

- **Collection of information**
  - Sniffers or debug outputs used for:
    - Analyzing and improving network performance or security
    - Making proposals for improvements
- **Continuous collection of information to establish a baseline**
  - Collection of statistics through use of the SNMP and traffic accounting by use of NetFlow technology.
    - Key network performance indicators
    - Network behavior over a long period of time
- **Notification of network events**
  - Syslog messages or SNMP
    - Based on events triggering devices to report specific information

© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

Traffic-Capturing Features and Tools

- Protocol analyzer



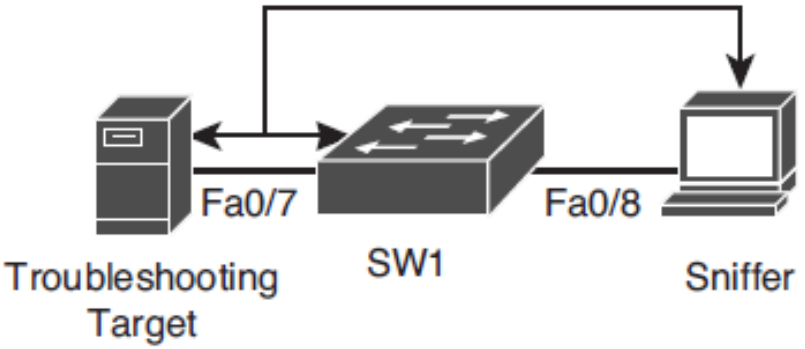
© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

SPAN (Switch Port Analyzer)

```
monitor session 1 source interface Fa0/7
monitor session 1 destination interface Fa0/8
```

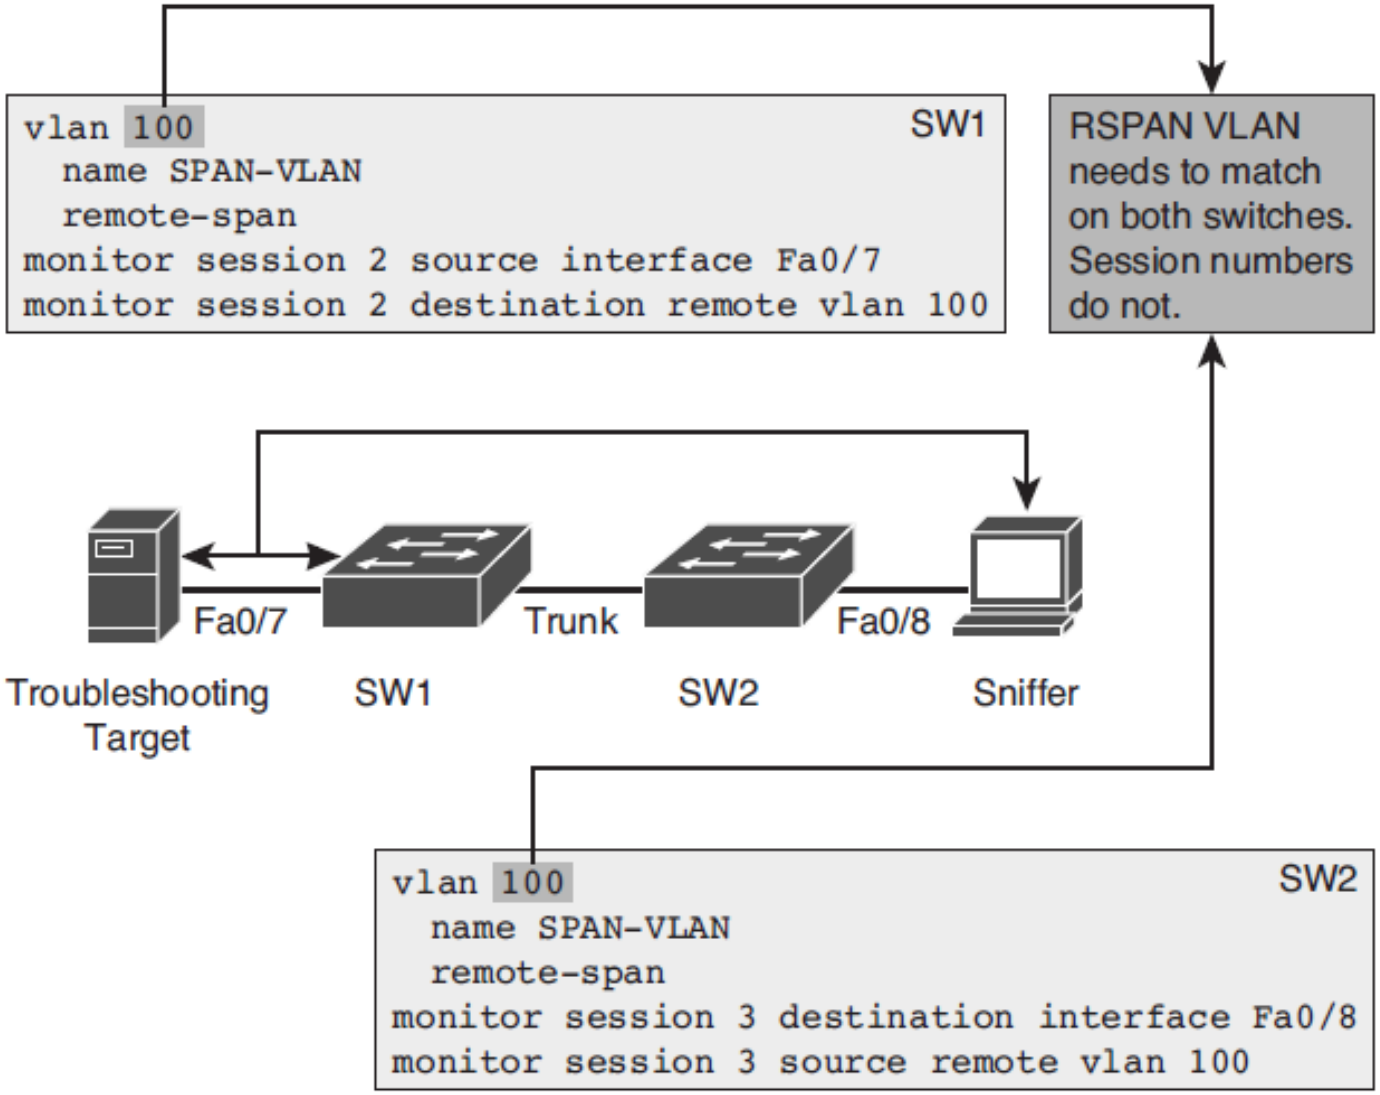
Sources and destinations that form a single SPAN session are identified by a session number

```
SW1#show monitor
Session 1
---------
Type                   : Local Session
Source Ports           :
    Both               : Fa0/7
Destination Ports      : Fa0/8
    Encapsulation      : Native
          Ingress      : Disabled
```



© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

RSPAN (Remote Switch Port Analyzer)



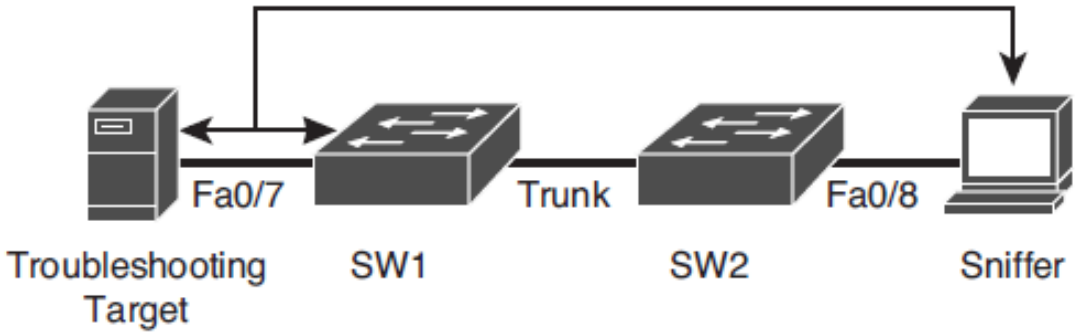
© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

Verifying RSPAN

```
SW1#show monitor
Session 2
---------
Type                  : Remote Source Session
Source Ports          :
     Both             : Fa0/7
Dest RSPAN VLAN       : 100
```

```
SW1#show vlan remote-span

Remote SPAN VLANs
------------------------
100
```




```
SW2#show vlan remote-span

Remote SPAN VLANs
------------------------
100
```

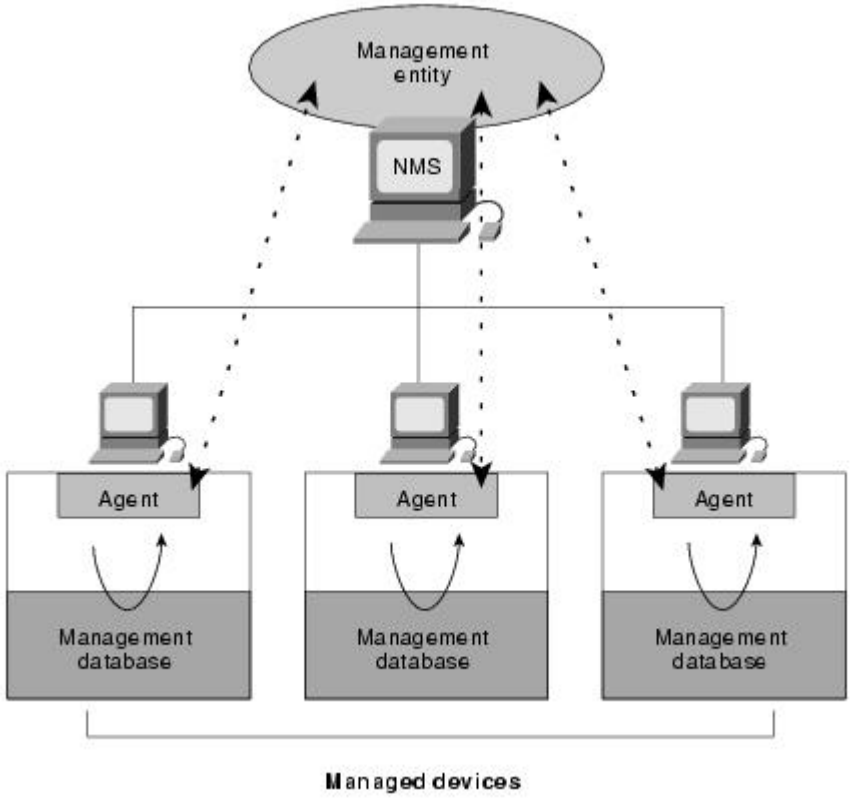
```
SW2#show monitor
Session 3
------------------------
Type                  : Remote Destination Session
Source RSPAN VLAN     : 100
Destination Ports     : Fa0/8
    Encapsulation     : Native
          Ingress     : Disabled
```


© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

Information Gathering with SNMP

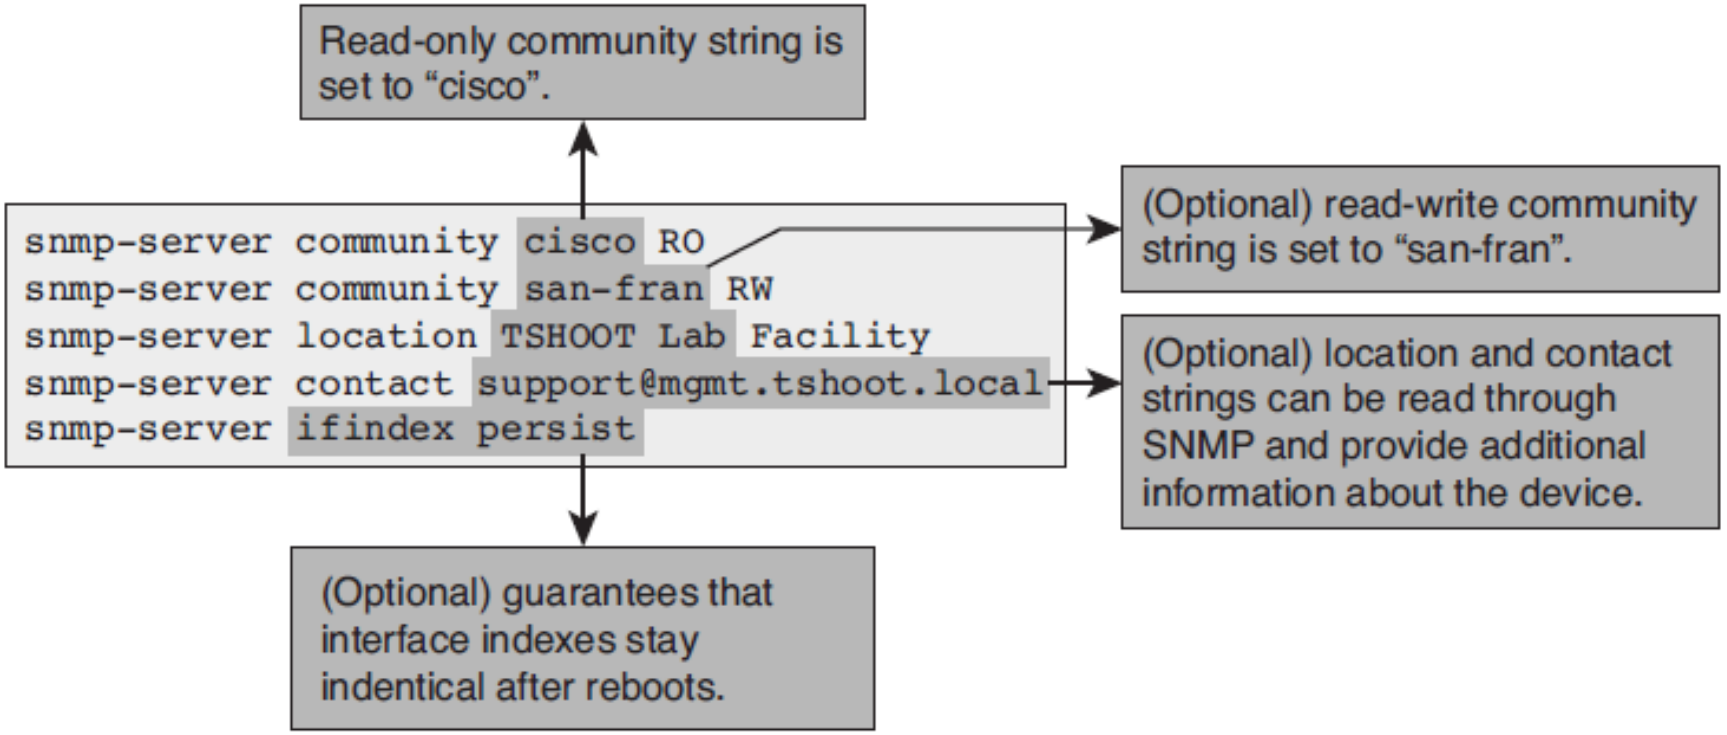
SNMP Components:

- NMS
- SNMP Agents
- MIB



© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

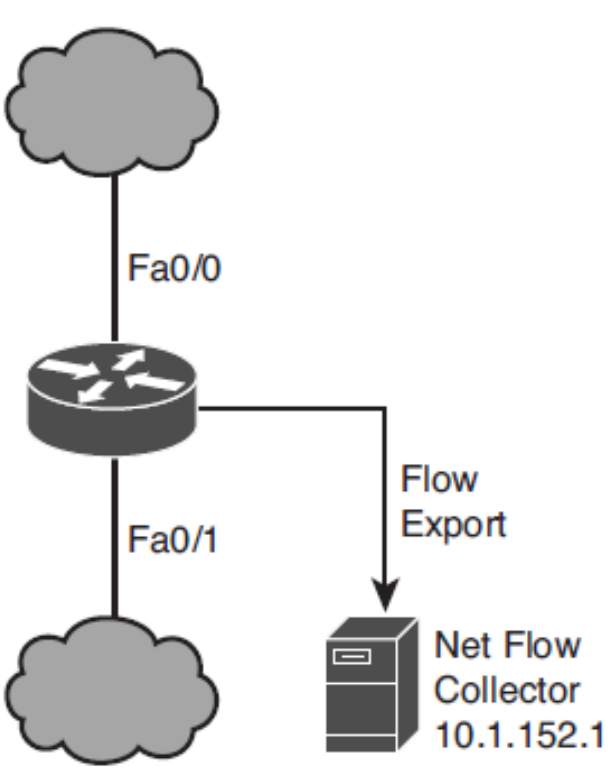
Information Gathering with SNMP



© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

Information Gathering with NetFlow

```
interface FastEthernet0/0
  ip flow ingress
!
interface FastEthernet0/1
  ip flow ingress
!
ip flow-export source Loopback0
ip flow-export version 5
ip flow-export destination 10.1.152.1
9996
```



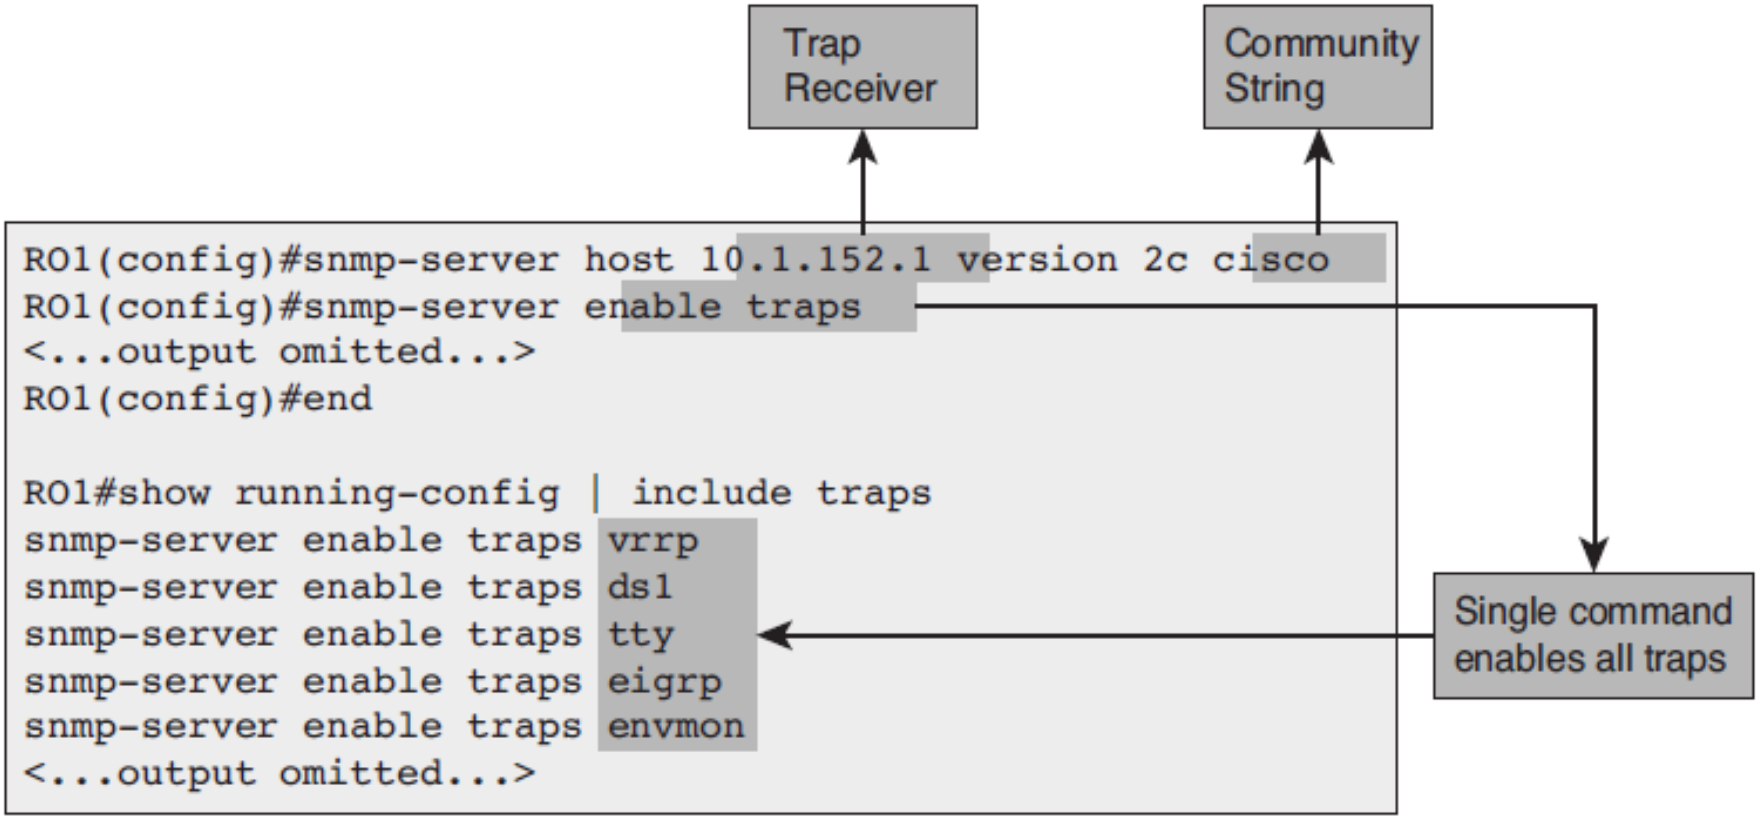
The NetFlow version and UDP port number need to match the version and port number of the collector.

The address used as the source needs to match the IP address defined on the collector for the router.

© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

Network Event Notification

- SNMP Traps



© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

Network Event Notification

- Syslog
  - Syslog is a simple protocol used by an IP device (syslog client) to send text-based log messages to another IP device (syslog server).
  - These messages are the same messages that are displayed on the console of Cisco routers and switches.
  - The syslog protocol allows these messages to be forwarded across the network to a central log server that collects and stores the messages from all the devices.

© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public



Network Event Notification

- EEM Embedded Event Manager
  - Enables you to define custom events and corresponding actions

```
Router(config)# event manager applet CONFIG-STARTED
Router(config-applet)# event cli pattern "configure terminal" sync no skip no
  occurs 1
Router(config-applet)# action 1.0 syslog priority critical msg "Configuration mode
  was entered"
Router(config-applet)# action 2.0 syslog priority informational msg "Change control
  policies apply. Authorized access only."
```

```
RO1# conf t
Enter configuration commands, one per line.  End with CNTL/Z.
RO1(config)#
Mar 13 03:24:41.473 PDT: %HA_EM-2-LOG: CONFIG-STARTED: Configuration mode was entered
Mar 13 03:24:41.473 PDT: %HA_EM-6-LOG: CONFIG-STARTED: Change control policies
  apply. Authorized access only.
```


© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

Chapter 5 Summary

- Categories of troubleshooting tools
- Traffic-capturing features and tools
- Information gathering with SNMP
- Information gathering with NetFlow
- Network event notification with EEM

© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

Chapter 5 Labs

- **Lab5-1 Second-Base**

© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public



© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public

Acknowledgment

- *Some of the texts and images are from Troubleshooting and Maintaining Cisco IP Networks (TSHOOT) Foundation Learning Guide by Amir Ranjbar (158720455X)*
- Copyright © 2015 – 2016 Cisco Systems, Inc.
- Special Thanks to *Bruno Silva*

© 2007 – 2016, Cisco Systems, Inc. All rights reserved. Cisco Public