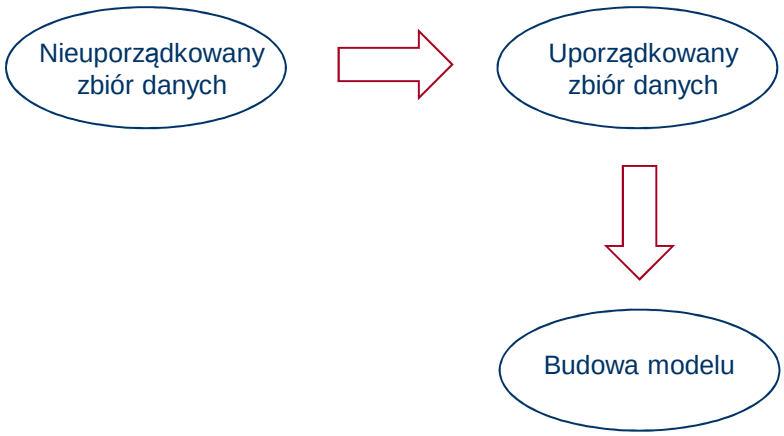
Ćwiczenia 1

PARAMETRYZACJA DANYCH

dr inż. Piotr Zwierzykowski

Dane i praktyka inżynierska



Parametryzacja danych

ZADANIE 1

Zadanie 1

Kierownictwo małej firmy rozważa zmianę aktualnego dostawcy usług internetowych. W celu określenia intensywności wykorzystania dostępu do Internetu przez pracowników firmy przeprowadzono obserwację liczby połączeń z Internetem w godzinach pracy firmy. Uzyskane wyniki zestawiono w poniższej tabeli.

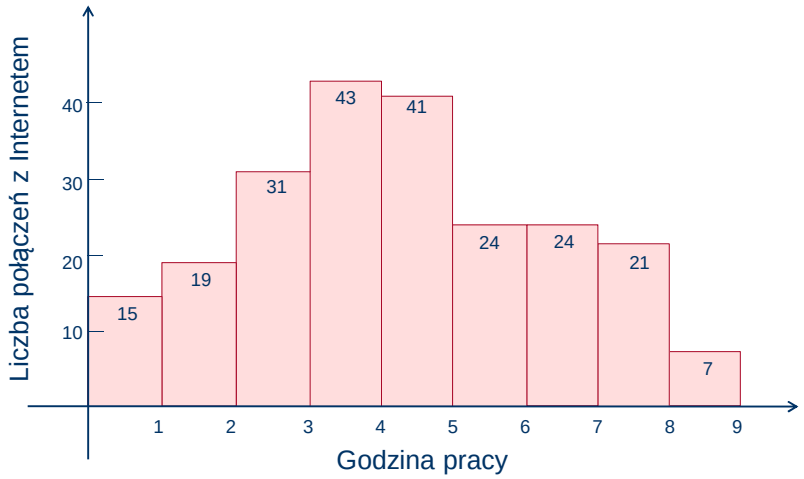
godziny	07.00- 08.00	08.00-09.00	09.00-10.00	10.00-11.00	11.00-12.00	12.00-13.00	13.00-14.00	14.00-15.00	15.00-16.00
godz. pracy (i)	1	2	3	4	5	6	7	8	9
połączenia (x_i)	15	19	31	43	41	24	24	21	7

W celu szczegółowej analizy uzyskanych danych:

- narysuj histogram
- wyznacz wartość średnią z próby
- oblicz wariancję z próby oraz odchylenie standardowe z próby
- podaj współczynnik zmienności i asymetrii dla analizowanych danych

Zadanie 1

Rozwiązanie: Histogram



Zadanie 1

Rozwiązanie: Wartość średnia

Dla ciągu obserwowalnych wartości $x_1, x_2, \ldots, x_n$ wartość średnia z próby $\bar{x}$ to średnia arytmetyczna:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

godziny	07.00- 08.00	08.00-09.00	09.00-10.00	10.00-11.00	11.00-12.00	12.00-13.00	13.00-14.00	14.00-15.00	15.00-16.00
godz. pracy (i)	1	2	3	4	5	6	7	8	9
połączenia (x_i)	15	19	31	43	41	24	24	21	7

$$\bar{x} = \frac{1}{9}(15+19+31+43+41+24+24+21+7) = \frac{225}{9} = 25$$

Zadanie 1

Rozwiązanie: Wariancja z próby

Dla ciągu obserwowalnych wartości $x_1, x_2, \ldots, x_n$ wariancja z próby σ^2 określa odchylenie kwadratowe od wartości średniej z próby.

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

godziny	07.00- 08.00	08.00-09.00	09.00-10.00	10.00-11.00	11.00-12.00	12.00-13.00	13.00-14.00	14.00-15.00	15.00-16.00
godz. pracy (i)	1	2	3	4	5	6	7	8	9
połączenia (x_i)	15	19	31	43	41	24	24	21	7
$(x_i - \bar{x})^2$	100	36	36	324	256	1	1	16	324

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{9}(100+36+36+324+256+1+1+16+324) = \frac{1094}{9} \cong 121{,}56$$

Zadanie 1

Rozwiązanie: Odchylenie standardowe z próby

Odchylenie standardowe σ to pierwiastek z wariancji próby:

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2} = \sqrt{121{,}56} = 11{,}025$$

Zadanie 1

Rozwiązanie: Współczynnik zmienności z próby

Współczynnik zmienności z próby δ to iloraz odchylenia standardowego i wartości średniej:

$$\delta = \frac{\sigma}{\bar{x}} = \frac{\sqrt{\sigma^2}}{\bar{x}} = \frac{11,025}{25} \cong 0,441$$

Zadanie 1

Rozwiązanie: Współczynnik asymetrii

Współczynnik asymetrii *g* to iloraz momentu trzeciego rzędu do sześcianu odchylenia standardowego:

$$g = \frac{\sigma^3}{(\sigma)^3} = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{\left(\sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}\right)^3} = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{(11,025)^3}$$

σ^3 - Średni moment trzeciego rzędu względem wartości średniej

Zadanie 1

Rozwiązanie: Współczynnik asymetrii

godziny	07.00- 08.00	08.00-09.00	09.00-10.00	10.00-11.00	11.00-12.00	12.00-13.00	13.00-14.00	14.00-15.00	15.00-16.00
godz. pracy (i)	1	2	3	4	5	6	7	8	9
połączenia (x_i)	15	19	31	43	41	24	24	21	7
$(x_i - \bar{x})^3$	-1000	-216	216	5832	4096	-1	-1	-64	-5832

$$\sigma^3 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3 = \frac{1}{9}(-1000 - 216 + 216 + 5832 + 4096 - 1 - 1 - 64 - 5832) = \frac{3030}{9} \approx 336{,}67$$

$$g = \frac{\sigma^3}{(\sigma)^3} = = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{(11{,}025)^3} = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{1340{,}096} = \frac{336{,}67}{1340{,}096} \approx 0{,}251$$

Parametryzacja danych

ZADANIE 2

Zadanie 2

Po roku kierownictwo tej samej firmy przeprowadziło ponowne badania. W celu wyznaczenia intensywności korzystania z dostępu do Internetu przez pracowników firmy przeprowadzono obserwację liczby połączeń z Internetem w godzinach pracy firmy. Uzyskane wyniki zestawiono w poniższej tabeli.

godziny	07.00- 08.00	08.00-09.00	09.00-10.00	10.00-11.00	11.00-12.00	12.00-13.00	13.00-14.00	14.00-15.00	15.00-16.00
godz. pracy (i)	1	2	3	4	5	6	7	8	9
połączenia (x_i)	5	34	43	44	41	34	10	7	5

W celu szczegółowej analizy uzyskanych danych:

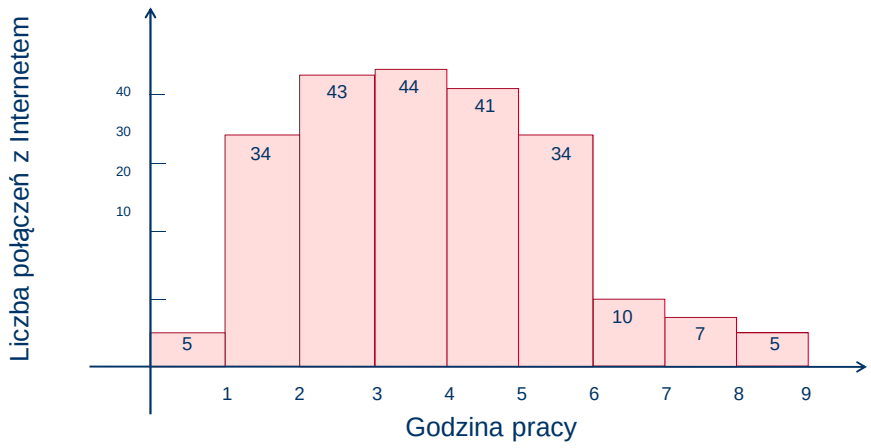
- narysuj histogram
- wyznacz wartość średnią z próby
- oblicz wariancję z próby oraz odchylenie standardowe z próby
- podaj współczynnik zmienności i asymetrii dla analizowanych danych

Jakie wnioski można wyciągnąć na podstawie analizy przypadków opisanych w Z1-2?

Politechnika Poznańska
Katedra Sieci Telekomunikacyjnych i Komputerowych

Zadanie 2

Rozwiązanie: Histogram



Zadanie 2

Rozwiązanie: Wartość średnia

Dla ciągu obserwowalnych wartości $x_1, x_2, \ldots, x_n$ wartość średnia z próby $\bar{x}$ to średnia arytmetyczna:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

godziny	07.00- 08.00	08.00-09.00	09.00-10.00	10.00-11.00	11.00-12.00	12.00-13.00	13.00-14.00	14.00-15.00	15.00-16.00
godz. pracy (i)	1	2	3	4	5	6	7	8	9
połączenia (x_i)	5	34	43	44	41	34	10	7	5

$$\bar{x} = \frac{1}{9}(5+34+43+44+41+34+10+7+5) = \frac{223}{9} = 24{,}76 \approx 25$$

Zadanie 2

Rozwiązanie: Wariancja z próby

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{n}\left\{\sum_{i=1}^{n} x_i^2 - n\times\left(\bar{x}\right)^2\right\}$$

godziny	07.00- 08.00	08.00-09.00	09.00-10.00	10.00-11.00	11.00-12.00	12.00-13.00	13.00-14.00	14.00-15.00	15.00-16.00
godz. pracy (i)	1	2	3	4	5	6	7	8	9
połączenia (x_i)	5	34	43	44	41	34	10	7	5
$(x_i)^2$	25	1156	1849	1936	1681	1156	100	49	25
$(\bar{x})^2$	625	625	625	625	625	625	625	625	625

$$\sigma^2 = \frac{1}{9}\left[(25+1156+1849+1936+1681+1156+100+49+25) - 9\times 625\right]$$

$$\sigma^2 = \frac{7977\text{-}5625}{9} = \frac{2352}{9} \approx 261{,}33$$

Zadanie 2

Rozwiązanie: Odchylenie standardowe z próby

Odchylenie standardowe σ to pierwiastek z wariancji próby:

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2} = \sqrt{261{,}33} \approx 16{,}17$$

Zadanie 2

Rozwiązanie: Współczynnik zmienności z próby

Współczynnik zmienności z próby δ to iloraz odchylenia standardowego i wartości średniej:

$$\delta = \frac{\sigma}{\bar{x}} = \frac{\sqrt{\sigma^2}}{\bar{x}} = \frac{16{,}17}{25} \cong 0{,}65$$

Zadanie 2

Rozwiązanie: Współczynnik asymetrii

Współczynnik asymetrii *g* to iloraz momentu trzeciego rzędu do sześcianu odchylenia standardowego:

$$g = \frac{\sigma^3}{(\sigma)^3} = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{\left(\sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}\right)^3} = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{(16{,}17)^3}$$

σ^3 - Średni moment trzeciego rzędu względem wartości średniej

Zadanie 2

Rozwiązanie: Współczynnik asymetrii

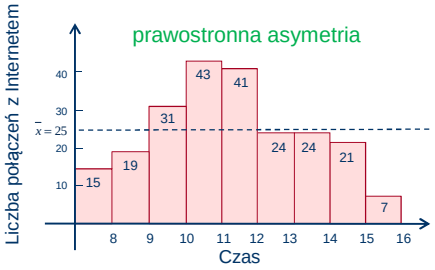
godziny	07.00- 08.00	08.00-09.00	09.00-10.00	10.00-11.00	11.00-12.00	12.00-13.00	13.00-14.00	14.00-15.00	15.00-16.00
godz. pracy (i)	1	2	3	4	5	6	7	8	9
połączenia (x_i)	5	34	43	44	41	34	10	7	5
$(x_i - \bar{x})$	-20	9	18	19	16	9	-15	-18	-20
$(x_i - \bar{x})^3$	-8000	729	5832	6859	4096	729	-3375	-5832	-8000

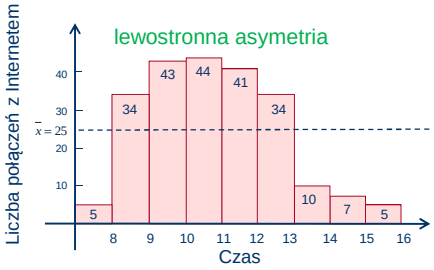
$$\sigma^3 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3 = \frac{1}{9}(-8000 + 729 + 5832 + 6859 + 4096 + 729 - 3375 - 5832 - 8000)$$

$$\sigma^3 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3 = -\frac{6962}{9} \approx -773{,}56$$

$$g = \frac{\sigma^3}{(\sigma)^3} = = \frac{-773{,}56}{(16{,}17)^3} = \frac{-773{,}56}{4227{,}95} \approx -0{,}183$$

Porównanie uzyskanych parametrów





Charakterystyki:

$\bar{x} = 25,$
$\sigma^2 = 121.56,$
$\sigma = 11.025,$
$g = +0.251$

Charakterystyki:

$\bar{x} = 25,$
$\sigma^2 = 272.44,$
$\sigma = 16.51,$
$g = -0.172$

Parametryzacja danych

ZADANIE 3

Zadanie 3

Biorąc pod uwagę wyniki pomiarów uzyskanych w odstępie rocznym, sprawdźmy zależność uzyskanych wyników.

godziny	07.00- 08.00	08.00-09.00	09.00-10.00	10.00-11.00	11.00-12.00	12.00-13.00	13.00-14.00	14.00-15.00	15.00-16.00
godz. pracy (i)	1	2	3	4	5	6	7	8	9
połączenia (x_i)	15	19	31	43	41	24	24	21	7
połączenia (y_i)	5	34	43	44	41	34	10	7	5

W celu analizy uzyskanych danych:
- wyznaczymy kowariancję dla obu zbiorów danych
- wyliczymy współczynnik korelacji

Zadanie 3

Biorąc pod uwagę wyniki pomiarów uzyskanych w odstępie rocznym, sprawdźmy zależność uzyskanych wyników.

godziny	07.00- 08.00	08.00-09.00	09.00-10.00	10.00-11.00	11.00-12.00	12.00-13.00	13.00-14.00	14.00-15.00	15.00-16.00
godz. pracy (i)	1	2	3	4	5	6	7	8	9
połączenia (x_i)	15	19	31	43	41	24	24	21	7
$(x_i - \bar{x})$	-10	-6	+6	+18	+16	-1	-1	-4	-18
połączenia (y_i)	5	34	43	44	41	34	10	7	5
$(y_i - y)$	-20	+9	+18	+19	+16	+9	-15	-18	-20

W celu analizy uzyskanych danych:
- wyznaczymy kowariancję dla obu zbiorów danych
- wyliczymy współczynnik korelacji

Zadanie 3

Rozwiązanie: kowariancja z próby

Kowariancja z próby $cov_{x,y}$ określa tendencję kojarzenia się pary wartości dużej z dużą i małej z małą:

$$cov_{x,y} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})\,(y_i - \bar{y})$$

godziny	07.00- 08.00	08.00-09.00	09.00-10.00	10.00-11.00	11.00-12.00	12.00-13.00	13.00-14.00	14.00-15.00	15.00-16.00
godz. pracy (i)	1	2	3	4	5	6	7	8	9
połączenia (x_i)	15	19	31	43	41	24	24	21	7
$(x_i - \bar{x})$	-10	-6	+6	+18	+16	-1	-1	-4	-18
połączenia (y_i)	5	34	43	44	41	34	10	7	5
$(y_i - \bar{y})$	-20	+9	+18	+19	+16	+9	-15	-18	-20

$$cov_{x,y} = \frac{1}{9}(200 - 54 + 108 + 342 + 256 - 9 + 15 + 72 + 360) = \frac{1290}{9} \approx 143,33$$

Zadanie 3

Rozwiązanie: współczynnik korelacji

Współczynnik korelacji z próby $cor_{x,y}$ określa znormalizowaną (względem odchyleń standardowych) kowariancję:

$$cor_{x,y} = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{\sigma_x}\right)\left(\frac{y_i - \bar{y}}{\sigma_y}\right)$$

$\sigma_x = 11.025, \quad \sigma_y = 16.506,$

godziny	07.00- 08.00	08.00-09.00	09.00-10.00	10.00-11.00	11.00-12.00	12.00-13.00	13.00-14.00	14.00-15.00	15.00-16.00
godz. pracy (i)	1	2	3	4	5	6	7	8	9
połączenia (x_i)	15	19	31	43	41	24	24	21	7
$(x_i - \bar{x})$	-10	-6	+6	+18	+16	-1	-1	-4	-18
połączenia (y_i)	5	34	43	44	41	34	10	7	5
$(y_i - \bar{y})$	-20	+9	+18	+19	+16	+9	-15	-18	-20

$$cor_{x,y} = \frac{1}{9}\frac{(200 - 54 + 108 + 342 + 256 - 9 + 15 + 72 + 360)}{11,025 \times 16,506} \approx \frac{1}{9} \times \frac{1290}{181,98} \approx \frac{1290}{1637,82} \approx 0.788$$

Dziękuję za uwagę!