Podstawy statystyki matematycznej

Prof. dr hab. inż. Maciej Stasiak

Politechnika Poznańska
Katedra Sieci Telekomunikacyjnych i Komputerowych

Statystyka matematyczna

Statystyka matematyczna to nauka o otrzymywaniu rozwiązań i podejmowaniu decyzji w warunkach nieokreśloności.

Przedmiot badań → właściwości zborów zawierających wyniki obserwacji, pomiarów itp. (tzw. dane statystyczne).

Statystyka opisowa → sposoby gromadzenia i systematyzacji danych statystycznych w odpowiedniej formie;

Statystyka indukcyjna → ocena parametrów, formułowanie wniosków charakteryzujących dane statystyczne.

Statystyka matematyczna

Podstawowe kierunki badań w statystyce matematycznej

- Teoria prób losowych
- Teoria estymacji
- Analiza regresji
- Weryfikacja hipotez
- Analiza wariancji

Statystyka matematyczna

Podstawowe pojęcia:

cechy statystyczne → właściwości elementów statystycznych;

cechy mierzalne → wyrażone w zapisie liczbowym;

cechy niemierzalne → wyrażone w zapisie słownym lub symbolicznym;

wartości cech statystycznych → otrzymujemy na podstawie obserwacji statystycznych;

Zbiór obserwacji statystycznych → materiał statystyczny;

Statystyka matematyczna

Podstawowe pojęcia:

populacja generalna → zbiorowość statystyczna tzn. zbiór elementów, które nie są identyczne z punktu widzenia badanej cechy;

próba losowa → część populacji, dostępna bezpośredniej obserwacji względem badanej cechy;

próba prosta → próba losowa, w której cechy poszczególnych elementów są niezależne i mają taki sam rozkład jak rozważana cecha w populacji generalnej;

liczność próby → liczba elementów w próbie (populacje generalne o nieskończonej i nieskończonej liczbie elementów);

próba reprezentatywna → charakterystyki próby są „podobne” do charakterystyk populacji generalnej.

Statystyka matematyczna

Pobieranie prób losowych:

populacja generalna → zbiorowość statystyczna tzn. zbiór elementów, które nie są identyczne z punktu widzenia badanej cechy;

próba losowa → część populacji, dostępna bezpośredniej obserwacji względem badanej cechy;

próba prosta → próba losowa, w której cechy poszczególnych elementów są niezależne i mają taki sam rozkład jak rozważana cecha w populacji generalnej;

liczność próby → liczba elementów w próbie (populacje generalne o nieskończonej i skończonej liczbie elementów);

próba reprezentatywna → charakterystyki próby są „podobne” do charakterystyk populacji generalnej.

Statystyka matematyczna – dystrybuanta empiryczna

Cecha X w populacji generalnej jest opisana dystrybuantą teoretyczną $F(x)$. Po dokonaniu próby losowej prostej, pobranej z populacji generalnej, uporządkowaniu elementów próby wzrastająco $x_{\min},...,x_{\max}$, wyznaczeniu elementów x_x, dla których $x \le X$ otrzymujemy tzw. dystrybuantę empiryczną:

$$F_n(x) = P_n(X \le x) = \frac{x_x}{n}$$

Prawdopodobieństwo, że ciąg dystrybuant $F_n(x)$ jest jednostajnie zbieżny do $F(x)$ jest równe jedności:

$$\lim_{n\to\infty} P\left[F_n(x) - F(x)\right] = 1,$$

czyli dla dostatecznie licznej próby losowej dystrybuanta empiryczna różni się „mało” od dystrybuanty teoretycznej.

Statystyka matematyczna – szereg rozdzielczy

Zakres zmienności badanej cechy (rozstęp):

$$R = x_{\max} - x_{\min}.$$

Podział zakresu zmienności na *k* przedziałów $\Delta_1,...,\Delta_k$, zwanych klasami, takich że:

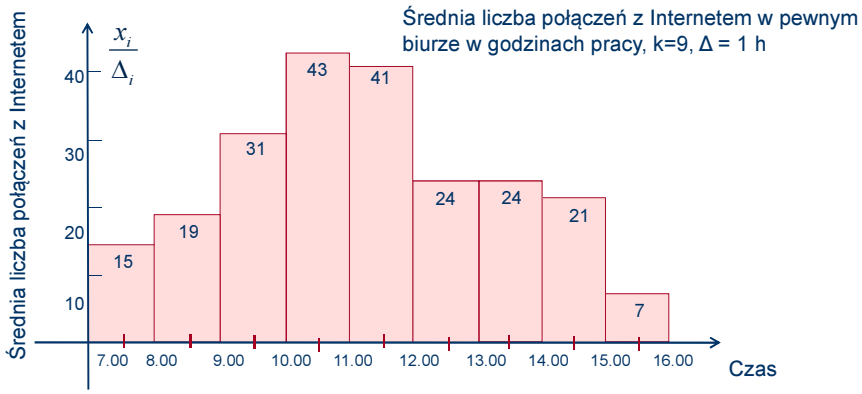
$$k\Delta_i \ge R.$$

Wybór długości klasy (przedziału) powinien być racjonalny, tj. liczba klas nie powinna być zbyt duża (złożoność obliczeń) i zbyt mała (utrata pewnych charakterystyk badanej cechy). W praktyce można zastosować jeden ze wzorów przybliżonych, najlepiej dopasowany do charakteru danych:

$$\frac{\sqrt{n}}{2} \le k \le n, \quad \Delta_i \approx \frac{R}{1+3{,}2\ \ln n}, \quad \Delta_i \approx \frac{R}{2\ \ln n}, \quad \Delta_i \approx \frac{R}{5\ \ln n}.$$

Statystyka matematyczna – szereg rozdzielczy

Wyznaczenie środków klas $\overline{\Delta}_1,...,\overline{\Delta}_k$, i przyporządkowanie każdemu $\overline{\Delta}_i$ wartości próby x_i zawartej w i-klasie. Pary liczb $(\overline{\Delta}_i, x_i)$ tworzą tzw. **szereg rozdzielczy**, który może być przedstawiony w postaci histogramu.



Szereg rozdzielczy - uogólnienie

Szereg rozdzielczy to w najbardziej ogólnym ujęciu ciąg par:

$$(f(\Delta_1), n_1), ..., (f(\Delta_k), n_k),$$

gdzie: $f(\Delta_i)$ reprezentant klasy i,

n_i liczność klasy i.

Momenty empiryczne

Momenty empiryczne to momenty odpowiadające momentom, w których wartość oczekiwana została zastąpiona średnią arytmetyczna ze wszystkich elementów próby (moment empiryczny pierwszego rzędu):

$$E_n(X) = \overline{X} = \frac{1}{k}\sum_{i=1}^{k} X_i$$

Wartość oczekiwana średniej arytmetycznej:

$$E(\overline{X}) = \frac{1}{k}\sum_{i=1}^{k} E(X_i) = E(X) = m_X$$

Wartość oczekiwana średniej arytmetycznej jest równa wartości oczekiwanej zmiennej losowej.

Momenty empiryczne

Wartość oczekiwana średniej arytmetycznej:

$$E(\overline{X}) = \frac{1}{k}\sum_{i=1}^{k} E(X_i) = E(X) = m_X$$

Wariancja średniej arytmetycznej:

$$D(\overline{X}) = \frac{1}{k}\sigma_X^2 \qquad \left| D(X) = \sigma_X^2 \right.$$

$$D(\overline{X}) = E\left[\overline{X} - E(X)\right]^2 = E\left[\frac{1}{k}\sum_{i=1}^{k} X_i - m_X\right]^2 = E\left[\frac{1}{k}\sum_{i=1}^{k} X_i - \frac{1}{k}\sum_{i=1}^{k} m_X\right]^2 =$$

$$= E\left[\frac{1}{k}\sum_{i=1}^{k}(X_i - m_X)\right]^2 = \frac{1}{k^2}\sum_{i=1}^{k} E\left[X_i - m_X\right]^2 = \frac{1}{k^2}\sum_{i=1}^{k} D(X) = \frac{1}{k} D(X) = \frac{1}{k}\sigma_X^2$$

Momenty empiryczne

Wariancja empiryczna:

$$D_n(X) = \frac{1}{k}\sum_{i=1}^{k}\left[X_i - E_n(X)\right]^2 = \frac{1}{k}\sum_{i=1}^{k}\left[X_i - \overline{X}\right]^2$$

Wartość oczekiwana wariancji empirycznej:

$$E\left[D_n(X)\right] = \frac{n-1}{n}\sigma_X^2$$

$$E\left[D_n(X)\right] = E\left\{\frac{1}{k}\sum_{i=1}^{k}\left(X_i - \overline{X}\right)^2\right\} = E\left\{\frac{1}{k}\sum_{i=1}^{k}\left[\left(X_i - m_X\right) - \left(\overline{X} - m_X\right)\right]^2\right\} =$$

$$= E\left\{\frac{1}{k}\sum_{i=1}^{k}\left[\left(X_i - m_X\right)^2 - 2\left(X_i - m_X\right)\left(\overline{X} - m_X\right) + \left(\overline{X} - m_X\right)^2\right]\right\} =$$

$$= E\left\{\frac{1}{k}\sum_{i=1}^{k}E\left(X_i - m_X\right)^2 - 2\left(\overline{X} - m_X\right)\left[\frac{1}{k}\sum_{i=1}^{k}\left(X_i - m_X\right)\right] + \frac{1}{k}\sum_{i=1}^{k}\left(\overline{X} - m_X\right)^2\right\} =$$

$$= \frac{1}{k}\sum_{i=1}^{k}E\left(X_i - m_X\right)^2 - 2E\left\{\left(\overline{X} - m_X\right)\left(\overline{X} - m_X\right)\right\} + E\left\{\frac{k}{k}\left(\overline{X} - m_X\right)^2\right\} = \frac{1}{k}k\sigma_X^2 - E\left(\overline{X} - m_X\right)^2 =$$

$$\sigma_X^2 - D(\overline{X}) = \sigma_X^2 - \frac{1}{k}\sigma_X^2 = \frac{k-1}{k}\sigma_X^2$$

Podstawowe rozkłady wykorzystywane w statystyce

Rozkład normalny $N(m_x, \sigma_X^2)$;

Rozkład normalny $N(0, 1)$ zmiennej losowej standardowej $Z = \left(X - m_x\right) / \sigma_X$;

Rozkład chi-kwadrat;

Rozkład Studenta;

Rozkład Fishera-Snedecora.

Rozkład normalny N(0,1)

Rozkład $N(0,1)$ - standardowy rozkład normalny:

$$f(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$$

Prawdopodobieństwo przedziałowe w rozkładzie $N(0,1)$:

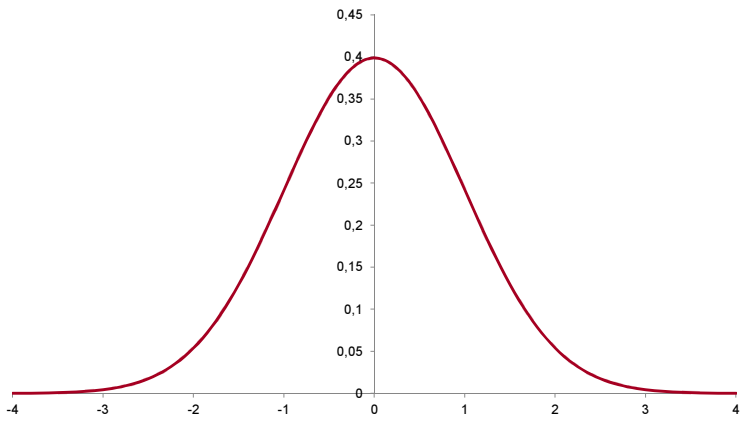
$$\mathrm{P}(a < x < b) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{z^2}{2}} dz = F(b) - F(a) = \Phi(b) - \Phi(a)$$

Funkcja Laplace'a:

$$\Phi(x) = \begin{cases} \frac{1}{\sqrt{2\pi}} \int_0^x e^{-z^2/2} dz & \text{dla} \quad x \geq 0, \\ -\Phi(-x) & \text{dla} \quad x < 0. \end{cases}$$

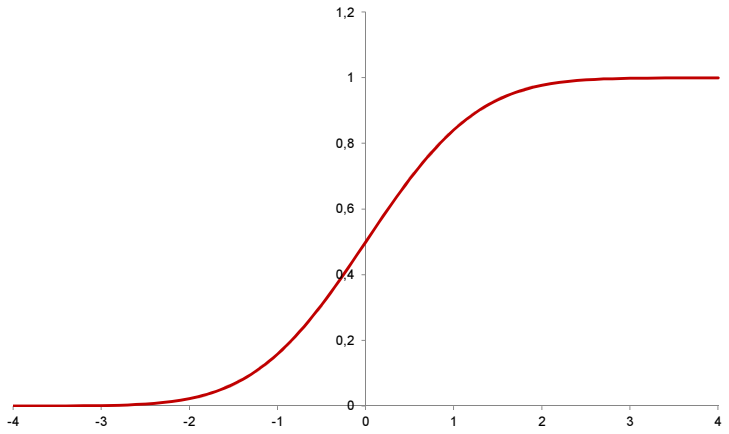
Rozkład normalny N(0,1)

Rozkład gęstości N(0,1):



Rozkład normalny N(0,1)

Dystrybuanta rozkładu N(0,1):



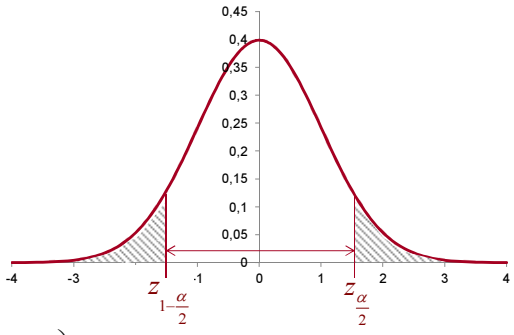
Rozkład normalny N(0,1)

Kwantylem rzędu $1-\alpha$ rozkładu normalnego N(0,1) nazywa się wartość z_α spełniającą warunek:

$$\mathrm{P}(z > z_\alpha) = \int_{z_\alpha}^{\infty} f(z)\,dz = \alpha, \quad \mathrm{P}(z_{1-\frac{\alpha}{2}} < z < z_{\frac{\alpha}{2}}) = 1 - \left[\int_{-\infty}^{z_{1-\frac{\alpha}{2}}} f(t_k)\,dt_k + \int_{z_{\frac{\alpha}{2}}}^{\infty} f(t_k)\,dt_k \right] = 1-\alpha,$$

$$\mathrm{P}(z_{1-\frac{\alpha}{2}} < z < z_{\frac{\alpha}{2}}) = \Phi\left(z_{\frac{\alpha}{2}}\right) - \Phi\left(z_{1-\frac{\alpha}{2}}\right) = 2\Phi\left(z_{\frac{\alpha}{2}}\right).$$

Rozkład normalny N(0,1)



Przedział $\left(z_{1-\frac{\alpha}{2}}, z_{\frac{\alpha}{2}} \right)$ nazywa się przedziałem ufności. Poziom ufności $p = 1 - \alpha$ określa prawdopodobieństwo, że zmienna losowa Z przyjmuje wartość należącą do przedziału ufności.

Rozkład chi-kwadrat

Rozkład zmiennej losowej χ_k^2, która jest sumą k kwadratów niezależnych zmiennych losowych o rozkładach N(0,1):

$$\chi_k^2 = \sum_{i=1}^{k} X_i^2 .$$

Mówimy, że zmienna losowa χ_k^2 ma k stopni swobody. Parametr ten całkowicie charakteryzuje funkcję gęstości prawdopodobieństwa rozkładu.

Jeżeli zmienne X_i, są związane zależnością $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$, to liczba stopni swobody wynosi *k*=*n*-1.

Rozkład chi-kwadrat

Rozkład gęstości:

$$f(\chi_k^2) = \begin{cases} 0, & \chi_k^2 < 0, \\ \dfrac{(\chi_k^2)^{\frac{k-2}{2}} e^{-\frac{\chi_k^2}{2}}}{2^{\frac{k}{2}}\Gamma\left(\frac{k}{2}\right)}, & \chi_k^2 \geq 0. \end{cases}$$

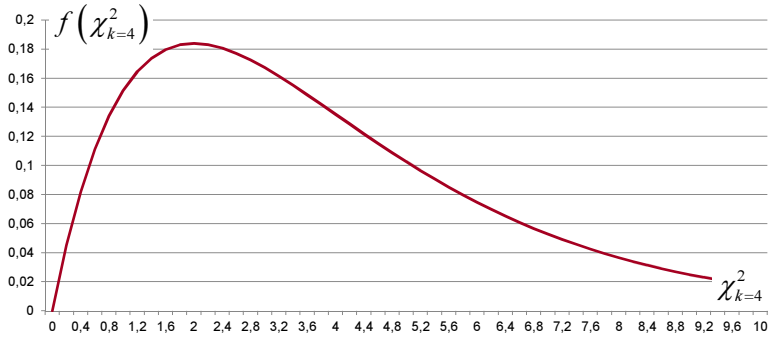
Rozkład gęstości sumy zmiennych losowych o rozkładzie chi-kwadrat jest rozkładem chi-kwadrat o liczbie stopni swobody równej sumie liczb stopni swobody poszczególnych zmiennych losowych.

Wartość średnia i wariancja:

$$m_{\chi_k^2} = k, \qquad \sigma^2_{\chi_k^2} = 2k.$$

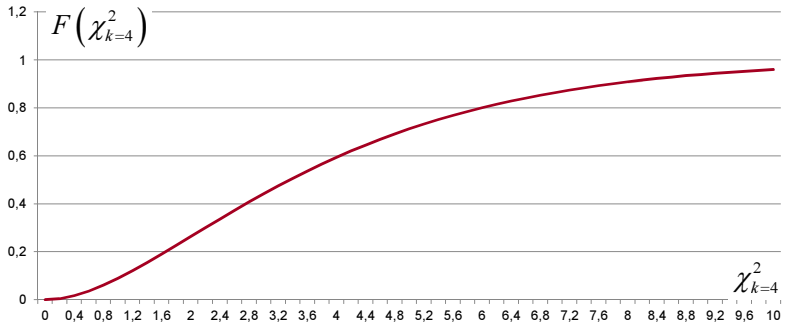
Rozkład chi-kwadrat

Rozkład gęstości $\chi^2_{k=4}$:

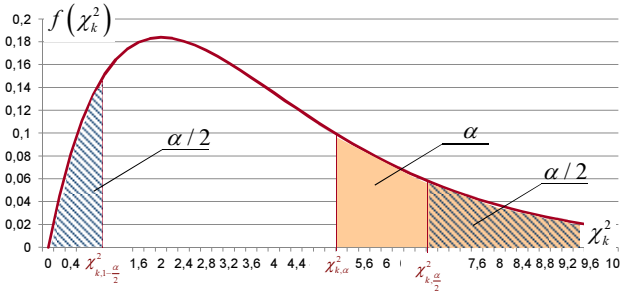


Rozkład chi-kwadrat

Dystrybuanta rozkładu $\chi^2_{k=4}$:



Rozkład chi-kwadrat



Konstrukcja tablic rozkładu chi-kwadrat - zależność prawdopodobieństwa α od kwantyli $\chi^2_{k,\alpha}$ i liczby stopni swobody k=n-1, gdzie n jest liczbą serii:

$$P(\chi^2_k \geq \chi^2_{k,\alpha}) = \int_{\chi^2_{k,\alpha}}^{\infty} f(\chi^2_k)\,d\chi^2_k = \alpha, \qquad P(\chi^2_{k,1-\frac{\alpha}{2}} < \chi^2_k < \chi^2_{k,\frac{\alpha}{2}}) = 1 - \left[\int_0^{\chi^2_{k,1-\frac{\alpha}{2}}} f(\chi^2_k)\,d\chi^2_k + \int_{\chi^2_{k,\frac{\alpha}{2}}}^{\infty} f(\chi^2_k)\,d\chi^2_k\right] = 1-\alpha$$

Rozkład Studenta (Gosseta)

Rozkład Studenta jest rozkładem zmiennej losowej T zdefiniowanej następująco:

$$T = Z / \sqrt{\frac{\chi_k^2}{k}},$$

gdzie zmienna losowa Z ma rozkład normalny N(0,1), a zmienna losowa χ_k^2 ma rozkład chi-kwadrat o k stopniach swobody. Rozkłady zmiennych losowych Z i χ_k^2 są niezależne.

Rozkład Studenta

Rozkład gęstości:

$$f(t_k) = \frac{\Gamma\left(\frac{k+1}{2}\right)}{\sqrt{\pi k}\ \Gamma\left(\frac{k}{2}\right)\left(1+\frac{t_k^2}{k}\right)^{\frac{k+1}{2}}}, \qquad t_k \in R.$$

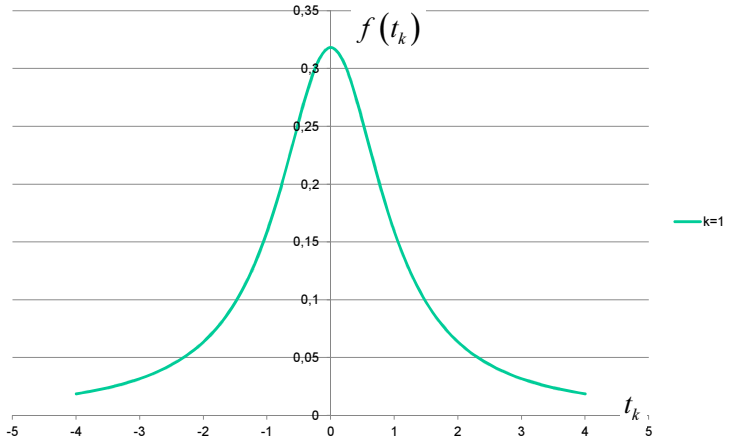
Wartość średnia i wariancja:

$$m_T = 0, \qquad k > 1,$$

$$\sigma_T^2 = \frac{k}{k-2}, \qquad k > 2.$$

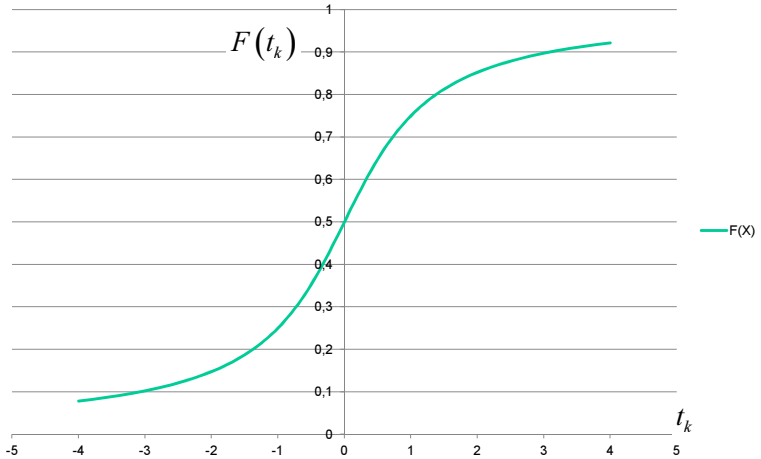
Rozkład Studenta

Rozkład gęstości Studenta:



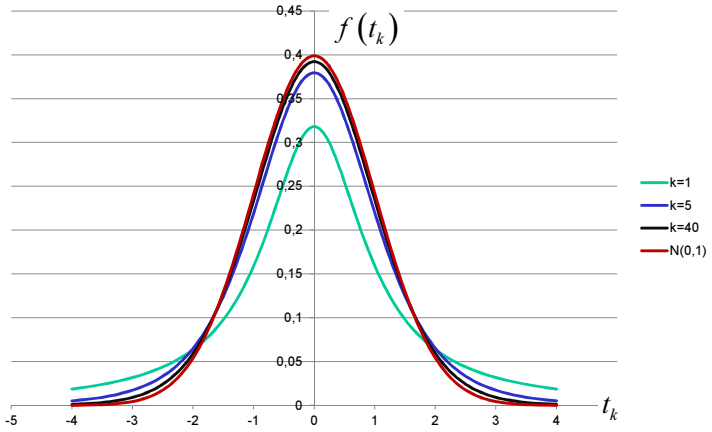
Rozkład Studenta

Dystrybuanta rozkładu Studenta:



Rozkład Studenta

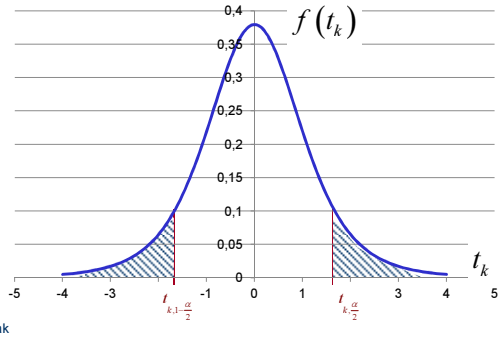
Rozkład gęstości Studenta:



Rozkład Studenta

Kwantylem rzędu $1-\alpha$ rozkładu Studenta nazywa się wartość $t_{k,\alpha}$ spełniające warunek:

$$P(t_k > t_{k,\alpha}) = \int_{t_{k,\alpha}}^{\infty} f(t_k)\,dt_k = \alpha, \quad P(t_{k,1-\frac{\alpha}{2}} < t_k < t^2_{k,\frac{\alpha}{2}}) = 1 - \left[\int_{-\infty}^{t_{k,1-\frac{\alpha}{2}}} f(t_k)\,dt_k + \int_{t_{k,\frac{\alpha}{2}}}^{\infty} f(t_k)\,dt_k\right] = 1-\alpha$$



Przedział ufności dla wartości oczekiwanej – jedna seria

Badana cecha ma dowolny rozkład z nieznanymi wartościami wartości średniej i wariancji(μ, σ^2).

Centralne twierdzenie graniczne Lindeberga-Levy'ego:

$$\lim_{n\to\infty} P\left(\frac{Y_n - n\mu}{\sigma\sqrt{n}} < x\right) = \Phi(x), \qquad \overline{X} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{Y_n}{n}$$

$$\lim_{n\to\infty} P\left(\frac{\overline{X} - \mu}{\sigma / \sqrt{n}} < x\right) = \Phi(x).$$

Rozkład $\frac{\overline{X} - \mu}{\sigma / \sqrt{n}}$ jest zbieżny asymptotycznie do rozkładu normalnego N(0,1)

Przedział ufności dla wartości oczekiwanej – jedna seria

Określenie empirycznej wartości średniej i wariancji:

$$E_n(X) = \overline{X} = \frac{1}{n}\sum_{i=1}^{n} x_i,$$

$$D_n(X) = \frac{1}{n}\sum_{i=1}^{n}\left(x_i - \overline{X}\right)^2.$$

Do określenie przedziału ufności wykorzystamy rozkład N(0,1) zmiennej losowej $Z = \frac{\overline{X} - \mu}{\sqrt{D_n(X)/n}}$.

Przedział ufności dla wartości oczekiwanej – jedna seria

Określenie przedziału ufności:

$$P(z_{1-\frac{\alpha}{2}} < z < z_{\frac{\alpha}{2}}) = 1-\alpha,$$

$$P(z_{1-\frac{\alpha}{2}} < \frac{\overline{X}-\mu}{\sqrt{D_n(X)/n}} < z_{\frac{\alpha}{2}}) = 1-\alpha,$$

$$P(z_{1-\frac{\alpha}{2}}\sqrt{D_n(X)/n} < \overline{X}-\mu < z_{\frac{\alpha}{2}}\sqrt{D_n(X)/n}) = 1-\alpha,$$

$$P(\overline{X} - z_{1-\frac{\alpha}{2}}\sqrt{D_n(X)/n} > \mu > \overline{X} - z_{\frac{\alpha}{2}}\sqrt{D_n(X)/n}) = 1-\alpha,$$

$$P(\overline{X} + z_{\frac{\alpha}{2}}\sqrt{D_n(X)/n} > \mu > \overline{X} - z_{\frac{\alpha}{2}}\sqrt{D_n(X)/n}) = 1-\alpha,$$